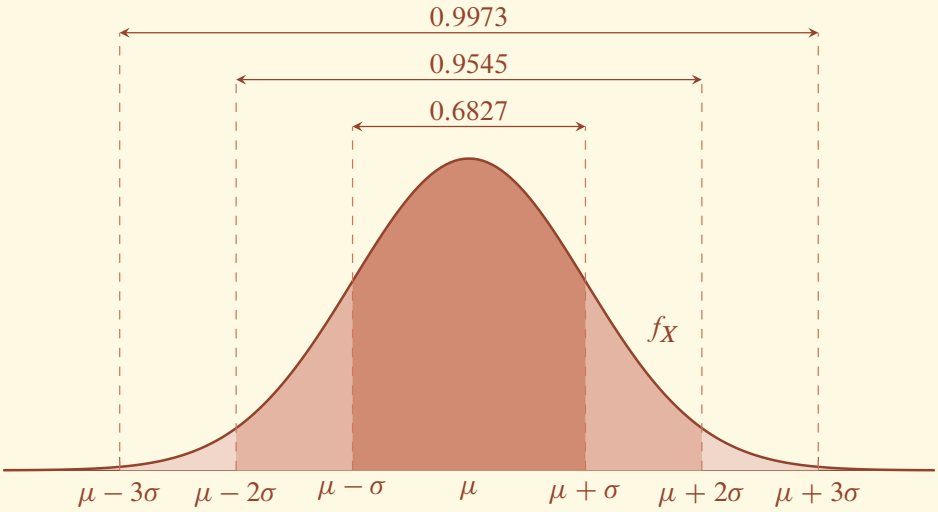


Probabilità e Statistica I

Appunti delle lezioni

Corso di laurea in Matematica
Università degli Studi di Napoli Federico II

Anno accademico 2026/2027

Davide De Marco

Nota

Questi appunti raccolgono, in forma rielaborata, le lezioni del corso di *Probabilità e Statistica I* tenuto nell'anno accademico 2026/2027 per il Corso di laurea in Matematica dell'Università degli Studi di Napoli Federico II. Non sostituiscono il materiale ufficiale del corso né i testi di riferimento; eventuali errori o imprecisioni sono da attribuire esclusivamente all'autore, che ringrazia chi vorrà segnalarglieli.

Copyright 2026 Davide De Marco
Tutti i diritti riservati
Università degli Studi di Napoli Federico II

(Legge italiana sul Copyright 22.04.1941 n. 633)

Indice

1 Calcolo delle probabilità **1**

1.1 Introduzione . . . 1
1.2 Alcune definizioni di probabilità di un evento . . . 2
1.3 Teoria degli insiemi applicata alla probabilità . . . 2
1.4 Misura di probabilità – assiomi e proprietà . . . 5
1.5 Calcolo combinatorio . . . 11
1.5.1 Funzione Γ di Eulero . . . 11
1.5.2 Strutture combinatorie elementari . . . 12
1.6 σ-algebre di Borel . . . 16
1.7 Alcuni esempi di limiti di successioni di eventi . . . 18
1.8 Teorema di equivalenza . . . 20
1.9 Eventi indipendenti e probabilità condizionata . . . 24
1.10 Variabili aleatorie e distribuzioni di probabilità . . . 37
1.10.1 Variabili aleatorie e loro legge . . . 37
1.10.2 Funzione di ripartizione . . . 40
1.10.3 Variabili aleatorie discrete . . . 44
1.10.4 Variabili aleatorie continue . . . 49
1.10.5 Quantili e mediana . . . 56
1.11 Trasformazioni di variabili aleatorie . . . 59
1.11.1 Trasformazioni monotòne . . . 59
1.11.2 Trasformazioni di variabili aleatorie discrete . . . 62
1.11.3 La variabile aleatoria lognormale . . . 63
1.12 Vettori aleatori . . . 64
1.12.1 Funzione di ripartizione congiunta . . . 64
1.12.2 Vettori aleatori assolutamente continui e discreti . . . 66
1.12.3 Il caso bidimensionale . . . 67
1.12.4 Variabili aleatorie indipendenti . . . 68
1.13 Somma, prodotto e rapporto di variabili aleatorie . . . 70
1.13.1 Somma di variabili aleatorie . . . 70
1.13.2 Prodotto di variabili aleatorie . . . 74
1.13.3 Rapporto di variabili aleatorie . . . 76
1.14 Momenti di variabili aleatorie . . . 78
1.14.1 Valore atteso delle variabili aleatorie notevoli . . . 80
1.14.2 Valore atteso e funzione di ripartizione . . . 83
1.14.3 Proprietà del valore atteso . . . 84
1.14.4 Momenti centrali e varianza . . . 87

1.14.5 Varianza delle variabili aleatorie notevoli . . . 89
1.14.6 Proprietà della varianza . . . 93
1.15 Momenti di vettori aleatori . . . 96
1.15.1 Valore atteso di funzioni di un vettore aleatorio . . . 96
1.15.2 Momenti misti, covarianza e coefficiente di correlazione . . . 98
1.15.3 Varianza della somma e coefficiente di correlazione . . . 101
1.16 Funzioni generatrici . . . 103
1.16.1 Funzione generatrice di probabilità . . . 104
1.16.2 Funzioni generatrici di probabilità delle variabili aleatorie notevoli . . . 107
1.16.3 Funzione generatrice dei momenti . . . 108
1.16.4 Funzioni generatrici dei momenti delle variabili aleatorie notevoli . . . 112
1.16.5 Trasformazioni affini e somme di variabili aleatorie indipendenti . . . 115
1.17 Legge del 3σ e disuguaglianze notevoli . . . 118
1.17.1 Legge del 3σ per le variabili aleatorie normali . . . 118
1.17.2 Disuguaglianze di Markov e di Čebyšëv . . . 120
1.17.3 Disuguaglianza di Schwarz . . . 124
1.18 Condizionamento e regressione . . . 126
1.18.1 Condizionamento nel continuo . . . 126
1.18.2 Valore atteso condizionato e regressione . . . 128
1.19 Teoremi limite . . . 132
1.19.1 Approssimazione normale della distribuzione binomiale . . . 132
1.19.2 Teorema di Bernoulli . . . 135

2 Statistica descrittiva **137**
2.1 Popolazione, caratteri e frequenze . . . 137
2.2 Rappresentazioni grafiche . . . 139
2.3 Indici di posizione . . . 141
2.4 Indici di dispersione . . . 148

Capitolo 1

Calcolo delle probabilità

1.1 Introduzione

Notazione 1.1. Nel seguito si indicano con $\mathbb{N} = \{1, 2, 3, \dots\}$ l'insieme dei numeri naturali e con $\mathbb{N}_0 = \mathbb{N} \cup \{0\}$ l'insieme dei naturali con lo zero. Inoltre, per ogni $n \in \mathbb{N}$, si pone

$$I_n := \{1, 2, \dots, n\}.$$

Si introduce la materia studiando l'esperimento casuale: *"lancio di un dado"*.

Esempio 1.1. Si definisce l'insieme dei possibili risultati dell'esperimento:

$$\Omega = \{\text{Possibili risultati}\} = I_6 = \{1,\ 2,\ 3,\ 4,\ 5,\ 6\}$$

L'insieme Ω prende il nome di *spazio campione*. Un *evento* è un sottoinsieme di Ω. Ad esempio, l'evento *"uscita di un numero pari"* è:

$$\{2,\ 4,\ 6\} \in \mathcal{P}(\Omega)$$

Se si è interessati all'uscita del 6, l'evento corrispondente è:

$$\{6\} \in \mathcal{P}(\Omega)$$

Si costruisce, a partire da questo evento, una famiglia di sottoinsiemi di Ω chiusa rispetto all'unione $\cup$, l'intersezione $\cap$ e la complementazione $(\cdot)^c$:

$$\mathcal{F} = \{\Omega,\ \{6\},\ \emptyset,\ \Omega \setminus \{6\}\}.$$

Osservazione. Le famiglie che sicuramente soddisfano le proprietà di chiusura sopra citate sono:

(*i*) la famiglia banale $\{\Omega, \emptyset\}$;

(*ii*) la famiglia massima possibile $\mathcal{P}(\Omega)$.

Definizione 1.2. L'insieme Ω prende il nome di *spazio campione*, *insieme universo* o *insieme certo*.

Definizione 1.3. Una famiglia $\mathcal{F}$ di sottoinsiemi di Ω è una σ*-algebra* se:

(*i*) $\Omega \in \mathcal{F}$;

(*ii*) se $A \in \mathcal{F}$, allora $A^{\mathsf{c}} \in \mathcal{F}$;

(*iii*) se $\{A_n\}_{n\in\mathbb{N}} \subseteq \mathcal{F}$ è una successione di insiemi, allora anche la loro unione numerabile appartiene a $\mathcal{F}$:

$$\bigcup_{n=1}^{+\infty} A_n \in \mathcal{F}.$$

D'ora in avanti, se non esplicitamente detto diversamente, si indicherà con $\mathcal{F}$ una σ-algebra di sottoinsiemi di Ω.

Definizione 1.4. La coppia $(\Omega, \mathcal{F})$ prende il nome di *spazio probabilizzabile*. Più in generale, una coppia $(X, \mathcal{G})$ formata da un insieme X e da una σ-algebra $\mathcal{G}$ di sottoinsiemi di X si dice *spazio misurabile*.

1.2 Alcune definizioni di probabilità di un evento

Definizione 1.5. *Classica.* Dato un evento A, la sua probabilità classica è il rapporto tra il numero di casi favorevoli e il numero di casi possibili, sempre che i casi possibili siano *equiprobabili*.

Osservazione. La definizione classica presenta un *ragionamento circolare*: richiedere che i casi possibili siano equiprobabili presuppone già una nozione di probabilità.

Definizione 1.6. *Frequentista.* Dato un evento A relativo a un esperimento ripetibile, indicato con n_A il numero di volte in cui A si verifica in n prove effettuate nelle medesime condizioni, la probabilità frequentista di A è il limite della *frequenza relativa*:

$$\lim_{n\to+\infty} \frac{n_A}{n}.$$

Osservazione. La definizione frequentista non è *concretamente verificabile*: nessun esperimento reale può essere ripetuto infinite volte, e l'esistenza stessa del limite non è garantita a priori.

Definizione 1.7. *Soggettiva.* Dato un evento A, la sua probabilità soggettiva è il prezzo $p \in [0, 1]$ che un individuo ritiene equo pagare per ricevere 1 se A si verifica e 0 se A non si verifica. La valutazione si dice *coerente* se non consente vincite o perdite certe ed è accettata dall'individuo sia nel ruolo di scommettitore sia in quello di banco.

Osservazione. La definizione soggettiva dipende dall'individuo che effettua la valutazione: individui diversi possono assegnare, in modo ugualmente coerente, probabilità diverse allo stesso evento.

1.3 Teoria degli insiemi applicata alla probabilità

Ogni evento è un sottoinsieme di Ω. Siano A e B due eventi. Se $A \subseteq B$, allora il verificarsi dell'evento A *implica* il verificarsi dell'evento B.

Esempio 1.2. Nell'esperimento del lancio del dado, si consideri l'evento $\{3\}$. Poiché vale l'inclusione

$$\{3\} \subset \{1,3,5\},$$

il verificarsi dell'evento $\{3\}$ implica il verificarsi dell'evento $\{1,3,5\}$, ovvero l'uscita di un numero dispari.

Definizione 1.8. L'evento Ω è detto *evento certo*, mentre l'evento $\emptyset$ è detto *evento impossibile*.

Definizione 1.9. Se $A \cap B = \emptyset$, si dice che A è *incompatibile* con B. In altre parole, A e B non possono avvenire simultaneamente.

Sono elencate di seguito alcune proprietà degli insiemi, utili per lo studio della probabilità.

Proprietà. (*i*) $A \subseteq B \Rightarrow B = A \cup (B \cap A^C) = A \cup (B \setminus A)$

(*ii*) $A = A \cap \Omega = A \cap (B \cup B^C) = (A \cap B) \cup (A \cap B^C)$

(*iii*) Siano $A, B, C \in \mathcal{F}$ eventi. Valgono le seguenti proprietà distributive:

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C);$$
$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C).$$

(*iv*) Valgono le seguenti *relazioni di De Morgan*:

$$(A \cup B)^C = A^C \cap B^C;$$
$$(A \cap B)^C = A^C \cup B^C.$$

Definizione 1.10. Sia $\{A_n\}_{n\in\mathbb{N}} \subseteq \mathcal{F}$ una successione di eventi. Essa si dice *crescente* (rispettivamente *strettamente crescente*) se:

$$A_n \subseteq A_{n+1} \quad \text{(rispettivamente } A_n \subsetneq A_{n+1}) \qquad \forall n \in \mathbb{N}.$$

Definizione 1.11. Sia $\{A_n\}_{n\in\mathbb{N}} \subseteq \mathcal{F}$ una successione di eventi. Essa si dice *decrescente* (rispettivamente *strettamente decrescente*) se:

$$A_n \supseteq A_{n+1} \quad \text{(rispettivamente } A_n \supsetneq A_{n+1}) \qquad \forall n \in \mathbb{N}.$$

Definizione 1.12. Il limite di una successione di eventi monotòna è definito come segue:

$$\lim_{n\to+\infty} A_n = \bigcup_{n=1}^{+\infty} A_n \qquad \text{per } A_n \text{ crescente;}$$
$$\lim_{n\to+\infty} A_n = \bigcap_{n=1}^{+\infty} A_n \qquad \text{per } A_n \text{ decrescente.}$$

Osservazione. Data una successione di eventi $\{A_n\}_{n\in\mathbb{N}}$ qualsiasi, si possono sempre costruire le seguenti due successioni:

(*i*) una successione crescente:

$$\left\{ \bigcap_{i=n}^{+\infty} A_i \right\}_{n\in\mathbb{N}} = \left\{ \inf_{k\geq n} A_k \right\}_{n\in\mathbb{N}}$$

dove l'inf è calcolato rispetto alla relazione di inclusione;

(*ii*) una successione decrescente:

$$\left\{ \bigcup_{i=n}^{+\infty} A_i \right\}_{n\in\mathbb{N}} = \left\{ \sup_{k\geq n} A_k \right\}_{n\in\mathbb{N}}$$

dove il sup è calcolato rispetto alla relazione di inclusione.

Definizione 1.13. Data una successione di eventi $\{A_n\}_{n\in\mathbb{N}}$ nello spazio $(\Omega, \mathcal{F})$, si definiscono:

1) il *limite inferiore* della successione:

$$\liminf_{n\to+\infty} A_n = \{\omega \in \Omega \mid \exists m \in \mathbb{N} : \forall k \geq m, \omega \in A_k\}$$

$$= \bigcup_{m=1}^{+\infty} \bigcap_{k=m}^{+\infty} A_k = \lim_{m\to+\infty} \bigcap_{k=m}^{+\infty} A_k = \sup_{m\in\mathbb{N}} \left(\inf_{k\geq m} A_k \right);$$

2) il *limite superiore* della successione:

$$\limsup_{n\to+\infty} A_n = \{\omega \in \Omega \mid \forall m \in \mathbb{N}, \exists k \geq m : \omega \in A_k\}$$

$$= \bigcap_{m=1}^{+\infty} \bigcup_{k=m}^{+\infty} A_k = \lim_{m\to+\infty} \bigcup_{k=m}^{+\infty} A_k = \inf_{m\in\mathbb{N}} \left(\sup_{k\geq m} A_k \right).$$

Proposizione 1.1. *Per ogni successione di eventi $\{A_n\}_{n\in\mathbb{N}}$, vale sempre la seguente inclusione:*

$$\liminf_{n\to+\infty} A_n \subseteq \limsup_{n\to+\infty} A_n$$

Dimostrazione. Sia

$$\omega \in \liminf_{n\to+\infty} A_n = \bigcup_{m=1}^{+\infty} \bigcap_{k=m}^{+\infty} A_k.$$

Per definizione di unione, esiste un indice $\bar{m} \in \mathbb{N}$ tale che

$$\omega \in \bigcap_{k=\bar{m}}^{+\infty} A_k,$$

ossia $\omega \in A_k$ per ogni $k \geq \bar{m}$. Si fissi ora un generico $m \in \mathbb{N}$ e si ponga $k := \max\{m, \bar{m}\}$. Essendo per costruzione $k \geq \bar{m}$, si ha $\omega \in A_k$; essendo inoltre $k \geq m$, ne consegue che

$$\forall m \in \mathbb{N} \quad \exists k \geq m : \ \omega \in A_k,$$

cioè

$$\omega \in \bigcup_{k=m}^{+\infty} A_k \quad \text{per ogni } m \in \mathbb{N}.$$

Questa è esattamente la condizione che definisce il limite superiore, dunque

$$\omega \in \limsup_{n\to+\infty} A_n.$$

Per l'arbitrarietà di ω, si conclude che

$$\liminf_{n\to+\infty} A_n \subseteq \limsup_{n\to+\infty} A_n.$$

□

Definizione 1.14. Una successione di eventi $\{A_n\}_{n\in\mathbb{N}} \subseteq \mathcal{F}$ si dice *convergente* (o si dice che *ammette limite*) se

$$\liminf_{n\to+\infty} A_n = \limsup_{n\to+\infty} A_n.$$

In tal caso, l'evento comune prende il nome di *limite* della successione e si denota con

$$\lim_{n\to+\infty} A_n := \liminf_{n\to+\infty} A_n = \limsup_{n\to+\infty} A_n.$$

Osservazione. Poiché $\mathcal{F}$ è una σ-algebra, chiusa rispetto a unioni e intersezioni numerabili, il limite inferiore e il limite superiore di una successione di eventi sono a loro volta eventi; in particolare, il limite di una successione convergente appartiene a $\mathcal{F}$.

Proposizione 1.2. *Per le successioni monotòne, la* Definizione 1.12 *e la* Definizione 1.14 *sono coerenti: ogni successione monotona di eventi è convergente nel senso della* Definizione 1.14*, e il suo limite coincide con quello fornito dalla* Definizione 1.12.

Dimostrazione. Omessa. □

1.4 Misura di probabilità – assiomi e proprietà

Sia $(\Omega, \mathcal{F})$ uno *spazio probabilizzabile*. Un'applicazione

$$\mathbb{P} : \mathcal{F} \to \mathbb{R} \tag{1.1}$$

si chiama *misura di probabilità* se soddisfa gli assiomi di Kolmogorov elencati di seguito.

Assioma 1. $\mathbb{P}(\Omega) = 1$.

Assioma 2. Per ogni evento $A \in \mathcal{F}$, si ha $\mathbb{P}(A) \geq 0$.

Assioma 3. Data una successione di eventi $\{A_n\}_{n\in\mathbb{N}}$ a due a due disgiunti, ovvero tali che $A_i \cap A_j = \emptyset$ per ogni $i \neq j$, la probabilità dell'unione (disgiunta) è pari alla somma delle probabilità:

$$\mathbb{P}\left(\dot{\bigcup_{n=1}^{+\infty}} A_n\right) = \sum_{n=1}^{+\infty} \mathbb{P}(A_n).$$

Definizione 1.15. Si definisce *spazio di probabilità* la terna $(\Omega, \mathcal{F}, \mathbb{P})$, dove:

(*i*) Ω è lo *spazio campione* (l'insieme di tutti i possibili esiti di un esperimento aleatorio);

(*ii*) $\mathcal{F}$ è una σ-algebra di sottoinsiemi di Ω (lo *spazio degli eventi*);

(*iii*) $\mathbb{P} : \mathcal{F} \to \mathbb{R}$ è una *misura di probabilità* che soddisfa gli assiomi di Kolmogorov.

Proprietà. Dagli assiomi appena enunciati derivano le proprietà fondamentali elencate di seguito.

(*i*) $\mathbb{P}(\emptyset) = 0$.

DIMOSTRAZIONE. La successione costante $A_n = \emptyset$ per ogni $n \in \mathbb{N}$ è formata da eventi a due a due disgiunti, e la sua unione è $\emptyset$. Posto $c := \mathbb{P}(\emptyset) \in \mathbb{R}$, l'ASSIOMA 3 fornisce:

$$c = \mathbb{P}(\emptyset) = \mathbb{P}\left(\bigcupdot_{n=1}^{+\infty} A_n\right) = \sum_{n=1}^{+\infty} \mathbb{P}(A_n) = \lim_{k\to+\infty} k\,\mathbb{P}(\emptyset) = \lim_{k\to+\infty} kc.$$

Per l'ASSIOMA 2 si ha $c \geq 0$. Se per assurdo fosse $c > 0$, il limite all'ultimo membro divergerebbe a $+\infty$, mentre il primo membro è un numero reale, il che è impossibile. Dunque $c = 0$. □

(*ii*) Per ogni famiglia finita di eventi $A_1, \ldots, A_k \in \mathcal{F}$ a due a due disgiunti si ha:

$$\mathbb{P}\left(\bigcupdot_{i=1}^{k} A_i\right) = \sum_{i=1}^{k} \mathbb{P}(A_i).$$

DIMOSTRAZIONE. Si consideri la successione di eventi $\{A'_n\}_{n\in\mathbb{N}}$ definita come segue:

$$A'_n = \begin{cases} A_n & \text{se } n \leq k \\ \emptyset & \text{se } n > k \end{cases} \qquad \forall n \in \mathbb{N}.$$

Gli eventi A'_n sono a due a due disgiunti, perché lo sono gli A_i e $\emptyset$ è disgiunto da ogni evento; inoltre la loro unione coincide con

$$\bigcupdot_{i=1}^{k} A_i.$$

Applicando l'ASSIOMA 3 e la proprietà (*i*) si ottiene:

$$\mathbb{P}\left(\bigcupdot_{i=1}^{k} A_i\right) = \sum_{n=1}^{+\infty} \mathbb{P}(A'_n) = \sum_{i=1}^{k} \mathbb{P}(A_i) + 0 = \sum_{i=1}^{k} \mathbb{P}(A_i).$$

□

(*iii*) $\mathbb{P}(A^{\mathsf{C}}) = 1 - \mathbb{P}(A)$.

DIMOSTRAZIONE. Essendo A e A^{C} disgiunti e tali che $A \cup A^{\mathsf{C}} = \Omega$, per la proprietà (*ii*) si ha:

$$1 = \mathbb{P}(\Omega) = \mathbb{P}\left(A \cup A^{\mathsf{C}}\right) = \mathbb{P}(A) + \mathbb{P}\left(A^{\mathsf{C}}\right).$$

Da questa relazione si ricava:

$$\mathbb{P}\left(A^{\mathsf{C}}\right) = 1 - \mathbb{P}(A).$$

□

(*iv*) $\forall A \in \mathcal{F}, \quad 0 \leq \mathbb{P}(A) \leq 1$.

DIMOSTRAZIONE. $\mathbb{P}(A) \geq 0$ è garantito direttamente dall'ASSIOMA 2. Inoltre, per la proprietà *(iii)* e ancora per l'ASSIOMA 2 applicato ad A^{C}, si ha:

$$\mathbb{P}(A) = 1 - \underbrace{\mathbb{P}\left(A^{\mathrm{C}}\right)}_{\geq 0} \implies \mathbb{P}(A) \leq 1.$$

□

(v) Se $A \subseteq B$, allora $\mathbb{P}(A) \leq \mathbb{P}(B)$.

DIMOSTRAZIONE. Essendo $A \subseteq B$, si può riscrivere l'evento B come unione di due eventi disgiunti:

$$B = A \cup (B \setminus A) = A \cup \left(B \cap A^{\mathrm{C}}\right).$$

Applicando la proprietà *(ii)* (poiché l'unione è disgiunta) e l'ASSIOMA 2, si ottiene:

$$\mathbb{P}(B) = \mathbb{P}(A) + \underbrace{\mathbb{P}\left(B \cap A^{\mathrm{C}}\right)}_{\geq 0} \geq \mathbb{P}(A).$$

□

(vi) $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$.

DIMOSTRAZIONE. Si può scrivere l'unione $A \cup B$ come unione disgiunta:

$$A \cup B = A \cup \left(B \cap A^{\mathrm{C}}\right).$$

Passando alle probabilità, per la proprietà *(ii)*:

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}\left(B \cap A^{\mathrm{C}}\right). \tag{1.2}$$

Si considera ora l'evento B. Usando una partizione con l'evento certo $\Omega = A \cup A^{\mathrm{C}}$, si ha:

$$B = B \cap \Omega = B \cap \left(A \cup A^{\mathrm{C}}\right) = (B \cap A) \cup \left(B \cap A^{\mathrm{C}}\right).$$

Applicando nuovamente la proprietà *(ii)*:

$$\mathbb{P}(B) = \mathbb{P}(A \cap B) + \mathbb{P}\left(B \cap A^{\mathrm{C}}\right) \implies \mathbb{P}\left(B \cap A^{\mathrm{C}}\right) = \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

Sostituendo quest'ultima espressione nell'equazione (1.2), si ottiene la tesi:

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

□

PROPOSIZIONE 1.3. *Siano $A_1, \ldots, A_n$ eventi. Allora vale la seguente disuguaglianza:*

$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) \leq \sum_{i=1}^{n} \mathbb{P}(A_i).$$

DIMOSTRAZIONE. La dimostrazione procede per induzione su n.

(Base d'induzione) Sia $n = 2$. Dalla proprietà *(vi)*:

$$\mathbb{P}(A_1 \cup A_2) = \mathbb{P}(A_1) + \mathbb{P}(A_2) - \mathbb{P}(A_1 \cap A_2).$$

Poiché $\mathbb{P}(A_1 \cap A_2) \geq 0$, si deduce immediatamente che

$$\mathbb{P}(A_1 \cup A_2) \leq \mathbb{P}(A_1) + \mathbb{P}(A_2).$$

(Passo induttivo) Si supponga che l'asserto sia valido per un certo $n \geq 2$. Applicando il caso $n = 2$ agli eventi $A_1 \cup \cdots \cup A_n$ e A_{n+1} e, successivamente, l'ipotesi induttiva, si ottiene:

$$\mathbb{P}\left(\bigcup_{i=1}^{n+1} A_i\right) = \mathbb{P}\left(\left(\bigcup_{i=1}^{n} A_i\right) \cup A_{n+1}\right) \leq \mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) + \mathbb{P}(A_{n+1}) \leq \sum_{i=1}^{n+1} \mathbb{P}(A_i).$$

La tesi è dunque dimostrata.

□

Proposizione 1.4 (Disuguaglianza di Boole). *Dato uno spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$ e una successione qualsiasi di eventi $\{A_n\}_{n\in\mathbb{N}}$, vale la seguente disuguaglianza:*

$$\mathbb{P}\left(\bigcup_{n=1}^{+\infty} A_n\right) \leq \sum_{n=1}^{+\infty} \mathbb{P}(A_n).$$

Dimostrazione. Si procede costruendo una nuova successione di eventi $\{B_n\}_{n\in\mathbb{N}}$ a partire da $\{A_n\}_{n\in\mathbb{N}}$ nel modo seguente:

$$\begin{aligned}
B_1 &:= A_1 \\
B_2 &:= A_2 \cap A_1^{\mathsf{C}} \\
B_3 &:= A_3 \cap A_1^{\mathsf{C}} \cap A_2^{\mathsf{C}} \\
&\vdots \\
B_n &:= A_n \cap \left(\bigcup_{i=1}^{n-1} A_i\right)^{\mathsf{C}} = A_n \cap \bigcap_{i=1}^{n-1} A_i^{\mathsf{C}}.
\end{aligned}$$

Per costruzione, gli insiemi B_n sono a due a due disgiunti e tali che $B_n \subseteq A_n$ per ogni $n \in \mathbb{N}$. Inoltre, l'unione numerabile dei B_n coincide esattamente con l'unione numerabile degli A_n:

$$\bigcup_{n=1}^{+\infty} A_n = \dot{\bigcup_{n=1}^{+\infty}} B_n.$$

Per verificare ciò si procede dimostrando la doppia inclusione.

$\boxed{\subseteq}$ Sia

$$\omega \in \bigcup_{n=1}^{+\infty} A_n.$$

Deve allora esistere almeno un indice $n \in \mathbb{N}$ tale che $\omega \in A_n$. Sia definito

$$m := \min\{\, n \in \mathbb{N} \mid \omega \in A_n \,\};$$

si ha allora che $\omega \in A_m$ ma $\omega \notin A_i$ per tutti gli $i < m$. Di conseguenza, $\omega \in A_i^c$ per ogni $i \in \{1, \dots, m-1\}$. Questo implica che $\omega \in B_m$, e quindi

$$\omega \in \dot{\bigcup_{n=1}^{+\infty}} B_n.$$

$\boxed{\supseteq}$ Dalla definizione risulta evidentemente che $B_n \subseteq A_n$ per ogni $n \in \mathbb{N}$. Ne consegue banalmente che l'unione di tutti i B_n è contenuta nell'unione di tutti gli A_n.

Poiché $B_n \subseteq A_n$, per la monotonia della misura di probabilità (proprietà *(v)*) si deduce che

$$\mathbb{P}(B_n) \leq \mathbb{P}(A_n) \qquad \forall n \in \mathbb{N}.$$

Sfruttando l'Assioma 3 sull'unione numerabile (disgiunta) degli eventi B_n, si può concludere la dimostrazione:

$$\mathbb{P}\left(\bigcup_{n=1}^{+\infty} A_n\right) = \mathbb{P}\left(\dot{\bigcup_{n=1}^{+\infty}} B_n\right) = \sum_{n=1}^{+\infty} \mathbb{P}(B_n) \leq \sum_{n=1}^{+\infty} \mathbb{P}(A_n).$$

□

Si conclude la sezione con un risultato molto importante, noto come *principio di inclusione-esclusione*, il quale permette di generalizzare la formula per l'unione di due eventi (vista nella proprietà *(vi)*) a una famiglia finita di n eventi qualsiasi, correggendo sistematicamente le sovrapposizioni.

Proposizione 1.5 (Principio di inclusione-esclusione). *Siano $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e $A_1, A_2, \dots, A_n \in \mathcal{F}$ eventi qualsiasi. Allora la probabilità della loro unione è data da:*

$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) = \sum_{i=1}^{n} \mathbb{P}(A_i) - \sum_{1 \leq i < j \leq n} \mathbb{P}(A_i \cap A_j) + \sum_{1 \leq i < j < k \leq n} \mathbb{P}(A_i \cap A_j \cap A_k)$$
$$- \cdots + (-1)^{n-1} \mathbb{P}\left(\bigcap_{i=1}^{n} A_i\right).$$

Dimostrazione. La dimostrazione procede per induzione sul numero di eventi n.

(Base d'induzione) Sia $n = 2$. La formula si riduce a:

$$\mathbb{P}(A_1 \cup A_2) = \mathbb{P}(A_1) + \mathbb{P}(A_2) - \mathbb{P}(A_1 \cap A_2),$$

che è vera in virtù della proprietà *(vi)* precedentemente dimostrata.

(Passo induttivo) Si supponga che l'asserto sia valido per un generico intero $n \geq 2$. Si vuole dimostrare che esso è valido anche per $n+1$. Si isoli l'evento A_{n+1} riscrivendo l'unione nel modo seguente:

$$\mathbb{P}\left(\bigcup_{i=1}^{n+1} A_i\right) = \mathbb{P}\left(\left(\bigcup_{i=1}^{n} A_i\right) \cup A_{n+1}\right).$$

Applicando il passo base (ovvero la formula per l'unione di due eventi) a questa espressione, si ottiene:

$$\mathbb{P}\left(\bigcup_{i=1}^{n+1} A_i\right) = \mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) + \mathbb{P}(A_{n+1}) - \mathbb{P}\left(\left(\bigcup_{i=1}^{n} A_i\right) \cap A_{n+1}\right). \tag{1.3}$$

Per le proprietà distributive dell'intersezione rispetto all'unione, l'argomento dell'ultima probabilità si può espandere come:

$$\left(\bigcup_{i=1}^{n} A_i\right) \cap A_{n+1} = \bigcup_{i=1}^{n} (A_i \cap A_{n+1}).$$

Sostituendo questa identità, il terzo termine al secondo membro dell'equazione (1.3) diventa la probabilità di un'unione di n eventi. È dunque possibile applicare l'ipotesi induttiva su entrambi i termini dell'equazione (1.3) che coinvolgono l'unione di n insiemi come segue.

(*i*) Per il primo termine, l'ipotesi induttiva fornisce direttamente l'enunciato per n:

$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) = \sum_{i=1}^{n} \mathbb{P}(A_i) - \sum_{1 \le i < j \le n} \mathbb{P}(A_i \cap A_j) + \cdots + (-1)^{n-1} \mathbb{P}\left(\bigcap_{i=1}^{n} A_i\right).$$

(*ii*) Per il terzo termine, applicando l'ipotesi induttiva agli n insiemi del tipo $(A_i \cap A_{n+1})$:

$$\mathbb{P}\left(\bigcup_{i=1}^{n} (A_i \cap A_{n+1})\right) = \sum_{i=1}^{n} \mathbb{P}(A_i \cap A_{n+1}) - \sum_{1 \le i < j \le n} \mathbb{P}(A_i \cap A_j \cap A_{n+1}) + \cdots + (-1)^{n-1} \mathbb{P}\left(\bigcap_{i=1}^{n} A_i \cap A_{n+1}\right).$$

Sostituendo queste due espansioni nell'equazione (1.3) occorre prestare attenzione al segno meno davanti al terzo termine del secondo membro, il quale inverte tutti i segni della seconda espansione (il $+$ diventa $-$ e il termine $(-1)^{n-1}$ diventa $(-1)^n$).

Raggruppando i termini che condividono la stessa dimensione delle intersezioni, si osserva che:

(*a*) Somma delle singole probabilità:

$$\sum_{i=1}^{n} \mathbb{P}(A_i) + \mathbb{P}(A_{n+1}) = \sum_{i=1}^{n+1} \mathbb{P}(A_i).$$

(*b*) Somma delle intersezioni a coppie:

$$-\sum_{1 \le i < j \le n} \mathbb{P}(A_i \cap A_j) - \sum_{i=1}^{n} \mathbb{P}(A_i \cap A_{n+1}) = -\sum_{1 \le i < j \le n+1} \mathbb{P}(A_i \cap A_j).$$

(*c*) La medesima logica si applica per le terne e così via, fino all'ultima intersezione contenente tutti gli $n + 1$ eventi, che avrà coefficiente $(-1)^n$.

Ricostruendo l'espressione completa si ottiene l'asserto:

$$\mathbb{P}\left(\bigcup_{i=1}^{n+1} A_i\right) = \sum_{i=1}^{n+1} \mathbb{P}(A_i) - \sum_{1\le i<j\le n+1} \mathbb{P}(A_i \cap A_j) + \cdots + (-1)^n \mathbb{P}\left(\bigcap_{i=1}^{n+1} A_i\right).$$

□

1.5 Calcolo combinatorio

1.5.1 Funzione Γ di Eulero

Definizione 1.16 (Funzione Gamma di Eulero)**.** Si dice *funzione Gamma di Eulero* l'applicazione $\Gamma : (0, +\infty) \to \mathbb{R}$ definita dal seguente integrale improprio:

$$\Gamma(t) := \int_0^{+\infty} z^{t-1} \mathrm{e}^{-z}\, \mathrm{d}z.$$

Proposizione 1.6 (Proprietà fondamentali della funzione Gamma). *La funzione Gamma gode delle seguenti proprietà:*

(*i*) $\Gamma(t+1) = t\,\Gamma(t)$ *per ogni* $t > 0$;

(*ii*) $\Gamma(1) = 1$;

(*iii*) $\Gamma(n+1) = n!$ *per ogni* $n \in \mathbb{N}$.

Dimostrazione.

(*i*) Sostituendo $t+1$ nella definizione della funzione Gamma, si ha:

$$\Gamma(t+1) = \int_0^{+\infty} z^t \mathrm{e}^{-z}\, \mathrm{d}z.$$

Risolvendo l'integrale per parti si ottiene:

$$\Gamma(t+1) = \left[-z^t \mathrm{e}^{-z}\right]_0^{+\infty} + \int_0^{+\infty} t z^{t-1} \mathrm{e}^{-z}\, \mathrm{d}z.$$

Valutando il primo addendo si ottiene:

$$\left[-z^t \mathrm{e}^{-z}\right]_0^{+\infty} = \lim_{z\to+\infty}\left(-\frac{z^t}{\mathrm{e}^z}\right) - \left(-0^t \mathrm{e}^{-0}\right) = 0.$$

L'espressione si riduce dunque al solo termine integrale:

$$\Gamma(t+1) = t \int_0^{+\infty} z^{t-1} \mathrm{e}^{-z}\, \mathrm{d}z = t\,\Gamma(t).$$

(*ii*) Valutando la definizione direttamente per $t = 1$:

$$\Gamma(1) = \int_0^{+\infty} z^{1-1} \mathrm{e}^{-z}\,\mathrm{d}z = \int_0^{+\infty} \mathrm{e}^{-z}\,\mathrm{d}z.$$

Risolvendo questo integrale elementare si ottiene:

$$\Gamma(1) = [-\mathrm{e}^{-z}]_0^{+\infty} = \lim_{z\to+\infty}\left(-\frac{1}{\mathrm{e}^z}\right) - \left(-\mathrm{e}^0\right) = 0 + 1 = 1.$$

(*iii*) Applicando iterativamente la proprietà (*i*) appena dimostrata e sfruttando il risultato della proprietà (*ii*) come caso base, si ottiene:

$$\begin{aligned}\Gamma(n+1) &= n\,\Gamma(n)\\ &= n(n-1)\,\Gamma(n-1)\\ &= n(n-1)(n-2)\,\Gamma(n-2)\\ &\;\;\vdots\\ &= \underbrace{n(n-1)(n-2)\ldots 2\cdot 1}_{n!}\cdot\underbrace{\Gamma(1)}_{1} = n!\end{aligned}$$

La dimostrazione è così conclusa. □

Esempio 1.3. Si calcoli il valore della funzione Gamma in $t = \frac{1}{2}$:

$$\Gamma\left(\frac{1}{2}\right) = \int_0^{+\infty} z^{\frac{1}{2}-1}\mathrm{e}^{-z}\,\mathrm{d}z = \int_0^{+\infty} z^{-\frac{1}{2}}\mathrm{e}^{-z}\,\mathrm{d}z.$$

Per risolvere l'integrale, si effettua la sostituzione di variabile ponendo $u^2 = z$, da cui si ottiene $2u\,\mathrm{d}u = \mathrm{d}z$. Poiché per $z \to 0$ si ha $u \to 0$ e per $z \to +\infty$ si ha $u \to +\infty$, gli estremi di integrazione rimangono invariati. Sostituendo all'interno dell'integrale si ottiene:

$$\Gamma\left(\frac{1}{2}\right) = \int_0^{+\infty} \frac{1}{u}\mathrm{e}^{-u^2}(2u)\,\mathrm{d}u = 2\int_0^{+\infty} \mathrm{e}^{-u^2}\,\mathrm{d}u.$$

Riconoscendo nel termine a destra il ben noto integrale di Gauss, il quale valutato su metà asse reale restituisce $\sqrt{\pi}/2$, si può concludere che:

$$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}.$$

1.5.2 Strutture combinatorie elementari

Per introdurre le tecniche del calcolo combinatorio, si consideri un generico insieme finito costituito da n elementi distinti, indicato con $S = \{a_1, a_2, \ldots, a_n\}$. Qualora ci dovessero essere delle ripetizioni da prendere in considerazione, si userà la n-upla $S = (a_1, a_2, \ldots, a_n)$.

Notazione 1.17. Si consideri una generica n-upla $S = (a_1, a_2, \ldots, a_n)$ all'interno della quale vi siano degli elementi ripetuti. Per costruire una notazione che ignora l'ordine posizionale degli elementi, interessandosi esclusivamente alla loro identità e al numero di volte in cui compaiono, si procede come segue.

(*i*) Si isolano i k elementi *distinti* (o unici) presenti nella n-upla, con $1 \leq k < n$. Per identificarli, si selezioni un opportuno sottoinsieme di indici $I = \{i_1, i_2, \ldots, i_k\} \subset \{1, 2, \ldots, n\}$, così da poter denotare tali elementi univoci come $a_{i_1}, a_{i_2}, \ldots, a_{i_k}$. L'insieme $\{a_{i_1}, a_{i_2}, \ldots, a_{i_k}\}$ ha dunque cardinalità k.

(*ii*) Per ciascun indice $i_h \in I$, si definisca $n_h \in \mathbb{N}$ come il numero di occorrenze (o *molteplicità*) dell'elemento a_{i_h} all'interno della n-upla originale.

Per costruzione, è necessario che la somma delle molteplicità sia pari ad n:

$$\sum_{h=1}^{k} n_h = n.$$

Sotto tali premesse, è possibile abbandonare la n-upla a favore di una notazione più compatta che evidenzi esclusivamente gli elementi distinti e le loro molteplicità:

$$\left\{ a_{i_1}^{(n_1)}, a_{i_2}^{(n_2)}, \ldots, a_{i_k}^{(n_k)} \right\}.$$

La classificazione dei raggruppamenti che è possibile formare a partire da un insieme composto da elementi distinti oppure da una n-upla con ripetizioni si basa su due criteri:

(*a*) l'*ordine* con cui vengono estratti o disposti gli elementi: se l'ordine conta si parla di *disposizioni*, se non conta si parla di *combinazioni*;

(*b*) la possibilità di *ripetere* o meno gli elementi all'interno del raggruppamento, generando sequenze *con ripetizione* o *semplici*.

Definizione 1.18. Dato un insieme finito S composto da n elementi distinti, si definisce *permutazione semplice* (o senza ripetizione) una sequenza ordinata che contiene tutti gli n elementi di S, in cui ogni elemento compare esattamente una volta. Il numero totale delle permutazioni semplici di n elementi è indicato con P_n ed è dato da:

$$P_n = n!$$

Definizione 1.19. Dato un insieme finito S composto da n elementi distinti e un intero $1 \leq k \leq n$, si definisce *disposizione semplice* di lunghezza k una sequenza ordinata di k elementi scelti tra gli n disponibili, senza ripetizioni. Il numero totale di tali sequenze è indicato con $D_{n,k}$ ed è dato da:

$$D_{n,k} = n(n-1)\cdots(n-k+1) = \frac{n!}{(n-k)!}.$$

Osservazione. Le permutazioni semplici sono un caso particolare delle disposizioni semplici, ottenuto per $k = n$:

$$D_{n,n} = \frac{n!}{(n-n)!} = \frac{n!}{0!} = n! = P_n.$$

Definizione 1.20. Dati $n \in \mathbb{N}$, $k \in \mathbb{N}$ e k interi non negativi $n_1, n_2, \ldots, n_k \in \mathbb{N}_0$ tali che

$$\sum_{i=1}^{k} n_i = n,$$

si definisce *coefficiente multinomiale* la quantità:

$$\binom{n}{n_1, n_2, \ldots, n_k} := \frac{n!}{\prod_{i=1}^{k}(n_i!)} = \frac{n!}{n_1!\, n_2! \cdots n_k!}.$$

Osservazione. Si osservi il caso particolare in cui $k = 2$. Dalla condizione $n_1 + n_2 = n$ si deduce immediatamente che $n_2 = n - n_1$. Sostituendo questa espressione all'interno della formula generale del coefficiente multinomiale, si ottiene:

$$\binom{n}{n_1, n_2} = \frac{n!}{n_1!\, n_2!} = \frac{n!}{n_1!\,(n - n_1)!} = \binom{n}{n_1}.$$

Proposizione 1.7 (Formula di Stifel). *Per ogni intero $n \geq 2$ e per ogni intero k tale che $1 \leq k \leq n - 1$, vale la seguente identità:*

$$\binom{n}{k} = \binom{n-1}{k} + \binom{n-1}{k-1}.$$

Dimostrazione. Riducendo allo stesso denominatore $k!\,(n-k)!$ si ottiene:

$$\begin{aligned}\binom{n-1}{k} + \binom{n-1}{k-1} &= \frac{(n-1)!}{k!\,(n-1-k)!} + \frac{(n-1)!}{(k-1)!\,(n-k)!} \\ &= \frac{(n-1)!}{k!\,(n-k)!}\big[(n-k) + k\big] = \frac{n!}{k!\,(n-k)!} = \binom{n}{k}.\end{aligned}$$

□

Definizione 1.21. Dato un insieme finito S composto da n elementi distinti e un intero $k \in \mathbb{N}$ (non necessariamente minore o uguale a n), si definisce *disposizione con ripetizione* di lunghezza k una sequenza ordinata di k elementi scelti tra gli n disponibili, in cui è ammessa la ripetizione di uno stesso elemento. In altre parole, dopo l'estrazione di un elemento, esso viene reinserito nell'insieme S e può essere nuovamente estratto. Il numero totale di tali sequenze è indicato con $D^*_{n,k}$ ed è dato da:

$$D^*_{n,k} = n^k.$$

Definizione 1.22. Si consideri un raggruppamento di n elementi descritto tramite la notazione per molteplicità precedentemente introdotta:

$$\left\{ a_{i_1}^{(n_1)},\ a_{i_2}^{(n_2)},\ \ldots,\ a_{i_k}^{(n_k)} \right\},$$

dove

$$\sum_{h=1}^{k} n_h = n.$$

Si definisce *permutazione con ripetizione* ogni sequenza ordinata di lunghezza n che riordina tutti gli elementi del raggruppamento, tenendo conto che scambiare di posizione due elementi identici non produce una sequenza distinguibile. Il numero totale di tali permutazioni è indicato con $P^*_{n,(n_1,\ldots,n_k)}$ ed è dato dal rapporto tra le permutazioni semplici di n elementi e le permutazioni interne agli insiemi di elementi identici:

$$P^*_{n,(n_1,\ldots,n_k)} = \binom{n}{n_1, n_2, \ldots, n_k} = \frac{n!}{n_1!\, n_2! \cdots n_k!}.$$

Osservazione. Da un punto di vista combinatorio, il termine

$$\prod_{h=1}^{k} (n_h!)$$

presente al denominatore compensa il fatto che, tra le $n!$ permutazioni, ogni sequenza distinguibile viene contata $n_1!\, n_2! \cdots n_k!$ volte, una per ciascun riordinamento interno degli elementi identici.

Esempio 1.4. Il problema di calcolare il numero di anagrammi della parola "MATEMATICA" è equivalente al calcolo del numero di permutazioni con ripetizione degli elementi di

$$\left\{ \mathrm{M}^{(2)},\ \mathrm{A}^{(3)},\ \mathrm{T}^{(2)},\ \mathrm{E}^{(1)},\ \mathrm{I}^{(1)},\ \mathrm{C}^{(1)} \right\}.$$

La parola è composta da un totale di $n = 10$ lettere. Applicando la formula per le permutazioni con ripetizione, si ottiene:

$$P^*_{10,(2,3,2,1,1,1)} = \binom{10}{2, 3, 2, 1, 1, 1} = \frac{10!}{2! \cdot 3! \cdot 2! \cdot 1! \cdot 1! \cdot 1!} = \frac{3\,628\,800}{2 \cdot 6 \cdot 2 \cdot 1 \cdot 1 \cdot 1} = 151\,200.$$

Vi sono dunque 151 200 possibili anagrammi (anche privi di senso compiuto) generabili a partire da tale parola.

Definizione 1.23. Dato un insieme finito S composto da n elementi distinti e un intero $0 \leq k \leq n$, si definisce *combinazione semplice* di lunghezza k un sottoinsieme di S costituito da esattamente k elementi distinti. A differenza delle disposizioni, nelle combinazioni l'ordine in cui gli elementi vengono selezionati è del tutto ininfluente.

Il numero totale di tali raggruppamenti è indicato con $C_{n,k}$. Poiché ogni singola combinazione di k elementi può essere riordinata al suo interno in $k!$ modi diversi (generando così $k!$ disposizioni semplici), il valore di $C_{n,k}$ si ottiene dividendo il numero di disposizioni semplici $D_{n,k}$ per le permutazioni interne P_k. Tale calcolo restituisce esattamente la formula del coefficiente binomiale:

$$C_{n,k} = \frac{D_{n,k}}{P_k} = \frac{\dfrac{n!}{(n-k)!}}{k!} = \frac{n!}{k!\,(n-k)!} = \binom{n}{k}.$$

Definizione 1.24. Dato un insieme finito S composto da n elementi distinti e un intero $k \in \mathbb{N}$ (non necessariamente minore o uguale a n), si definisce *combinazione con ripetizione* di lunghezza k un raggruppamento di k elementi scelti tra gli n disponibili, in cui l'ordine non conta ed è ammessa la ripetizione degli elementi.

Il numero totale di tali raggruppamenti è indicato con $C^*_{n,k}$ ed è dato da:

$$C^*_{n,k} = \binom{n+k-1}{k, n-1} = \binom{n+k-1}{k} = \binom{n+k-1}{n-1}.$$

Tale problema equivale al calcolo del numero di permutazioni con ripetizione dell'insieme

$$\left\{ 0^{(n-1)},\ 1^{(k)} \right\}.$$

Viene fornito un esempio pratico per $n = 3$ e $k = 6$.

Esempio 1.5. Si calcoli il numero di combinazioni con ripetizione di lunghezza 6 che è possibile formare a partire dall'insieme $S = \{a, b, c\}$, con a, b, c distinti. Per comprendere graficamente la corrispondenza biunivoca con le sequenze binarie, si consideri una specifica combinazione in cui si estrae due volte a, tre volte b e una volta c, indicata con

$$\left\{ a^{(2)},\ b^{(3)},\ c^{(1)} \right\}.$$

Si associno gli elementi estratti al simbolo 1 e si utilizzino i simboli 0 come *separatori* per demarcare il passaggio da un elemento di S al successivo. Essendoci $n = 3$ elementi in S, sono sufficienti $n - 1 = 2$ separatori.

La combinazione considerata si codifica univocamente nella stringa riportata di seguito.

$$\underbrace{1\ 1}_{a}\ \boxed{0}\ \underbrace{1\ 1\ 1}_{b}\ \boxed{0}\ \underbrace{1}_{c}$$

Le combinazioni sono quindi in corrispondenza biunivoca con le sequenze di questi 8 simboli contenenti esattamente 2 separatori. Il calcolo si riduce pertanto a determinare le permutazioni con ripetizione di

$$\left\{ 0^{(2)},\ 1^{(6)} \right\}.$$

Applicando la formula si ottiene:

$$C^*_{3,6} = P^*_{8,(2,6)} = \binom{3+6-1}{6} = \binom{8}{6} = \frac{8!}{6!\,2!} = \frac{8 \cdot 7}{2} = 28.$$

1.6 σ-algebre di Borel

Definizione 1.25. Sia X un insieme e $\mathcal{Y} \subseteq \mathcal{P}(X)$ un arbitrario insieme di sottoinsiemi di X. Si indichi con $\mathcal{A}$ la famiglia di tutte le σ-algebre definite su X e contenenti $\mathcal{Y}$:

$$\mathcal{A} := \left\{ \mathcal{G} \subseteq \mathcal{P}(X) \mid \mathcal{G} \text{ è una } \sigma\text{-algebra e } \mathcal{Y} \subseteq \mathcal{G} \right\}.$$

Si definisce *σ-algebra generata* da $\mathcal{Y}$, e si denota con $\sigma(\mathcal{Y})$, la più piccola σ-algebra contenente $\mathcal{Y}$:

$$\sigma(\mathcal{Y}) := \bigcap_{\mathcal{G} \in \mathcal{A}} \mathcal{G}.$$

Proposizione 1.8. *Nelle notazioni della definizione precedente, $\sigma(\mathcal{Y})$ è ben definita ed è una σ-algebra su X contenente $\mathcal{Y}$. Inoltre, per ogni σ-algebra $\mathcal{G}$ su X tale che $\mathcal{Y} \subseteq \mathcal{G}$, si ha $\sigma(\mathcal{Y}) \subseteq \mathcal{G}$.*

Dimostrazione. La famiglia $\mathcal{A}$ non è vuota, poiché $\mathcal{P}(X)$ è una σ-algebra contenente $\mathcal{Y}$, e dunque $\mathcal{P}(X) \in \mathcal{A}$; l'intersezione che definisce $\sigma(\mathcal{Y})$ è pertanto ben posta. Si verifica che $\sigma(\mathcal{Y})$ soddisfa le tre proprietà di σ-algebra:

(*i*) $X \in \mathcal{G}$ per ogni $\mathcal{G} \in \mathcal{A}$, dunque $X \in \sigma(\mathcal{Y})$;

(*ii*) se $A \in \sigma(\mathcal{Y})$, allora $A \in \mathcal{G}$ per ogni $\mathcal{G} \in \mathcal{A}$; essendo ciascuna $\mathcal{G}$ una σ-algebra, si ha $A^{\mathrm{C}} \in \mathcal{G}$ per ogni $\mathcal{G} \in \mathcal{A}$, cioè $A^{\mathrm{C}} \in \sigma(\mathcal{Y})$;

(*iii*) se $\{A_n\}_{n\in\mathbb{N}} \subseteq \sigma(\mathcal{Y})$, allora $\{A_n\}_{n\in\mathbb{N}} \subseteq \mathcal{G}$ per ogni $\mathcal{G} \in \mathcal{A}$, e quindi

$$\bigcup_{n=1}^{+\infty} A_n \in \mathcal{G} \quad \text{per ogni } \mathcal{G} \in \mathcal{A} \implies \bigcup_{n=1}^{+\infty} A_n \in \sigma(\mathcal{Y}).$$

Inoltre, poiché $\mathcal{Y} \subseteq \mathcal{G}$ per ogni $\mathcal{G} \in \mathcal{A}$, si ha $\mathcal{Y} \subseteq \sigma(\mathcal{Y})$. Infine, se $\widetilde{\mathcal{G}}$ è una qualsiasi σ-algebra contenente $\mathcal{Y}$, allora $\widetilde{\mathcal{G}} \in \mathcal{A}$ e quindi

$$\sigma(\mathcal{Y}) = \bigcap_{\mathcal{G}\in\mathcal{A}} \mathcal{G} \subseteq \widetilde{\mathcal{G}}. \qquad \square$$

È possibile adattare la definizione appena fornita al caso in cui la famiglia $\mathcal{Y}$ sia composta da un singolo sottoinsieme $Y \subseteq X$.

Definizione 1.26. Sia X un insieme e $Y \in \mathcal{P}(X)$ un suo sottoinsieme arbitrario. Si definisce *σ-algebra generata* dall'insieme Y, e la si denota con $\sigma(Y)$, la σ-algebra generata dalla famiglia composta dal solo elemento Y:

$$\sigma(Y) := \sigma\big(\{Y\}\big).$$

Osservazione. La σ-algebra generata da un singolo sottoinsieme $Y \subseteq X$ si esplicita sempre in una famiglia di al più quattro elementi:

$$\sigma(Y) = \sigma\big(\{Y\}\big) = \big\{\, \emptyset,\ X,\ Y,\ X \setminus Y \,\big\}.$$

Esempio 1.6. Si consideri lo spazio campione relativo al lancio di un dado a sei facce:

$$\Omega = \big\{\, 1,\ 2,\ 3,\ 4,\ 5,\ 6 \,\big\}.$$

Sia dato l'evento $Y = \{6\}$, corrispondente all'uscita del numero 6. Applicando la definizione appena fornita per un singolo sottoinsieme, la σ-algebra generata da tale evento risulta esplicitamente:

$$\sigma(Y) = \big\{\, \emptyset,\ \Omega,\ \{6\},\ \Omega \setminus \{6\} \,\big\}.$$

Definizione 1.27. Preso l'insieme dei numeri reali $\mathbb{R}$, si consideri la famiglia $\mathcal{Y}$ costituita da tutti gli intervalli chiusi a destra e illimitati inferiormente:

$$\mathcal{Y} = \big\{\, (-\infty, x] \mid x \in \mathbb{R} \,\big\}.$$

La *σ-algebra di Borel*, denotata con la lettera $\mathfrak{B}$, è definita come la σ-algebra generata da tale famiglia di intervalli:

$$\mathfrak{B} := \sigma(\mathcal{Y}).$$

Gli elementi di $\mathfrak{B}$ sono detti *insiemi boreliani* (o semplicemente *boreliani*).

Proposizione 1.9. *Indicando con τ la* topologia naturale *di $\mathbb{R}$, ovvero la famiglia degli insiemi aperti di $\mathbb{R}$, si ha:*

$$\mathfrak{B} = \sigma(\tau).$$

In altre parole, la σ-algebra di Borel coincide con la σ-algebra generata dagli insiemi aperti di $\mathbb{R}$.

Dimostrazione. Omessa. □

Osservazione. Nonostante la sua vastità, è possibile dimostrare che la cardinalità della σ-algebra di Borel coincide con la potenza del continuo:

$$\#\mathfrak{B} = 2^{\aleph_0} := \mathfrak{c}.$$

Qualora lo spazio campione di interesse sia limitato a un sottoinsieme proprio dei reali, come ad esempio l'intervallo $[0, 1]$, è possibile definire la σ-algebra di Borel ristretta al nuovo dominio:

$$\mathfrak{B}_{[0,1]} := \sigma\Big(\big\{\,[0, x) \mid x \in [0, 1]\,\big\}\Big).$$

Il corrispondente spazio misurabile ristretto diventa dunque $\big([0, 1], \mathfrak{B}_{[0,1]}\big)$.

1.7 Alcuni esempi di limiti di successioni di eventi

Esempio 1.7. Si consideri una successione di eventi $\{A_n\}_{n\in\mathbb{N}}$ definita per casi nel modo seguente:

$$A_n = \begin{cases} (0, 1) & \text{se } n \text{ è pari} \\ \left(0, \dfrac{1}{n}\right) & \text{se } n \text{ è dispari} \end{cases} \qquad \forall n \in \mathbb{N}.$$

Ci si pone il problema di verificare se tale successione ammette limite, ovvero se

$$\liminf_{n\to+\infty} A_n = \limsup_{n\to+\infty} A_n.$$

Si calcoli innanzitutto il limite inferiore:

$$\liminf_{n\to+\infty} A_n = \bigcup_{n=1}^{+\infty}\left(\bigcap_{k=n}^{+\infty} A_k\right) = \lim_{n\to+\infty}\left(\bigcap_{k=n}^{+\infty} A_k\right).$$

Per ogni $n \in \mathbb{N}$, gli insiemi di indice pari valgono $(0, 1)$ e non restringono l'intersezione, che è quindi determinata dagli insiemi A_k di indice dispari $k \geq n$, ovvero dagli intervalli $(0, 1/k)$ con k arbitrariamente grande. Poiché $A_k \subseteq (0, 1)$ per ogni k, è sufficiente considerare $x \in (0, 1)$: fissato un tale x, è sempre possibile scegliere un indice dispari $k \geq n$ tale che $k > 1/x$, per il quale risulta $x \notin A_k$. Ne segue che nessun punto appartiene a tutti gli A_k con $k \geq n$:

$$\bigcap_{k=n}^{+\infty} A_k = \emptyset \qquad \forall n \in \mathbb{N}.$$

La successione crescente delle intersezioni è dunque costantemente vuota, e così anche la sua unione:

$$\liminf_{n\to+\infty} A_n = \bigcup_{n=1}^{+\infty} \emptyset = \emptyset.$$

Procedendo in maniera analoga per il limite superiore:

$$\limsup_{n\to+\infty} A_n = \bigcap_{n=1}^{+\infty}\left(\bigcup_{k=n}^{+\infty} A_k\right) = \lim_{n\to+\infty}\left(\bigcup_{k=n}^{+\infty} A_k\right).$$

Poiché per ogni n esiste un indice pari $k \geq n$ con $A_k = (0,1)$, e tutti gli A_k sono contenuti in $(0,1)$, si ha:

$$\bigcup_{k=n}^{+\infty} A_k = (0,1) \qquad \forall n \in \mathbb{N}.$$

Passando al limite per $n \to +\infty$ si ottiene $(0,1)$:

$$\limsup_{n\to+\infty} A_n = (0,1).$$

Essendo $\emptyset \neq (0,1)$, si deduce che la successione di eventi non ammette limite.

Esempio 1.8. Si consideri una successione di eventi $\{A_n\}_{n\in\mathbb{N}}$ definita per casi nel modo seguente:

$$A_n = \begin{cases} \emptyset & \text{se } n \text{ è pari} \\ \left[0, \dfrac{1}{n}\right) & \text{se } n \text{ è dispari} \end{cases} \qquad \forall n \in \mathbb{N}.$$

Si calcoli innanzitutto il limite inferiore:

$$\liminf_{n\to+\infty} A_n = \bigcup_{n=1}^{+\infty}\left(\bigcap_{k=n}^{+\infty} A_k\right) = \lim_{n\to+\infty}\left(\bigcap_{k=n}^{+\infty} A_k\right).$$

Poiché in ogni sequenza di indici $k \geq n$ vi è necessariamente almeno un indice pari per il quale $A_k = \emptyset$, l'intersezione interna si annulla costantemente:

$$\bigcap_{k=n}^{+\infty} A_k = \emptyset \qquad \forall n \in \mathbb{N}.$$

Passando al limite per $n \to +\infty$ si ottiene banalmente $\emptyset$:

$$\liminf_{n\to+\infty} A_n = \emptyset.$$

Si calcoli ora il limite superiore:

$$\limsup_{n\to+\infty} A_n = \bigcap_{n=1}^{+\infty}\left(\bigcup_{k=n}^{+\infty} A_k\right) = \lim_{n\to+\infty}\left(\bigcup_{k=n}^{+\infty} A_k\right).$$

Sviluppando l'unione, i termini pari vuoti non contribuiscono, pertanto ci si riduce all'intervallo dispari più ampio:

$$\bigcup_{k=n}^{+\infty} A_k = \begin{cases} \left[0, \dfrac{1}{n}\right) & \text{se } n \text{ è dispari} \\ \left[0, \dfrac{1}{n+1}\right) & \text{se } n \text{ è pari} \end{cases} \qquad \forall n \in \mathbb{N}.$$

Passando al limite per $n \to +\infty$, l'estremo destro tende a zero. Essendo l'intervallo chiuso a sinistra, lo zero non viene mai escluso:

$$\limsup_{n\to+\infty} A_n = \{0\}.$$

Essendo $\emptyset \neq \{0\}$, si deduce che la successione di eventi non ammette limite.

Esempio 1.9. Si consideri una variante dell'esempio precedente:

$$A_n = \begin{cases} \emptyset & \text{se } n \text{ è pari} \\ \left(0, \dfrac{1}{n}\right) & \text{se } n \text{ è dispari} \end{cases} \qquad \forall n \in \mathbb{N}.$$

Il limite inferiore, per le medesime ragioni analizzate in precedenza, risulta vuoto:

$$\liminf_{n\to+\infty} A_n = \emptyset.$$

Per il limite superiore si ottiene invece:

$$\bigcup_{k=n}^{+\infty} A_k = \begin{cases} \left(0, \dfrac{1}{n}\right) & \text{se } n \text{ è dispari} \\ \left(0, \dfrac{1}{n+1}\right) & \text{se } n \text{ è pari} \end{cases} \qquad \forall n \in \mathbb{N}.$$

Passando al limite per $n \to +\infty$, in questo caso lo zero non appartiene a nessuno degli insiemi originari. L'intersezione generalizzata non trattiene dunque alcun elemento:

$$\limsup_{n\to+\infty} A_n = \emptyset = \liminf_{n\to+\infty} A_n.$$

Si deduce, dunque, che la successione di eventi ammette limite e tale limite è l'insieme vuoto $\emptyset$.

1.8 Teorema di equivalenza

Definizione 1.28. Sia $(\Omega, \mathcal{F})$ uno spazio probabilizzabile e sia $\mathbb{P}\colon \mathcal{F} \to \mathbb{R}$ una funzione d'insieme. Si dice che $\mathbb{P}$ è:

(*i*) *finitamente additiva* se, per ogni famiglia finita di eventi $A_1, \ldots, A_k \in \mathcal{F}$ a due a due disgiunti, si ha

$$\mathbb{P}\left(\dot{\bigcup_{i=1}^{k}} A_i\right) = \sum_{i=1}^{k} \mathbb{P}(A_i);$$

(*ii*) *continua* se, per ogni successione di eventi $\{A_n\}_{n\in\mathbb{N}} \subseteq \mathcal{F}$ che ammette limite, si ha

$$\lim_{n\to+\infty} \mathbb{P}(A_n) = \mathbb{P}\left(\lim_{n\to+\infty} A_n\right).$$

Teorema di equivalenza 1.10. *Sia $(\Omega, \mathcal{F})$ uno spazio probabilizzabile e sia $\mathbb{P}\colon \mathcal{F} \to \mathbb{R}$ una funzione d'insieme che soddisfa l'Assioma 1 e l'Assioma 2, ovvero tale che $\mathbb{P}(\Omega) = 1$ e $\mathbb{P}(A) \geq 0$ per ogni $A \in \mathcal{F}$. Allora $\mathbb{P}$ è σ-additiva (cioè soddisfa l'Assioma 3) se e solo se è finitamente additiva e continua.*

In altre parole, nella definizione di misura di probabilità l'Assioma 3 può essere sostituito, in modo equivalente, dalla coppia di proprietà: additività finita e continuità.

Dimostrazione.

$\boxed{\Rightarrow}$ In questo caso $\mathbb{P}$ soddisfa tutti e tre gli assiomi di Kolmogorov, dunque è una misura di probabilità e, pertanto, valgono tutte le proprietà già dimostrate.

(*i*) L'additività finita è stata già dimostrata nella proprietà (*ii*) della misura di probabilità.

(*ii*) Si consideri una successione di eventi $\{B_n\}_{n\in\mathbb{N}}$ monotòna decrescente e convergente a $\emptyset$. Fissato un generico indice n, è possibile esprimere B_n come l'unione numerabile delle "corone" successive, le quali sono sempre disgiunte tra loro:

$$B_n = \dot{\bigcup_{k=n}^{+\infty}} \left(B_k \cap B_{k+1}^{\mathsf{C}}\right).$$

Applicando la σ-additività, si ottiene:

$$\begin{aligned} \mathbb{P}(B_n) &= \mathbb{P}\left(\dot{\bigcup_{k=n}^{+\infty}} \left(B_k \cap B_{k+1}^{\mathsf{C}}\right)\right) \\ &= \sum_{k=n}^{+\infty} \mathbb{P}\left(B_k \cap B_{k+1}^{\mathsf{C}}\right). \end{aligned} \tag{1.4}$$

Risulta dunque:

$$0 \leq \mathbb{P}(B_1) = \sum_{k=1}^{+\infty} \mathbb{P}\left(B_k \cap B_{k+1}^{\mathsf{C}}\right) \leq 1.$$

La (1.4) rappresenta il resto n-esimo di una serie convergente, pertanto tende a zero per $n \to +\infty$:

$$\lim_{n\to+\infty} \mathbb{P}(B_n) = 0 = \mathbb{P}(\emptyset) = \mathbb{P}\left(\lim_{n\to+\infty} B_n\right).$$

(*iii*) Si consideri una successione di eventi $\{D_n\}_{n\in\mathbb{N}}$ monotòna decrescente e convergente a D. Vale la relazione:

$$\begin{aligned} D_n &= D_n \cap \Omega = D_n \cap \left(D \uplus D^{\mathsf{C}}\right) \\ &= (D_n \cap D) \uplus \left(D_n \cap D^{\mathsf{C}}\right) = D \uplus \left(D_n \cap D^{\mathsf{C}}\right). \end{aligned}$$

Passando alla probabilità e applicando la σ-additività, si ottiene:

$$\mathbb{P}(D_n) = \mathbb{P}(D) + \mathbb{P}(D_n \cap D^{\mathsf{C}}).$$

Passando al limite per $n \to +\infty$, si osserva che la successione $\{D_n \cap D^{\mathsf{C}}\}_{n\in\mathbb{N}}$ è monotòna decrescente e converge a $\emptyset$. Applicando il risultato del punto precedente, si ottiene:

$$\lim_{n\to+\infty} \mathbb{P}(D_n) = \mathbb{P}(D) + \underbrace{\lim_{n\to+\infty} \mathbb{P}(D_n \cap D^{\mathsf{C}})}_{=0} = \mathbb{P}(D) = \mathbb{P}\left(\lim_{n\to+\infty} D_n\right).$$

(*iv*) Si consideri una successione di eventi $\{C_n\}_{n\in\mathbb{N}}$ monotòna crescente e convergente a C. Vale la relazione:

$$C^{\mathsf{C}} = \left(\lim_{n\to+\infty} C_n\right)^{\mathsf{C}} = \left(\bigcup_{n=1}^{+\infty} C_n\right)^{\mathsf{C}} = \bigcap_{n=1}^{+\infty} C_n^{\mathsf{C}} = \lim_{n\to+\infty} C_n^{\mathsf{C}}.$$

Per il punto precedente, si ha che:

$$1 - \mathbb{P}(C) = \mathbb{P}\left(C^{\mathsf{C}}\right) = \mathbb{P}\left(\lim_{n\to+\infty} C_n^{\mathsf{C}}\right) = \lim_{n\to+\infty} \mathbb{P}(C_n^{\mathsf{C}}) = 1 - \lim_{n\to+\infty} \mathbb{P}(C_n).$$

Si conclude che:

$$\lim_{n\to+\infty} \mathbb{P}(C_n) = \mathbb{P}(C) = \mathbb{P}\left(\lim_{n\to+\infty} C_n\right).$$

(*v*) Si consideri un'arbitraria successione di eventi $\{A_n\}_{n\in\mathbb{N}}$ convergente a un evento A. Si considerino le due successioni associate a $\{A_n\}_{n\in\mathbb{N}}$:

$$\left\{\bigcap_{i=n}^{+\infty} A_i\right\}_{n\in\mathbb{N}} \quad \text{successione crescente;}$$

$$\left\{\bigcup_{i=n}^{+\infty} A_i\right\}_{n\in\mathbb{N}} \quad \text{successione decrescente.}$$

Vale la relazione:

$$\bigcap_{i=n}^{+\infty} A_i \subseteq A_n \subseteq \bigcup_{i=n}^{+\infty} A_i \qquad \forall n \in \mathbb{N}.$$

Passando alla probabilità si ottiene:

$$\mathbb{P}\left(\bigcap_{i=n}^{+\infty} A_i\right) \leq \mathbb{P}(A_n) \leq \mathbb{P}\left(\bigcup_{i=n}^{+\infty} A_i\right).$$

Passando al limite per $n \to +\infty$ e applicando i risultati dei punti precedenti, si ottiene:

$$\lim_{n\to+\infty} \mathbb{P}\left(\bigcap_{i=n}^{+\infty} A_i\right) \leq \lim_{n\to+\infty} \mathbb{P}(A_n) \leq \lim_{n\to+\infty} \mathbb{P}\left(\bigcup_{i=n}^{+\infty} A_i\right);$$

$$\implies \underbrace{\mathbb{P}\left(\lim_{n\to+\infty} \bigcap_{i=n}^{+\infty} A_i\right)}_{=\mathbb{P}(A)} \leq \lim_{n\to+\infty} \mathbb{P}(A_n) \leq \underbrace{\mathbb{P}\left(\lim_{n\to+\infty} \bigcup_{i=n}^{+\infty} A_i\right)}_{=\mathbb{P}(A)}.$$

Si deduce necessariamente che:

$$\lim_{n\to+\infty} \mathbb{P}(A_n) = \mathbb{P}(A) = \mathbb{P}\left(\lim_{n\to+\infty} A_n\right).$$

$\boxed{\Leftarrow}$ Sia $\{A_n\}_{n\in\mathbb{N}}$ una successione di eventi a due a due disgiunti. Fissato $h \in \mathbb{N}$, per l'additività finita vale la relazione:

$$\begin{aligned}\mathbb{P}\left(\dot{\bigcup_{n=1}^{+\infty}} A_n\right) &= \mathbb{P}\left(\left(\dot{\bigcup_{n=1}^{h}} A_n\right) \dot{\cup} \left(\dot{\bigcup_{n=h+1}^{+\infty}} A_n\right)\right) \\ &= \underbrace{\mathbb{P}\left(\dot{\bigcup_{n=1}^{h}} A_n\right)}_{\sum_{n=1}^{h} \mathbb{P}(A_n)} + \mathbb{P}\left(\dot{\bigcup_{n=h+1}^{+\infty}} A_n\right).\end{aligned}$$

La successione

$$\dot{\bigcup_{n=h+1}^{+\infty}} A_n$$

è decrescente, dunque ammette limite. Per $h \to +\infty$, applicando l'ipotesi di continuità, si ottiene:

$$\begin{aligned}\mathbb{P}\left(\dot{\bigcup_{n=1}^{+\infty}} A_n\right) &= \sum_{n=1}^{+\infty} \mathbb{P}(A_n) + \lim_{h\to+\infty} \mathbb{P}\left(\dot{\bigcup_{n=h+1}^{+\infty}} A_n\right) \\ &= \sum_{n=1}^{+\infty} \mathbb{P}(A_n) + \mathbb{P}\left(\lim_{h\to+\infty} \dot{\bigcup_{n=h+1}^{+\infty}} A_n\right).\end{aligned}$$

Si supponga per assurdo che esista un esito

$$\omega \in \lim_{h\to+\infty} \dot{\bigcup_{n=h+1}^{+\infty}} A_n = \bigcap_{h=1}^{+\infty}\left(\dot{\bigcup_{n=h+1}^{+\infty}} A_n\right),$$

ossia tale che

$$\omega \in \dot{\bigcup_{n=h+1}^{+\infty}} A_n \quad \text{per ogni } h \in \mathbb{N}.$$

In particolare, per $h = 1$ si ha

$$\omega \in \dot{\bigcup_{n=2}^{+\infty}} A_n,$$

da cui segue che esiste almeno un indice $n_1 \geq 2$ tale che $\omega \in A_{n_1}$. Scegliendo ora $h = n_1$, si ha anche

$$\omega \in \dot{\bigcup_{n=n_1+1}^{+\infty}} A_n,$$

da cui si deduce che esiste almeno un indice $n_2 > n_1$ tale che $\omega \in A_{n_2}$. Dunque $\omega \in A_{n_1} \cap A_{n_2}$, il che è assurdo, poiché gli eventi sono a due a due disgiunti. Pertanto

$$\lim_{h\to+\infty} \dot{\bigcup_{n=h+1}^{+\infty}} A_n = \emptyset.$$

Resta da osservare che, per l'additività finita, $\mathbb{P}(\emptyset) = \mathbb{P}(\emptyset \cup \emptyset) = 2\,\mathbb{P}(\emptyset)$, da cui $\mathbb{P}(\emptyset) = 0$. Segue l'asserto:

$$\mathbb{P}\left(\bigcup_{n=1}^{+\infty} A_n\right) = \sum_{n=1}^{+\infty} \mathbb{P}(A_n) + \mathbb{P}(\emptyset) = \sum_{n=1}^{+\infty} \mathbb{P}(A_n).$$

□

1.9 Eventi indipendenti e probabilità condizionata

Esempio 1.10. Si consideri l'esperimento casuale del lancio di un dado a sei facce:

$$\Omega = \{1, 2, 3, 4, 5, 6\}.$$

Si consideri l'evento $\{1, 3, 5\}$, corrispondente all'uscita di un numero dispari, e la σ-algebra generata da esso:

$$\mathcal{F} = \sigma(\{1, 3, 5\}) = \{\emptyset, \Omega, \{1, 3, 5\}, \{2, 4, 6\}\}.$$

Allo spazio probabilizzabile $(\Omega, \mathcal{F})$ si può assegnare una misura di probabilità $\mathbb{P}_1$ definita come segue.

$$\begin{aligned} \mathbb{P}_1 : \mathcal{F} &\longrightarrow [0, 1] \\ \emptyset &\longmapsto 0 \\ \Omega &\longmapsto 1 \\ \{1, 3, 5\} &\longmapsto 1/2 \\ \{2, 4, 6\} &\longmapsto 1/2 \end{aligned}$$

$\mathbb{P}_1$ descrive il comportamento di un dado *non truccato* ed è detta *misura di probabilità classica*, in quanto assegna a ogni evento $A \in \mathcal{F}$ la quantità

$$\mathbb{P}_1(A) = \frac{\#A}{\#\Omega}.$$

È possibile però assegnare una misura di probabilità $\mathbb{P}_2$ diversa, definita come segue.

$$\begin{aligned} \mathbb{P}_2 : \mathcal{F} &\longrightarrow [0, 1] \\ \emptyset &\longmapsto 0 \\ \Omega &\longmapsto 1 \\ \{1, 3, 5\} &\longmapsto 0 \\ \{2, 4, 6\} &\longmapsto 1 \end{aligned}$$

$\mathbb{P}_2$ descrive il comportamento di un dado *truccato*, il quale non può mai restituire un numero dispari.

Da tale esempio si evince che, a parità di spazio probabilizzabile $(\Omega, \mathcal{F})$, è possibile definire misure di probabilità differenti che rispettino gli assiomi di Kolmogorov (Assioma 1, Assioma 2 e Assioma 3). In generale, dunque, la misura di probabilità non è univocamente determinata dallo spazio probabilizzabile.

Definizione 1.29. Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e siano $I, C \in \mathcal{F}$ due eventi tali che $I \neq \emptyset$ e $C \neq \Omega$.

(*i*) L'evento I è detto *quasi impossibile* se $\mathbb{P}(I) = 0$.

(*ii*) L'evento C è detto *quasi certo* se $\mathbb{P}(C) = 1$.

Proposizione 1.11. *Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e siano $A, I, C \in \mathcal{F}$, con I quasi impossibile e C quasi certo. Allora:*

(*i*) $\mathbb{P}(A \cap I) = 0$;

(*ii*) $\mathbb{P}(A \cup C) = 1$;

(*iii*) $\mathbb{P}(A \cup I) = \mathbb{P}(A)$;

(*iv*) $\mathbb{P}(A \cap C) = \mathbb{P}(A)$.

Dimostrazione.

(*i*) $A \cap I \subseteq I \implies 0 \leq \mathbb{P}(A \cap I) \leq \mathbb{P}(I) = 0$;

(*ii*) $C \subseteq A \cup C \implies 1 = \mathbb{P}(C) \leq \mathbb{P}(A \cup C) \leq 1$;

(*iii*) $\mathbb{P}(A \cup I) = \mathbb{P}(A) + \mathbb{P}(I) - \mathbb{P}(A \cap I) = \mathbb{P}(A) + 0 - 0 = \mathbb{P}(A)$;

(*iv*) $\mathbb{P}(A \cap C) = \mathbb{P}(A) + \mathbb{P}(C) - \mathbb{P}(A \cup C) = \mathbb{P}(A) + 1 - 1 = \mathbb{P}(A)$.

□

Definizione 1.30. Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e siano $A, B \in \mathcal{F}$ due eventi. Si dice che A e B sono *indipendenti* se vale la relazione:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B).$$

Osservazione. Mentre la definizione di *incompatibilità* di due eventi dipende intrinsecamente dalla loro struttura insiemistica, la definizione di *indipendenza* dipende invece dalla misura di probabilità $\mathbb{P}$ assegnata allo spazio probabilizzabile. In altre parole, è possibile che, a parità di spazio probabilizzabile $(\Omega, \mathcal{F})$, due eventi non siano indipendenti rispetto a una misura di probabilità $\mathbb{P}_1$ e lo siano rispetto a una misura di probabilità $\mathbb{P}_2$.

Esempio 1.11. Si consideri lo scenario dell'Esempio 1.10. Per il dado non truccato si ha:

$$\mathbb{P}_1\big(\{1,3,5\} \cap \{2,4,6\}\big) = \mathbb{P}_1(\emptyset) = 0,$$
$$\mathbb{P}_1\big(\{1,3,5\}\big) \cdot \mathbb{P}_1\big(\{2,4,6\}\big) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4} \neq 0,$$

e quindi gli eventi $\{1,3,5\}$ e $\{2,4,6\}$ non sono indipendenti rispetto a $\mathbb{P}_1$. Per il dado truccato, invece, si ha:

$$\mathbb{P}_2\big(\{1,3,5\} \cap \{2,4,6\}\big) = \mathbb{P}_2(\emptyset) = 0,$$
$$\mathbb{P}_2\big(\{1,3,5\}\big) \cdot \mathbb{P}_2\big(\{2,4,6\}\big) = 0 \cdot 1 = 0,$$

e quindi gli eventi $\{1,3,5\}$ e $\{2,4,6\}$ risultano indipendenti rispetto a $\mathbb{P}_2$.

Teorema 1.12. *Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e siano $A, B \in \mathcal{F}$ due eventi. Sono equivalenti le seguenti affermazioni:*

(*i*) *A e B sono indipendenti;*

(*ii*) *A e B^{C} sono indipendenti;*

(*iii*) *A^{C} e B sono indipendenti;*

(*iv*) *A^{C} e B^{C} sono indipendenti.*

DIMOSTRAZIONE.

(*i*) $\Longrightarrow$ (*ii*) Si consideri l'identità $A = (A \cap B) \uplus (A \cap B^{\mathsf{C}})$. Passando alla misura di probabilità si ha:

$$\mathbb{P}(A) = \mathbb{P}(A \cap B) + \mathbb{P}\big(A \cap B^{\mathsf{C}}\big).$$

Sfruttando l'ipotesi di indipendenza tra A e B, si ottiene:

$$\begin{aligned}\mathbb{P}\big(A \cap B^{\mathsf{C}}\big) &= \mathbb{P}(A) - \mathbb{P}(A \cap B) = \mathbb{P}(A) - \mathbb{P}(A)\mathbb{P}(B) \\ &= \mathbb{P}(A)\big(1 - \mathbb{P}(B)\big) = \mathbb{P}(A)\mathbb{P}\big(B^{\mathsf{C}}\big).\end{aligned}$$

(*ii*) $\Longrightarrow$ (*iii*) Dalle identità $B = (A \cap B) \uplus (A^{\mathsf{C}} \cap B)$ e $A = (A \cap B) \uplus (A \cap B^{\mathsf{C}})$, passando alla misura di probabilità si ricava:

$$\mathbb{P}\big(A^{\mathsf{C}} \cap B\big) = \mathbb{P}(B) - \mathbb{P}(A \cap B) = \mathbb{P}(B) - \mathbb{P}(A) + \mathbb{P}\big(A \cap B^{\mathsf{C}}\big).$$

Sfruttando l'ipotesi di indipendenza tra A e B^{C}, si ottiene:

$$\begin{aligned}\mathbb{P}\big(A^{\mathsf{C}} \cap B\big) &= \mathbb{P}(B) - \mathbb{P}(A) + \mathbb{P}(A)\mathbb{P}\big(B^{\mathsf{C}}\big) = \mathbb{P}(B) - \mathbb{P}(A)\big(1 - \mathbb{P}\big(B^{\mathsf{C}}\big)\big) \\ &= \mathbb{P}(B) - \mathbb{P}(A)\mathbb{P}(B) = \big(1 - \mathbb{P}(A)\big)\mathbb{P}(B) = \mathbb{P}\big(A^{\mathsf{C}}\big)\mathbb{P}(B).\end{aligned}$$

(*iii*) $\Longrightarrow$ (*iv*) Si consideri l'identità $A^{\mathsf{C}} = (A^{\mathsf{C}} \cap B) \uplus (A^{\mathsf{C}} \cap B^{\mathsf{C}})$. Passando alla misura di probabilità si ha:

$$\mathbb{P}\big(A^{\mathsf{C}}\big) = \mathbb{P}\big(A^{\mathsf{C}} \cap B\big) + \mathbb{P}\big(A^{\mathsf{C}} \cap B^{\mathsf{C}}\big).$$

Sfruttando l'ipotesi di indipendenza tra A^{C} e B, si ottiene:

$$\begin{aligned}\mathbb{P}\big(A^{\mathsf{C}} \cap B^{\mathsf{C}}\big) &= \mathbb{P}\big(A^{\mathsf{C}}\big) - \mathbb{P}\big(A^{\mathsf{C}} \cap B\big) = \mathbb{P}\big(A^{\mathsf{C}}\big) - \mathbb{P}\big(A^{\mathsf{C}}\big)\mathbb{P}(B) \\ &= \mathbb{P}\big(A^{\mathsf{C}}\big)\big(1 - \mathbb{P}(B)\big) = \mathbb{P}\big(A^{\mathsf{C}}\big)\mathbb{P}\big(B^{\mathsf{C}}\big).\end{aligned}$$

(*iv*) $\Longrightarrow$ (*i*) Dalla relazione $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$ si ottiene:

$$\begin{aligned}\mathbb{P}(A \cap B) &= \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cup B) \\ &= \mathbb{P}(A) + \mathbb{P}(B) - \Big(1 - \mathbb{P}\big((A \cup B)^{\mathsf{C}}\big)\Big) \\ &= \mathbb{P}(A) + \mathbb{P}(B) - 1 + \mathbb{P}\big((A \cup B)^{\mathsf{C}}\big).\end{aligned}$$

Applicando la prima delle relazioni di De Morgan, $(A \cup B)^{\mathsf{C}} = A^{\mathsf{C}} \cap B^{\mathsf{C}}$, e sfruttando l'ipotesi di indipendenza tra A^{C} e B^{C}, si ottiene:

$$\begin{aligned}\mathbb{P}(A \cap B) &= \mathbb{P}(A) + \mathbb{P}(B) - 1 + \mathbb{P}\big(A^{\mathsf{C}} \cap B^{\mathsf{C}}\big) \\ &= \mathbb{P}(A) + \mathbb{P}(B) - 1 + \mathbb{P}\big(A^{\mathsf{C}}\big)\mathbb{P}\big(B^{\mathsf{C}}\big) \\ &= \mathbb{P}(A) + \mathbb{P}(B) - 1 + \big(1 - \mathbb{P}(A)\big)\big(1 - \mathbb{P}(B)\big) \\ &= \mathbb{P}(A) + \mathbb{P}(B) - 1 + 1 - \mathbb{P}(A) - \mathbb{P}(B) + \mathbb{P}(A)\mathbb{P}(B) \\ &= \mathbb{P}(A)\mathbb{P}(B).\end{aligned}$$

□

Definizione 1.31. Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia $\{A_n\}_{n\in\mathbb{N}} \subseteq \mathcal{F}$ una successione di eventi. Si dice che $\{A_n\}_{n\in\mathbb{N}}$ è una successione di eventi *collettivamente indipendenti* se, per ogni $k \in \mathbb{N}$ e per ogni sottoinsieme finito di indici tutti distinti $\{n_1, n_2, \dots, n_k\} \subseteq \mathbb{N}$, vale la relazione:

$$\mathbb{P}\left(\bigcap_{i=1}^{k} A_{n_i}\right) = \prod_{i=1}^{k} \mathbb{P}(A_{n_i}).$$

Osservazione. La definizione si applica anche a una famiglia finita di eventi $A_1, \dots, A_n \in \mathcal{F}$: essi si dicono *collettivamente indipendenti* se, per ogni $k \in I_n$ e per ogni sottoinsieme di indici tutti distinti $\{i_1, \dots, i_k\} \subseteq I_n$, vale la relazione:

$$\mathbb{P}\left(\bigcap_{j=1}^{k} A_{i_j}\right) = \prod_{j=1}^{k} \mathbb{P}(A_{i_j}).$$

Ciò equivale a richiedere che la successione ottenuta ponendo $A_m := \Omega$ per ogni $m > n$ sia collettivamente indipendente nel senso della Definizione 1.31: infatti, essendo $\Omega \cap A = A$ per ogni $A \in \mathcal{F}$ e $\mathbb{P}(\Omega) = 1$, gli eventuali indici maggiori di n non alterano né il primo né il secondo membro della relazione. Per $k = 1$ la condizione è banale, mentre per $k = 2$ essa esprime l'indipendenza di ciascuna coppia A_i, A_j con $i \neq j$: eventi collettivamente indipendenti sono dunque, in particolare, *a due a due indipendenti*. Il viceversa è falso, come si vedrà nell'Esempio 1.12; non basta neppure la sola fattorizzazione sulla famiglia completa, $\mathbb{P}(A_1 \cap \cdots \cap A_n) = \mathbb{P}(A_1) \cdots \mathbb{P}(A_n)$. Le relazioni da verificare sono in tutto $2^n - n - 1$, una per ogni sottoinsieme di I_n con almeno due elementi.

Teorema 1.13. *Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia $\{A_n\}_{n\in\mathbb{N}} \subseteq \mathcal{F}$ una successione di eventi collettivamente indipendenti. Allora, comunque si scelga una successione $\{B_n\}_{n\in\mathbb{N}} \subseteq \mathcal{F}$ tale che $B_n \in \{A_n, A_n^c\}$ per ogni $n \in \mathbb{N}$, anche $\{B_n\}_{n\in\mathbb{N}}$ è una successione di eventi collettivamente indipendenti.*

Dimostrazione. Omessa. □

Lemma di Borel–Cantelli 1.14. *Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia $\{A_n\}_{n\in\mathbb{N}} \subseteq \mathcal{F}$ una successione di eventi. Se vale la relazione*

$$\sum_{n=1}^{+\infty} \mathbb{P}(A_n) < +\infty,$$

allora si ha che

$$\mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) = 0.$$

Dimostrazione. Per definizione di limite superiore, si ha che

$$\limsup_{n\to+\infty} A_n = \bigcap_{n=1}^{+\infty} \bigcup_{k=n}^{+\infty} A_k = \lim_{n\to+\infty} \bigcup_{k=n}^{+\infty} A_k.$$

Passando alla probabilità, applicando la *continuità della misura di probabilità* e successivamente la Disuguaglianza di Boole (Proposizione 1.4) all'unione, si ottiene:

$$\mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) = \mathbb{P}\left(\lim_{n\to+\infty} \bigcup_{k=n}^{+\infty} A_k\right) = \lim_{n\to+\infty} \mathbb{P}\left(\bigcup_{k=n}^{+\infty} A_k\right)$$
$$\leq \lim_{n\to+\infty} \sum_{k=n}^{+\infty} \mathbb{P}(A_k). \tag{1.5}$$

La (1.5) è il limite, per $n \to +\infty$, del resto n-esimo di una serie convergente, il quale è nullo; dunque:

$$\mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) \leq 0.$$

Poiché d'altra parte

$$\mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) \geq 0,$$

per l'Assioma 2, si conclude che

$$\mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) = 0. \qquad \square$$

Il risultato appena provato, che vale per una generica successione di eventi senza richiedere alcuna ipotesi di indipendenza, costituisce la prima parte del teorema esposto di seguito.

Teorema 1.15 (Legge 0-1). *Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia $\{A_n\}_{n\in\mathbb{N}} \subseteq \mathcal{F}$ una successione di eventi collettivamente indipendenti. Allora:*

(*i*) *la serie delle probabilità degli eventi è convergente se e solo se il limite superiore della successione ha probabilità nulla:*

$$\sum_{n=1}^{+\infty} \mathbb{P}(A_n) < +\infty \iff \mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) = 0;$$

(*ii*) *la serie delle probabilità degli eventi è divergente se e solo se il limite superiore della successione ha probabilità* 1*:*

$$\sum_{n=1}^{+\infty} \mathbb{P}(A_n) = +\infty \iff \mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) = 1.$$

Dimostrazione.

(*i*) $\boxed{\Rightarrow}$ Lemma di Borel–Cantelli 1.14.

(*ii*) $\boxed{\Rightarrow}$ Usando la definizione di limite superiore, passando alla probabilità e applicando la *continuità della misura di probabilità*, si ottiene:

$$\mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) = \mathbb{P}\left(\lim_{n\to+\infty} \bigcup_{k=n}^{+\infty} A_k\right) = \lim_{n\to+\infty} \mathbb{P}\left(\bigcup_{k=n}^{+\infty} A_k\right)$$
$$= \lim_{n\to+\infty} \mathbb{P}\left(\left(\bigcap_{k=n}^{+\infty} A_k^{\mathsf{C}}\right)^{\mathsf{C}}\right) = \lim_{n\to+\infty} \left(1 - \mathbb{P}\left(\bigcap_{k=n}^{+\infty} A_k^{\mathsf{C}}\right)\right).$$

Per il TEOREMA 1.13 gli eventi A_k^{C} sono collettivamente indipendenti; si sviluppi quindi nel seguente modo la probabilità della loro intersezione:

$$\mathbb{P}\left(\bigcap_{k=n}^{+\infty} A_k^{\mathsf{C}}\right) = \lim_{r\to+\infty} \mathbb{P}\left(\bigcap_{k=n}^{r} A_k^{\mathsf{C}}\right) = \lim_{r\to+\infty} \prod_{k=n}^{r} \mathbb{P}\left(A_k^{\mathsf{C}}\right)$$

$$= \lim_{r\to+\infty} \prod_{k=n}^{r} \big(1 - \mathbb{P}(A_k)\big).$$

Sfruttando la nota disuguaglianza $1 - x \leq \mathrm{e}^{-x}$, valida per ogni $x \in [0, 1]$, si ottiene:

$$\mathbb{P}\left(\bigcap_{k=n}^{+\infty} A_k^{\mathsf{C}}\right) \leq \lim_{r\to+\infty} \prod_{k=n}^{r} \exp\big(-\mathbb{P}(A_k)\big) = \lim_{r\to+\infty} \exp\left(-\sum_{k=n}^{r} \mathbb{P}(A_k)\right)$$

$$= \exp\left(-\sum_{k=n}^{+\infty} \mathbb{P}(A_k)\right).$$

Da ciò segue che:

$$\mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) \geq 1 - \lim_{n\to+\infty} \exp\left(-\sum_{k=n}^{+\infty} \mathbb{P}(A_k)\right)$$

$$= 1 - \exp\left(-\lim_{n\to+\infty} \sum_{k=n}^{+\infty} \mathbb{P}(A_k)\right),$$

dove, essendo la serie

$$\sum_{k=1}^{+\infty} \mathbb{P}(A_k) = +\infty,$$

ogni suo resto n-esimo vale $+\infty$, e dunque l'esponenziale è nullo. Si conclude che:

$$\mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) \geq 1 - 0 = 1 \implies \mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) = 1.$$

(i) $\boxed{\Leftarrow}$ Supposto per assurdo che

$$\sum_{n=1}^{+\infty} \mathbb{P}(A_n) = +\infty,$$

per l'implicazione (ii)$\Rightarrow$ si avrebbe che

$$\mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) = 1,$$

il che è assurdo.

(ii) $\boxed{\Leftarrow}$ Supposto per assurdo che

$$\sum_{n=1}^{+\infty} \mathbb{P}(A_n) < +\infty,$$

per l'implicazione $(i)\Rightarrow$ si avrebbe che

$$\mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) = 0,$$

il che è assurdo.

□

Esempio 1.12. Sia dato lo spazio campione

$$\Omega = \{\omega_1, \omega_2, \omega_3, \omega_4\},$$

si prenda la σ-algebra $\mathcal{F} = \mathcal{P}(\Omega)$ e si definisca la misura di probabilità $\mathbb{P}$ come segue.

$$\begin{aligned}
\mathbb{P} : \mathcal{F} &\longrightarrow [0,1] \\
\emptyset &\longmapsto 0 \\
\Omega &\longmapsto 1 \\
\{\omega_i\} &\longmapsto 1/4 \quad \forall i \in I_4 \\
\{\omega_i, \omega_j\} &\longmapsto 1/2 \quad \forall i, j \in I_4,\ i \neq j \\
\Omega \setminus \{\omega_i\} &\longmapsto 3/4 \quad \forall i \in I_4
\end{aligned}$$

Siano definiti gli eventi

$$A = \{\omega_1, \omega_2\}, \quad B = \{\omega_1, \omega_3\}, \quad C = \{\omega_1, \omega_4\}.$$

Si ha che

$$\mathbb{P}(A) = \mathbb{P}(B) = \mathbb{P}(C) = \frac{1}{2}.$$

Risulta immediato verificare che

$$\mathbb{P}(A \cap B) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A)\mathbb{P}(B),$$

e analogamente

$$\mathbb{P}(A \cap C) = \frac{1}{4} = \mathbb{P}(A)\mathbb{P}(C), \quad \mathbb{P}(B \cap C) = \frac{1}{4} = \mathbb{P}(B)\mathbb{P}(C).$$

Tuttavia, si ha che

$$\mathbb{P}(A \cap B \cap C) = \frac{1}{4} \neq \frac{1}{8} = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C).$$

Si deduce che, per la misura di probabilità sopra definita, gli eventi A, B e C sono a due a due indipendenti, ma non sono collettivamente indipendenti poiché non soddisfano la Definizione 1.31.

Definizione 1.32. Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia $B \in \mathcal{F}$ un evento tale che $\mathbb{P}(B) > 0$. Si definisce *misura di probabilità condizionata* rispetto all'evento B la funzione d'insieme

$$\mathbb{P}(\cdot \mid B) : \mathcal{F} \longrightarrow [0,1]$$

che associa a ogni evento $A \in \mathcal{F}$ la quantità

$$\mathbb{P}(A \mid B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

La quantità $\mathbb{P}(A \mid B)$ prende il nome di *probabilità condizionata* dell'evento A dato l'evento B.

Notazione 1.33. Fissato un evento $B \in \mathcal{F}$ con $\mathbb{P}(B) > 0$, la probabilità condizionata si indica anche con

$$\mathbb{P}_B(A) := \mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \qquad \forall A \in \mathcal{F}.$$

Teorema 1.16. *Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia $B \in \mathcal{F}$ un evento tale che $\mathbb{P}(B) > 0$. Allora la funzione d'insieme $\mathbb{P}_B : \mathcal{F} \to \mathbb{R}$ è una misura di probabilità sullo spazio probabilizzabile $(\Omega, \mathcal{F})$.*

Dimostrazione. Si verifica che $\mathbb{P}_B$ soddisfa gli assiomi di Kolmogorov.

(*i*) Essendo $B \cap \Omega = B$, si ha:

$$\mathbb{P}_B(\Omega) = \frac{\mathbb{P}(\Omega \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B)}{\mathbb{P}(B)} = 1.$$

(*ii*) Per ogni $A \in \mathcal{F}$, per l'Assioma 2 applicato all'evento $A \cap B$ e poiché $\mathbb{P}(B) > 0$, si ha:

$$\mathbb{P}_B(A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \geq 0.$$

(*iii*) Sia $\{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{F}$ una successione di eventi a due a due disgiunti, ovvero tali che $A_i \cap A_j = \emptyset$ per ogni $i \neq j$. Per la proprietà distributiva dell'intersezione rispetto all'unione si ha

$$\left(\dot{\bigcup_{n=1}^{+\infty}} A_n \right) \cap B = \dot{\bigcup_{n=1}^{+\infty}} (A_n \cap B),$$

dove gli eventi $A_n \cap B \subseteq A_n$ sono ancora a due a due disgiunti. Applicando l'Assioma 3 alla misura $\mathbb{P}$, si ottiene:

$$\mathbb{P}_B\left(\dot{\bigcup_{n=1}^{+\infty}} A_n \right) = \frac{\mathbb{P}\left(\dot{\bigcup}_{n=1}^{+\infty} (A_n \cap B) \right)}{\mathbb{P}(B)} = \sum_{n=1}^{+\infty} \frac{\mathbb{P}(A_n \cap B)}{\mathbb{P}(B)} = \sum_{n=1}^{+\infty} \mathbb{P}_B(A_n). \qquad \square$$

Osservazione. In virtù del teorema appena dimostrato, $(\Omega, \mathcal{F}, \mathbb{P}_B)$ è a sua volta uno spazio di probabilità, e per $\mathbb{P}_B$ valgono tutte le proprietà già dimostrate per una generica misura di probabilità. Ad esempio, $\mathbb{P}_B(A^C) = 1 - \mathbb{P}_B(A)$ per ogni $A \in \mathcal{F}$.

Essendo $\mathbb{P}_B$ una misura di probabilità, è possibile condizionarla a sua volta rispetto a un secondo evento.

Proposizione 1.17 (Probabilità condizionata ricorsiva). *Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e siano $B, C \in \mathcal{F}$ due eventi tali che $\mathbb{P}(B \cap C) > 0$. Allora $\mathbb{P}(B) > 0$, $\mathbb{P}_B(C) > 0$ e, per ogni $A \in \mathcal{F}$, si ha:*

$$\left(\mathbb{P}_B\right)_C(A) = \mathbb{P}_{B \cap C}(A) = \mathbb{P}(A \mid B \cap C).$$

Dimostrazione. Poiché $B \cap C \subseteq B$, per la monotonia della misura di probabilità (proprietà (*v*)) si ha $\mathbb{P}(B) \geq \mathbb{P}(B \cap C) > 0$, e dunque $\mathbb{P}_B$ è ben definita; inoltre

$$\mathbb{P}_B(C) = \frac{\mathbb{P}(C \cap B)}{\mathbb{P}(B)} > 0,$$

e quindi anche la misura $\left(\mathbb{P}_B\right)_C$ è ben definita. Per ogni $A \in \mathcal{F}$ si ottiene allora:

$$\left(\mathbb{P}_B\right)_C(A) = \frac{\mathbb{P}_B(A \cap C)}{\mathbb{P}_B(C)} = \frac{\mathbb{P}(A \cap B \cap C)}{\mathbb{P}(B)} \cdot \frac{\mathbb{P}(B)}{\mathbb{P}(B \cap C)} = \frac{\mathbb{P}(A \cap B \cap C)}{\mathbb{P}(B \cap C)} = \mathbb{P}_{B \cap C}(A).$$

$\square$

Osservazione. Condizionare prima rispetto all'evento B e poi rispetto all'evento C equivale dunque a condizionare, in un solo passo, rispetto all'evento $B \cap C$. Si noti che l'unica ipotesi necessaria è $\mathbb{P}(B \cap C) > 0$, la quale implica sia $\mathbb{P}(B) > 0$ sia $\mathbb{P}(C) > 0$.

Teorema 1.18 (Caratterizzazione dell'indipendenza). *Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e siano $A, B \in \mathcal{F}$ due eventi tali che $\mathbb{P}(A) > 0$ e $\mathbb{P}(B) > 0$. Sono equivalenti le seguenti affermazioni:*

(i) A e B sono indipendenti, cioè $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$;
(ii) $\mathbb{P}(A \mid B) = \mathbb{P}(A)$;
(iii) $\mathbb{P}(B \mid A) = \mathbb{P}(B)$.

Dimostrazione.

(i) $\Longrightarrow$ *(ii)* Sfruttando l'ipotesi di indipendenza tra A e B, si ottiene:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A)\mathbb{P}(B)}{\mathbb{P}(B)} = \mathbb{P}(A).$$

(ii) $\Longrightarrow$ *(iii)* Moltiplicando e dividendo per $\mathbb{P}(B)$ e sfruttando l'ipotesi, si ottiene:

$$\begin{aligned}\mathbb{P}(B \mid A) &= \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \cdot \frac{\mathbb{P}(B)}{\mathbb{P}(A)} \\ &= \frac{\mathbb{P}(A \mid B)\mathbb{P}(B)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A)\mathbb{P}(B)}{\mathbb{P}(A)} = \mathbb{P}(B).\end{aligned}$$

(iii) $\Longrightarrow$ *(i)* Dalla definizione di probabilità condizionata e dall'ipotesi si ricava:

$$\mathbb{P}(B \mid A) = \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)} \implies \mathbb{P}(A \cap B) = \mathbb{P}(B \mid A)\mathbb{P}(A) = \mathbb{P}(B)\mathbb{P}(A). \qquad \square$$

Osservazione. Dal punto di vista intuitivo, due eventi di probabilità positiva sono indipendenti se e solo se l'informazione che uno di essi si è verificato non modifica la probabilità dell'altro.

Teorema delle probabilità composte 1.19. *Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità, sia $n \in \mathbb{N}$ con $n \geq 2$ e siano $A_1, A_2, \ldots, A_n \in \mathcal{F}$ eventi tali che*

$$\mathbb{P}\left(\bigcap_{i=1}^{n} A_i\right) > 0.$$

Allora si ha:

$$\begin{aligned}\mathbb{P}\left(\bigcap_{i=1}^{n} A_i\right) &= \mathbb{P}(A_1)\,\mathbb{P}(A_2 \mid A_1)\,\mathbb{P}(A_3 \mid A_1 \cap A_2) \cdots \mathbb{P}(A_n \mid A_1 \cap \cdots \cap A_{n-1}) \\ &= \mathbb{P}(A_1) \prod_{i=2}^{n} \mathbb{P}\left(A_i \,\middle|\, \bigcap_{j=1}^{i-1} A_j\right).\end{aligned}$$

DIMOSTRAZIONE. Si osservi preliminarmente che tutte le probabilità condizionate che compaiono nella tesi sono ben definite: per ogni $k \in I_n$ si ha infatti

$$\bigcap_{j=1}^{n} A_j \subseteq \bigcap_{j=1}^{k} A_j \implies \mathbb{P}\left(\bigcap_{j=1}^{k} A_j\right) \geq \mathbb{P}\left(\bigcap_{j=1}^{n} A_j\right) > 0,$$

per la monotonia della misura di probabilità (proprietà (*v*)). La dimostrazione procede per induzione su n.

(Base d'induzione) Sia $n = 2$. Dalla definizione di probabilità condizionata, essendo $\mathbb{P}(A_1) > 0$ e $\mathbb{P}(A_2) > 0$, si ha:

$$\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1)\,\mathbb{P}(A_2 \mid A_1) = \mathbb{P}(A_2)\,\mathbb{P}(A_1 \mid A_2).$$

(Passo induttivo) Si supponga che l'asserto sia valido per un certo $n \geq 2$ e siano $A_1, \ldots, A_{n+1} \in \mathcal{F}$ eventi tali che $\mathbb{P}(A_1 \cap \cdots \cap A_{n+1}) > 0$. Per l'osservazione preliminare si ha anche $\mathbb{P}(A_1 \cap \cdots \cap A_n) > 0$, e dunque l'ipotesi induttiva è applicabile agli eventi $A_1, \ldots, A_n$. Applicando il caso $n = 2$ agli eventi $A_1 \cap \cdots \cap A_n$ e A_{n+1} e, successivamente, l'ipotesi induttiva, si ottiene:

$$\begin{aligned}
\mathbb{P}\left(\bigcap_{i=1}^{n+1} A_i\right) &= \mathbb{P}\left(\bigcap_{i=1}^{n} A_i\right) \mathbb{P}\left(A_{n+1} \,\middle|\, \bigcap_{j=1}^{n} A_j\right) \\
&= \mathbb{P}(A_1) \prod_{i=2}^{n} \mathbb{P}\left(A_i \,\middle|\, \bigcap_{j=1}^{i-1} A_j\right) \cdot \mathbb{P}\left(A_{n+1} \,\middle|\, \bigcap_{j=1}^{n} A_j\right) \\
&= \mathbb{P}(A_1) \prod_{i=2}^{n+1} \mathbb{P}\left(A_i \,\middle|\, \bigcap_{j=1}^{i-1} A_j\right).
\end{aligned}$$

La tesi è dunque dimostrata.

□

Osservazione. Poiché l'intersezione è commutativa, il teorema si può applicare agli eventi presi in un ordine qualsiasi. Ad esempio, considerandoli nell'ordine $A_n, A_{n-1}, \ldots, A_1$, si ottiene la formula equivalente:

$$\mathbb{P}\left(\bigcap_{i=1}^{n} A_i\right) = \mathbb{P}(A_n)\,\mathbb{P}(A_{n-1} \mid A_n)\,\mathbb{P}(A_{n-2} \mid A_n \cap A_{n-1}) \cdots \mathbb{P}(A_1 \mid A_n \cap A_{n-1} \cap \cdots \cap A_2).$$

DEFINIZIONE 1.34. Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia $J \subseteq \mathbb{N}$ un insieme di indici non vuoto (finito o numerabile). Una famiglia di eventi $\{H_i\}_{i \in J} \subseteq \mathcal{F}$ si dice *insieme completo di alternative* se:

(*i*) $H_i \cap H_j = \emptyset$ per ogni $i, j \in J$ con $i \neq j$;

(*ii*) la loro unione è l'evento certo:

$$\bigcup_{i \in J}^{\cdot} H_i = \Omega;$$

(*iii*) $\mathbb{P}(H_i) > 0$ per ogni $i \in J$.

Osservazione. Un insieme completo di alternative è dunque una partizione al più numerabile dello spazio campione Ω in eventi di probabilità positiva: in ogni realizzazione dell'esperimento aleatorio si verifica uno e un solo evento H_i.

Teorema delle alternative 1.20. *Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia $\{H_i\}_{i\in J}$ un insieme completo di alternative. Allora, per ogni evento $A \in \mathcal{F}$, si ha:*

$$\mathbb{P}(A) = \sum_{i\in J} \mathbb{P}(A \mid H_i)\, \mathbb{P}(H_i).$$

Dimostrazione. Per la proprietà distributiva dell'intersezione rispetto all'unione si ha

$$A = A \cap \Omega = A \cap \left(\dot{\bigcup_{i\in J}} H_i \right) = \dot{\bigcup_{i\in J}} (A \cap H_i),$$

dove gli eventi $A \cap H_i \subseteq H_i$ sono a due a due disgiunti. Applicando l'Assioma 3 (o la proprietà (*ii*), se J è finito) e la definizione di probabilità condizionata, ben posta poiché $\mathbb{P}(H_i) > 0$ per ogni $i \in J$, si ottiene:

$$\mathbb{P}(A) = \mathbb{P}\left(\dot{\bigcup_{i\in J}} (A \cap H_i) \right) = \sum_{i\in J} \mathbb{P}(A \cap H_i) = \sum_{i\in J} \mathbb{P}(A \mid H_i)\, \mathbb{P}(H_i). \qquad \square$$

Teorema di Bayes 1.21. *Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità, sia $\{H_i\}_{i\in J}$ un insieme completo di alternative e sia $A \in \mathcal{F}$ un evento tale che $\mathbb{P}(A) > 0$. Allora, per ogni $j \in J$, si ha:*

$$\mathbb{P}(H_j \mid A) = \frac{\mathbb{P}(A \mid H_j)\, \mathbb{P}(H_j)}{\displaystyle\sum_{i\in J} \mathbb{P}(A \mid H_i)\, \mathbb{P}(H_i)}.$$

Dimostrazione. Dalla definizione di probabilità condizionata, ben posta essendo $\mathbb{P}(A) > 0$ e $\mathbb{P}(H_j) > 0$, si ha $\mathbb{P}(H_j \cap A) = \mathbb{P}(A \mid H_j)\, \mathbb{P}(H_j)$. Esprimendo il denominatore mediante il Teorema delle alternative 1.20, si ottiene:

$$\mathbb{P}(H_j \mid A) = \frac{\mathbb{P}(H_j \cap A)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \mid H_j)\, \mathbb{P}(H_j)}{\displaystyle\sum_{i\in J} \mathbb{P}(A \mid H_i)\, \mathbb{P}(H_i)}. \qquad \square$$

Osservazione. Interpretando gli eventi H_i come le possibili *cause* (o *ipotesi*) e l'evento A come un *effetto* osservato, il Teorema di Bayes consente di calcolare, una volta verificatosi l'evento A, la probabilità che esso sia stato causato da H_j. In questo contesto:

(*i*) $\mathbb{P}(H_j)$ prende il nome di probabilità *a priori* dell'evento H_j;

(*ii*) $\mathbb{P}(H_j \mid A)$ prende il nome di probabilità *a posteriori* dell'evento H_j, dato il verificarsi dell'evento A.

La nozione di insieme completo di alternative si estende in modo naturale al caso in cui la partizione riguardi un evento H diverso dallo spazio campione.

Definizione 1.35. Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità, sia $H \in \mathcal{F}$ un evento e sia $J \subseteq \mathbb{N}$ un insieme di indici non vuoto (finito o numerabile). Una famiglia di eventi $\{H_i\}_{i\in J} \subseteq \mathcal{F}$ si dice *insieme completo di alternative per H* se:

(*i*) $H_i \cap H_j = \emptyset$ per ogni $i, j \in J$ con $i \neq j$;
(*ii*) $\mathbb{P}(H_i) > 0$ per ogni $i \in J$;
(*iii*) la loro unione è l'evento H:

$$\bigcupdot_{i \in J} H_i = H.$$

Osservazione. Per $H = \Omega$ si ritrova la Definizione 1.34. Si osservi inoltre che, essendo $H_i \subseteq H$, si ha necessariamente $\mathbb{P}(H) \geq \mathbb{P}(H_i) > 0$, e dunque le probabilità condizionate rispetto a H sono sempre ben definite.

Proposizione 1.22 (Legge delle alternative relativa a un evento). *Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità, sia $H \in \mathcal{F}$ e sia $\{H_i\}_{i \in J}$ un insieme completo di alternative per H. Allora, per ogni evento $A \in \mathcal{F}$, si ha:*

$$\mathbb{P}(A \mid H) = \sum_{i \in J} \mathbb{P}(A \mid H_i)\, \mathbb{P}(H_i \mid H).$$

Dimostrazione. Procedendo come nella dimostrazione del Teorema delle alternative 1.20, si ha

$$A \cap H = A \cap \left(\bigcupdot_{i \in J} H_i \right) = \bigcupdot_{i \in J} (A \cap H_i),$$

con eventi $A \cap H_i$ a due a due disgiunti. Moltiplicando e dividendo ciascun addendo per $\mathbb{P}(H_i) > 0$ e osservando che $H_i \cap H = H_i$, poiché $H_i \subseteq H$, si ottiene:

$$\begin{aligned} \mathbb{P}(A \mid H) &= \frac{\mathbb{P}(A \cap H)}{\mathbb{P}(H)} = \frac{1}{\mathbb{P}(H)}\, \mathbb{P}\left(\bigcupdot_{i \in J} (A \cap H_i) \right) = \sum_{i \in J} \frac{\mathbb{P}(A \cap H_i)}{\mathbb{P}(H)} \\ &= \sum_{i \in J} \frac{\mathbb{P}(A \cap H_i)}{\mathbb{P}(H_i)} \cdot \frac{\mathbb{P}(H_i \cap H)}{\mathbb{P}(H)} = \sum_{i \in J} \mathbb{P}(A \mid H_i)\, \mathbb{P}(H_i \mid H). \end{aligned}$$

□

Osservazione. Per $H = \Omega$, essendo $\mathbb{P}(A \mid \Omega) = \mathbb{P}(A)$ e $\mathbb{P}(H_i \mid \Omega) = \mathbb{P}(H_i)$, si ritrova il Teorema delle alternative 1.20.

Esempio 1.13 (Dilemma di Monty Hall)**.** Un concorrente di un gioco a premi si trova di fronte a tre porte chiuse, numerate da 1 a 3: dietro una di esse si trova un'automobile, mentre dietro ciascuna delle altre due si trova una capra. Il concorrente sceglie una porta, ad esempio la porta 3. Il presentatore, che sa dove si trova l'automobile, apre una delle due porte non scelte dal concorrente, mostrando sempre una capra; se entrambe le porte non scelte nascondono una capra, ne apre una a caso. Supponendo che il presentatore apra la porta 1, conviene al concorrente cambiare la propria scelta e passare alla porta 2?

Per ogni $i \in I_3$ si definisca l'evento

$$H_i := \{\text{l'automobile si trova dietro la porta } i\text{-esima}\}.$$

In assenza di ulteriori informazioni si ha $\mathbb{P}(H_i) = 1/3$ per ogni $i \in I_3$, e $\{H_i\}_{i \in I_3}$ è un insieme completo di alternative. Si consideri ora l'evento

$$A := \{\text{il presentatore apre la porta 1, mostrando una capra}\}.$$

Dalle regole del gioco si deducono le seguenti probabilità condizionate:
(*i*) $\mathbb{P}(A \mid H_1) = 0$, poiché il presentatore non apre mai la porta che nasconde l'automobile;

(*ii*) $\mathbb{P}(A \mid H_2) = 1$, poiché il presentatore non può aprire né la porta 3, scelta dal concorrente, né la porta 2, che nasconde l'automobile;
(*iii*) $\mathbb{P}(A \mid H_3) = 1/2$, poiché entrambe le porte 1 e 2 nascondono una capra e il presentatore ne sceglie una a caso.

Applicando il Teorema di Bayes 1.21, si ottiene:

$$\begin{aligned}\mathbb{P}(H_2 \mid A) &= \frac{\mathbb{P}(A \mid H_2)\,\mathbb{P}(H_2)}{\mathbb{P}(A \mid H_1)\,\mathbb{P}(H_1) + \mathbb{P}(A \mid H_2)\,\mathbb{P}(H_2) + \mathbb{P}(A \mid H_3)\,\mathbb{P}(H_3)} \\ &= \frac{1 \cdot \frac{1}{3}}{0 \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} + \frac{1}{2} \cdot \frac{1}{3}} = \frac{1}{0 + 1 + \frac{1}{2}} = \frac{2}{3},\end{aligned}$$

e analogamente

$$\mathbb{P}(H_3 \mid A) = \frac{1/2}{3/2} = \frac{1}{3},$$

mentre $\mathbb{P}(H_1 \mid A) = 0$. Al concorrente conviene dunque cambiare porta: così facendo raddoppia la propria probabilità di vincere l'automobile.

Più in generale, si supponga che il presentatore, nel caso in cui l'automobile si trovi dietro la porta 3 scelta dal concorrente, apra la porta 1 con probabilità $p \in [0, 1]$ (non necessariamente pari a $1/2$), cioè $\mathbb{P}(A \mid H_3) = p$. Procedendo allo stesso modo si ottiene:

$$\begin{aligned}\mathbb{P}(H_2 \mid A) &= \frac{1}{0 + 1 + p} = \frac{1}{1 + p} \geq \frac{1}{2}, \\ \mathbb{P}(H_3 \mid A) &= \frac{p}{0 + 1 + p} = \frac{p}{1 + p} \leq \frac{1}{2},\end{aligned}$$

con uguaglianza se e solo se $p = 1$. Cambiare porta, dunque, non è mai svantaggioso.

Esempio 1.14. Si considerino due urne: la prima contiene 20 palline bianche e 10 palline nere, la seconda contiene 10 palline bianche, 3 palline nere e 4 palline rosse. Si sceglie a caso una delle due urne e da essa si estrae una pallina, che risulta essere nera. Si calcoli la probabilità che sia stata scelta la seconda urna.

Si definiscano gli eventi

$$A := \{\text{viene estratta una pallina nera}\}$$

e, per ogni $i \in I_2$,

$$H_i := \{\text{viene scelta l'urna } i\text{-esima}\}.$$

Si ha $\mathbb{P}(H_i) = 1/2$ per ogni $i \in I_2$, e $\{H_i\}_{i \in I_2}$ è un insieme completo di alternative. Inoltre, contando le palline nere presenti in ciascuna urna:

$$\mathbb{P}(A \mid H_1) = \frac{10}{30} = \frac{1}{3}, \qquad \mathbb{P}(A \mid H_2) = \frac{3}{17}.$$

Applicando il Teorema di Bayes 1.21 e semplificando il fattore comune $\mathbb{P}(H_1) = \mathbb{P}(H_2) = 1/2$, si ottiene:

$$\mathbb{P}(H_2 \mid A) = \frac{\mathbb{P}(A \mid H_2)}{\mathbb{P}(A \mid H_1) + \mathbb{P}(A \mid H_2)} = \frac{\frac{3}{17}}{\frac{1}{3} + \frac{3}{17}} = \frac{\frac{3}{17}}{\frac{26}{51}} = \frac{3}{17} \cdot \frac{51}{26} = \frac{9}{26},$$

e quindi $\mathbb{P}(H_1 \mid A) = 1 - \mathbb{P}(H_2 \mid A) = 17/26$.

Esempio 1.15. Un'urna contiene 10 palline, ciascuna delle quali è bianca oppure nera, in una composizione incognita. Per ogni $i \in \{0, 1, \dots, 10\}$ si definisca l'evento

$$H_i := \{\text{nell'urna ci sono } i \text{ palline bianche}\},$$

e si supponga che $\mathbb{P}(H_i) = i/55$ (assegnazione ammissibile, poiché $0 + 1 + \cdots + 10 = 55$). Si effettuano 9 estrazioni senza reimmissione e si ottengono 9 palline nere, ovvero si verifica l'evento

$$A := \{\text{le 9 palline estratte senza reimmissione sono tutte nere}\}.$$

Si calcoli la probabilità $\mathbb{P}(H_1 \mid A)$.

Si osservi innanzitutto che la famiglia $\{H_i\}_{i=0}^{10}$ non è un insieme completo di alternative, poiché $\mathbb{P}(H_0) = 0$; tuttavia i suoi eventi sono a due a due disgiunti e la loro unione è Ω, per cui

$$A = \dot{\bigcup_{i=0}^{10}} (A \cap H_i).$$

Si analizzano i singoli termini:

(*i*) se $i \geq 2$, nell'urna ci sono al più 8 palline nere ed è impossibile estrarne 9, quindi $A \cap H_i = \emptyset$;

(*ii*) essendo $A \cap H_0 \subseteq H_0$, si ha $0 \leq \mathbb{P}(A \cap H_0) \leq \mathbb{P}(H_0) = 0$;

(*iii*) se $i = 1$, le 9 estrazioni devono lasciare nell'urna l'unica pallina bianca, e quindi

$$\mathbb{P}(A \mid H_1) = \frac{9}{10} \cdot \frac{8}{9} \cdot \frac{7}{8} \cdots \frac{1}{2} = \frac{1}{10}.$$

Si ottiene dunque:

$$\mathbb{P}(A) = \sum_{i=0}^{10} \mathbb{P}(A \cap H_i) = \mathbb{P}(A \cap H_1) = \mathbb{P}(A \mid H_1)\, \mathbb{P}(H_1) = \frac{1}{10} \cdot \frac{1}{55} = \frac{1}{550} > 0,$$

e infine:

$$\mathbb{P}(H_1 \mid A) = \frac{\mathbb{P}(A \cap H_1)}{\mathbb{P}(A)} = 1.$$

Il risultato si poteva prevedere senza alcun calcolo: una volta osservato l'evento A, le sole ipotesi compatibili sono H_0 e H_1, e poiché l'ipotesi H_0 ha probabilità a priori nulla, l'ipotesi H_1 diventa certa a posteriori.

1.10 Variabili aleatorie e distribuzioni di probabilità

1.10.1 Variabili aleatorie e loro legge

Definizione 1.36. Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità. Si chiama *variabile aleatoria* (o *variabile casuale*) una funzione $X : \Omega \to \mathbb{R}$ che sia $\mathcal{F}$*-misurabile*, ovvero tale che:

$$X^{-1}(B) = \{\omega \in \Omega \mid X(\omega) \in B\} \in \mathcal{F} \qquad \forall B \in \mathcal{B},$$

dove $\mathcal{B}$ è la σ-algebra di Borel su $\mathbb{R}$.

Osservazione. La misurabilità di X dipende soltanto dalla σ-algebra $\mathcal{F}$ e non dalla misura di probabilità $\mathbb{P}$: una stessa funzione $X : \Omega \to \mathbb{R}$ può essere una variabile aleatoria rispetto a una σ-algebra e non esserlo rispetto a un'altra. Se in particolare $\mathcal{F} = \mathcal{P}(\Omega)$, ogni funzione $X : \Omega \to \mathbb{R}$ è una variabile aleatoria.

Esempio 1.16. Si consideri lo spazio campione relativo al lancio di un dado a sei facce, $\Omega = I_6$, munito della σ-algebra generata dall'evento $\{1\}$:

$$\mathcal{F} = \sigma\big(\{1\}\big) = \big\{\emptyset,\ \Omega,\ \{1\},\ \{2,3,4,5,6\}\big\}.$$

(i) La funzione identità

$$\begin{aligned} X : \Omega &\longrightarrow \mathbb{R} \\ i &\longmapsto i \end{aligned}$$

non è una variabile aleatoria. Infatti, considerato il boreliano $B = [3.5, 8] \in \mathcal{B}$, si ha:

$$X^{-1}(B) = \{4,5,6\} \notin \mathcal{F}.$$

(ii) La funzione

$$Y : \Omega \longrightarrow \mathbb{R}, \qquad Y(i) = \begin{cases} 100 & \text{se } i = 1 \\ 27 & \text{se } i \in \{2,3,4,5,6\} \end{cases}$$

è una variabile aleatoria. Infatti, per ogni $B \in \mathcal{B}$, la controimmagine $Y^{-1}(B)$ dipende soltanto da quali dei due valori 100 e 27 appartengono a B:

$$Y^{-1}(B) = \begin{cases} \emptyset & \text{se } 100 \notin B,\ 27 \notin B \\ \{1\} & \text{se } 100 \in B,\ 27 \notin B \\ \{2,3,4,5,6\} & \text{se } 100 \notin B,\ 27 \in B \\ \Omega & \text{se } 100 \in B,\ 27 \in B \end{cases}$$

e in ogni caso $Y^{-1}(B) \in \mathcal{F}$.

(iii) Se invece si munisce Ω della σ-algebra

$$\mathcal{F}' = \sigma\big(\{1,2\}\big) = \big\{\emptyset,\ \Omega,\ \{1,2\},\ \{3,4,5,6\}\big\},$$

la funzione Y non è più una variabile aleatoria, poiché $Y^{-1}\big(\{100\}\big) = \{1\} \notin \mathcal{F}'$, mentre è una variabile aleatoria rispetto a $\mathcal{F}'$ la funzione

$$Z : \Omega \longrightarrow \mathbb{R}, \qquad Z(i) = \begin{cases} 100 & \text{se } i \in \{1,2\} \\ 27 & \text{se } i \in \{3,4,5,6\} \end{cases}$$

come si verifica ragionando esattamente come al punto precedente.

Sia X una variabile aleatoria definita sullo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$. Poiché $X^{-1}(B) \in \mathcal{F}$ per ogni $B \in \mathcal{B}$, ha senso calcolare la probabilità $\mathbb{P}\big(X^{-1}(B)\big)$: la variabile aleatoria X consente quindi di trasportare la misura di probabilità $\mathbb{P}$ sullo spazio misurabile $(\mathbb{R}, \mathcal{B})$, secondo lo schema

$$(\Omega, \mathcal{F}, \mathbb{P}) \xrightarrow{\ X\ } (\mathbb{R}, \mathcal{B}, \mathbb{P}_X).$$

Si formalizza questo concetto con la definizione seguente.

Definizione 1.37. Sia X una variabile aleatoria definita sullo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$. Si dice *legge* (o *distribuzione*) della variabile aleatoria X la funzione d'insieme definita di seguito.

$$\begin{aligned} \mathbb{P}_X : \mathfrak{B} &\longrightarrow [0,1] \\ B &\longmapsto \mathbb{P}\Big(\big\{\, \omega \in \Omega \mid X(\omega) \in B \,\big\}\Big) = \mathbb{P}\big(X^{-1}(B)\big) \end{aligned}$$

Notazione 1.38. Per ogni $B \in \mathfrak{B}$ si utilizza la notazione compatta

$$\mathbb{P}(X \in B) := \mathbb{P}_X(B) = \mathbb{P}\Big(\big\{\, \omega \in \Omega \mid X(\omega) \in B \,\big\}\Big) = \mathbb{P} \circ X^{-1}(B).$$

In modo analogo si scrive, ad esempio, $\mathbb{P}(X \leq x)$ in luogo di $\mathbb{P}\big(X \in (-\infty, x]\big)$, $\mathbb{P}(X = x)$ in luogo di $\mathbb{P}\big(X \in \{x\}\big)$ e $\mathbb{P}(a < X \leq b)$ in luogo di $\mathbb{P}\big(X \in (a, b]\big)$.

Proposizione 1.23. *Siano $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e X una variabile aleatoria definita su di esso. Allora la legge $\mathbb{P}_X$ è una misura di probabilità sullo spazio misurabile $(\mathbb{R}, \mathfrak{B})$, e dunque $(\mathbb{R}, \mathfrak{B}, \mathbb{P}_X)$ è uno spazio di probabilità, detto* spazio di probabilità indotto *da X.*

Dimostrazione. Si verifica che $\mathbb{P}_X$ soddisfa gli assiomi di Kolmogorov.

(*i*) Poiché X assume valori reali, si ha $X^{-1}(\mathbb{R}) = \Omega$, e quindi:

$$\mathbb{P}_X(\mathbb{R}) = \mathbb{P}\Big(\big\{\, \omega \in \Omega \mid X(\omega) \in \mathbb{R} \,\big\}\Big) = \mathbb{P}(\Omega) = 1.$$

(*ii*) Per ogni $B \in \mathfrak{B}$, per l'Assioma 2 applicato all'evento $X^{-1}(B) \in \mathcal{F}$, si ha:

$$\mathbb{P}_X(B) = \mathbb{P}\big(X^{-1}(B)\big) \geq 0.$$

(*iii*) Sia $\{B_n\}_{n\in\mathbb{N}} \subseteq \mathfrak{B}$ una successione di boreliani a due a due disgiunti. La controimmagine commuta con le operazioni insiemistiche, per cui gli eventi $X^{-1}(B_n)$ sono anch'essi a due a due disgiunti:

$$X^{-1}(B_i) \cap X^{-1}(B_j) = X^{-1}(B_i \cap B_j) = X^{-1}(\emptyset) = \emptyset \qquad \forall i \neq j,$$

e inoltre

$$X^{-1}\left(\bigcupdot_{n=1}^{+\infty} B_n\right) = \bigcupdot_{n=1}^{+\infty} X^{-1}(B_n).$$

Applicando l'Assioma 3 alla misura $\mathbb{P}$, si ottiene:

$$\mathbb{P}_X\left(\bigcupdot_{n=1}^{+\infty} B_n\right) = \mathbb{P}\left(\bigcupdot_{n=1}^{+\infty} X^{-1}(B_n)\right) = \sum_{n=1}^{+\infty} \mathbb{P}\big(X^{-1}(B_n)\big) = \sum_{n=1}^{+\infty} \mathbb{P}_X(B_n). \qquad \square$$

1.10.2 Funzione di ripartizione

Definizione 1.39. Sia $X : \Omega \to \mathbb{R}$ una variabile aleatoria definita sullo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$. Si definisce *funzione di ripartizione* (o *funzione di distribuzione*) della variabile aleatoria X la funzione $F_X : \mathbb{R} \to [0,1]$ tale che

$$F_X(x) := \mathbb{P}(X \leq x) = \mathbb{P}_X\big((-\infty, x]\big) = \mathbb{P}\Big(\big\{\omega \in \Omega \mid X(\omega) \leq x\big\}\Big)$$
$$= \mathbb{P}\Big(X^{-1}\big((-\infty, x]\big)\Big) \qquad \forall x \in \mathbb{R}.$$

Notazione 1.40. Per ogni $x \in \mathbb{R}$ si pone

$$F_X(x^-) := \mathbb{P}(X < x) = \mathbb{P}_X\big((-\infty, x)\big).$$

La scelta della notazione sarà giustificata nell'osservazione successiva alla Proposizione 1.24.

Osservazione. La funzione di ripartizione dipende soltanto dalla legge $\mathbb{P}_X$, e non individua univocamente la variabile aleatoria: esistono infinite variabili aleatorie, anche definite su spazi di probabilità diversi, aventi la stessa funzione di ripartizione. Ad esempio, nel lancio di una moneta non truccata, descritto da $\Omega = \{\mathrm{T}, \mathrm{C}\}$, $\mathcal{F} = \mathcal{P}(\Omega)$ e $\mathbb{P}\big(\{\mathrm{T}\}\big) = \mathbb{P}\big(\{\mathrm{C}\}\big) = 1/2$, le variabili aleatorie

$$X(\mathrm{T}) = 1, \quad X(\mathrm{C}) = 0 \qquad \text{e} \qquad Y(\mathrm{T}) = 0, \quad Y(\mathrm{C}) = 1$$

sono tali che $X(\omega) \neq Y(\omega)$ per ogni $\omega \in \Omega$, ma hanno la stessa funzione di ripartizione:

$$F_X(x) = F_Y(x) = \begin{cases} 0 & \text{se } x < 0 \\ 1/2 & \text{se } 0 \leq x < 1 \\ 1 & \text{se } x \geq 1 \end{cases}$$

La stessa funzione di ripartizione è posseduta, più in generale, da ogni variabile aleatoria che vale 1 sugli esiti di un evento E con $\mathbb{P}(E) = 1/2$ e 0 altrove, in un qualsiasi spazio di probabilità.

Proposizione 1.24 (Proprietà della funzione di ripartizione). *Sia X una variabile aleatoria con funzione di ripartizione F_X. Allora:*

(*i*) $0 \leq F_X(x) \leq 1$ *per ogni* $x \in \mathbb{R}$;

(*ii*) F_X *è monotòna non decrescente, ovvero per ogni* $x_1, x_2 \in \mathbb{R}$ *si ha:*

$$x_1 < x_2 \implies F_X(x_1) \leq F_X(x_2);$$

(*iii*) F_X *è continua a destra in ogni punto, ovvero:*

$$\lim_{\varepsilon \to 0^+} F_X(x + \varepsilon) = F_X(x) \qquad \forall x \in \mathbb{R};$$

(*iv*) *valgono i limiti agli estremi:*

$$\lim_{x \to -\infty} F_X(x) = 0 \quad e \quad \lim_{x \to +\infty} F_X(x) = 1.$$

Dimostrazione.

(*i*) Segue immediatamente dalla definizione, essendo $F_X(x)$ la probabilità di un evento, e dalla proprietà (*iv*) della misura di probabilità.

(*ii*) Se $x_1 < x_2$, si ha $(-\infty, x_1] \subseteq (-\infty, x_2]$ e quindi

$$\begin{aligned}\big\{\,\omega \in \Omega \mid X(\omega) \le x_1\,\big\} &= X^{-1}\big((-\infty, x_1]\big) \\ &\subseteq X^{-1}\big((-\infty, x_2]\big) = \big\{\,\omega \in \Omega \mid X(\omega) \le x_2\,\big\}.\end{aligned}$$

Per la monotonia della misura di probabilità (proprietà (*v*)) si ottiene:

$$F_X(x_1) = \mathbb{P}(X \le x_1) \le \mathbb{P}(X \le x_2) = F_X(x_2).$$

(*iii*) Fissato $x \in \mathbb{R}$, per la monotonia di F_X appena dimostrata il limite destro di F_X in x esiste e coincide con il limite lungo la successione $\big\{x + 1/n\big\}_{n\in\mathbb{N}}$; basta quindi provare che $F_X(x + 1/n) \to F_X(x)$ per $n \to +\infty$. Per ogni $n \in \mathbb{N}$ vale la decomposizione disgiunta

$$X^{-1}\left((-\infty, x + \frac{1}{n}]\right) = X^{-1}\big((-\infty, x]\big) \uplus X^{-1}\left((x, x + \frac{1}{n}]\right),$$

e dunque, posto $E_n := X^{-1}\big((x, x + 1/n]\big)$, si ha:

$$F_X\left(x + \frac{1}{n}\right) = F_X(x) + \mathbb{P}(E_n).$$

La successione di eventi $\big\{E_n\big\}_{n\in\mathbb{N}}$ è monotòna decrescente e, poiché la controimmagine commuta con l'intersezione,

$$\lim_{n\to+\infty} E_n = \bigcap_{n=1}^{+\infty} E_n = X^{-1}\left(\bigcap_{n=1}^{+\infty}(x, x + \frac{1}{n}]\right) = X^{-1}(\emptyset) = \emptyset.$$

Per la *continuità della misura di probabilità* si ottiene quindi:

$$\begin{aligned}\lim_{n\to+\infty} F_X\left(x + \frac{1}{n}\right) &= F_X(x) + \lim_{n\to+\infty} \mathbb{P}(E_n) = F_X(x) + \mathbb{P}\left(\lim_{n\to+\infty} E_n\right) \\ &= F_X(x) + \mathbb{P}(\emptyset) = F_X(x).\end{aligned}$$

(*iv*) Come al punto precedente, per la monotonia di F_X i due limiti esistono e possono essere calcolati lungo le successioni $\big\{-n\big\}_{n\in\mathbb{N}}$ e $\big\{n\big\}_{n\in\mathbb{N}}$. Per il primo limite si ponga

$$A_n := \big\{\,\omega \in \Omega \mid X(\omega) \le -n\,\big\} \qquad \forall n \in \mathbb{N}.$$

La successione $\big\{A_n\big\}_{n\in\mathbb{N}}$ è monotòna decrescente e converge a

$$\bigcap_{n=1}^{+\infty} A_n = \emptyset,$$

poiché per ogni $\omega \in \Omega$, essendo $X(\omega) \in \mathbb{R}$, esiste $n \in \mathbb{N}$ tale che $X(\omega) > -n$. Per la continuità della misura di probabilità si ha:

$$\lim_{n\to+\infty} F_X(-n) = \lim_{n\to+\infty} \mathbb{P}(A_n) = \mathbb{P}\left(\lim_{n\to+\infty} A_n\right) = \mathbb{P}(\emptyset) = 0.$$

Per il secondo limite si ponga invece

$$A_n := \{\omega \in \Omega \mid X(\omega) \leq n\} \qquad \forall n \in \mathbb{N}.$$

La successione $\{A_n\}_{n\in\mathbb{N}}$ è monotòna crescente e converge a

$$\bigcup_{n=1}^{+\infty} A_n = \Omega,$$

poiché per ogni $\omega \in \Omega$ esiste $n \in \mathbb{N}$ tale che $X(\omega) \leq n$. Per la continuità della misura di probabilità si ha:

$$\lim_{n\to+\infty} F_X(n) = \lim_{n\to+\infty} \mathbb{P}(A_n) = \mathbb{P}\left(\lim_{n\to+\infty} A_n\right) = \mathbb{P}(\Omega) = 1. \qquad \square$$

Osservazione. Con un ragionamento analogo a quello del punto *(iii)* si giustifica la notazione $F_X(x^-) = \mathbb{P}(X < x)$. Per ogni $x \in \mathbb{R}$, la successione di eventi $\{X \leq x - 1/n\}_{n\in\mathbb{N}}$ è monotòna crescente e converge a

$$\bigcup_{n=1}^{+\infty} \left\{X \leq x - \frac{1}{n}\right\} = \{X < x\},$$

per cui, per la monotonia di F_X e la continuità della misura di probabilità, il limite sinistro di F_X in x esiste e vale:

$$\lim_{\varepsilon\to 0^+} F_X(x-\varepsilon) = \lim_{n\to+\infty} F_X\left(x - \frac{1}{n}\right) = \mathbb{P}(X < x) = F_X(x^-).$$

In generale, dunque, F_X è continua a destra ma non necessariamente a sinistra.

Teorema 1.25. *Sia X una variabile aleatoria con funzione di ripartizione F_X e siano $x, a, b \in \mathbb{R}$ con $a < b$. Allora:*

(i) $\mathbb{P}(X = x) = \mathbb{P}(X \leq x) - \mathbb{P}(X < x) = F_X(x) - F_X(x^-)$;

(ii) $\mathbb{P}\big(X \in (a,b)\big) = \mathbb{P}(X < b) - \mathbb{P}(X \leq a) = F_X(b^-) - F_X(a)$;

(iii) $\mathbb{P}\big(X \in [a,b]\big) = \mathbb{P}(X \leq b) - \mathbb{P}(X < a) = F_X(b) - F_X(a^-)$;

(iv) $\mathbb{P}\big(X \in (a,b]\big) = \mathbb{P}(X \leq b) - \mathbb{P}(X \leq a) = F_X(b) - F_X(a)$;

(v) $\mathbb{P}\big(X \in [a,b)\big) = \mathbb{P}(X < b) - \mathbb{P}(X < a) = F_X(b^-) - F_X(a^-)$;

(vi) $\mathbb{P}\big(X \in (a,+\infty)\big) = 1 - \mathbb{P}(X \leq a) = 1 - F_X(a)$;

(vii) $\mathbb{P}\big(X \in [a,+\infty)\big) = 1 - \mathbb{P}(X < a) = 1 - F_X(a^-)$.

Dimostrazione. In ciascuno dei primi cinque casi si scrive l'evento $\{X \leq b\}$ oppure l'evento $\{X < b\}$ (rispettivamente $\{X \leq x\}$ nel primo caso) come unione disgiunta di due eventi, uno dei quali è quello di interesse, e si applica la proprietà *(ii)* della misura di probabilità; negli ultimi due casi si passa invece all'evento complementare.

(i) Da $\{X \leq x\} = \{X < x\} \cup \{X = x\}$ segue $F_X(x) = F_X(x^-) + \mathbb{P}(X = x)$.

(*ii*) Da $\{X < b\} = \{X \leq a\} \cup \{a < X < b\}$ segue $F_X(b^-) = F_X(a) + \mathbb{P}(a < X < b)$.

(*iii*) Da $\{X \leq b\} = \{X < a\} \cup \{a \leq X \leq b\}$ segue $F_X(b) = F_X(a^-) + \mathbb{P}(a \leq X \leq b)$.

(*iv*) Da $\{X \leq b\} = \{X \leq a\} \cup \{a < X \leq b\}$ segue $F_X(b) = F_X(a) + \mathbb{P}(a < X \leq b)$.

(*v*) Da $\{X < b\} = \{X < a\} \cup \{a \leq X < b\}$ segue $F_X(b^-) = F_X(a^-) + \mathbb{P}(a \leq X < b)$.

(*vi*) Essendo $\{X > a\} = \{X \leq a\}^c$, per la proprietà (*iii*) si ha $\mathbb{P}(X > a) = 1 - F_X(a)$.

(*vii*) Essendo $\{X \geq a\} = \{X < a\}^c$, per la proprietà (*iii*) si ha $\mathbb{P}(X \geq a) = 1 - F_X(a^-)$. □

Osservazione. Dal punto (*i*) discende che F_X è continua in un punto $x \in \mathbb{R}$ se e solo se $\mathbb{P}(X = x) = 0$; nei punti in cui $\mathbb{P}(X = x) > 0$, invece, la funzione F_X presenta un salto di ampiezza pari proprio a $\mathbb{P}(X = x)$.

Le proprietà (*ii*), (*iii*) e (*iv*) della Proposizione 1.24 caratterizzano completamente le funzioni di ripartizione, come afferma il teorema seguente.

Teorema 1.26. *Sia $F : \mathbb{R} \to [0, 1]$ una funzione tale che:*
(*i*) *F è monotòna non decrescente;*
(*ii*) *F è continua a destra in ogni punto;*
(*iii*) $\lim_{x \to -\infty} F(x) = 0$ *e* $\lim_{x \to +\infty} F(x) = 1$.
Allora esistono uno spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$ e una variabile aleatoria $X : \Omega \to \mathbb{R}$ di cui F è la funzione di ripartizione, ovvero tale che $F_X = F$.

Dimostrazione. Omessa. □

Esempio 1.17. Si riprenda lo spazio probabilizzabile dell'Esempio 1.16, con $\Omega = I_6$ e $\mathcal{F} = \sigma(\{1\})$, e lo si munisca della misura di probabilità definita come segue.

$$\begin{aligned} \mathbb{P} : \mathcal{F} &\longrightarrow [0, 1] \\ \emptyset &\longmapsto 0 \\ \Omega &\longmapsto 1 \\ \{1\} &\longmapsto 1/6 \\ \{2, 3, 4, 5, 6\} &\longmapsto 5/6 \end{aligned}$$

Si consideri la variabile aleatoria Y dell'Esempio 1.16, che vale 100 se $\omega = 1$ e 27 se $\omega \in \{2, 3, 4, 5, 6\}$, e se ne costruisca la funzione di ripartizione $F_Y(x) = \mathbb{P}\big(\{\omega \in \Omega \mid Y(\omega) \leq x\}\big)$:
(*i*) se $x < 27$, nessun esito soddisfa $Y(\omega) \leq x$, e quindi $F_Y(x) = \mathbb{P}(\emptyset) = 0$;
(*ii*) se $27 \leq x < 100$, si ha $\{Y \leq x\} = \{2, 3, 4, 5, 6\} = \{1\}^c$, e quindi $F_Y(x) = 5/6$;
(*iii*) se $x \geq 100$, si ha $\{Y \leq x\} = \Omega$, e quindi $F_Y(x) = 1$.
Riassumendo, la funzione di ripartizione di Y è data da:

$$F_Y(x) = \begin{cases} 0 & \text{se } x < 27 \\ 5/6 & \text{se } 27 \leq x < 100 \\ 1 & \text{se } x \geq 100 \end{cases}$$

La funzione F_Y è costante a tratti, continua a destra e presenta due salti, nei punti 27 e 100. In accordo con il Teorema 1.25, l'ampiezza di ciascun salto fornisce la probabilità che Y assuma il valore corrispondente:

$$\mathbb{P}(Y = 27) = F_Y(27) - F_Y(27^-) = \frac{5}{6} - 0 = \frac{5}{6},$$
$$\mathbb{P}(Y = 100) = F_Y(100) - F_Y(100^-) = 1 - \frac{5}{6} = \frac{1}{6},$$

mentre $\mathbb{P}(Y = x) = 0$ per ogni $x \notin \{27, 100\}$.

1.10.3 Variabili aleatorie discrete

Definizione 1.41. Sia $X : \Omega \to \mathbb{R}$ una variabile aleatoria. Essa si dice *discreta* se esiste un insieme $S_X \subseteq \mathbb{R}$ al più numerabile tale che:

(*i*) $\mathbb{P}(X \in S_X) := \mathbb{P} \circ X^{-1}(S_X) = 1$, in altre parole, S_X è un evento quasi certo nello spazio di probabilità indotto da X: $(\mathbb{R}, \mathfrak{B}, \mathbb{P}_X)$;

(*ii*) $\mathbb{P}(X = x) := \mathbb{P} \circ X^{-1}\big(\{x\}\big) > 0 \quad \forall x \in S_X$.

L'insieme S_X si chiama *supporto* o *spettro* della variabile aleatoria X e rappresenta, a meno di insiemi di probabilità nulla, l'insieme dei valori effettivamente assunti da X.

Definizione 1.42. Sia X una variabile aleatoria discreta con supporto S_X. Si definisce di seguito la *funzione massa di probabilità* di X (o *densità discreta* della variabile aleatoria X).

$$\begin{aligned} p_X : S_X &\longrightarrow (0, 1] \\ x &\longmapsto \mathbb{P}(X = x) \end{aligned}$$

Per una variabile aleatoria discreta, la funzione di ripartizione si esprime come:

$$F_X(x) = \mathbb{P}(X \leq x) = \sum_{\substack{x_\alpha \in S_X \\ x_\alpha \leq x}} \mathbb{P}(X = x_\alpha) = \sum_{\substack{x_\alpha \in S_X \\ x_\alpha \leq x}} p_X(x_\alpha).$$

Definizione 1.43. Una variabile aleatoria X si dice *degenere* in $c \in \mathbb{R}$ se $\mathbb{P}(X = c) = 1$. In tal caso X è una variabile aleatoria discreta con supporto $S_X = \{c\}$.

Osservazione. La funzione di ripartizione $F_X : \mathbb{R} \to [0, 1]$ di una variabile aleatoria degenere in $c \in \mathbb{R}$ è data da:

$$F_X(x) = \mathbb{P}(X \leq x) = \begin{cases} 0 & \text{se } x < c \\ 1 & \text{se } x \geq c \end{cases}$$

Infatti, se $x < c$ si ha $\{X \leq x\} \subseteq \{X \neq c\}$, evento di probabilità nulla; se invece $x \geq c$ si ha $\{X \leq x\} \supseteq \{X = c\}$, evento quasi certo. Dal punto di vista intuitivo, una variabile aleatoria degenere non presenta una reale incertezza sull'esito, ma descrive un fenomeno *deterministico*.

Definizione 1.44. Una variabile aleatoria discreta X si dice di *Bernoulli* se il suo supporto è

$$S_X = \{0, 1\}.$$

Si pone $p := \mathbb{P}(X = 1) \in (0, 1)$, e lo si denomina *parametro* della variabile di Bernoulli; in tal caso si scrive $X \sim \text{Ber}(p)$.

Osservazione. Per una variabile aleatoria di Bernoulli X, si ha necessariamente $\mathbb{P}(X = 0) = 1 - p$ e, di conseguenza, la sua funzione massa di probabilità è data da:

$$p_X(x) = \mathbb{P}(X = x) = \begin{cases} 1-p & \text{se } x = 0 \\ p & \text{se } x = 1 \end{cases} = p^x(1-p)^{1-x} \quad \text{per } x \in \{0,1\}.$$

Infine, la funzione di ripartizione $F_X : \mathbb{R} \to [0,1]$ è costruita come segue.

$$F_X(x) = \sum_{\substack{x_\alpha \in S_X \\ x_\alpha \leq x}} p_X(x_\alpha) = \begin{cases} 0 & \text{se } x < 0 \\ 1-p & \text{se } 0 \leq x < 1 \\ 1 & \text{se } x \geq 1 \end{cases}$$

Esempio 1.18. Si consideri l'esperimento casuale del lancio di una moneta, descritto dallo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$ così costruito:

(i) spazio campione:
$$\Omega = \{\mathrm{T}, \mathrm{C}\};$$

(ii) σ-algebra degli eventi:
$$\mathcal{F} = \mathcal{P}(\Omega) = \{\emptyset, \Omega, \{\mathrm{T}\}, \{\mathrm{C}\}\};$$

(iii) misura di probabilità definita, per un fissato $p \in (0,1)$, come segue:
$$\begin{aligned} \mathbb{P} : \mathcal{F} &\longrightarrow [0,1] \\ \emptyset &\longmapsto 0 \\ \Omega &\longmapsto 1 \\ \{\mathrm{T}\} &\longmapsto p \\ \{\mathrm{C}\} &\longmapsto 1-p \end{aligned}$$

Il parametro p quantifica l'eventuale *trucco della moneta* (se $p = 1/2$ la moneta si dice equilibrata o non truccata).

Si definisca la variabile aleatoria $X : \Omega \to \mathbb{R}$ associando 1 al successo, coincidente con il verificarsi di T, e 0 all'insuccesso, coincidente con il verificarsi di C:

$$\begin{aligned} X : \Omega &\longrightarrow \mathbb{R} \\ \mathrm{T} &\longmapsto 1 \\ \mathrm{C} &\longmapsto 0 \end{aligned}$$

Essendo $S_X = \{0,1\}$ con

$$p_X(1) = \mathbb{P}(X = 1) = \mathbb{P}\big(\{\mathrm{T}\}\big) = p \quad \text{e} \quad p_X(0) = \mathbb{P}(X = 0) = \mathbb{P}\big(\{\mathrm{C}\}\big) = 1 - p,$$

la variabile aleatoria X così definita è una variabile aleatoria di Bernoulli di parametro p.

Definizione 1.45. Una variabile aleatoria discreta X si dice *binomiale* di parametri $n \in \mathbb{N}$ e $p \in (0,1)$, e si indica con $X \sim \mathrm{Bin}(n,p)$, se ha supporto $S_X = \{0,1,\ldots,n\}$ e funzione massa di probabilità

$$p_X(x) = \binom{n}{x} p^x (1-p)^{n-x} \qquad \text{per } x \in \{0,1,\ldots,n\}.$$

Osservazione. La variabile binomiale descrive il numero di successi in n prove indipendenti, ciascuna con probabilità di successo p; equivalentemente, X si esprime come somma di n variabili aleatorie di Bernoulli indipendenti di parametro p. Infatti, per l'indipendenza delle prove, calcolando la probabilità sui singoli valori del supporto si ha:

$$\begin{aligned} p_X(0) &= \mathbb{P}(X=0) = (1-p)^n, \\ p_X(1) &= \mathbb{P}(X=1) = np(1-p)^{n-1}, \\ &\vdots \\ p_X(n) &= \mathbb{P}(X=n) = p^n, \end{aligned}$$

e, in generale, si ritrova la funzione massa della definizione:

$$p_X(x) = \mathbb{P}(X=x) = \binom{n}{x} p^x (1-p)^{n-x} \quad \text{per } x \in \{0,1,\dots,n\},$$

che soddisfa la condizione di normalizzazione:

$$\sum_{x=0}^{n} p_X(x) = \sum_{x=0}^{n} \binom{n}{x} p^x (1-p)^{n-x} = \big(p + (1-p)\big)^n = 1.$$

Infine, la funzione di ripartizione $F_X : \mathbb{R} \to [0,1]$ è costruita come segue.

$$F_X(x) = \sum_{\substack{x_\alpha \in S_X \\ x_\alpha \le x}} p_X(x_\alpha) = \begin{cases} 0 & \text{se } x < 0 \\ (1-p)^n & \text{se } 0 \le x < 1 \\ (1-p)^n + np(1-p)^{n-1} & \text{se } 1 \le x < 2 \\ \quad\vdots & \quad\vdots \\ 1 - p^n & \text{se } n-1 \le x < n \\ 1 & \text{se } x \ge n \end{cases}$$

Definizione 1.46. Una variabile aleatoria discreta X si dice *geometrica* di parametro $p \in (0,1)$, e si indica con $X \sim \mathrm{Geom}(p)$, se ha supporto $S_X = \mathbb{N}$ e funzione massa di probabilità

$$p_X(x) = p(1-p)^{x-1} \qquad \text{per } x \in \mathbb{N}.$$

Osservazione. La variabile geometrica descrive il numero di prove indipendenti (ciascuna con probabilità di successo p) necessarie per ottenere il primo successo. Infatti, l'evento $\{X = x\}$ equivale a ottenere $x-1$ insuccessi consecutivi seguiti da un successo alla prova x-esima; per i primi valori del supporto si ha:

$$\begin{aligned} p_X(1) &= p && \text{(successo alla } 1^{\text{a}} \text{ prova)}, \\ p_X(2) &= (1-p)p && \text{(insuccesso alla } 1^{\text{a}} \text{ prova e successo alla } 2^{\text{a}}), \\ &\vdots \end{aligned}$$

e, in generale, si ritrova la funzione massa della definizione:

$$p_X(x) = \mathbb{P}(X=x) = p(1-p)^{x-1} \quad \text{per } x \in \mathbb{N}.$$

Operando la sostituzione di indice $y = x - 1$ e sfruttando la somma della serie geometrica di ragione $1 - p \in (0, 1)$, si verifica la condizione di normalizzazione su tutto il supporto:

$$\sum_{x \in S_X} p(1-p)^{x-1} = p \sum_{x=1}^{+\infty} (1-p)^{x-1} = p \sum_{y=0}^{+\infty} (1-p)^{y} = p \, \frac{1}{1-(1-p)} = p \, \frac{1}{p} = 1.$$

Infine, la funzione di ripartizione $F_X : \mathbb{R} \to [0, 1]$ è costruita come segue.

$$F_X(x) = \sum_{\substack{x_\alpha \in S_X \\ x_\alpha \leq x}} p_X(x_\alpha) = \begin{cases} 0 & \text{se } x < 1 \\ p & \text{se } 1 \leq x < 2 \\ p + p(1-p) & \text{se } 2 \leq x < 3 \\ \quad \vdots & \quad \vdots \\ 1 - (1-p)^m & \text{se } m \leq x < m+1,\ m \in \mathbb{N} \\ \quad \vdots & \quad \vdots \end{cases}$$

Si è usata la formula della somma parziale di una serie geometrica:

$$\sum_{k=1}^{m} p(1-p)^{k-1} = 1 - (1-p)^m;$$

si ha inoltre che

$$\lim_{x \to +\infty} F_X(x) = 1.$$

Definizione 1.47. Una variabile aleatoria discreta X si dice di *Poisson* di parametro $\lambda > 0$, e si indica con $X \sim \text{Poisson}(\lambda)$, se ha supporto $S_X = \mathbb{N}_0$ e funzione massa di probabilità

$$p_X(x) = \frac{\lambda^x}{x!} \, \mathrm{e}^{-\lambda} \qquad \text{per } x \in \mathbb{N}_0.$$

Osservazione. Sviluppando in serie di Taylor l'esponenziale e^{λ}, si verifica la condizione di normalizzazione:

$$\sum_{x=0}^{+\infty} \frac{\lambda^x}{x!} \mathrm{e}^{-\lambda} = \mathrm{e}^{-\lambda} \sum_{x=0}^{+\infty} \frac{\lambda^x}{x!} = \mathrm{e}^{-\lambda} \mathrm{e}^{\lambda} = 1.$$

Proposizione 1.27 (Legge degli eventi rari). *Sia $\lambda > 0$ e, per ogni intero $n > \lambda$, sia $X_n \sim \text{Bin}(n, \lambda/n)$. Allora, per ogni $x \in \mathbb{N}_0$,*

$$\lim_{n \to +\infty} \mathbb{P}(X_n = x) = \frac{\lambda^x}{x!} \, \mathrm{e}^{-\lambda}.$$

In altre parole, la distribuzione binomiale con n grande e $p = \lambda/n$ piccolo è approssimata dalla distribuzione di Poisson di parametro $\lambda = np$.

Dimostrazione. Posto $p = \lambda/n$, per ogni $x \in \mathbb{N}_0$ si ha:

$$\mathbb{P}(X_n = x) = \binom{n}{x} p^x (1-p)^{n-x} = \frac{n!}{x!(n-x)!} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x}$$

$$= \frac{\lambda^x}{x!} \cdot \frac{n(n-1)(n-2)\cdots(n-x+1)}{n^x} \cdot \frac{\left(1 - \frac{\lambda}{n}\right)^n}{\left(1 - \frac{\lambda}{n}\right)^x}.$$

Per $n \to +\infty$, la frazione costituita dai due prodotti di x fattori e il termine $(1-\lambda/n)^x$ tendono entrambi a 1, mentre $(1-\lambda/n)^n \to \mathrm{e}^{-\lambda}$. Si ottiene quindi:

$$\lim_{n\to+\infty} \mathbb{P}(X_n = x) = \frac{\lambda^x}{x!}\,\mathrm{e}^{-\lambda}. \qquad \square$$

Definizione 1.48. Una variabile aleatoria X a valori in $\mathbb{N}_0$ si dice dotata della proprietà di *assenza di memoria* se, per ogni $r, s \in \mathbb{N}_0$ tali che $\mathbb{P}(X > s) > 0$, soddisfa la condizione:

$$\mathbb{P}(X > r+s \,|\, X > s) = \mathbb{P}(X > r).$$

Esempio 1.19. Si consideri un insieme costituito da n persone e si voglia calcolare la probabilità che almeno due di esse compiano gli anni lo stesso giorno (assumendo anni non bisestili di 365 giorni e che tutti i giorni dell'anno siano equiprobabili e indipendenti per ciascuna nascita).

Si definisca l'evento:

$$A := \big\{\text{le } n \text{ persone hanno compleanni tutti diversi}\big\}.$$

Applicando la definizione classica di probabilità (rapporto tra il numero di casi favorevoli e il numero totale di sequenze ordinate possibili di n date, pari a 365^n), per $n \le 365$ si ottiene:

$$\mathbb{P}(A) = \frac{365 \cdot 364 \cdot 363 \cdots (365-n+1)}{365^n} = \frac{365!}{(365-n)!\,365^n}.$$

Passando all'evento complementare

$$A^{\mathrm{c}} = \big\{\text{almeno due persone hanno lo stesso compleanno}\big\},$$

la sua probabilità è data da:

$$\mathbb{P}\big(A^{\mathrm{c}}\big) = 1 - \mathbb{P}(A) = 1 - \frac{365 \cdot 364 \cdots (365-n+1)}{365^n}.$$

Valutando tale probabilità al crescere di n, si osserva che:

(*i*) per $n = 23$ (primo valore intero per cui risulta $\mathbb{P}(A^{\mathrm{c}}) > \frac{1}{2}$), essendo $365-23+1 = 343$:

$$\mathbb{P}\big(A^{\mathrm{c}}\big) = 1 - \frac{365 \cdot 364 \cdots 343}{365^{23}} \approx 0.5073;$$

(*ii*) per $n = 40$:

$$\mathbb{P}\big(A^{\mathrm{c}}\big) = 1 - \frac{365 \cdot 364 \cdots 326}{365^{40}} \approx 0.8912.$$

Proposizione 1.28. *Ogni variabile aleatoria geometrica X di parametro $p \in (0,1)$ gode della proprietà di assenza di memoria:*

$$\mathbb{P}(X > r+s \,|\, X > s) = \mathbb{P}(X > r) \qquad \forall r, s \in \mathbb{N}_0.$$

Dimostrazione. Dall'osservazione sulla funzione di ripartizione della variabile geometrica si ha $F_X(m) = 1-(1-p)^m$ per ogni $m \in \mathbb{N}$, e $F_X(0) = 0$. Passando all'evento complementare, per ogni $x \in \mathbb{N}_0$ si ottiene quindi:

$$\mathbb{P}(X > x) = 1 - F_X(x) = (1-p)^x,$$

dove per $x = 0$ si ha $\mathbb{P}(X > 0) = 1 = (1-p)^0$. In particolare, $\mathbb{P}(X > s) = (1-p)^s > 0$ per ogni $s \in \mathbb{N}_0$, e la probabilità condizionata è ben definita.

Osservando che per $r, s \in \mathbb{N}_0$ vale l'inclusione $\{X > r+s\} \subseteq \{X > s\}$, e quindi $\{X > r+s\} \cap \{X > s\} = \{X > r+s\}$, dalla definizione di probabilità condizionata si ottiene:

$$\begin{aligned}\mathbb{P}(X > r+s \,|\, X > s) &= \frac{\mathbb{P}\big(\{X > r+s\} \cap \{X > s\}\big)}{\mathbb{P}(X > s)} = \frac{\mathbb{P}(X > r+s)}{\mathbb{P}(X > s)} \\ &= \frac{(1-p)^{r+s}}{(1-p)^s} = (1-p)^r = \mathbb{P}(X > r). \qquad \square\end{aligned}$$

1.10.4 Variabili aleatorie continue

Per trattare in modo unificato variabili aleatorie discrete e continue, è utile introdurre una generalizzazione dell'integrale di Riemann.

Definizione 1.49. Siano $f : [a,b] \to \mathbb{R}$ una funzione continua e $g : \mathbb{R} \to \mathbb{R}$ una funzione monotòna non decrescente. Assegnata una decomposizione

$$D = \big\{ a = x_1 < x_2 < \cdots < x_{n+1} = b \big\}$$

dell'intervallo $[a,b]$ di ampiezza

$$\delta(D) := \max_{1 \le k \le n} (x_{k+1} - x_k),$$

si scelga in ciascun sottointervallo un punto arbitrario $\xi_k \in [x_k, x_{k+1}]$, per $k = 1, \dots, n$. Si definisce *integrale di Riemann–Stieltjes* di f rispetto alla funzione integratrice g sull'intervallo $[a,b]$ il limite

$$\int_a^b f(x)\,\mathrm{d}g(x) := \lim_{\delta(D)\to 0} \sum_{k=1}^{n} f(\xi_k)\big(g(x_{k+1}) - g(x_k)\big),$$

qualora esso esista finito e non dipenda né dalla scelta delle decomposizioni D né da quella dei punti ξ_k. Nel caso particolare $g(x) = x$ si ritrova la definizione dell'integrale di Riemann:

$$\int_a^b f(x)\,\mathrm{d}x = \lim_{\delta(D)\to 0} \sum_{k=1}^{n} f(\xi_k)(x_{k+1} - x_k).$$

Osservazione. Valgono le seguenti proprietà fondamentali:

(*i*) le proprietà formali dell'integrale di Riemann–Stieltjes (linearità, additività rispetto all'intervallo di integrazione, monotonia) sono le stesse dell'integrale di Riemann;

(*ii*) se g è derivabile con derivata continua (o integrabile) su $[a,b]$, vale la relazione differenziale $\mathrm{d}g(x) = g'(x)\,\mathrm{d}x$ e pertanto l'integrale di Riemann–Stieltjes si riduce ad un integrale di Riemann ordinario:

$$\int_a^b f(x)\,\mathrm{d}g(x) = \int_a^b f(x)g'(x)\,\mathrm{d}x.$$

Definizione 1.50. Sia $X : \Omega \to \mathbb{R}$ una variabile aleatoria con funzione di ripartizione F_X. La variabile aleatoria X si dice *assolutamente continua*, e di conseguenza anche F_X si dice *assolutamente continua*, se esiste una funzione $f_X : \mathbb{R} \to [0, +\infty)$ integrabile tale che:

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\,\mathrm{d}t \qquad \forall x \in \mathbb{R}.$$

La funzione f_X prende il nome di *funzione densità di probabilità* di X.

Osservazione. Per il teorema fondamentale del calcolo integrale, nei punti $x \in \mathbb{R}$ in cui la funzione densità f_X è continua, la funzione di ripartizione F_X è derivabile e risulta:

$$f_X(x) = \frac{\mathrm{d}F_X}{\mathrm{d}x}(x) = \lim_{\Delta x \to 0} \frac{F_X(x + \Delta x) - F_X(x)}{\Delta x} = \lim_{\Delta x \to 0^+} \frac{\mathbb{P}(x < X < x + \Delta x)}{\Delta x}.$$

Inoltre, per una variabile aleatoria assolutamente continua X, la funzione di ripartizione F_X verifica le seguenti proprietà:

(*i*) F_X è monotòna non decrescente (strettamente crescente negli intervalli in cui $f_X(x) > 0$);

(*ii*) F_X è continua su tutto $\mathbb{R}$;

(*iii*) valgono i limiti agli estremi:

$$\lim_{x \to +\infty} F_X(x) = 1 \quad \text{e} \quad \lim_{x \to -\infty} F_X(x) = 0.$$

Dalla continuità di F_X su $\mathbb{R}$ discendono immediatamente le seguenti identità:

(*i*) la probabilità che X assuma un singolo valore reale è sempre nulla:

$$\mathbb{P}(X = x) = \mathbb{P}(X \leq x) - \mathbb{P}(X < x) = F_X(x) - F_X(x^-) = 0 \qquad \forall x \in \mathbb{R};$$

(*ii*) la probabilità di un intervallo di estremi $a, b \in \mathbb{R}$ (con $a < b$) non dipende dall'inclusione o esclusione degli estremi:

$$\begin{aligned}\mathbb{P}(a \leq X \leq b) &= \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X < b) \\ &= \mathbb{P}(a < X < b) = F_X(b) - F_X(a) = \int_a^b f_X(t)\,\mathrm{d}t;\end{aligned}$$

(*iii*) $\mathbb{P}(X < x) = \mathbb{P}(X \leq x) = F_X(x)$ per ogni $x \in \mathbb{R}$;

(*iv*) $\mathbb{P}(X \geq x) = \mathbb{P}(X > x) = 1 - F_X(x)$ per ogni $x \in \mathbb{R}$.

Definizione 1.51. Una variabile aleatoria assolutamente continua X si dice *normale* (o *di Gauss*) di parametri $a \in \mathbb{R}$ e $b \in (0, +\infty)$, e si indica con $X \sim \mathcal{N}(a, b)$, se la sua funzione densità di probabilità è data da:

$$f_X(x) = \frac{1}{\sqrt{2\pi b}} \exp\left(-\frac{(x-a)^2}{2b}\right) \qquad \text{per } x \in \mathbb{R}.$$

Osservazione. Il supporto di una variabile aleatoria normale è l'intera retta reale $S_X = \mathbb{R}$ (essendo $f_X(x) > 0$ per ogni $x \in \mathbb{R}$), e la sua funzione densità di probabilità soddisfa la condizione di normalizzazione. Infatti, con la sostituzione $u = (x-a)/\sqrt{2b}$, da cui $\mathrm{d}x = \sqrt{2b}\,\mathrm{d}u$, si ottiene:

$$\int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi b}} \exp\!\left(-\frac{(x-a)^2}{2b}\right) \mathrm{d}x = \frac{\sqrt{2b}}{\sqrt{2\pi b}} \int_{-\infty}^{+\infty} \exp\!\left(-u^2\right) \mathrm{d}u = \frac{1}{\sqrt{\pi}} \cdot \sqrt{\pi} = 1,$$

dove si è usato che l'integrale di Gauss su tutto l'asse reale vale $\sqrt{\pi}$.

Osservazione. Si studia ora l'andamento della funzione densità di probabilità f_X.

(*i*) *Simmetria e comportamento agli estremi:* per ogni $t \in \mathbb{R}$ si ha $f_X(a+t) = f_X(a-t)$, poiché la densità dipende da x solo attraverso $(x-a)^2$; il grafico è dunque simmetrico rispetto alla retta $x = a$. Inoltre

$$\lim_{x \to \pm\infty} f_X(x) = 0,$$

e quindi l'asse delle ascisse è asintoto orizzontale per $x \to \pm\infty$.

(*ii*) *Derivata prima e monotonia (ricerca del massimo):* derivando $f_X(x)$ rispetto a x, si ottiene:

$$f_X'(x) = \frac{1}{\sqrt{2\pi b}} \exp\!\left(-\frac{(x-a)^2}{2b}\right) \cdot \frac{-2(x-a)}{2b} = -\frac{x-a}{b\sqrt{2\pi b}} \exp\!\left(-\frac{(x-a)^2}{2b}\right).$$

Poiché $b > 0$ e il termine esponenziale è strettamente positivo su tutto $\mathbb{R}$, lo studio del segno di $f_X'(x)$ fornisce:

$$f_X'(x) \geq 0 \iff -(x-a) \geq 0 \iff x \leq a.$$

Pertanto f_X è strettamente crescente su $(-\infty, a]$ e strettamente decrescente su $[a, +\infty)$, assumendo in $x = a$ il punto di massimo assoluto, con valore:

$$f_X(a) = \frac{1}{\sqrt{2\pi b}}.$$

(*iii*) *Derivata seconda, convessità e punti di flesso:* derivando ulteriormente $f_X'(x)$, si ha:

$$\begin{aligned} f_X''(x) &= \frac{1}{b\sqrt{2\pi b}} \left(-\exp\!\left(-\frac{(x-a)^2}{2b}\right) + \frac{(x-a)^2}{b} \exp\!\left(-\frac{(x-a)^2}{2b}\right) \right) \\ &= \frac{1}{b^2\sqrt{2\pi b}} \exp\!\left(-\frac{(x-a)^2}{2b}\right) \big((x-a)^2 - b \big). \end{aligned}$$

Imponendo la condizione di convessità $f_X''(x) \geq 0$, si ha:

$$\begin{aligned} f_X''(x) \geq 0 &\iff (x-a)^2 \geq b \\ &\iff x - a \leq -\sqrt{b} \quad \vee \quad x - a \geq \sqrt{b} \\ &\iff x \leq a - \sqrt{b} \quad \vee \quad x \geq a + \sqrt{b}. \end{aligned}$$

La funzione f_X è dunque convessa su ciascuno degli intervalli

$$\left(-\infty, a-\sqrt{b}\right] \quad \text{e} \quad \left[a+\sqrt{b}, +\infty\right),$$

concava sull'intervallo

$$\left[a-\sqrt{b}, a+\sqrt{b}\right]$$

e ammette due punti di flesso, simmetrici rispetto alla retta $x = a$, di coordinate:

$$P_1 = \left(a-\sqrt{b}, \frac{\exp(-1/2)}{\sqrt{2\pi b}}\right), \qquad P_2 = \left(a+\sqrt{b}, \frac{\exp(-1/2)}{\sqrt{2\pi b}}\right).$$

In conclusione, il grafico di f_X ha la caratteristica forma *a campana*: il parametro a individua la posizione del massimo e dell'asse di simmetria, mentre $\sqrt{b}$ coincide con la distanza dei punti di flesso dall'asse di simmetria. Al crescere di b il valore massimo $1/\sqrt{2\pi b}$ diminuisce e i flessi si allontanano da a: la campana diventa più bassa e più larga, conservando area unitaria.

Osservazione. Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia $X : \Omega \to \mathbb{R}$ una variabile aleatoria qualsiasi, con funzione di ripartizione F_X. La variabile aleatoria X induce sullo spazio misurabile $(\mathbb{R}, \mathfrak{B})$ lo spazio di probabilità $(\mathbb{R}, \mathfrak{B}, \mathbb{P}_X)$ e, per ogni boreliano $B \in \mathfrak{B}$, si ha:

$$\mathbb{P}(X \in B) = \mathbb{P}_X(B) = \int_B \mathrm{d}F_X(x),$$

dove l'integrale va inteso nel senso di Stieltjes rispetto alla funzione integratrice monotòna non decrescente F_X. Nel caso di un intervallo $B = (a, b]$, con $a < b$, ogni somma di Riemann–Stieltjes relativa alla funzione $f \equiv 1$ è telescopica, e si ritrova:

$$\mathbb{P}(a < X \leq b) = \int_a^b \mathrm{d}F_X(x) = F_X(b) - F_X(a);$$

per un boreliano qualsiasi l'integrale si interpreta invece nel senso di Lebesgue–Stieltjes, la cui costruzione esula da questi appunti.

Se X è assolutamente continua, nei punti di continuità di f_X si ha $\mathrm{d}F_X(x) = f_X(x)\,\mathrm{d}x$ e la relazione precedente assume la forma:

$$\mathbb{P}(X \in B) = \int_B f_X(x)\,\mathrm{d}x \qquad \forall B \in \mathfrak{B}.$$

In particolare, per ogni $a, b \in \mathbb{R}$ con $a < b$, si ritrova:

$$\int_a^b f_X(x)\,\mathrm{d}x = \int_{-\infty}^b f_X(x)\,\mathrm{d}x - \int_{-\infty}^a f_X(x)\,\mathrm{d}x = F_X(b) - F_X(a),$$

in accordo con quanto osservato in precedenza: la funzione di ripartizione è una primitiva della densità, e

$$\frac{\mathrm{d}F_X}{\mathrm{d}x}(x) = f_X(x)$$

in tutti i punti $x \in \mathbb{R}$ in cui f_X è continua.

Definizione 1.52. Una variabile aleatoria assolutamente continua X si dice *esponenziale* di parametro $\lambda > 0$, e si indica con $X \sim \mathrm{Exp}(\lambda)$, se la sua funzione densità di probabilità è data da:

$$f_X(x) = \begin{cases} \lambda \mathrm{e}^{-\lambda x} & \text{se } x > 0 \\ 0 & \text{se } x \leq 0 \end{cases}$$

Osservazione. La funzione f_X è non negativa e soddisfa la condizione di normalizzazione:

$$\int_{-\infty}^{+\infty} f_X(x)\,\mathrm{d}x = \int_0^{+\infty} \lambda \mathrm{e}^{-\lambda x}\,\mathrm{d}x = \Big[-\mathrm{e}^{-\lambda x}\Big]_0^{+\infty} = 0 - (-1) = 1.$$

La funzione di ripartizione $F_X : \mathbb{R} \to [0,1]$ si ottiene integrando la densità. Se $x \leq 0$ la densità è nulla su $(-\infty, x]$ e quindi $F_X(x) = 0$; se invece $x > 0$, si ha:

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\,\mathrm{d}t = \underbrace{\int_{-\infty}^{0} 0\,\mathrm{d}t}_{0} + \int_0^x \lambda \mathrm{e}^{-\lambda t}\,\mathrm{d}t = \Big[-\mathrm{e}^{-\lambda t}\Big]_0^x = 1 - \mathrm{e}^{-\lambda x}.$$

Poiché per $x = 0$ si ha $1 - \mathrm{e}^0 = 0$, le due espressioni si raccordano con continuità nell'origine e si può scrivere:

$$F_X(x) = \begin{cases} 0 & \text{se } x < 0 \\ 1 - \mathrm{e}^{-\lambda x} & \text{se } x \geq 0 \end{cases}$$

In particolare, passando all'evento complementare, si ha:

$$\mathbb{P}(X > x) = 1 - F_X(x) = \mathrm{e}^{-\lambda x} \qquad \forall x \geq 0.$$

La proprietà di assenza di memoria, introdotta per variabili aleatorie a valori in $\mathbb{N}_0$, si estende in modo naturale al caso di variabili aleatorie che assumono valori reali non negativi.

Definizione 1.53. Una variabile aleatoria X tale che $\mathbb{P}(X \geq 0) = 1$ si dice dotata della proprietà di *assenza di memoria* se, per ogni $r, s \in [0, +\infty)$ tali che $\mathbb{P}(X > s) > 0$, soddisfa la condizione:

$$\mathbb{P}(X > r + s \,|\, X > s) = \mathbb{P}(X > r).$$

Proposizione 1.29. *Ogni variabile aleatoria esponenziale $X \sim \mathrm{Exp}(\lambda)$, con $\lambda > 0$, gode della proprietà di assenza di memoria:*

$$\mathbb{P}(X > r + s \,|\, X > s) = \mathbb{P}(X > r) \qquad \forall r, s \in [0, +\infty).$$

Dimostrazione. Dall'osservazione precedente si ha $\mathbb{P}(X > s) = \mathrm{e}^{-\lambda s} > 0$ per ogni $s \geq 0$, e quindi la probabilità condizionata è ben definita. Per $r, s \geq 0$ vale l'inclusione $\{X > r + s\} \subseteq \{X > s\}$, da cui $\{X > r + s\} \cap \{X > s\} = \{X > r + s\}$; dalla definizione di probabilità condizionata si ottiene allora:

$$\mathbb{P}(X > r + s \,|\, X > s) = \frac{\mathbb{P}\big(\{X > r + s\} \cap \{X > s\}\big)}{\mathbb{P}(X > s)} = \frac{\mathbb{P}(X > r + s)}{\mathbb{P}(X > s)} = \frac{1 - F_X(r + s)}{1 - F_X(s)}$$

$$= \frac{\mathrm{e}^{-\lambda(r+s)}}{\mathrm{e}^{-\lambda s}} = \mathrm{e}^{-\lambda r} = \mathbb{P}(X > r). \qquad \square$$

Osservazione. Dal punto di vista intuitivo, se X rappresenta il tempo di vita di un componente, la proprietà di assenza di memoria afferma che, sapendo che il componente ha funzionato fino all'istante s, la probabilità che esso funzioni per un ulteriore intervallo di durata r è la stessa che aveva un componente nuovo: il componente *non invecchia*. La variabile esponenziale svolge dunque, tra le variabili aleatorie assolutamente continue, il ruolo che la variabile geometrica svolge tra quelle discrete a valori in $\mathbb{N}$.

Definizione 1.54. Siano $a, b \in \mathbb{R}$ con $a < b$. Una variabile aleatoria assolutamente continua X si dice *uniforme* sull'intervallo $[a, b]$, e si indica con $X \sim \mathcal{U}(a, b)$, se la sua funzione densità di probabilità è data da:

$$f_X(x) = \begin{cases} \dfrac{1}{b-a} & \text{se } x \in [a, b] \\ 0 & \text{se } x \notin [a, b] \end{cases}$$

Osservazione. Integrando la densità si ottiene la funzione di ripartizione $F_X : \mathbb{R} \to [0, 1]$. Se $x < a$ la densità è nulla su $(-\infty, x]$ e quindi $F_X(x) = 0$; se $a \leq x \leq b$ si ha

$$F_X(x) = \int_a^x \frac{1}{b-a}\,\mathrm{d}t = \frac{x-a}{b-a};$$

se infine $x > b$, si ha

$$F_X(x) = \int_a^b \frac{1}{b-a}\,\mathrm{d}t = 1.$$

Riassumendo:

$$F_X(x) = \mathbb{P}(X \leq x) = \begin{cases} 0 & \text{se } x < a \\ \dfrac{x-a}{b-a} & \text{se } a \leq x \leq b \\ 1 & \text{se } x > b \end{cases}$$

Viceversa, la funzione F_X è derivabile in ogni punto $x \notin \{a, b\}$ e ivi risulta

$$\frac{\mathrm{d}F_X}{\mathrm{d}x}(x) = f_X(x);$$

in particolare

$$f_X(x) = \frac{\mathrm{d}F_X}{\mathrm{d}x}(x) = \frac{1}{b-a} \qquad \forall x \in (a, b).$$

Nei punti $x = a$ e $x = b$, in corrispondenza dei quali f_X è discontinua, la funzione F_X presenta invece due punti angolosi e non è derivabile. Il valore assegnato alla densità in tali punti è irrilevante, poiché la modifica di f_X in un numero finito di punti non altera gli integrali che definiscono F_X: la scelta dell'intervallo chiuso $[a, b]$ nella definizione è dunque puramente convenzionale.

Infine, per ogni sottointervallo $[c, d] \subseteq [a, b]$ si ha:

$$\mathbb{P}(c \leq X \leq d) = F_X(d) - F_X(c) = \frac{d-c}{b-a},$$

ovvero la probabilità che X cada in un sottointervallo di $[a, b]$ dipende soltanto dalla sua ampiezza e non dalla sua posizione, da cui il nome di distribuzione *uniforme*.

Esempio 1.20. Siano $a > -1$ e $b > 0$. Si determini la costante $k > 0$ affinché la funzione

$$f(x) = \begin{cases} k\, x^a \mathrm{e}^{-\frac{x}{b}} & \text{se } x > 0 \\ 0 & \text{se } x \leq 0 \end{cases}$$

sia la funzione densità di probabilità di una variabile aleatoria assolutamente continua.

Poiché $k > 0$, si ha $f(x) \geq 0$ per ogni $x \in \mathbb{R}$; resta da imporre la condizione di normalizzazione:

$$1 = \int_{-\infty}^{+\infty} f(x)\,\mathrm{d}x = k \int_0^{+\infty} x^a \mathrm{e}^{-\frac{x}{b}}\,\mathrm{d}x.$$

Per risolvere l'integrale si effettua la sostituzione di variabile $z = x/b$, da cui $x = bz$ e $\mathrm{d}x = b\,\mathrm{d}z$. Poiché $b > 0$, per $x \to 0^+$ si ha $z \to 0^+$ e per $x \to +\infty$ si ha $z \to +\infty$, quindi gli estremi di integrazione rimangono invariati. Sostituendo all'interno dell'integrale si ottiene:

$$\int_0^{+\infty} x^a \mathrm{e}^{-\frac{x}{b}}\,\mathrm{d}x = \int_0^{+\infty} (bz)^a \mathrm{e}^{-z}\, b\,\mathrm{d}z = b^{a+1} \int_0^{+\infty} z^{(a+1)-1} \mathrm{e}^{-z}\,\mathrm{d}z = b^{a+1}\,\Gamma(a+1).$$

Si noti che l'ipotesi $a > -1$ è essenziale: essa garantisce $a + 1 > 0$, e quindi che l'ultimo integrale sia convergente e coincida con la funzione Gamma di Eulero valutata in $a + 1$; per $a \leq -1$ l'integrale diverge in un intorno destro dell'origine e nessuna scelta di k rende f una densità. Imponendo la condizione di normalizzazione si ha allora:

$$1 = k\, b^{a+1}\,\Gamma(a+1) \implies k = \frac{1}{b^{a+1}\,\Gamma(a+1)}.$$

L'esempio precedente consente di introdurre la seguente famiglia di variabili aleatorie assolutamente continue.

Definizione 1.55. Siano $a > -1$ e $b > 0$. Una variabile aleatoria assolutamente continua X si dice *di tipo Gamma* di parametri a e b se la sua funzione densità di probabilità è data da:

$$f_X(x) = \begin{cases} \dfrac{x^a \mathrm{e}^{-\frac{x}{b}}}{b^{a+1}\,\Gamma(a+1)} & \text{se } x > 0 \\ 0 & \text{se } x \leq 0 \end{cases}$$

Osservazione. Ponendo $a = 0$ e $b = 1/\lambda$, con $\lambda > 0$, e ricordando che $\Gamma(1) = 1$ (proprietà *(ii)* della funzione Gamma), per $x > 0$ si ottiene:

$$f_X(x) = \frac{x^0 \mathrm{e}^{-\lambda x}}{(1/\lambda)^1\,\Gamma(1)} = \lambda \mathrm{e}^{-\lambda x},$$

ovvero la densità di una variabile aleatoria $\mathrm{Exp}(\lambda)$: la variabile esponenziale è un caso particolare di variabile di tipo Gamma. Si osservi inoltre che in letteratura la densità Gamma è spesso scritta in termini del parametro di *forma* $\alpha := a + 1 > 0$ e del parametro di *scala* $b > 0$:

$$f_X(x) = \frac{x^{\alpha-1} \mathrm{e}^{-\frac{x}{b}}}{b^\alpha\,\Gamma(\alpha)} \qquad \text{per } x > 0.$$

1.10.5 Quantili e mediana

Definizione 1.56. Sia X una variabile aleatoria qualsiasi e sia $\alpha \in (0,1)$. Si dice *quantile inferiore di ordine* α di X ogni numero reale x_α tale che:

$$\mathbb{P}(X \leq x_\alpha) \geq \alpha \quad \text{e} \quad \mathbb{P}(X \geq x_\alpha) \geq 1-\alpha.$$

Proposizione 1.30. *Sia X una variabile aleatoria con funzione di ripartizione F_X e sia $\alpha \in (0,1)$. Allora il numero reale*

$$q_\alpha := \inf\{\, x \in \mathbb{R} \mid F_X(x) \geq \alpha \,\}$$

è un quantile inferiore di ordine α di X. In particolare, i quantili inferiori di ogni ordine $\alpha \in (0,1)$ esistono sempre.

Dimostrazione. Si ricorda che F_X è monotòna non decrescente, continua a destra e tale che $\lim_{x\to-\infty} F_X(x) = 0$ e $\lim_{x\to+\infty} F_X(x) = 1$. Si ponga $A_\alpha := \{\, x \in \mathbb{R} \mid F_X(x) \geq \alpha \,\}$.

(*i*) Essendo $\alpha < 1$, esiste $x \in \mathbb{R}$ con $F_X(x) > \alpha$, e dunque $A_\alpha \neq \emptyset$. Essendo $\alpha > 0$, esiste $\bar{x} \in \mathbb{R}$ con $F_X(\bar{x}) < \alpha$ e, per la monotonia di F_X, ogni elemento di A_α è maggiore di $\bar{x}$: l'insieme A_α è limitato inferiormente e quindi $q_\alpha \in \mathbb{R}$.

(*ii*) Per la monotonia di F_X, se $x \in A_\alpha$ allora $[x, +\infty) \subseteq A_\alpha$; pertanto $q_\alpha + 1/n \in A_\alpha$ per ogni $n \in \mathbb{N}$ e, per la continuità a destra di F_X, si ha:

$$\mathbb{P}(X \leq q_\alpha) = F_X(q_\alpha) = \lim_{n\to+\infty} F_X\left(q_\alpha + \frac{1}{n}\right) \geq \alpha.$$

(*iii*) Per ogni $x < q_\alpha$ si ha $x \notin A_\alpha$, cioè $F_X(x) < \alpha$; passando al limite si ottiene

$$\mathbb{P}(X < q_\alpha) = F_X(q_\alpha^-) = \lim_{x\to q_\alpha^-} F_X(x) \leq \alpha,$$

e quindi, passando all'evento complementare, $\mathbb{P}(X \geq q_\alpha) = 1 - \mathbb{P}(X < q_\alpha) \geq 1-\alpha$. □

Osservazione. Si osservi che:

(*i*) il quantile inferiore di ordine α *non è in generale unico*. Ad esempio, se X è una variabile aleatoria di Bernoulli di parametro $p \in (0,1)$ e $\alpha = 1-p$, ogni $x \in [0,1]$ è un quantile inferiore di ordine α: infatti $\mathbb{P}(X \leq x) \geq 1-p$ e $\mathbb{P}(X \geq x) \geq p$ per ogni $x \in [0,1]$;

(*ii*) i valori estremi $\alpha = 0$ e $\alpha = 1$ sono esclusi dalla definizione perché, in generale, non esisterebbe alcun quantile di tali ordini. Ad esempio, se $X \sim \mathcal{N}(a,b)$, essendo $f_X(x) > 0$ per ogni $x \in \mathbb{R}$, si ha $0 < F_X(x) < 1$ per ogni $x \in \mathbb{R}$, e quindi nessun reale x soddisfa $\mathbb{P}(X \leq x) \geq 1$ oppure $\mathbb{P}(X \geq x) \geq 1$.

Proposizione 1.31. *Sia X una variabile aleatoria e sia $\alpha \in (0,1)$. Un numero reale x_α è un quantile inferiore di ordine α di X se e solo se:*

$$\alpha \leq \mathbb{P}(X \leq x_\alpha) \leq \alpha + \mathbb{P}(X = x_\alpha).$$

Dimostrazione. Poiché $\{X > x_\alpha\} = \{X \geq x_\alpha\} \setminus \{X = x_\alpha\}$ e $\{X = x_\alpha\} \subseteq \{X \geq x_\alpha\}$, passando all'evento complementare si ha:

$$\begin{aligned} \mathbb{P}(X \leq x_\alpha) &= 1 - \mathbb{P}(X > x_\alpha) = 1 - \big[\mathbb{P}(X \geq x_\alpha) - \mathbb{P}(X = x_\alpha)\big] \\ &= 1 + \mathbb{P}(X = x_\alpha) - \mathbb{P}(X \geq x_\alpha). \end{aligned} \tag{1.6}$$

$\boxed{\Rightarrow}$ Se x_α è un quantile inferiore di ordine α, la prima disuguaglianza è la prima condizione della DEFINIZIONE 1.56; utilizzando la seconda condizione $\mathbb{P}(X \geq x_\alpha) \geq 1-\alpha$ nella (1.6) si ottiene:

$$\mathbb{P}(X \leq x_\alpha) \leq 1 + \mathbb{P}(X = x_\alpha) - (1-\alpha) = \alpha + \mathbb{P}(X = x_\alpha).$$

$\boxed{\Leftarrow}$ Viceversa, se vale la doppia disuguaglianza, la prima condizione della DEFINIZIONE 1.56 è immediata; ricavando $\mathbb{P}(X \geq x_\alpha)$ dalla (1.6) e usando la seconda disuguaglianza si ha:

$$\begin{aligned}\mathbb{P}(X \geq x_\alpha) &= 1 + \mathbb{P}(X = x_\alpha) - \mathbb{P}(X \leq x_\alpha) \\ &\geq 1 + \mathbb{P}(X = x_\alpha) - \alpha - \mathbb{P}(X = x_\alpha) = 1 - \alpha.\end{aligned}$$ □

COROLLARIO 1.32. *Sia X una variabile aleatoria assolutamente continua e sia $\alpha \in (0,1)$. Un numero reale x_α è un quantile inferiore di ordine α di X se e solo se:*

$$\mathbb{P}(X \leq x_\alpha) = F_X(x_\alpha) = \int_{-\infty}^{x_\alpha} f_X(x)\,\mathrm{d}x = \alpha.$$

DIMOSTRAZIONE. Per una variabile aleatoria assolutamente continua si ha $\mathbb{P}(X = x_\alpha) = 0$, e la doppia disuguaglianza della PROPOSIZIONE 1.31 si riduce all'uguaglianza $\mathbb{P}(X \leq x_\alpha) = \alpha$. □

Osservazione. Geometricamente, il quantile inferiore x_α di una variabile aleatoria assolutamente continua è un punto che lascia alla sua sinistra un'area pari ad α sotto il grafico della densità f_X. Essendo F_X continua, con limiti 0 e 1 rispettivamente per $x \to -\infty$ e per $x \to +\infty$, l'esistenza di soluzioni dell'equazione $F_X(x) = \alpha$ discende anche dal teorema dei valori intermedi; la soluzione è inoltre unica se F_X è strettamente crescente in un intorno dell'insieme delle soluzioni, come accade ad esempio quando $f_X > 0$ su un intervallo che le contiene.

DEFINIZIONE 1.57. Sia X una variabile aleatoria assolutamente continua e sia $\alpha \in (0,1)$. Si dice *quantile superiore di ordine* α di X ogni numero reale ξ_α tale che:

$$\mathbb{P}(X \geq \xi_\alpha) = \alpha.$$

Osservazione. Poiché X è assolutamente continua, si ha $\mathbb{P}(X \leq \xi_\alpha) = \mathbb{P}(X < \xi_\alpha) = 1 - \mathbb{P}(X \geq \xi_\alpha)$; pertanto

$$\mathbb{P}(X \geq \xi_\alpha) = \alpha \iff \mathbb{P}(X \leq \xi_\alpha) = 1 - \alpha,$$

e, per il COROLLARIO 1.32, i quantili superiori di ordine α coincidono con i quantili inferiori di ordine $1-\alpha$:

$$\xi_\alpha = x_{1-\alpha}.$$

Geometricamente, ξ_α lascia alla sua destra un'area pari ad α sotto il grafico della densità f_X.

DEFINIZIONE 1.58. Sia X una variabile aleatoria. Si dice *mediana* di X ogni quantile inferiore di ordine $1/2$, ovvero ogni numero reale M tale che:

$$\mathbb{P}(X \leq M) \geq \frac{1}{2} \quad \text{e} \quad \mathbb{P}(X \geq M) \geq \frac{1}{2}.$$

Osservazione. Se X è assolutamente continua, per il COROLLARIO 1.32 un reale M è una mediana di X se e solo se

$$F_X(M) = \mathbb{P}(X \leq M) = \frac{1}{2},$$

ovvero se e solo se M divide la regione sottesa al grafico della densità f_X in due parti di uguale area, pari a $1/2$.

ESEMPIO 1.21. Sia $X \sim \text{Exp}(\lambda)$, con $\lambda > 0$. Si determini la mediana M di X.

Essendo X assolutamente continua, la mediana è caratterizzata dalla condizione $F_X(M) = 1/2$. Poiché $F_X(x) = 0$ per $x < 0$, deve essere $M \geq 0$, e quindi:

$$\begin{aligned}\mathbb{P}(X \leq M) = F_X(M) = 1 - \mathrm{e}^{-\lambda M} = \frac{1}{2} &\iff \mathrm{e}^{-\lambda M} = \frac{1}{2} \\ &\iff -\lambda M = \log\frac{1}{2} = -\log 2,\end{aligned}$$

dove log indica il logaritmo naturale. Si ottiene dunque:

$$M = \frac{\log 2}{\lambda}.$$

La mediana è unica, poiché F_X è strettamente crescente su $[0, +\infty)$. Procedendo allo stesso modo, per ogni $\alpha \in (0, 1)$ si ricava il quantile inferiore di ordine α:

$$1 - \mathrm{e}^{-\lambda x_\alpha} = \alpha \iff x_\alpha = -\frac{\log(1-\alpha)}{\lambda}.$$

ESEMPIO 1.22. Sia $X \sim \mathcal{U}(-3, 2)$. Si determini la mediana M di X.

Essendo $b - a = 2 - (-3) = 5$, la funzione di ripartizione di X è data da:

$$F_X(x) = \begin{cases} 0 & \text{se } x < -3 \\ \dfrac{x+3}{5} & \text{se } -3 \leq x \leq 2 \\ 1 & \text{se } x > 2 \end{cases}$$

Al di fuori dell'intervallo $[-3, 2]$ la funzione F_X assume solo i valori 0 e 1, quindi la condizione $F_X(M) = 1/2$ impone $M \in [-3, 2]$ e:

$$\frac{M+3}{5} = \frac{1}{2} \iff 2M + 6 = 5 \iff M = -\frac{1}{2}.$$

La mediana coincide con il punto medio dell'intervallo $[-3, 2]$. Più in generale, se $X \sim \mathcal{U}(a, b)$, dalla condizione

$$\frac{M-a}{b-a} = \frac{1}{2}$$

si ricava

$$M = \frac{a+b}{2}.$$

1.11 Trasformazioni di variabili aleatorie

Sia X una variabile aleatoria definita sullo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$ e sia $g : \mathbb{R} \to \mathbb{R}$ una funzione. In questa sezione si studia la variabile aleatoria $Y = g \circ X$, ottenuta *trasformando* X mediante g, e se ne ricavano la funzione di ripartizione e, quando esiste, la funzione densità di probabilità a partire da quelle di X.

Definizione 1.59. Una funzione $g : \mathbb{R} \to \mathbb{R}$ si dice $\mathcal{B}$-*misurabile* (o *boreliana*) se

$$g^{-1}(B) = \{ x \in \mathbb{R} \mid g(x) \in B \} \in \mathcal{B} \qquad \forall B \in \mathcal{B}.$$

Osservazione. Tutte le funzioni di uso comune sono boreliane: lo sono, ad esempio, le funzioni continue, le funzioni monotòne e le funzioni costanti a tratti; inoltre somme, prodotti e composizioni di funzioni boreliane sono boreliane. Nel seguito tutte le funzioni g considerate saranno tacitamente supposte boreliane.

Proposizione 1.33. *Siano $X : \Omega \to \mathbb{R}$ una variabile aleatoria definita sullo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$ e $g : \mathbb{R} \to \mathbb{R}$ una funzione $\mathcal{B}$-misurabile. Allora $Y := g \circ X : \Omega \to \mathbb{R}$ è una variabile aleatoria e, per ogni $B \in \mathcal{B}$, si ha:*

$$\mathbb{P}(Y \in B) = \mathbb{P}\big(X \in g^{-1}(B)\big).$$

Dimostrazione. Per ogni $B \in \mathcal{B}$ si ha $g^{-1}(B) \in \mathcal{B}$, poiché g è $\mathcal{B}$-misurabile; essendo X una variabile aleatoria, si ottiene allora:

$$Y^{-1}(B) = \{ \omega \in \Omega \mid g\big(X(\omega)\big) \in B \} = \{ \omega \in \Omega \mid X(\omega) \in g^{-1}(B) \} = X^{-1}\big(g^{-1}(B)\big) \in \mathcal{F}.$$

Dunque Y è $\mathcal{F}$-misurabile, e passando alla probabilità dell'evento $Y^{-1}(B) = X^{-1}\big(g^{-1}(B)\big)$ si ottiene la tesi. □

Notazione 1.60. Nel seguito si scrive più semplicemente $Y = g(X)$ in luogo di $Y = g \circ X$.

1.11.1 Trasformazioni monotòne

Teorema 1.34. *Siano X una variabile aleatoria con funzione di ripartizione F_X e $g : \mathbb{R} \to \mathbb{R}$ una funzione continua e strettamente monotòna, e sia $Y = g(X)$. Allora, per ogni $y \in g(\mathbb{R})$, si ha:*

$$F_Y(y) = \begin{cases} F_X\big(g^{-1}(y)\big) & \text{se } g \text{ è strettamente crescente} \\ 1 - F_X\big(g^{-1}(y)^-\big) & \text{se } g \text{ è strettamente decrescente} \end{cases}$$

dove, come di consueto, $F_X(x^-) = \mathbb{P}(X < x)$.

Dimostrazione. Una funzione continua e strettamente monotòna è invertibile sulla propria immagine $g(\mathbb{R})$, che è un intervallo, e la sua inversa $g^{-1} : g(\mathbb{R}) \to \mathbb{R}$ è a sua volta continua e strettamente monotòna, nello stesso senso di g; in particolare g è $\mathcal{B}$-misurabile e Y è una variabile aleatoria per la Proposizione 1.33. Sia $y \in g(\mathbb{R})$.

(*i*) Se g è strettamente crescente, per ogni $x \in \mathbb{R}$ si ha $g(x) \le y \iff x \le g^{-1}(y)$, e dunque:

$$F_Y(y) = \mathbb{P}\big(g(X) \le y\big) = \mathbb{P}\big(X \le g^{-1}(y)\big) = F_X\big(g^{-1}(y)\big).$$

(*ii*) Se g è strettamente decrescente, per ogni $x \in \mathbb{R}$ si ha $g(x) \leq y \iff x \geq g^{-1}(y)$, e dunque, per il punto (*vii*) del Teorema 1.25:

$$F_Y(y) = \mathbb{P}\big(g(X) \leq y\big) = \mathbb{P}\big(X \geq g^{-1}(y)\big) = 1 - F_X\big(g^{-1}(y)^-\big). \qquad \square$$

Osservazione. Per $y \notin g(\mathbb{R})$ la funzione di ripartizione di Y si determina direttamente: essendo $g(\mathbb{R})$ un intervallo, se y è minore di ogni elemento di $g(\mathbb{R})$ si ha $F_Y(y) = 0$, mentre se y è maggiore di ogni elemento di $g(\mathbb{R})$ si ha $F_Y(y) = 1$. Se inoltre X è assolutamente continua, allora F_X è continua e nel caso decrescente si può scrivere semplicemente $F_Y(y) = 1 - F_X\big(g^{-1}(y)\big)$.

Teorema 1.35. *Siano X una variabile aleatoria assolutamente continua con funzione densità di probabilità f_X e $g : \mathbb{R} \to \mathbb{R}$ una funzione strettamente monotòna e derivabile, con $g'(x) \neq 0$ per ogni $x \in \mathbb{R}$, e sia $Y = g(X)$. Allora Y è assolutamente continua, con funzione densità di probabilità*

$$f_Y(y) = \begin{cases} f_X\big(g^{-1}(y)\big) \cdot \dfrac{1}{\big|g'\big(g^{-1}(y)\big)\big|} & \text{se } y \in g(\mathbb{R}) \\ 0 & \text{se } y \notin g(\mathbb{R}) \end{cases}$$

nei punti y in cui f_X è continua in $g^{-1}(y)$.

Dimostrazione. Essendo g derivabile con derivata mai nulla, per il teorema di derivazione della funzione inversa g^{-1} è derivabile su $g(\mathbb{R})$ e si ha

$$\frac{\mathrm{d}g^{-1}}{\mathrm{d}y}(y) = \frac{1}{g'\big(g^{-1}(y)\big)} \qquad \forall y \in g(\mathbb{R}). \tag{1.7}$$

Sia $y \in g(\mathbb{R})$ tale che f_X sia continua in $g^{-1}(y)$; per il teorema fondamentale del calcolo integrale F_X è derivabile in $g^{-1}(y)$, con derivata $f_X\big(g^{-1}(y)\big)$.

(*i*) Se g è strettamente crescente, per il Teorema 1.34 si ha $F_Y = F_X \circ g^{-1}$ su $g(\mathbb{R})$. Derivando con la regola della catena e usando la (1.7), essendo $g' > 0$, si ottiene:

$$\begin{aligned} f_Y(y) = \frac{\mathrm{d}F_Y}{\mathrm{d}y}(y) &= f_X\big(g^{-1}(y)\big) \cdot \frac{\mathrm{d}g^{-1}}{\mathrm{d}y}(y) = f_X\big(g^{-1}(y)\big) \cdot \frac{1}{g'\big(g^{-1}(y)\big)} \\ &= f_X\big(g^{-1}(y)\big) \cdot \frac{1}{\big|g'\big(g^{-1}(y)\big)\big|}. \end{aligned}$$

(*ii*) Se g è strettamente decrescente, essendo F_X continua, per il Teorema 1.34 si ha $F_Y = 1 - F_X \circ g^{-1}$ su $g(\mathbb{R})$. Derivando allo stesso modo, essendo $g' < 0$, si ottiene:

$$f_Y(y) = \frac{\mathrm{d}F_Y}{\mathrm{d}y}(y) = -f_X\big(g^{-1}(y)\big) \cdot \frac{1}{g'\big(g^{-1}(y)\big)} = f_X\big(g^{-1}(y)\big) \cdot \frac{1}{\big|g'\big(g^{-1}(y)\big)\big|}.$$

Infine, se $y \notin g(\mathbb{R})$, la funzione F_Y è costante (pari a 0 oppure a 1) in un intorno di y, e dunque $f_Y(y) = 0$. La funzione f_Y così definita è non negativa e, per quanto appena visto, F_Y ne è una primitiva: Y è pertanto assolutamente continua con densità f_Y. $\square$

Osservazione. Il fattore $1/\left|g'\left(g^{-1}(y)\right)\right|$ prende il nome di *fattore jacobiano* della trasformazione: esso coincide con il valore assoluto della derivata dell'inversa, $\left|(g^{-1})'(y)\right|$, e tiene conto di come g dilata o contrae le lunghezze. Si osservi che il valore assoluto rende la formula identica nei due casi, crescente e decrescente, e che il teorema richiede che g sia monotòna su tutto $\mathbb{R}$; se g è monotòna soltanto a tratti, come nell'esempio seguente, occorre procedere direttamente a partire dalla funzione di ripartizione.

Esempio 1.23. Sia $X \sim \mathcal{N}(0,1)$, con densità

$$f_X(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \qquad \text{per } x \in \mathbb{R},$$

e sia $Y = X^2$. La funzione $g(x) = x^2$ non è monotòna su $\mathbb{R}$, per cui si procede a partire dalla funzione di ripartizione. Poiché $Y \geq 0$, si ha $F_Y(y) = 0$ per $y < 0$; per $y \geq 0$, invece, essendo X assolutamente continua,

$$F_Y(y) = \mathbb{P}\left(X^2 \leq y\right) = \mathbb{P}\left(-\sqrt{y} \leq X \leq \sqrt{y}\right) = F_X\left(\sqrt{y}\right) - F_X\left(-\sqrt{y}\right).$$

Derivando rispetto a y, per $y > 0$, e sfruttando la simmetria $f_X(-x) = f_X(x)$ della densità normale, si ottiene:

$$\begin{aligned} f_Y(y) &= f_X\left(\sqrt{y}\right) \cdot \frac{1}{2\sqrt{y}} + f_X\left(-\sqrt{y}\right) \cdot \frac{1}{2\sqrt{y}} = \frac{f_X\left(\sqrt{y}\right)}{\sqrt{y}} \\ &= \frac{1}{\sqrt{2\pi y}} \exp\left(-\frac{y}{2}\right). \end{aligned}$$

Riassumendo:

$$f_Y(y) = \begin{cases} \dfrac{1}{\sqrt{2\pi y}} \exp\left(-\dfrac{y}{2}\right) & \text{se } y > 0 \\ 0 & \text{se } y \leq 0 \end{cases}$$

La variabile aleatoria Y prende il nome di *chi quadro con un grado di libertà*.

Definizione 1.61. Sia $n \in \mathbb{N}$. Una variabile aleatoria assolutamente continua X si dice *chi quadro con n gradi di libertà*, e si indica con $X \sim \chi^2(n)$, se la sua funzione densità di probabilità è data da:

$$f_X(x) = \begin{cases} \dfrac{x^{n/2-1} \mathrm{e}^{-x/2}}{2^{n/2}\, \Gamma\left(\dfrac{n}{2}\right)} & \text{se } x > 0 \\ 0 & \text{se } x \leq 0 \end{cases}$$

Osservazione. Si osservi che:

(*i*) la variabile $\chi^2(n)$ è una variabile di tipo Gamma (Definizione 1.55) di parametri $a = n/2-1$ e $b = 2$: infatti $b^{a+1}\, \Gamma(a+1) = 2^{n/2}\, \Gamma(n/2)$, e la condizione di normalizzazione è quindi garantita dall'Esempio 1.20;

(*ii*) per $n = 1$, ricordando che $\Gamma(1/2) = \sqrt{\pi}$ (Esempio 1.3), si ha per $x > 0$

$$f_X(x) = \frac{x^{-1/2} \mathrm{e}^{-x/2}}{2^{1/2}\sqrt{\pi}} = \frac{1}{\sqrt{2\pi x}} \exp\left(-\frac{x}{2}\right),$$

in accordo con la densità ottenuta nell'Esempio 1.23: il quadrato di una variabile normale standard è una variabile $\chi^2(1)$;

(*iii*) per $n = 2$, essendo $\Gamma(1) = 1$, si ha per $x > 0$

$$f_X(x) = \frac{x^0 \mathrm{e}^{-x/2}}{2\,\Gamma(1)} = \frac{1}{2}\,\mathrm{e}^{-x/2},$$

ovvero la densità di una variabile esponenziale di parametro $\lambda = 1/2$: $\chi^2(2) \sim \mathrm{Exp}(1/2)$.

1.11.2 Trasformazioni di variabili aleatorie discrete

Proposizione 1.36. *Siano X una variabile aleatoria discreta con supporto S_X e funzione massa di probabilità p_X, e $g : \mathbb{R} \to \mathbb{R}$ una funzione. Allora $Y = g(X)$ è una variabile aleatoria discreta con supporto $S_Y = g(S_X)$ e, per ogni $y \in \mathbb{R}$, si ha:*

$$p_Y(y) = \mathbb{P}(Y = y) = \sum_{\substack{x \in S_X \\ x \in g^{-1}(\{y\})}} p_X(x),$$

$$F_Y(y) = \mathbb{P}(Y \le y) = \sum_{\substack{x \in S_X \\ x \in g^{-1}((-\infty, y])}} p_X(x).$$

Dimostrazione. Omessa. □

Osservazione. L'insieme $g(S_X)$ è al più numerabile, essendo immagine di un insieme al più numerabile, e ha probabilità 1 poiché contiene $g\big(X(\omega)\big)$ per ogni ω con $X(\omega) \in S_X$. Le due formule esprimono il fatto che l'evento $\{Y = y\}$ è l'unione disgiunta degli eventi $\{X = x\}$ al variare di x nella controimmagine $g^{-1}\big(\{y\}\big) \cap S_X$, e analogamente per $\{Y \le y\}$ con $g^{-1}\big((-\infty, y]\big) \cap S_X$. A differenza del caso continuo, non è richiesta alcuna ipotesi di monotonia su g: se g non è iniettiva su S_X, più valori di X confluiscono nello stesso valore di Y e le relative probabilità si sommano.

Esempio 1.24. Sia X una variabile aleatoria di Bernoulli di parametro $p \in (0, 1)$, con $S_X = \{0, 1\}$ e $p_X(x) = p^x(1-p)^{1-x}$, e sia $Y = \mathrm{e}^X$. La funzione $g(x) = \mathrm{e}^x$ è iniettiva, per cui $S_Y = \{1, \mathrm{e}\}$ e

$$p_Y(1) = \mathbb{P}(Y = 1) = \mathbb{P}\big(\mathrm{e}^X = 1\big) = \mathbb{P}(X = 0) = 1 - p,$$
$$p_Y(\mathrm{e}) = \mathbb{P}(Y = \mathrm{e}) = \mathbb{P}\big(\mathrm{e}^X = \mathrm{e}\big) = \mathbb{P}(X = 1) = p.$$

Essendo $x = \log y$ per $y \in S_Y$, la funzione massa di probabilità di Y si può scrivere in forma compatta come

$$p_Y(y) = p_X(\log y) = p^{\log y}(1-p)^{1-\log y} \qquad \text{per } y \in \{1, \mathrm{e}\},$$

e la funzione di ripartizione $F_Y : \mathbb{R} \to [0, 1]$ è costruita come segue:

$$F_Y(y) = \mathbb{P}(Y \le y) = \begin{cases} 0 & \text{se } y < 1 \\ 1 - p & \text{se } 1 \le y < \mathrm{e} \\ 1 & \text{se } y \ge \mathrm{e} \end{cases}$$

Notazione 1.62. Per una variabile aleatoria discreta con supporto finito è comodo riassumere supporto e funzione massa di probabilità in una *tabella di distribuzione*, scrivendo nella prima riga i valori del supporto e nella seconda le corrispondenti probabilità. Ad esempio, per le variabili aleatorie X e Y dell'Esempio 1.24 si scrive:

$$X \sim \begin{pmatrix} 0 & 1 \\ 1-p & p \end{pmatrix}, \qquad Y \sim \begin{pmatrix} 1 & \mathrm{e} \\ 1-p & p \end{pmatrix}.$$

Esempio 1.25. Sia X una variabile aleatoria discreta con tabella di distribuzione

$$X \sim \begin{pmatrix} -1 & 0 & 1 \\ 1/3 & 1/2 & 1/6 \end{pmatrix},$$

e sia $Y = X^2$. La funzione $g(x) = x^2$ non è iniettiva su $S_X = \{-1, 0, 1\}$: i valori -1 e 1 hanno la stessa immagine, per cui $S_Y = \{0, 1\}$ e

$$p_Y(0) = \mathbb{P}(Y = 0) = \mathbb{P}\big(X^2 = 0\big) = \mathbb{P}(X = 0) = \frac{1}{2},$$
$$p_Y(1) = \mathbb{P}(Y = 1) = \mathbb{P}\big(X^2 = 1\big) = \mathbb{P}\big(\{X = -1\} \cup \{X = 1\}\big) = \frac{1}{3} + \frac{1}{6} = \frac{1}{2}.$$

Dunque Y è una variabile di Bernoulli di parametro $1/2$, con tabella di distribuzione e funzione di ripartizione

$$Y \sim \begin{pmatrix} 0 & 1 \\ 1/2 & 1/2 \end{pmatrix}, \qquad F_Y(y) = \begin{cases} 0 & \text{se } y < 0 \\ 1/2 & \text{se } 0 \le y < 1 \\ 1 & \text{se } y \ge 1 \end{cases}$$

1.11.3 La variabile aleatoria lognormale

Esempio 1.26. Sia $X \sim \mathcal{N}(0, 1)$ e sia $Y = \mathrm{e}^X$. La funzione $g(x) = \mathrm{e}^x$ è strettamente crescente e derivabile su $\mathbb{R}$, con $g'(x) = \mathrm{e}^x > 0$, inversa $g^{-1}(y) = \log y$ e immagine $g(\mathbb{R}) = (0, +\infty)$. Per il Teorema 1.35, per $y > 0$ si ha:

$$f_Y(y) = f_X(\log y) \cdot \frac{1}{g'(\log y)} = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(\log y)^2}{2}\right) \cdot \frac{1}{\exp(\log y)}$$
$$= \frac{1}{y\sqrt{2\pi}} \exp\left(-\frac{(\log y)^2}{2}\right),$$

mentre $f_Y(y) = 0$ per $y \le 0$. La variabile aleatoria Y prende il nome di *lognormale* (standard), poiché il suo logaritmo $\log Y = X$ è una variabile normale. Si osservi che l'esponente contiene il *quadrato* di $\log y$, mentre il fattore jacobiano $1/y$ resta fuori dall'esponenziale: la densità lognormale non si riduce a $\exp(-\log y/2)/\sqrt{2\pi y}$, espressione che non è neppure una densità, poiché $\exp(-\log y/2) = y^{-1/2}$ e l'integrale di $1/y$ su $(0, +\infty)$ diverge.

Esempio 1.27. Più in generale, siano $X \sim \mathcal{N}(a, b)$, con $a \in \mathbb{R}$ e $b > 0$, e $Y = \mathrm{e}^X$. Procedendo esattamente come nell'Esempio 1.26, con

$$f_X(x) = \frac{1}{\sqrt{2\pi b}} \exp\left(-\frac{(x-a)^2}{2b}\right),$$

si ottiene, per $y > 0$:

$$f_Y(y) = f_X(\log y) \cdot \frac{1}{y} = \frac{1}{y\sqrt{2\pi b}} \exp\left(-\frac{(\log y - a)^2}{2b}\right),$$

e $f_Y(y) = 0$ per $y \leq 0$. La variabile aleatoria Y si dice *lognormale* di parametri a e b; per $a = 0$ e $b = 1$ si ritrova l'Esempio 1.26. Si verifica la condizione di normalizzazione con la sostituzione $x = \log y$, da cui $\mathrm{d}y = \mathrm{e}^x \,\mathrm{d}x = y\,\mathrm{d}x$:

$$\int_0^{+\infty} f_Y(y)\,\mathrm{d}y = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi b}} \exp\left(-\frac{(x-a)^2}{2b}\right)\mathrm{d}x = 1,$$

essendo l'ultimo integrale quello della densità normale $\mathcal{N}(a, b)$.

1.12 Vettori aleatori

Si estende ora la nozione di variabile aleatoria al caso di più variabili considerate simultaneamente sullo stesso spazio di probabilità.

Definizione 1.63. Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia $n \in \mathbb{N}$. Si chiama *vettore aleatorio* (n-dimensionale) una n-upla $\boldsymbol{X} = (X_1, \ldots, X_n)$ di variabili aleatorie $X_i : \Omega \to \mathbb{R}$, $\mathcal{F}$-misurabili per ogni $i \in I_n$. Il vettore aleatorio $\boldsymbol{X}$ si identifica con la funzione definita di seguito.

$$\begin{aligned} \boldsymbol{X} : \Omega &\longrightarrow \mathbb{R}^n \\ \omega &\longmapsto \big(X_1(\omega), \ldots, X_n(\omega)\big) \end{aligned}$$

Notazione 1.64. Nel seguito, per alleggerire la notazione, l'evento $\{\omega \in \Omega \mid X_1(\omega) \leq x_1, \ldots, X_n(\omega) \leq x_n\}$ si indica con $\{X_1 \leq x_1, \ldots, X_n \leq x_n\}$, e analogamente per le altre condizioni; la virgola tra le condizioni denota l'intersezione dei corrispondenti eventi.

1.12.1 Funzione di ripartizione congiunta

Definizione 1.65. Sia $\boldsymbol{X} = (X_1, \ldots, X_n)$ un vettore aleatorio definito sullo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$. Si definisce *funzione di ripartizione congiunta* (o *di distribuzione congiunta*) del vettore $\boldsymbol{X}$ la funzione $F_{X_1,\ldots,X_n} : \mathbb{R}^n \to [0, 1]$ tale che

$$\begin{aligned} F_{X_1,\ldots,X_n}(x_1, \ldots, x_n) &:= \mathbb{P}\Big(\{\omega \in \Omega \mid X_1(\omega) \leq x_1, \ldots, X_n(\omega) \leq x_n\}\Big) \\ &= \mathbb{P}(X_1 \leq x_1, \ldots, X_n \leq x_n). \end{aligned}$$

Si scrive anche $F_{\boldsymbol{X}}$ in luogo di $F_{X_1,\ldots,X_n}$.

Osservazione. L'insieme

$$\{X_1 \leq x_1, \ldots, X_n \leq x_n\} = \bigcap_{i=1}^{n} X_i^{-1}\big((-\infty, x_i]\big)$$

è un evento di $\mathcal{F}$, in quanto intersezione finita di eventi, e dunque la definizione è ben posta.

Proposizione 1.37 (Proprietà della funzione di ripartizione congiunta). *Sia dato un vettore aleatorio $\boldsymbol{X} = (X_1, \dots, X_n)$ con funzione di ripartizione congiunta $F_{\boldsymbol{X}}$. Allora:*

(*i*) *per ogni $k \in I_n$, fissate le altre variabili, si ha*

$$\lim_{x_k \to -\infty} F_{\boldsymbol{X}}(x_1, \dots, x_k, \dots, x_n) = 0;$$

(*ii*) *per ogni $k \in I_n$, fissate le altre variabili, si ha*

$$\begin{aligned}\lim_{x_k \to +\infty} F_{\boldsymbol{X}}(x_1, \dots, x_k, \dots, x_n) &= \mathbb{P}(X_1 \le x_1, \dots, X_{k-1} \le x_{k-1}, \\ &\qquad X_{k+1} \le x_{k+1}, \dots, X_n \le x_n) \\ &= F_{X_1,\dots,X_{k-1},X_{k+1},\dots,X_n}(x_1, \dots, x_{k-1}, x_{k+1}, \dots, x_n);\end{aligned}$$

(*iii*) *facendo tendere tutte le variabili a $+\infty$, si ha*

$$\lim_{\substack{x_1 \to +\infty \\ \dots \\ x_n \to +\infty}} F_{\boldsymbol{X}}(x_1, \dots, x_n) = 1;$$

(*iv*) *più in generale, per ogni $m \in I_n$ con $m < n$, facendo tendere a $+\infty$ le prime m variabili si ha*

$$\lim_{\substack{x_1 \to +\infty \\ \dots \\ x_m \to +\infty}} F_{\boldsymbol{X}}(x_1, \dots, x_n) = F_{X_{m+1},\dots,X_n}(x_{m+1}, \dots, x_n),$$

e analogamente per qualsiasi altra scelta di m variabili.

Dimostrazione. Si procede come nella dimostrazione della Proposizione 1.24, sfruttando la *continuità della misura di probabilità* e la monotonia di $F_{\boldsymbol{X}}$ in ciascuna variabile, che consente di calcolare i limiti lungo successioni di interi.

(*i*) Fissate le altre variabili, per ogni $h \in \mathbb{N}$ si ponga $A_h := \{X_1 \le x_1, \dots, X_k \le -h, \dots, X_n \le x_n\}$. La successione $\{A_h\}_{h\in\mathbb{N}}$ è monotòna decrescente e converge a

$$\bigcap_{h=1}^{+\infty} A_h \subseteq \bigcap_{h=1}^{+\infty} \{X_k \le -h\} = \emptyset,$$

per cui $\lim_{h\to+\infty} F_{\boldsymbol{X}}(x_1, \dots, -h, \dots, x_n) = \lim_{h\to+\infty} \mathbb{P}(A_h) = \mathbb{P}(\emptyset) = 0$.

(*ii*) Fissate le altre variabili, per ogni $h \in \mathbb{N}$ si ponga ora $A_h := \{X_1 \le x_1, \dots, X_k \le h, \dots, X_n \le x_n\}$. La successione $\{A_h\}_{h\in\mathbb{N}}$ è monotòna crescente e, poiché

$$\bigcup_{h=1}^{+\infty} \{X_k \le h\} = \Omega,$$

converge a

$$\bigcup_{h=1}^{+\infty} A_h = \{X_1 \le x_1, \dots, X_{k-1} \le x_{k-1}, X_{k+1} \le x_{k+1}, \dots, X_n \le x_n\},$$

da cui la tesi, passando alla probabilità.

(*iii*)–(*iv*) Si applica ripetutamente il punto (*ii*), una variabile alla volta: ogni passaggio al limite elimina una variabile dalla funzione di ripartizione. Eliminate m variabili si ottiene la (*iv*); eliminate tutte le n variabili, l'evento residuo è Ω e si ottiene la (*iii*). □

Definizione 1.66. Nelle notazioni della Proposizione 1.37, la funzione $F_{X_{m+1},\dots,X_n}$, cioè la funzione di ripartizione congiunta del sottovettore $(X_{m+1},\dots,X_n)$, prende il nome di *funzione di ripartizione marginale* del vettore $\boldsymbol{X}$ relativa alle variabili $X_{m+1},\dots,X_n$. In particolare, per ogni $k \in I_n$, la funzione di ripartizione F_{X_k} della sola variabile X_k si ottiene dalla congiunta facendo tendere a $+\infty$ tutte le altre variabili.

1.12.2 Vettori aleatori assolutamente continui e discreti

Definizione 1.67. Un vettore aleatorio $\boldsymbol{X} = (X_1,\dots,X_n)$ si dice *assolutamente continuo* se esiste una funzione $f_{X_1,\dots,X_n} : \mathbb{R}^n \to [0,+\infty)$ integrabile tale che

$$F_{X_1,\dots,X_n}(x_1,\dots,x_n) = \int_{-\infty}^{x_1}\int_{-\infty}^{x_2}\cdots\int_{-\infty}^{x_n} f_{X_1,\dots,X_n}(y_1,\dots,y_n)\,\mathrm{d}y_n\cdots\mathrm{d}y_2\,\mathrm{d}y_1$$

per ogni $(x_1,\dots,x_n) \in \mathbb{R}^n$. La funzione $f_{X_1,\dots,X_n}$, indicata anche con $f_{\boldsymbol{X}}$, prende il nome di *funzione densità di probabilità congiunta* del vettore $\boldsymbol{X}$.

Osservazione. Dalla definizione e dalla proprietà (*iii*) discende la *condizione di normalizzazione*

$$\int_{-\infty}^{+\infty}\cdots\int_{-\infty}^{+\infty} f_{\boldsymbol{X}}(x_1,\dots,x_n)\,\mathrm{d}x_1\cdots\mathrm{d}x_n = 1,$$

e, più in generale, per ogni boreliano $B \in \mathcal{B}(\mathbb{R}^n)$ si ha

$$\mathbb{P}(\boldsymbol{X} \in B) = \int_B f_{\boldsymbol{X}}(x_1,\dots,x_n)\,\mathrm{d}x_1\cdots\mathrm{d}x_n,$$

dove $\mathcal{B}(\mathbb{R}^n)$ denota la σ-algebra di Borel di $\mathbb{R}^n$, generata dai rettangoli $(a_1,b_1]\times\cdots\times(a_n,b_n]$. Inoltre, nei punti in cui $f_{\boldsymbol{X}}$ è continua, per il teorema fondamentale del calcolo integrale applicato a ciascuna variabile si ha

$$f_{\boldsymbol{X}}(x_1,\dots,x_n) = \frac{\partial^n F_{\boldsymbol{X}}}{\partial x_1\,\partial x_2\cdots\partial x_n}(x_1,\dots,x_n).$$

Definizione 1.68. Un vettore aleatorio $\boldsymbol{X} = (X_1,\dots,X_n)$ si dice *discreto* se ciascuna sua componente X_i è una variabile aleatoria discreta. Si definisce *funzione massa di probabilità congiunta* del vettore $\boldsymbol{X}$ la funzione

$$\begin{aligned} p_{X_1,\dots,X_n} : \mathbb{R}^n &\longrightarrow [0,1] \\ (x_1,\dots,x_n) &\longmapsto \mathbb{P}(X_1 = x_1,\dots,X_n = x_n) \end{aligned}$$

indicata anche con $p_{\boldsymbol{X}}$; essa è diversa da zero soltanto sui punti del supporto $S_{\boldsymbol{X}} \subseteq S_{X_1}\times\cdots\times S_{X_n}$, insieme al più numerabile, e soddisfa la condizione di normalizzazione

$$\sum_{(x_1,\dots,x_n)\in S_{\boldsymbol{X}}} p_{\boldsymbol{X}}(x_1,\dots,x_n) = 1.$$

1.12.3 Il caso bidimensionale

Si particolarizzano ora le definizioni precedenti al caso $n = 2$, che è quello di maggiore interesse per il seguito. Sia (X, Y) un vettore aleatorio definito sullo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$.

(*i*) La funzione di ripartizione congiunta è $F_{X,Y}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$ per ogni $(x, y) \in \mathbb{R}^2$.

(*ii*) Le funzioni di ripartizione marginali si ottengono come

$$\lim_{x \to +\infty} F_{X,Y}(x, y) = F_Y(y), \qquad \lim_{y \to +\infty} F_{X,Y}(x, y) = F_X(x).$$

(*iii*) Se il vettore è assolutamente continuo, la densità congiunta $f_{X,Y} : \mathbb{R}^2 \to [0, +\infty)$ è tale che

$$F_{X,Y}(x, y) = \int_{-\infty}^{x} \int_{-\infty}^{y} f_{X,Y}(r, s)\, \mathrm{d}s\, \mathrm{d}r \qquad \forall (x, y) \in \mathbb{R}^2,$$

e nei punti di continuità di $f_{X,Y}$ si ha

$$f_{X,Y}(x, y) = \frac{\partial^2 F_{X,Y}}{\partial x\, \partial y}(x, y).$$

Proposizione 1.38 (Densità marginali). *Sia (X, Y) un vettore aleatorio assolutamente continuo con densità congiunta $f_{X,Y}$. Allora X e Y sono variabili aleatorie assolutamente continue, con funzioni densità di probabilità*

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y)\, \mathrm{d}y, \qquad f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y)\, \mathrm{d}x,$$

dette densità marginali *del vettore* (X, Y).

Dimostrazione. Facendo tendere $x \to +\infty$ nell'espressione integrale di $F_{X,Y}$ e scambiando l'ordine di integrazione, per ogni $y \in \mathbb{R}$ si ottiene

$$\begin{aligned} F_Y(y) = \lim_{x \to +\infty} F_{X,Y}(x, y) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{y} f_{X,Y}(r, s)\, \mathrm{d}s\, \mathrm{d}r \\ &= \int_{-\infty}^{y} \left(\int_{-\infty}^{+\infty} f_{X,Y}(r, s)\, \mathrm{d}r \right) \mathrm{d}s, \end{aligned}$$

ovvero F_Y è l'integrale da $-\infty$ a y della funzione non negativa

$$s \longmapsto \int_{-\infty}^{+\infty} f_{X,Y}(r, s)\, \mathrm{d}r :$$

questa è dunque una densità di Y, e derivando rispetto a y nei suoi punti di continuità si ha

$$f_Y(y) = \frac{\mathrm{d}F_Y}{\mathrm{d}y}(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y)\, \mathrm{d}x.$$

Analogamente, facendo tendere $y \to +\infty$, si ottiene

$$F_X(x) = \int_{-\infty}^{x} \left(\int_{-\infty}^{+\infty} f_{X,Y}(r, s)\, \mathrm{d}s \right) \mathrm{d}r$$

e quindi

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y)\, \mathrm{d}y. \qquad \square$$

Osservazione. Nel caso discreto le *funzioni massa marginali* si ottengono sommando, anziché integrando, la funzione massa congiunta rispetto all'altra variabile:

$$p_X(x) = \sum_{y \in S_Y} p_{X,Y}(x,y), \qquad p_Y(y) = \sum_{x \in S_X} p_{X,Y}(x,y).$$

Si osservi che le marginali sono determinate dalla congiunta, ma non viceversa: vettori aleatori con le stesse marginali possono avere congiunte diverse.

1.12.4 Variabili aleatorie indipendenti

Definizione 1.69. Sia $\boldsymbol{X} = (X_1, \dots, X_n)$ un vettore aleatorio definito sullo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$. Le variabili aleatorie $X_1, \dots, X_n$ si dicono *indipendenti* se, per ogni scelta di boreliani $B_1, \dots, B_n \in \mathcal{B}$, si ha:

$$\mathbb{P}(X_1 \in B_1, \dots, X_n \in B_n) = \prod_{i=1}^{n} \mathbb{P}(X_i \in B_i).$$

Osservazione. La Definizione 1.69 equivale a richiedere che, comunque si scelgano i boreliani $B_1, \dots, B_n \in \mathcal{B}$, gli eventi $\{X_1 \in B_1\}, \dots, \{X_n \in B_n\}$ siano collettivamente indipendenti nel senso della Definizione 1.31. A differenza di quanto accade per una famiglia fissata di eventi, non è necessario imporre separatamente la fattorizzazione per ogni sottofamiglia, poiché essa segue automaticamente dalla quantificazione universale sui boreliani. Infatti, fissati $B_1, \dots, B_n \in \mathcal{B}$, $k \in I_n$ e un sottoinsieme di indici tutti distinti $J := \{i_1, \dots, i_k\} \subseteq I_n$, si definiscano i boreliani $\widetilde{B}_1, \dots, \widetilde{B}_n \in \mathcal{B}$ ponendo:

$$\widetilde{B}_j := \begin{cases} B_j & \text{se } j \in J \\ \mathbb{R} & \text{se } j \notin J \end{cases} \qquad \forall\, j \in I_n.$$

Poiché per ogni $j \notin J$ si ha $\{X_j \in \mathbb{R}\} = \Omega$ e $\mathbb{P}(X_j \in \mathbb{R}) = 1$, applicando la condizione della Definizione 1.69 alla n-upla $(\widetilde{B}_1, \dots, \widetilde{B}_n)$ si ottiene:

$$\begin{aligned} \mathbb{P}\left(\bigcap_{m=1}^{k} \{X_{i_m} \in B_{i_m}\} \right) &= \mathbb{P}\left(\bigcap_{j=1}^{n} \left\{X_j \in \widetilde{B}_j\right\} \right) \\ &= \prod_{j=1}^{n} \mathbb{P}\left(X_j \in \widetilde{B}_j\right) = \prod_{m=1}^{k} \mathbb{P}\left(X_{i_m} \in B_{i_m}\right), \end{aligned}$$

ovvero la fattorizzazione sulla sottofamiglia individuata da J; per l'arbitrarietà di J, gli eventi $\{X_1 \in B_1\}, \dots, \{X_n \in B_n\}$ sono collettivamente indipendenti.

Proposizione 1.39. *Siano $X_1, \dots, X_n$ variabili aleatorie indipendenti. Allora:*

(*i*) *la funzione di ripartizione congiunta si fattorizza nel prodotto delle marginali:*

$$F_{X_1,\dots,X_n}(x_1, \dots, x_n) = F_{X_1}(x_1) \cdots F_{X_n}(x_n) \qquad \forall (x_1, \dots, x_n) \in \mathbb{R}^n;$$

(*ii*) *se il vettore è discreto, la funzione massa congiunta si fattorizza nel prodotto delle marginali:*

$$\begin{aligned} p_{X_1,\dots,X_n}(x_1, \dots, x_n) &= \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) \\ &= \prod_{i=1}^{n} \mathbb{P}(X_i = x_i) = p_{X_1}(x_1) \cdots p_{X_n}(x_n); \end{aligned}$$

(*iii*) *se le X_i sono assolutamente continue con densità f_{X_i}, il vettore è assolutamente continuo con densità congiunta*

$$f_{X_1,\dots,X_n}(x_1,\dots,x_n) = f_{X_1}(x_1)\cdots f_{X_n}(x_n).$$

In particolare, per $n = 2$ si ha $F_{X,Y}(x,y) = F_X(x)F_Y(y)$ e, nel caso discreto, $p_{X,Y}(x,y) = p_X(x)\,p_Y(y)$.

Dimostrazione.

(*i*) Basta applicare la definizione di indipendenza ai boreliani $B_i = (-\infty, x_i]$, per i quali $\{X_i \in B_i\} = \{X_i \le x_i\}$.

(*ii*) Basta applicare la definizione di indipendenza ai boreliani $B_i = \{x_i\}$.

(*iii*) Per il punto (*i*) e la definizione di densità di ciascuna X_i si ha

$$F_{\boldsymbol{X}}(x_1,\dots,x_n) = \prod_{i=1}^{n}\int_{-\infty}^{x_i} f_{X_i}(y_i)\,\mathrm{d}y_i = \int_{-\infty}^{x_1}\cdots\int_{-\infty}^{x_n} f_{X_1}(y_1)\cdots f_{X_n}(y_n)\,\mathrm{d}y_n\cdots\mathrm{d}y_1,$$

e la funzione prodotto $f_{X_1}(y_1)\cdots f_{X_n}(y_n)$ è non negativa: essa è dunque una densità congiunta del vettore. □

Osservazione. Vale anche il viceversa (di cui si omette la dimostrazione): se la funzione di ripartizione congiunta si fattorizza nel prodotto delle marginali, le variabili sono indipendenti; lo stesso vale per la fattorizzazione della funzione massa congiunta, nel caso discreto, e della densità congiunta, nel caso assolutamente continuo. La fattorizzazione è dunque una caratterizzazione dell'indipendenza.

Osservazione. Le variabili aleatorie $X_1,\dots,X_n$ si dicono *a due a due indipendenti* se, per ogni $i, j \in I_n$ con $i \neq j$, le variabili aleatorie X_i e X_j sono indipendenti. Variabili aleatorie indipendenti sono, in particolare, a due a due indipendenti: basta scegliere $B_m = \mathbb{R}$ per ogni $m \notin \{i, j\}$ nella Definizione 1.69. Come per gli eventi (Esempio 1.12), il viceversa è falso.

Esempio 1.28. Si consideri l'esperimento casuale del lancio di una moneta non truccata ripetuto due volte, descritto dallo spazio campione

$$\Omega = \{\mathrm{TT},\ \mathrm{TC},\ \mathrm{CT},\ \mathrm{CC}\},$$

con la σ-algebra $\mathcal{F} = \mathcal{P}(\Omega)$ e la misura di probabilità $\mathbb{P}$ che assegna probabilità $1/4$ a ciascun esito. Si definiscano le variabili aleatorie X, Y e Z ponendo $X = 1$ se al primo lancio esce testa e $X = 0$ se esce croce, $Y = 1$ se al secondo lancio esce testa e $Y = 0$ se esce croce, $Z = 1$ se i due lanci danno risultati diversi e $Z = 0$ se danno lo stesso risultato. I valori assunti dalle tre variabili in corrispondenza di ciascun esito sono riportati nella Tabella 1.1.

Si ha $S_X = S_Y = S_Z = \{0, 1\}$ e ciascuna delle tre variabili assume i valori 0 e 1 su due esiti, per cui X, Y e Z sono variabili di Bernoulli di parametro $1/2$. Inoltre, come si legge dalla Tabella 1.1, ciascuna coppia di variabili distinte assume ciascuna delle quattro coppie di valori $(i, j) \in \{0, 1\}^2$ su un solo esito; ad esempio

$$\mathbb{P}(X = 0, Z = 0) = \mathbb{P}\big(\{\mathrm{CC}\}\big) = \frac{1}{4} = \frac{1}{2}\cdot\frac{1}{2} = \mathbb{P}(X = 0)\,\mathbb{P}(Z = 0),$$

Tabella 1.1. Valori assunti dalle variabili aleatorie X, Y e Z in corrispondenza di ciascun esito del doppio lancio di una moneta.

ω	TT	TC	CT	CC
$X(\omega)$	1	1	0	0
$Y(\omega)$	1	0	1	0
$Z(\omega)$	0	1	1	0

e allo stesso modo, per ogni $i, j \in \{0, 1\}$,

$$p_{X,Y}(i,j) = p_X(i)\, p_Y(j), \qquad p_{X,Z}(i,j) = p_X(i)\, p_Z(j), \qquad p_{Y,Z}(i,j) = p_Y(i)\, p_Z(j).$$

Poiché la fattorizzazione della funzione massa congiunta caratterizza l'indipendenza (osservazione successiva alla Proposizione 1.39), le variabili X, Y e Z sono a due a due indipendenti. Esse non sono tuttavia indipendenti: scegliendo $B_1 = B_2 = B_3 = \{0\}$ nella Definizione 1.69, si ha

$$\mathbb{P}(X = 0, Y = 0, Z = 0) = \mathbb{P}\big(\{\mathrm{CC}\}\big) = \frac{1}{4}$$
$$\neq \frac{1}{8} = \left(\frac{1}{2}\right)^3 = \mathbb{P}(X = 0)\, \mathbb{P}(Y = 0)\, \mathbb{P}(Z = 0).$$

Intuitivamente, la conoscenza del valore di una sola tra X e Y non fornisce alcuna informazione su Z, mentre la conoscenza di entrambe determina Z completamente, essendo $Z = |X - Y|$.

1.13 Somma, prodotto e rapporto di variabili aleatorie

Sia (X, Y) un vettore aleatorio assolutamente continuo definito sullo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$, con densità congiunta $f_{X,Y}$; non si suppone, in generale, che X e Y siano indipendenti. In questa sezione si determinano la funzione di ripartizione e la densità delle variabili aleatorie $Z = X + Y$, $T = XY$ e $R = X/Y$. Lo schema è sempre lo stesso: l'evento $\{Z \le z\}$ (rispettivamente $\{T \le t\}$, $\{R \le r\}$) coincide con l'evento $\{(X, Y) \in B\}$, dove $B \subseteq \mathbb{R}^2$ è una regione del piano, e la sua probabilità è l'integrale doppio di $f_{X,Y}$ su B; la densità si ottiene poi derivando rispetto al parametro.

1.13.1 Somma di variabili aleatorie

Teorema 1.40. *Sia (X, Y) un vettore aleatorio assolutamente continuo con densità congiunta $f_{X,Y}$, e sia $Z := X + Y$. Allora, per ogni $z \in \mathbb{R}$,*

$$F_Z(z) = \mathbb{P}(X + Y \le z) = \int_{-\infty}^{+\infty} \left(\int_{-\infty}^{z-x} f_{X,Y}(x, y)\, \mathrm{d}y \right) \mathrm{d}x,$$

e Z è assolutamente continua con densità

$$f_Z(z) = \int_{-\infty}^{+\infty} f_{X,Y}(x, z - x)\, \mathrm{d}x = \int_{-\infty}^{+\infty} f_{X,Y}(z - y, y)\, \mathrm{d}y.$$

Dimostrazione. Fissato $z \in \mathbb{R}$, l'evento $\{Z \le z\}$ coincide con $\{(X,Y) \in B_z\}$, dove

$$B_z := \big\{ (x,y) \in \mathbb{R}^2 \mid x + y \le z \big\}$$

è il semipiano chiuso delimitato dalla retta $x + y = z$ e situato al di sotto di essa (Figura 1.1). Per ogni $x \in \mathbb{R}$ fissato, i punti di B_z di ascissa x sono quelli con $y \le z - x$; integrando la densità congiunta su B_z si ottiene dunque:

$$F_Z(z) = \iint_{B_z} f_{X,Y}(x,y)\,\mathrm{d}x\,\mathrm{d}y = \int_{-\infty}^{+\infty} \left(\int_{-\infty}^{z-x} f_{X,Y}(x,y)\,\mathrm{d}y \right) \mathrm{d}x.$$

Per ricavare la densità si deriva rispetto a z sotto il segno di integrale, applicando all'integrale

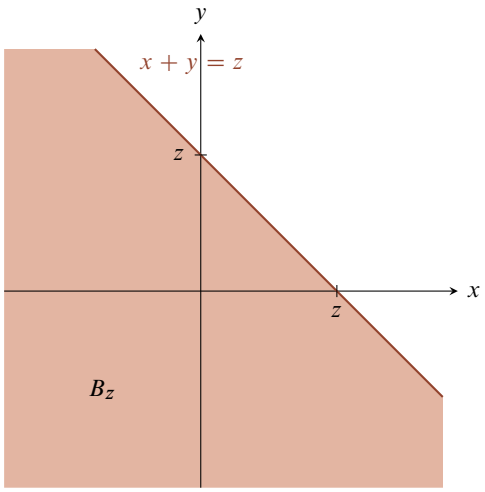


Figura 1.1. La regione $B_z = \{(x,y) \in \mathbb{R}^2 \mid x + y \le z\}$.

interno la *formula di Leibniz* per la derivazione di un integrale dipendente da un parametro:

$$\frac{\mathrm{d}}{\mathrm{d}t} \left\{ \int_{\alpha(t)}^{\beta(t)} h(x,t)\,\mathrm{d}x \right\} = \beta'(t)\,h\big(\beta(t),t\big) - \alpha'(t)\,h\big(\alpha(t),t\big) + \int_{\alpha(t)}^{\beta(t)} \frac{\partial h}{\partial t}(x,t)\,\mathrm{d}x.$$

Nel caso in esame la funzione integranda $f_{X,Y}(x,y)$ non dipende da z, l'estremo inferiore è costante e l'estremo superiore è $\beta(z) = z - x$, con $\beta'(z) = 1$; si ottiene pertanto:

$$f_Z(z) = \frac{\mathrm{d}F_Z}{\mathrm{d}z}(z) = \int_{-\infty}^{+\infty} \frac{\mathrm{d}}{\mathrm{d}z} \left\{ \int_{-\infty}^{z-x} f_{X,Y}(x,y)\,\mathrm{d}y \right\} \mathrm{d}x = \int_{-\infty}^{+\infty} f_{X,Y}(x, z-x)\,\mathrm{d}x.$$

La seconda espressione si ottiene allo stesso modo integrando prima rispetto a x (i punti di B_z di ordinata y sono quelli con $x \le z - y$), oppure con la sostituzione $y = z - x$ nell'integrale appena ottenuto. La funzione f_Z è non negativa e F_Z ne è una primitiva, per cui Z è assolutamente continua con densità f_Z. □

Corollario 1.41 (Formula di convoluzione). *Se X e Y sono variabili aleatorie assolutamente continue e indipendenti, con densità f_X e f_Y, la densità della somma $Z = X + Y$ è data da*

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x)\,f_Y(z-x)\,\mathrm{d}x = \int_{-\infty}^{+\infty} f_X(z-y)\,f_Y(y)\,\mathrm{d}y,$$

detta convoluzione *delle densità f_X e f_Y e indicata con $f_Z = f_X * f_Y$.*

DIMOSTRAZIONE. Per la PROPOSIZIONE 1.39 si ha $f_{X,Y}(x,y) = f_X(x)\,f_Y(y)$, e basta sostituire nel TEOREMA 1.40. □

ESEMPIO 1.29. Sia (X,Y) un vettore aleatorio con densità congiunta

$$f_{X,Y}(x,y) = \begin{cases} 8xy & \text{se } 0 \le y \le x \le 1 \\ 0 & \text{altrove} \end{cases}$$

Si verifica innanzitutto che $f_{X,Y}$ è una densità: essa è non negativa e, integrando sul triangolo $\{0 \le y \le x \le 1\}$,

$$\int_0^1 \left(\int_0^x 8xy\,dy \right) dx = \int_0^1 8x \cdot \frac{x^2}{2}\,dx = \int_0^1 4x^3\,dx = 1.$$

Si determini la funzione di ripartizione della somma $Z = X + Y$. Poiché $0 \le X + Y \le 2$, si ha $F_Z(z) = 0$ per $z < 0$ e $F_Z(z) = 1$ per $z \ge 2$; per $z \in [0,2)$ occorre integrare la densità sulla parte del triangolo che giace al di sotto della retta $x + y = z$ (Figura 1.2). La retta interseca la retta $y = x$ nel punto $(z/2, z/2)$ e l'asse delle ascisse nel punto $(z,0)$, e si presentano due casi.

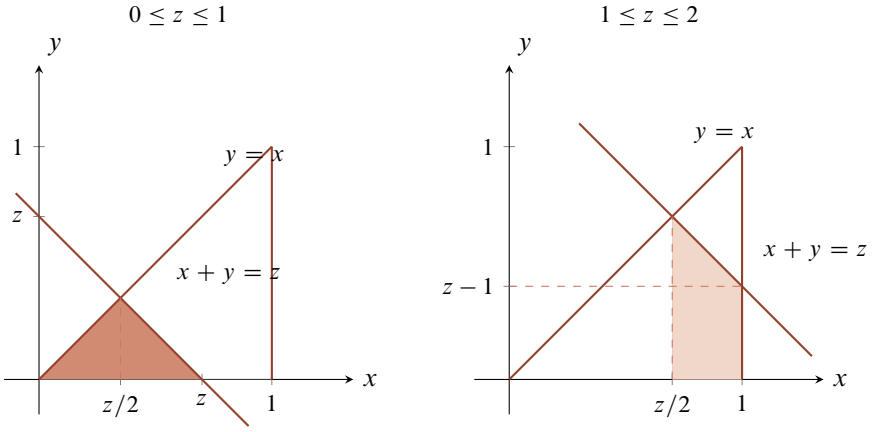


Figura 1.2. Il supporto $\{0 \le y \le x \le 1\}$ della densità $f_{X,Y}$ e, nel colore più scuro, la regione $\{x + y \le z\}$ nei casi $0 \le z \le 1$ e $1 \le z \le 2$.

(*i*) Se $0 \le z \le 1$, la regione è il triangolo di vertici $(0,0)$, $(z/2, z/2)$ e $(z,0)$: per $0 \le x \le z/2$ la variabile y va da 0 a x, mentre per $z/2 \le x \le z$ va da 0 a $z - x$. Si ha quindi:

$$\begin{aligned} F_Z(z) &= \int_0^{z/2} \left(\int_0^x 8xy\,dy \right) dx + \int_{z/2}^z \left(\int_0^{z-x} 8xy\,dy \right) dx \\ &= \int_0^{z/2} 4x^3\,dx + \int_{z/2}^z 4x(z-x)^2\,dx = \frac{z^4}{16} + 4\left[\frac{z^2x^2}{2} - \frac{2zx^3}{3} + \frac{x^4}{4} \right]_{z/2}^z \\ &= \frac{z^4}{16} + 4\left(\frac{z^4}{12} - \frac{5z^4}{192} \right) = \frac{z^4}{16} + \frac{11z^4}{48} = \frac{z^4}{6}. \end{aligned}$$

(*ii*) Se $1 \le z < 2$, conviene passare all'evento complementare: i punti del supporto con $x + y > z$ formano il triangolo di vertici $(z/2, z/2)$, $(1, z-1)$ e $(1,1)$, nel quale, per

$z/2 \le x \le 1$, la variabile y va da $z-x$ a x. Si ha quindi:

$$\begin{aligned} 1 - F_Z(z) &= \int_{z/2}^{1} \left(\int_{z-x}^{x} 8xy \, \mathrm{d}y \right) \mathrm{d}x = \int_{z/2}^{1} 4x\big(x^2 - (z-x)^2\big) \, \mathrm{d}x \\ &= \int_{z/2}^{1} \big(8zx^2 - 4z^2x\big) \, \mathrm{d}x = \left[\frac{8zx^3}{3} - 2z^2x^2 \right]_{z/2}^{1} \\ &= \frac{8z}{3} - 2z^2 - \frac{z^4}{3} + \frac{z^4}{2} = \frac{z^4}{6} - 2z^2 + \frac{8z}{3}, \end{aligned}$$

da cui

$$F_Z(z) = 1 - \frac{8z}{3} + 2z^2 - \frac{z^4}{6}.$$

Riassumendo:

$$F_Z(z) = \begin{cases} 0 & \text{se } z < 0 \\ \dfrac{z^4}{6} & \text{se } 0 \le z < 1 \\ 1 - \dfrac{8z}{3} + 2z^2 - \dfrac{z^4}{6} & \text{se } 1 \le z < 2 \\ 1 & \text{se } z \ge 2 \end{cases}$$

Le due espressioni si raccordano con continuità in $z = 1$, dove entrambe valgono $1/6$, e in $z = 2$, dove la seconda vale 1. Derivando si ottiene la densità:

$$f_Z(z) = \begin{cases} \dfrac{2}{3}z^3 & \text{se } 0 < z < 1 \\ -\dfrac{2}{3}z^3 + 4z - \dfrac{8}{3} & \text{se } 1 \le z < 2 \\ 0 & \text{altrove} \end{cases}$$

Lo stesso risultato si ottiene con la formula del Teorema 1.40: per $0 < z < 1$ la funzione $x \longmapsto f_{X,Y}(x, z-x)$ è diversa da zero solo per $z/2 \le x \le z$, e vale $8x(z-x)$, per cui

$$f_Z(z) = \int_{z/2}^{z} 8x(z-x) \, \mathrm{d}x = \left[4zx^2 - \frac{8x^3}{3} \right]_{z/2}^{z} = \frac{4z^3}{3} - z^3 + \frac{z^3}{3} = \frac{2}{3}z^3.$$

Esempio 1.30. Si determini la costante $a > 0$ affinché la funzione

$$f_{X,Y}(x, y) = \begin{cases} a\,xy & \text{se } 0 \le x \le 1,\ 0 \le y \le 1 \\ 0 & \text{altrove} \end{cases}$$

sia una densità congiunta. Imponendo la condizione di normalizzazione sul quadrato $[0,1]\times[0,1]$ si ha

$$1 = \int_0^1 \left(\int_0^1 a\,xy \, \mathrm{d}y \right) \mathrm{d}x = a \int_0^1 x \, \mathrm{d}x \int_0^1 y \, \mathrm{d}y = \frac{a}{4} \implies a = 4.$$

Si osservi che in questo caso la densità si fattorizza, $f_{X,Y}(x, y) = (2x)(2y)$, nel prodotto delle due marginali $f_X(x) = 2x$ e $f_Y(y) = 2y$ su $[0, 1]$: le variabili X e Y sono dunque indipendenti, a differenza di quelle dell'Esempio 1.29, il cui supporto triangolare non è un prodotto cartesiano.

Esempio 1.31. Siano $X \sim \text{Exp}(1)$ e $Y \sim \text{Exp}(2)$ variabili aleatorie indipendenti, con

$$F_X(x) = \begin{cases} 0 & \text{se } x < 0 \\ 1 - \mathrm{e}^{-x} & \text{se } x \geq 0 \end{cases} \qquad F_Y(y) = \begin{cases} 0 & \text{se } y < 0 \\ 1 - \mathrm{e}^{-2y} & \text{se } y \geq 0 \end{cases}$$

e densità $f_X(x) = \mathrm{e}^{-x}$ per $x > 0$ e $f_Y(y) = 2\mathrm{e}^{-2y}$ per $y > 0$, nulle altrove. Per l'indipendenza, la funzione di ripartizione e la densità congiunte sono, per $x, y \geq 0$,

$$F_{X,Y}(x, y) = \big(1 - \mathrm{e}^{-x}\big)\big(1 - \mathrm{e}^{-2y}\big), \qquad f_{X,Y}(x, y) = 2\mathrm{e}^{-x}\mathrm{e}^{-2y}.$$

Si determini la distribuzione di $Z = X + Y$. Poiché $Z \geq 0$, si ha $F_Z(z) = 0$ per $z < 0$; per $z \geq 0$, il supporto $[0, +\infty) \times [0, +\infty)$ interseca il semipiano $x + y \leq z$ nel triangolo di vertici $(0, 0)$, $(z, 0)$ e $(0, z)$, e dunque:

$$\begin{aligned} F_Z(z) &= \int_0^z \left(\int_0^{z-x} 2\mathrm{e}^{-x}\mathrm{e}^{-2y}\,\mathrm{d}y \right) \mathrm{d}x = \int_0^z \mathrm{e}^{-x}\big[-\mathrm{e}^{-2y}\big]_0^{z-x}\,\mathrm{d}x = \int_0^z \mathrm{e}^{-x}\big(1 - \mathrm{e}^{-2(z-x)}\big)\,\mathrm{d}x \\ &= \int_0^z \mathrm{e}^{-x}\,\mathrm{d}x - \mathrm{e}^{-2z}\int_0^z \mathrm{e}^{x}\,\mathrm{d}x = \big(1 - \mathrm{e}^{-z}\big) - \mathrm{e}^{-2z}\big(\mathrm{e}^{z} - 1\big) = 1 - 2\mathrm{e}^{-z} + \mathrm{e}^{-2z}. \end{aligned}$$

Riassumendo, $F_Z(z) = 1 - 2\mathrm{e}^{-z} + \mathrm{e}^{-2z}$ per $z \geq 0$ e $F_Z(z) = 0$ per $z < 0$; derivando si ottiene la densità

$$f_Z(z) = \begin{cases} 2\mathrm{e}^{-z} - 2\mathrm{e}^{-2z} = 2\big(\mathrm{e}^{-z} - \mathrm{e}^{-2z}\big) & \text{se } z > 0 \\ 0 & \text{se } z \leq 0 \end{cases}$$

Lo stesso risultato si ottiene direttamente con la formula di convoluzione del Corollario 1.41: per $z > 0$ la funzione $x \longmapsto f_X(x)\, f_Y(z - x)$ è diversa da zero solo per $0 < x < z$, e dunque

$$f_Z(z) = \int_0^z \mathrm{e}^{-x} \cdot 2\mathrm{e}^{-2(z-x)}\,\mathrm{d}x = 2\mathrm{e}^{-2z}\int_0^z \mathrm{e}^{x}\,\mathrm{d}x = 2\mathrm{e}^{-2z}\big(\mathrm{e}^{z} - 1\big) = 2\big(\mathrm{e}^{-z} - \mathrm{e}^{-2z}\big).$$

1.13.2 Prodotto di variabili aleatorie

Teorema 1.42. *Sia (X, Y) un vettore aleatorio assolutamente continuo con densità congiunta $f_{X,Y}$, e sia $T := XY$. Allora, per ogni $t \in \mathbb{R}$,*

$$F_T(t) = \mathbb{P}(XY \leq t) = \int_{-\infty}^0 \left(\int_{t/x}^{+\infty} f_{X,Y}(x, y)\,\mathrm{d}y \right) \mathrm{d}x + \int_0^{+\infty} \left(\int_{-\infty}^{t/x} f_{X,Y}(x, y)\,\mathrm{d}y \right) \mathrm{d}x,$$

e T è assolutamente continua con densità

$$f_T(t) = \int_{-\infty}^{+\infty} \frac{1}{|x|}\, f_{X,Y}\left(x, \frac{t}{x}\right) \mathrm{d}x.$$

Dimostrazione. Fissato $t \in \mathbb{R}$, l'evento $\{T \leq t\}$ coincide con $\{(X, Y) \in D_t\}$, dove

$$D_t := \big\{ (x, y) \in \mathbb{R}^2 \mid xy \leq t \big\}.$$

La regione D_t è delimitata dall'iperbole $xy = t$ ed è rappresentata nella Figura 1.3 nei due casi $t > 0$ e $t < 0$; per $t = 0$ essa è l'unione del secondo e del quarto quadrante (chiusi). Fissato $x \in \mathbb{R}$, la condizione $xy \leq t$ equivale a $y \leq t/x$ se $x > 0$ e a $y \geq t/x$ se $x < 0$ (la retta $x = 0$ ha misura nulla e non contribuisce all'integrale). Integrando la densità congiunta su D_t

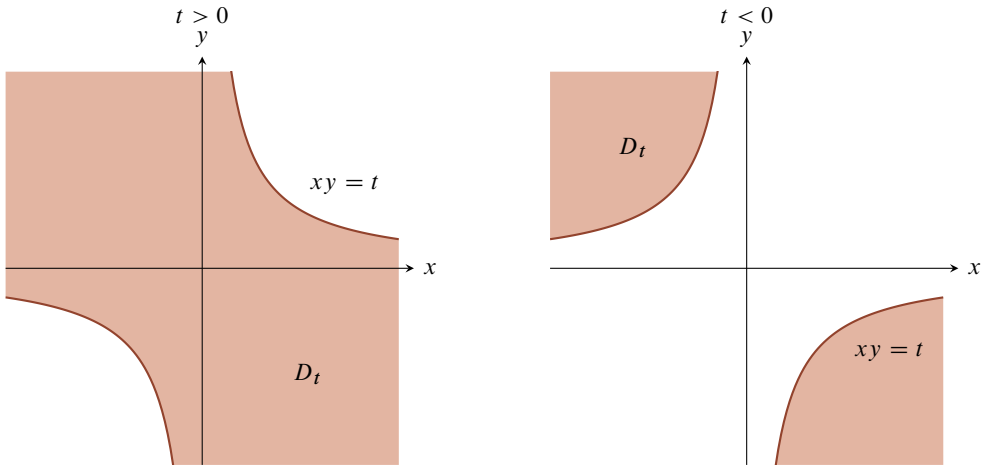


Figura 1.3. La regione $D_t = \{(x, y) \in \mathbb{R}^2 \mid xy \le t\}$ nei casi $t > 0$ e $t < 0$.

si ottiene dunque l'espressione di $F_T(t)$ dell'enunciato, valida per ogni segno di t. Per ricavare la densità si deriva rispetto a t sotto il segno di integrale, applicando la formula di Leibniz agli integrali interni, nei quali t compare solo nell'estremo t/x, la cui derivata è $1/x$. Nel primo addendo l'estremo dipendente da t è quello inferiore, e il segno è negativo; nel secondo è quello superiore. Si ottiene:

$$\begin{aligned} f_T(t) &= \int_{-\infty}^{0} \left(-\frac{1}{x}\right) f_{X,Y}\left(x, \frac{t}{x}\right) \mathrm{d}x + \int_{0}^{+\infty} \frac{1}{x}\, f_{X,Y}\left(x, \frac{t}{x}\right) \mathrm{d}x \\ &= \int_{-\infty}^{+\infty} \frac{1}{|x|}\, f_{X,Y}\left(x, \frac{t}{x}\right) \mathrm{d}x, \end{aligned}$$

essendo $-1/x = 1/|x|$ per $x < 0$ e $1/x = 1/|x|$ per $x > 0$. Come nel Teorema 1.40, f_T è non negativa e F_T ne è una primitiva. □

Esempio 1.32. Si consideri il vettore aleatorio (X, Y) dell'Esempio 1.29, con densità congiunta $f_{X,Y}(x, y) = 8xy$ sul triangolo $\{0 \le y \le x \le 1\}$ e nulla altrove, e si determini la distribuzione del prodotto $T = XY$. Poiché $0 \le XY \le 1$, si ha $F_T(t) = 0$ per $t < 0$ e, per $t \ge 1$, integrando su tutto il supporto,

$$F_T(t) = \int_0^1 \left(\int_0^x 8xy \,\mathrm{d}y \right) \mathrm{d}x = \int_0^1 4x^3 \,\mathrm{d}x = \left[x^4\right]_0^1 = 1.$$

Per $t \in [0, 1)$ occorre integrare sulla parte del supporto che giace al di sotto dell'iperbole $xy = t$ (Figura 1.4). L'iperbole interseca la retta $y = x$ nel punto $(\sqrt{t}, \sqrt{t})$: per $0 \le x \le \sqrt{t}$ la variabile y va da 0 a x, mentre per $\sqrt{t} \le x \le 1$ va da 0 a t/x. Si ha quindi:

$$\begin{aligned} F_T(t) &= \int_0^{\sqrt{t}} \left(\int_0^x 8xy \,\mathrm{d}y \right) \mathrm{d}x + \int_{\sqrt{t}}^1 \left(\int_0^{t/x} 8xy \,\mathrm{d}y \right) \mathrm{d}x = \int_0^{\sqrt{t}} 4x^3 \,\mathrm{d}x + \int_{\sqrt{t}}^1 \frac{4t^2}{x} \,\mathrm{d}x \\ &= \left[x^4\right]_0^{\sqrt{t}} + 4t^2 \left[\log x\right]_{\sqrt{t}}^1 = t^2 - 4t^2 \log \sqrt{t} = t^2 - 2t^2 \log t. \end{aligned}$$

Riassumendo:

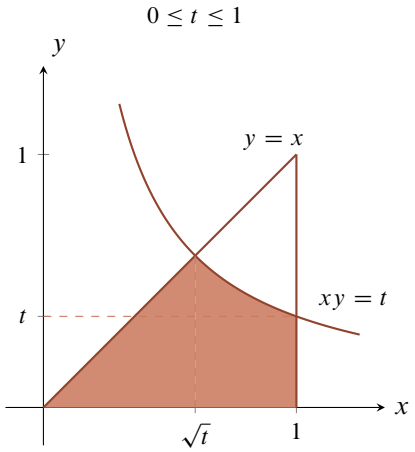


Figura 1.4. Il supporto $\{0 \le y \le x \le 1\}$ della densità $f_{X,Y}$ e, nel colore più scuro, la regione $\{xy \le t\}$ per $0 \le t \le 1$.

$$F_T(t) = \begin{cases} 0 & \text{se } t < 0 \\ t^2\big(1 - 2\log t\big) & \text{se } 0 \le t < 1 \\ 1 & \text{se } t \ge 1 \end{cases}$$

dove in $t = 0$ la seconda espressione va intesa come limite, $\lim_{t\to 0^+} t^2(1 - 2\log t) = 0$, in accordo con la continuità di F_T; in $t = 1$ essa vale 1. Derivando si ottiene la densità

$$f_T(t) = \begin{cases} 2t\big(1 - 2\log t\big) - 2t = -4t\log t & \text{se } 0 < t < 1 \\ 0 & \text{altrove} \end{cases}$$

che è positiva su $(0,1)$, essendo $\log t < 0$. Lo stesso risultato si ottiene con la formula del Teorema 1.42: per $0 < t < 1$ il punto $(x, t/x)$ appartiene al supporto se e solo se $0 \le t/x \le x \le 1$, cioè $\sqrt{t} \le x \le 1$, per cui

$$f_T(t) = \int_{\sqrt{t}}^1 \frac{1}{x} \cdot 8x \cdot \frac{t}{x}\,\mathrm{d}x = 8t \int_{\sqrt{t}}^1 \frac{\mathrm{d}x}{x} = -8t\log\sqrt{t} = -4t\log t.$$

1.13.3 Rapporto di variabili aleatorie

Teorema 1.43. *Sia (X, Y) un vettore aleatorio assolutamente continuo con densità congiunta $f_{X,Y}$, con $\mathbb{P}(Y = 0) = 0$, e sia $R := X/Y$. Allora, per ogni $r \in \mathbb{R}$,*

$$F_R(r) = \mathbb{P}\left(\frac{X}{Y} \le r\right) = \int_0^{+\infty}\left(\int_{-\infty}^{ry} f_{X,Y}(x,y)\,\mathrm{d}x\right)\mathrm{d}y + \int_{-\infty}^{0}\left(\int_{ry}^{+\infty} f_{X,Y}(x,y)\,\mathrm{d}x\right)\mathrm{d}y,$$

e R è assolutamente continua con densità

$$f_R(r) = \int_{-\infty}^{+\infty} |y|\, f_{X,Y}(ry, y)\,\mathrm{d}y.$$

Dimostrazione. La variabile R è ben definita quasi certamente, poiché $\mathbb{P}(Y = 0) = 0$. Fissato $r \in \mathbb{R}$, l'evento $\{R \le r\}$ coincide con $\{(X,Y) \in E_r\}$, dove

$$E_r := \big\{(x,y) \in \mathbb{R}^2 \mid y > 0,\ x \le ry\big\} \cup \big\{(x,y) \in \mathbb{R}^2 \mid y < 0,\ x \ge ry\big\}.$$

Infatti, moltiplicando la disuguaglianza $x/y \le r$ per y, il verso si conserva se $y > 0$ e si inverte se $y < 0$. La regione E_r è delimitata dalla retta $x = ry$ (ovvero $y = x/r$, se $r \neq 0$) ed è rappresentata nella Figura 1.5 nei due casi $r > 0$ e $r < 0$; per $r = 0$ essa è l'unione del secondo e del quarto quadrante (aperti). Integrando la densità congiunta su E_r, questa volta per y fissato, si ottiene l'espressione di $F_R(r)$ dell'enunciato. Per ricavare la densità si deriva

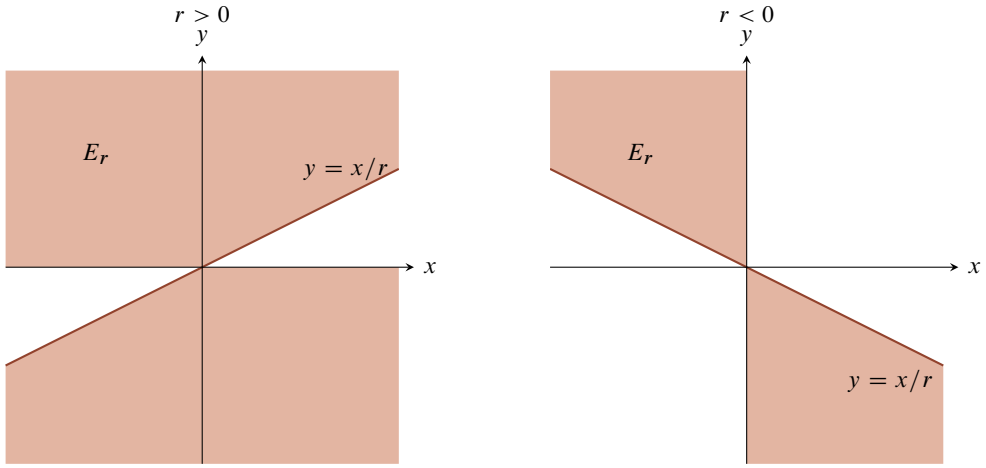


Figura 1.5. La regione $E_r = \{(x, y) \mid y > 0,\ x \le ry\} \cup \{(x, y) \mid y < 0,\ x \ge ry\}$ nei casi $r > 0$ e $r < 0$.

rispetto a r sotto il segno di integrale con la formula di Leibniz: negli integrali interni r compare solo nell'estremo ry, la cui derivata è y. Nel primo addendo l'estremo dipendente da r è quello superiore, nel secondo quello inferiore (con segno negativo); si ottiene:

$$f_R(r) = \int_0^{+\infty} y\, f_{X,Y}(ry, y)\,\mathrm{d}y + \int_{-\infty}^{0} (-y)\, f_{X,Y}(ry, y)\,\mathrm{d}y = \int_{-\infty}^{+\infty} |y|\, f_{X,Y}(ry, y)\,\mathrm{d}y,$$

essendo $y = |y|$ per $y > 0$ e $-y = |y|$ per $y < 0$. Come in precedenza, f_R è non negativa e F_R ne è una primitiva. □

Osservazione. Se $f_{X,Y}$ è nulla per $y \le 0$ (ovvero $Y > 0$ quasi certamente), il secondo addendo di $F_R(r)$ scompare e, per $r > 0$, la formula si può riscrivere passando all'evento complementare:

$$F_R(r) = 1 - \int_0^{+\infty} \left(\int_{ry}^{+\infty} f_{X,Y}(x, y)\,\mathrm{d}x \right) \mathrm{d}y,$$

forma talvolta più comoda nei calcoli.

Esempio 1.33. Si consideri il vettore aleatorio (X, Y) dell'Esempio 1.29, con densità congiunta $f_{X,Y}(x, y) = 8xy$ sul triangolo $\{0 \le y \le x \le 1\}$ e nulla altrove, e si determini la distribuzione del rapporto $R = X/Y$. Si ha $\mathbb{P}(Y = 0) = 0$, essendo Y assolutamente continua, e sul supporto vale $0 < y \le x$, per cui $R \ge 1$ quasi certamente: $F_R(r) = 0$ per $r < 1$. Per $r \ge 1$, dalla formula del Teorema 1.43, essendo $f_{X,Y}$ nulla per $y \le 0$ e per $x > 1$, la condizione $x \le ry$ sul supporto si scrive $y \le x \le \min\{ry, 1\}$; conviene integrare prima rispetto a y: per x fissato in $[0, 1]$ la variabile y va da x/r a x, e dunque

$$F_R(r) = \int_0^1 \left(\int_{x/r}^{x} 8xy\,\mathrm{d}y \right) \mathrm{d}x = \int_0^1 4x \left(x^2 - \frac{x^2}{r^2} \right) \mathrm{d}x = 4\left(1 - \frac{1}{r^2}\right) \int_0^1 x^3\,\mathrm{d}x = 1 - \frac{1}{r^2}.$$

Riassumendo, $F_R(r) = 1 - 1/r^2$ per $r \geq 1$ e $F_R(r) = 0$ per $r < 1$, con $\lim_{r\to+\infty} F_R(r) = 1$; derivando si ottiene la densità

$$f_R(r) = \begin{cases} \dfrac{2}{r^3} & \text{se } r > 1 \\ 0 & \text{se } r \leq 1 \end{cases}$$

Lo stesso risultato si ottiene con la formula della densità: il punto (ry, y) appartiene al supporto se e solo se $0 \leq y \leq ry \leq 1$, cioè $0 \leq y \leq 1/r$ (per $r \geq 1$), per cui

$$f_R(r) = \int_0^{1/r} y \cdot 8(ry)y \,\mathrm{d}y = 8r \int_0^{1/r} y^3 \,\mathrm{d}y = 8r \cdot \frac{1}{4r^4} = \frac{2}{r^3}.$$

1.14 Momenti di variabili aleatorie

Definizione 1.70. Sia X una variabile aleatoria definita sullo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$, con funzione di ripartizione F_X, e sia $k \in \mathbb{N}_0$. Si dice *momento intorno all'origine di ordine k* della variabile aleatoria X, e si indica con $\mathbb{E}\left[X^k\right]$ oppure con μ'_k, l'integrale di Riemann–Stieltjes

$$\mathbb{E}\left[X^k\right] = \mu'_k := \int_{-\infty}^{+\infty} x^k \,\mathrm{d}F_X(x),$$

qualora esso sia *assolutamente convergente*, ovvero qualora esistano finiti, separatamente, i due limiti

$$\lim_{a\to-\infty} \int_a^0 x^k \,\mathrm{d}F_X(x) \qquad \text{e} \qquad \lim_{b\to+\infty} \int_0^b x^k \,\mathrm{d}F_X(x),$$

la cui somma definisce l'integrale. In tal caso si dice che X è *dotata di momento di ordine k*.

Osservazione. Si osservi che:

(*i*) poiché la funzione $x \longmapsto x^k$ ha segno costante su ciascuna delle semirette $(-\infty, 0]$ e $[0, +\infty)$, l'esistenza finita dei due limiti equivale alla condizione

$$\int_{-\infty}^{+\infty} |x|^k \,\mathrm{d}F_X(x) < +\infty,$$

da cui il nome di convergenza assoluta. È essenziale che i due limiti siano calcolati separatamente: l'esistenza del solo limite simmetrico

$$\lim_{c\to+\infty} \int_{-c}^{c} x^k \,\mathrm{d}F_X(x)$$

non è sufficiente (Esempio 1.34);

(*ii*) per $k = 0$, con la convenzione $x^0 = 1$ per ogni $x \in \mathbb{R}$, si ha

$$\mathbb{E}\left[X^0\right] = \int_{-\infty}^{+\infty} \mathrm{d}F_X(x) = \lim_{x\to+\infty} F_X(x) - \lim_{x\to-\infty} F_X(x) = 1 :$$

il momento di ordine zero esiste per ogni variabile aleatoria e ne esprime la condizione di normalizzazione;

(*iii*) se X è dotata di momento di ordine k, essa è dotata anche di tutti i momenti di ordine $h \in \{0, 1, \dots, k\}$: infatti si ha $|x|^h \leq 1$ se $|x| \leq 1$ e $|x|^h \leq |x|^k$ se $|x| > 1$, per cui $|x|^h \leq 1 + |x|^k$ per ogni $x \in \mathbb{R}$ e

$$\int_{-\infty}^{+\infty} |x|^h \, \mathrm{d}F_X(x) \leq 1 + \int_{-\infty}^{+\infty} |x|^k \, \mathrm{d}F_X(x) < +\infty.$$

Nei due casi fondamentali di variabili aleatorie discrete e assolutamente continue, l'integrale di Riemann–Stieltjes che definisce i momenti si riduce, rispettivamente, a una somma (eventualmente una serie) e a un integrale ordinario.

Proposizione 1.44. *Sia X una variabile aleatoria e sia $k \in \mathbb{N}_0$.*

(*i*) *Se X è discreta, con supporto S_X e funzione massa di probabilità p_X, essa è dotata di momento di ordine k se e solo se la serie a secondo membro della relazione seguente converge assolutamente e, in tal caso, si ha:*

$$\mathbb{E}\left[X^k\right] = \sum_{x \in S_X} x^k \, p_X(x).$$

(*ii*) *Se X è assolutamente continua, con funzione densità di probabilità f_X, essa è dotata di momento di ordine k se e solo se l'integrale a secondo membro della relazione seguente converge assolutamente e, in tal caso, si ha:*

$$\mathbb{E}\left[X^k\right] = \int_{-\infty}^{+\infty} x^k \, f_X(x) \, \mathrm{d}x.$$

Dimostrazione.

(*i*) Omessa.

(*ii*) Se f_X è continua, la funzione di ripartizione F_X è derivabile con derivata f_X e, per la proprietà dell'integrale di Riemann–Stieltjes rispetto a una funzione integratrice derivabile, si ha $\mathrm{d}F_X(x) = f_X(x)\,\mathrm{d}x$; dunque, per ogni $a < 0 < b$,

$$\int_a^0 x^k \, \mathrm{d}F_X(x) = \int_a^0 x^k \, f_X(x) \, \mathrm{d}x, \qquad \int_0^b x^k \, \mathrm{d}F_X(x) = \int_0^b x^k \, f_X(x) \, \mathrm{d}x,$$

e passando al limite per $a \to -\infty$ e $b \to +\infty$ si ottiene la tesi, inclusa l'equivalenza tra le due condizioni di convergenza assoluta. Il caso in cui f_X presenti un numero finito di discontinuità si tratta suddividendo gli intervalli di integrazione in corrispondenza dei punti di discontinuità; il caso generale si omette. □

Definizione 1.71. Sia X una variabile aleatoria dotata di momento di ordine 1. Il momento $\mathbb{E}[X] := \mathbb{E}\left[X^1\right] = \mu'_1$ si chiama *media*, *valore atteso*, *valor medio* o *aspettazione* della variabile aleatoria X.

Osservazione. Nel caso discreto, per la Proposizione 1.44, si ha

$$\mathbb{E}[X] = \sum_{x \in S_X} x \, p_X(x),$$

ovvero il valore atteso è la media ponderata dei valori del supporto, con pesi pari alle rispettive probabilità (la cui somma è 1). Interpretando $p_X(x)$ come una massa concentrata nel punto x della retta reale, $\mathbb{E}[X]$ è il *baricentro* della distribuzione di massa così ottenuta; analogamente, nel caso assolutamente continuo, $\mathbb{E}[X]$ è il baricentro della distribuzione di massa di densità f_X.

Esempio 1.34. Si consideri la funzione

$$f_X(x) = \frac{1}{\pi\,(1+x^2)} \qquad \text{per } x \in \mathbb{R},$$

che è non negativa e soddisfa la condizione di normalizzazione:

$$\int_{-\infty}^{+\infty} \frac{1}{\pi\,(1+x^2)}\,\mathrm{d}x = \frac{1}{\pi}[\arctan x]_{-\infty}^{+\infty} = \frac{1}{\pi}\Big(\frac{\pi}{2}+\frac{\pi}{2}\Big) = 1.$$

Una variabile aleatoria assolutamente continua X con densità f_X si dice *di Cauchy*. Essa non è dotata di valore atteso: infatti

$$\lim_{b\to+\infty} \int_0^b \frac{x}{\pi\,(1+x^2)}\,\mathrm{d}x = \lim_{b\to+\infty} \frac{1}{2\pi}\log\big(1+b^2\big) = +\infty.$$

Tuttavia, essendo la funzione integranda dispari, si ha

$$\int_{-c}^{c} \frac{x}{\pi\,(1+x^2)}\,\mathrm{d}x = 0 \qquad \forall c > 0,$$

per cui il limite simmetrico esiste e vale 0: la simmetria della densità rispetto all'origine non basta a garantire che X abbia valore atteso nullo, poiché il valore atteso non esiste affatto.

1.14.1 Valore atteso delle variabili aleatorie notevoli

Si calcola ora il valore atteso delle variabili aleatorie notevoli introdotte in precedenza, a partire da quelle discrete, per le quali si applica il punto (*i*) della Proposizione 1.44.

Esempio 1.35. Sia $X \sim \mathrm{Ber}(p)$ (Definizione 1.44), con $p \in (0,1)$, supporto $S_X = \{0,1\}$ e funzione massa di probabilità $p_X(x) = p^x(1-p)^{1-x}$. Si ha:

$$\mathbb{E}[X] = \sum_{x=0}^{1} x\,p_X(x) = 0\cdot(1-p) + 1\cdot p = p.$$

Esempio 1.36. Sia $X \sim \mathrm{Bin}(n,p)$ (Definizione 1.45), con supporto $S_X = \{0,1,\dots,n\}$ e funzione massa di probabilità

$$p_X(x) = \binom{n}{x} p^x(1-p)^{n-x}.$$

L'addendo corrispondente a $x = 0$ è nullo e, semplificando x con $x! = x\,(x-1)!$, si ha:

$$\begin{aligned}\mathbb{E}[X] &= \sum_{x=0}^{n} x\binom{n}{x} p^x(1-p)^{n-x} = \sum_{x=1}^{n} x\,\frac{n!}{x!\,(n-x)!}\,p^x(1-p)^{n-x} \\ &= \sum_{x=1}^{n} \frac{n\,(n-1)!}{(x-1)!\,(n-x)!}\,p^x(1-p)^{n-x} = np\sum_{x=1}^{n}\binom{n-1}{x-1}p^{x-1}(1-p)^{(n-1)-(x-1)},\end{aligned}$$

dove si è usato che $n-x = (n-1)-(x-1)$. Con la sostituzione $y = x-1$ e la formula del binomio di Newton si ottiene infine:

$$\mathbb{E}[X] = np\sum_{y=0}^{n-1}\binom{n-1}{y}p^y(1-p)^{(n-1)-y} = np\big(p+(1-p)\big)^{n-1} = np.$$

Esempio 1.37. Sia $X \sim \text{Geom}(p)$ (Definizione 1.46), con supporto $S_X = \mathbb{N}$ e funzione massa di probabilità $p_X(x) = p(1-p)^{x-1}$. Si ha:

$$\mathbb{E}[X] = \sum_{x=1}^{+\infty} x\, p(1-p)^{x-1} = p \sum_{x=1}^{+\infty} x(1-p)^{x-1}.$$

Poiché per ogni $x \in \mathbb{N}$ risulta

$$\frac{\mathrm{d}}{\mathrm{d}p}\{(1-p)^x\} = -x(1-p)^{x-1},$$

derivando termine a termine la serie geometrica di ragione $1-p$ (operazione lecita, trattandosi di una serie di potenze nella variabile $1-p$ con raggio di convergenza 1, e appartenendo $1-p$ all'intervallo aperto $(0,1)$) si ottiene:

$$\mathbb{E}[X] = -p \sum_{x=1}^{+\infty} \frac{\mathrm{d}}{\mathrm{d}p}\{(1-p)^x\} = -p \frac{\mathrm{d}}{\mathrm{d}p}\left\{\sum_{x=1}^{+\infty}(1-p)^x\right\}.$$

Essendo

$$\sum_{x=1}^{+\infty}(1-p)^x = \sum_{x=0}^{+\infty}(1-p)^x - 1 = \frac{1}{1-(1-p)} - 1 = \frac{1}{p} - 1,$$

la cui derivata rispetto a p vale $-1/p^2$, si conclude che

$$\mathbb{E}[X] = -p\left(-\frac{1}{p^2}\right) = \frac{1}{p}.$$

Il risultato è in accordo con l'intuizione: se la probabilità di successo in ciascuna prova è p, occorrono in media $1/p$ prove per ottenere il primo successo.

Esempio 1.38. Sia $X \sim \text{Poisson}(\lambda)$ (Definizione 1.47), con $\lambda > 0$, supporto $S_X = \mathbb{N}_0$ e funzione massa di probabilità $p_X(x) = \lambda^x \mathrm{e}^{-\lambda}/x!$. L'addendo corrispondente a $x = 0$ è nullo e, con la sostituzione $y = x - 1$, si ha:

$$\mathbb{E}[X] = \sum_{x=0}^{+\infty} x \frac{\lambda^x}{x!} \mathrm{e}^{-\lambda} = \sum_{x=1}^{+\infty} \frac{\lambda^x}{(x-1)!} \mathrm{e}^{-\lambda} = \lambda \mathrm{e}^{-\lambda} \sum_{x=1}^{+\infty} \frac{\lambda^{x-1}}{(x-1)!}$$

$$= \lambda \mathrm{e}^{-\lambda} \sum_{y=0}^{+\infty} \frac{\lambda^y}{y!} = \lambda \mathrm{e}^{-\lambda} \mathrm{e}^{\lambda} = \lambda.$$

Il parametro di una variabile di Poisson coincide dunque con il suo valore atteso.

Si considerano ora le variabili aleatorie assolutamente continue notevoli, per le quali si applica il punto *(ii)* della Proposizione 1.44; in tutti i casi seguenti la convergenza assoluta dell'integrale è immediata, essendo la funzione integranda non negativa oppure (nel caso normale) maggiorata in modulo da una funzione integrabile.

Esempio 1.39. Sia $X \sim \text{Exp}(\lambda)$ (Definizione 1.52), con $\lambda > 0$. Integrando per parti e osservando che

$$\lim_{x \to +\infty} x\mathrm{e}^{-\lambda x} = 0,$$

si ha:

$$\mathbb{E}[X] = \int_0^{+\infty} x\, \lambda \mathrm{e}^{-\lambda x}\, \mathrm{d}x = \left[-x\mathrm{e}^{-\lambda x}\right]_0^{+\infty} + \int_0^{+\infty} \mathrm{e}^{-\lambda x}\, \mathrm{d}x = 0 + \left[-\frac{\mathrm{e}^{-\lambda x}}{\lambda}\right]_0^{+\infty} = \frac{1}{\lambda}.$$

Esempio 1.40. Sia $X \sim \mathcal{U}(a,b)$ (Definizione 1.54), con $a < b$. Si ha:

$$\mathbb{E}[X] = \int_a^b \frac{x}{b-a}\,\mathrm{d}x = \left[\frac{x^2}{2(b-a)}\right]_a^b = \frac{b^2-a^2}{2(b-a)} = \frac{a+b}{2},$$

ovvero il valore atteso è il punto medio dell'intervallo $[a,b]$, in accordo con l'interpretazione come baricentro di una distribuzione di massa uniforme.

Esempio 1.41. Sia $X \sim \mathcal{N}(a,b)$ (Definizione 1.51), con $a \in \mathbb{R}$ e $b > 0$. Si ha:

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} \frac{x}{\sqrt{2\pi b}} \exp\left(-\frac{(x-a)^2}{2b}\right)\mathrm{d}x.$$

Con la sostituzione $z = (x-a)/\sqrt{b}$, da cui $x = \sqrt{b}\,z + a$ e $\mathrm{d}x = \sqrt{b}\,\mathrm{d}z$, si ottiene:

$$\begin{aligned}\mathbb{E}[X] &= \int_{-\infty}^{+\infty} \frac{\sqrt{b}\,z + a}{\sqrt{2\pi b}}\,\mathrm{e}^{-z^2/2}\,\sqrt{b}\,\mathrm{d}z = \frac{\sqrt{b}}{\sqrt{2\pi}}\int_{-\infty}^{+\infty} z\mathrm{e}^{-z^2/2}\,\mathrm{d}z + \frac{a}{\sqrt{2\pi}}\int_{-\infty}^{+\infty}\mathrm{e}^{-z^2/2}\,\mathrm{d}z \\ &= -\frac{\sqrt{b}}{\sqrt{2\pi}}\int_{-\infty}^{+\infty}\frac{\mathrm{d}}{\mathrm{d}z}\left\{\mathrm{e}^{-z^2/2}\right\}\mathrm{d}z + a = -\frac{\sqrt{b}}{\sqrt{2\pi}}\Big[\mathrm{e}^{-z^2/2}\Big]_{-\infty}^{+\infty} + a = a,\end{aligned}$$

dove si è usato che, per la condizione di normalizzazione della densità $\mathcal{N}(0,1)$,

$$\int_{-\infty}^{+\infty}\mathrm{e}^{-z^2/2}\,\mathrm{d}z = \sqrt{2\pi}.$$

Entrambi gli integrali convergono assolutamente, essendo

$$\int_{-\infty}^{+\infty}|z|\mathrm{e}^{-z^2/2}\,\mathrm{d}z = 2.$$

Il parametro a di una variabile normale coincide dunque con il suo valore atteso, che è anche il centro di simmetria della densità.

Esempio 1.42. Sia $X \sim \chi^2(n)$ (Definizione 1.61), con $n \in \mathbb{N}$. Si ha:

$$\mathbb{E}[X] = \frac{1}{2^{n/2}\,\Gamma\left(\frac{n}{2}\right)}\int_0^{+\infty} x\cdot x^{n/2-1}\mathrm{e}^{-x/2}\,\mathrm{d}x = \frac{1}{2^{n/2}\,\Gamma\left(\frac{n}{2}\right)}\int_0^{+\infty} x^{n/2}\mathrm{e}^{-x/2}\,\mathrm{d}x.$$

Con la sostituzione $z = x/2$, da cui $\mathrm{d}x = 2\,\mathrm{d}z$, e ricordando la proprietà (*i*) della funzione Gamma, si ottiene:

$$\mathbb{E}[X] = \frac{2^{n/2+1}}{2^{n/2}\,\Gamma\left(\frac{n}{2}\right)}\int_0^{+\infty} z^{(n/2+1)-1}\mathrm{e}^{-z}\,\mathrm{d}z = \frac{2\,\Gamma\left(\frac{n}{2}+1\right)}{\Gamma\left(\frac{n}{2}\right)} = 2\cdot\frac{n}{2}\cdot\frac{\Gamma\left(\frac{n}{2}\right)}{\Gamma\left(\frac{n}{2}\right)} = n.$$

Osservazione. Per una variabile aleatoria X di tipo Gamma (Definizione 1.55) di parametri $a > -1$ e $b > 0$ il calcolo è analogo: con la sostituzione $z = x/b$ si ha

$$\mathbb{E}[X] = \frac{1}{b^{a+1}\,\Gamma(a+1)}\int_0^{+\infty} x^{a+1}\mathrm{e}^{-x/b}\,\mathrm{d}x = \frac{b^{a+2}\,\Gamma(a+2)}{b^{a+1}\,\Gamma(a+1)} = b\,(a+1).$$

Per $a = 0$ e $b = 1/\lambda$ si ritrova il valore atteso $1/\lambda$ della variabile $\mathrm{Exp}(\lambda)$ (Esempio 1.39), mentre per $a = n/2-1$ e $b = 2$ si ritrova il valore atteso n della variabile $\chi^2(n)$ (Esempio 1.42).

1.14.2 Valore atteso e funzione di ripartizione

Proposizione 1.45. *Sia X una variabile aleatoria dotata di valore atteso, con funzione di ripartizione F_X. Allora:*

$$\mathbb{E}[X] = -\int_{-\infty}^{0} F_X(x)\,\mathrm{d}x + \int_{0}^{+\infty} \big(1 - F_X(x)\big)\,\mathrm{d}x.$$

Dimostrazione. Si dimostra la tesi nel caso in cui X sia assolutamente continua, con densità f_X; il caso generale si omette. Per la Proposizione 1.44 si ha

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x)\,\mathrm{d}x,$$

dove, per la convergenza assoluta, gli integrali di $x f_X(x)$ sulle due semirette $(-\infty, 0]$ e $[0, +\infty)$ sono entrambi finiti. Scrivendo

$$x = \int_0^x \mathrm{d}y \quad \text{per } x \geq 0 \quad \text{e} \quad x = -\int_x^0 \mathrm{d}y \quad \text{per } x < 0,$$

si ottiene:

$$\mathbb{E}[X] = -\int_{-\infty}^{0} \left(\int_x^0 f_X(x)\,\mathrm{d}y \right) \mathrm{d}x + \int_0^{+\infty} \left(\int_0^x f_X(x)\,\mathrm{d}y \right) \mathrm{d}x.$$

I due integrali doppi sono estesi, rispettivamente, alle regioni

$$\big\{(x,y) \in \mathbb{R}^2 \,|\, x \leq y \leq 0\big\} \qquad \text{e} \qquad \big\{(x,y) \in \mathbb{R}^2 \,|\, 0 \leq y \leq x\big\},$$

rappresentate nella Figura 1.6. Essendo la funzione integranda non negativa, è lecito scambiare l'ordine di integrazione: nella prima regione, fissato $y \leq 0$, la variabile x varia in $(-\infty, y]$, mentre nella seconda, fissato $y \geq 0$, la variabile x varia in $[y, +\infty)$. Si ottiene pertanto:

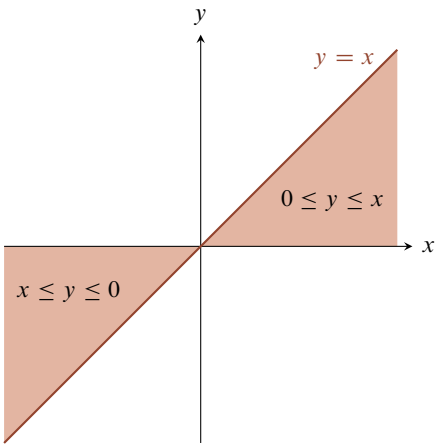


Figura 1.6. Le regioni di integrazione $\{x \leq y \leq 0\}$ e $\{0 \leq y \leq x\}$, delimitate dalla retta $y = x$ e dall'asse delle ascisse.

$$\begin{aligned}
\mathbb{E}[X] &= -\int_{-\infty}^{0} \left(\int_{-\infty}^{y} f_X(x)\,\mathrm{d}x \right) \mathrm{d}y + \int_0^{+\infty} \left(\int_y^{+\infty} f_X(x)\,\mathrm{d}x \right) \mathrm{d}y \\
&= -\int_{-\infty}^{0} F_X(y)\,\mathrm{d}y + \int_0^{+\infty} \left(\int_{-\infty}^{+\infty} f_X(x)\,\mathrm{d}x - \int_{-\infty}^{y} f_X(x)\,\mathrm{d}x \right) \mathrm{d}y \\
&= -\int_{-\infty}^{0} F_X(y)\,\mathrm{d}y + \int_0^{+\infty} \big(1 - F_X(y)\big)\,\mathrm{d}y,
\end{aligned}$$

che è la tesi. □

Osservazione. Se $\mathbb{P}(X \geq 0) = 1$, si ha $F_X(x) = 0$ per ogni $x < 0$, e la relazione precedente si riduce a

$$\mathbb{E}[X] = \int_0^{+\infty} \big(1 - F_X(x)\big)\,\mathrm{d}x = \int_0^{+\infty} \mathbb{P}(X > x)\,\mathrm{d}x.$$

Ad esempio, per $X \sim \mathrm{Exp}(\lambda)$ si ha $\mathbb{P}(X > x) = \mathrm{e}^{-\lambda x}$ per ogni $x \geq 0$, e si ritrova

$$\mathbb{E}[X] = \int_0^{+\infty} \mathrm{e}^{-\lambda x}\,\mathrm{d}x = \frac{1}{\lambda},$$

in accordo con l'Esempio 1.39. In generale, il valore atteso è la differenza tra l'area della regione compresa tra il grafico di $1 - F_X$ e il semiasse positivo delle ascisse e l'area della regione compresa tra il grafico di F_X e il semiasse negativo.

1.14.3 Proprietà del valore atteso

Osservazione. Indicata con $\mathcal{A}$ la famiglia delle variabili aleatorie definite sullo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$ e dotate di valore atteso, il valore atteso si può interpretare come un *funzionale*, ovvero come una funzione che associa un numero reale a ciascun elemento di $\mathcal{A}$.

$$\begin{aligned} \mathbb{E} : \mathcal{A} &\longrightarrow \mathbb{R} \\ X &\longmapsto \mathbb{E}[X] \end{aligned}$$

Si osservi che $\mathbb{E}[X]$ dipende da X soltanto attraverso la sua funzione di ripartizione F_X, cioè attraverso la sua legge: variabili aleatorie con la stessa legge hanno lo stesso valore atteso. Nel seguito si studia come il funzionale $\mathbb{E}$ agisce sulle trasformazioni $g(X) := g \circ X$ di una variabile aleatoria X.

Teorema 1.46. *Siano X una variabile aleatoria con funzione di ripartizione F_X e $g : \mathbb{R} \to \mathbb{R}$ una funzione $\mathfrak{B}$-misurabile, e sia $Y = g(X)$. Allora Y è dotata di valore atteso se e solo se*

$$\int_{-\infty}^{+\infty} \big|g(x)\big|\,\mathrm{d}F_X(x) < +\infty$$

e, in tal caso, si ha:

$$\mathbb{E}\big[g(X)\big] = \int_{-\infty}^{+\infty} g(x)\,\mathrm{d}F_X(x).$$

In particolare:

(*i*) *se X è discreta, con supporto S_X e funzione massa di probabilità p_X, si ha*

$$\mathbb{E}\big[g(X)\big] = \sum_{x \in S_X} g(x)\, p_X(x);$$

(*ii*) *se X è assolutamente continua, con funzione densità di probabilità f_X, si ha*

$$\mathbb{E}\big[g(X)\big] = \int_{-\infty}^{+\infty} g(x)\, f_X(x)\,\mathrm{d}x.$$

Dimostrazione. Si dimostra la tesi nei due casi particolari seguenti; il caso generale richiede la teoria dell'integrale di Lebesgue–Stieltjes, nel cui senso va inteso l'integrale dell'enunciato quando g non è continua, e si omette.

(i) Sia X discreta. Per la Proposizione 1.36, Y è discreta con supporto $S_Y = g(S_X)$ e

$$p_Y(y) = \sum_{\substack{x \in S_X \\ g(x)=y}} p_X(x) \qquad \forall y \in S_Y.$$

Gli insiemi $\{x \in S_X \,|\, g(x) = y\}$, al variare di $y \in S_Y$, formano una partizione di S_X; essendo i termini non negativi, è lecito riordinare e raggruppare le somme, e si ottiene:

$$\sum_{y \in S_Y} |y|\, p_Y(y) = \sum_{y \in S_Y} \sum_{\substack{x \in S_X \\ g(x)=y}} \big|g(x)\big|\, p_X(x) = \sum_{x \in S_X} \big|g(x)\big|\, p_X(x).$$

Per la Proposizione 1.44, Y è dunque dotata di valore atteso se e solo se l'ultima serie converge e, in tal caso, la convergenza assoluta consente di ripetere lo stesso calcolo senza i valori assoluti:

$$\mathbb{E}[Y] = \sum_{y \in S_Y} y\, p_Y(y) = \sum_{y \in S_Y} \sum_{\substack{x \in S_X \\ g(x)=y}} g(x)\, p_X(x) = \sum_{x \in S_X} g(x)\, p_X(x).$$

(ii) Sia X assolutamente continua e sia g strettamente monotòna e derivabile, con $g'(x) \neq 0$ per ogni $x \in \mathbb{R}$. La funzione g è continua, per cui la sua immagine $g(\mathbb{R}) = (\alpha, \beta)$ è un intervallo aperto, con $-\infty \leq \alpha < \beta \leq +\infty$. Per il Teorema 1.35, Y è assolutamente continua e

$$\mathbb{E}[Y] = \int_{-\infty}^{+\infty} y f_Y(y)\,\mathrm{d}y = \int_{\alpha}^{\beta} y\, \frac{f_X\big(g^{-1}(y)\big)}{\big|g'\big(g^{-1}(y)\big)\big|}\,\mathrm{d}y.$$

Si effettua la sostituzione $y = g(x)$, da cui $x = g^{-1}(y)$ e $\mathrm{d}y = g'(x)\,\mathrm{d}x$. Se g è strettamente crescente, si ha $g' > 0$ e x varia da $-\infty$ a $+\infty$ quando y varia da α a β, per cui

$$\mathbb{E}[Y] = \int_{-\infty}^{+\infty} g(x)\, \frac{f_X(x)}{g'(x)}\, g'(x)\,\mathrm{d}x = \int_{-\infty}^{+\infty} g(x)\, f_X(x)\,\mathrm{d}x.$$

Se g è strettamente decrescente, si ha $\big|g'(x)\big| = -g'(x)$ e x varia da $+\infty$ a $-\infty$ quando y varia da α a β, per cui

$$\mathbb{E}[Y] = \int_{+\infty}^{-\infty} g(x)\, \frac{f_X(x)}{-g'(x)}\, g'(x)\,\mathrm{d}x = \int_{-\infty}^{+\infty} g(x)\, f_X(x)\,\mathrm{d}x.$$

Lo stesso calcolo, con $|y|$ al posto di y e $\big|g(x)\big|$ al posto di $g(x)$, mostra che le due condizioni di convergenza assoluta sono equivalenti. □

Osservazione. Il Teorema 1.46 consente di calcolare il valore atteso di $Y = g(X)$ a partire dalla sola legge di X, senza determinare preliminarmente la legge di Y. Esso garantisce inoltre la coerenza della notazione introdotta per i momenti (Definizione 1.70): applicandolo

con $g(x) = x^k$, si ottiene che il momento di ordine k di una variabile aleatoria X coincide con il valore atteso della variabile aleatoria X^k, per cui il simbolo $\mathbb{E}\big[X^k\big]$ può essere letto indifferentemente nei due modi. Ad esempio, posto $Y := aX + b$, il simbolo $\mathbb{E}\big[(aX+b)^n\big]$ denota sia il momento di ordine n di Y sia il valore atteso della variabile aleatoria $(aX+b)^n$ e, per lo stesso teorema applicato a X con $g(x) = (ax+b)^n$, si ha

$$\mathbb{E}\big[(aX+b)^n\big] = \int_{-\infty}^{+\infty} y^n \,\mathrm{d}F_Y(y) = \int_{-\infty}^{+\infty} (ax+b)^n \,\mathrm{d}F_X(x).$$

Proposizione 1.47 (Proprietà del valore atteso). *Sia X una variabile aleatoria con funzione di ripartizione F_X. Allora:*

(*i*) *per ogni $c \in \mathbb{R}$, la variabile aleatoria costante pari a c ha valore atteso*

$$\mathbb{E}[c] = c;$$

(*ii*) *se $g(X)$ è dotata di valore atteso, per ogni $c \in \mathbb{R}$ anche $c\,g(X)$ lo è, e si ha*

$$\mathbb{E}\big[c\,g(X)\big] = c\,\mathbb{E}\big[g(X)\big];$$

(*iii*) *se X è dotata di valore atteso, per ogni $a, b \in \mathbb{R}$ anche $aX + b$ lo è, e si ha*

$$\mathbb{E}[aX+b] = a\,\mathbb{E}[X] + b;$$

(*iv*) *se X è dotata di momento di ordine $n \in \mathbb{N}$, per ogni $a, b \in \mathbb{R}$ anche $(aX+b)^n$ è dotata di valore atteso, e si ha*

$$\mathbb{E}\big[(aX+b)^n\big] = \sum_{j=0}^{n} \binom{n}{j} a^j b^{n-j}\,\mathbb{E}\big[X^j\big],$$

con la convenzione $t^0 = 1$ per ogni $t \in \mathbb{R}$.

Dimostrazione. In ciascun punto si applica il Teorema 1.46 con un'opportuna funzione g, usando la linearità dell'integrale di Riemann–Stieltjes e la condizione di normalizzazione

$$\int_{-\infty}^{+\infty} \mathrm{d}F_X(x) = 1.$$

(*i*) Con la funzione costante $g(x) = c$, che è $\mathfrak{B}$-misurabile, si ha:

$$\mathbb{E}[c] = \int_{-\infty}^{+\infty} c\,\mathrm{d}F_X(x) = c\int_{-\infty}^{+\infty} \mathrm{d}F_X(x) = c.$$

Più in generale, se Z è una variabile aleatoria degenere in c (Definizione 1.43), si ha $S_Z = \{c\}$ e, per la Proposizione 1.44, $\mathbb{E}[Z] = c\,p_Z(c) = c$.

(*ii*) Si ha

$$\int_{-\infty}^{+\infty} \big|c\,g(x)\big|\,\mathrm{d}F_X(x) = |c| \int_{-\infty}^{+\infty} \big|g(x)\big|\,\mathrm{d}F_X(x) < +\infty$$

e

$$\mathbb{E}\big[c\,g(X)\big] = \int_{-\infty}^{+\infty} c\,g(x)\,\mathrm{d}F_X(x) = c\int_{-\infty}^{+\infty} g(x)\,\mathrm{d}F_X(x) = c\,\mathbb{E}\big[g(X)\big].$$

(*iii*) Essendo $|ax+b| \le |a|\,|x| + |b|$ per ogni $x \in \mathbb{R}$, l'integrale di $|ax+b|$ rispetto a F_X è finito, e

$$\begin{aligned}\mathbb{E}[aX+b] &= \int_{-\infty}^{+\infty} (ax+b)\,\mathrm{d}F_X(x) \\ &= a\int_{-\infty}^{+\infty} x\,\mathrm{d}F_X(x) + b\int_{-\infty}^{+\infty} \mathrm{d}F_X(x) = a\,\mathbb{E}[X] + b.\end{aligned}$$

(*iv*) Poiché X è dotata di momento di ordine n, essa è dotata anche di tutti i momenti di ordine $j \in \{0, 1, \dots, n\}$ (osservazione successiva alla Definizione 1.70); essendo inoltre

$$|ax+b|^n \le \big(|a|\,|x| + |b|\big)^n = \sum_{j=0}^{n} \binom{n}{j} |a|^j\,|b|^{n-j}\,|x|^j,$$

la variabile aleatoria $(aX+b)^n$ è dotata di valore atteso. Sviluppando la potenza con la formula del binomio di Newton si ottiene:

$$\begin{aligned}\mathbb{E}\big[(aX+b)^n\big] &= \int_{-\infty}^{+\infty} (ax+b)^n\,\mathrm{d}F_X(x) = \int_{-\infty}^{+\infty} \left(\sum_{j=0}^{n} \binom{n}{j} (ax)^j\,b^{n-j}\right) \mathrm{d}F_X(x) \\ &= \sum_{j=0}^{n} \binom{n}{j} a^j b^{n-j} \int_{-\infty}^{+\infty} x^j\,\mathrm{d}F_X(x) = \sum_{j=0}^{n} \binom{n}{j} a^j b^{n-j}\,\mathbb{E}\big[X^j\big]. \qquad \square\end{aligned}$$

Osservazione. Per $n = 1$ la proprietà (*iv*) si riduce alla (*iii*), essendo $\mathbb{E}\big[X^0\big] = 1$. La proprietà (*iii*) afferma che, per ogni funzione *affine* $g(x) = ax + b$, con $a, b \in \mathbb{R}$, si ha

$$\mathbb{E}\big[g(X)\big] = g\big(\mathbb{E}[X]\big),$$

ovvero il valore atteso di $aX + b$ dipende soltanto dal valore atteso di X. Per una funzione g non affine ciò non è più vero: ad esempio, per $g(x) = x^2$ si ha in generale $\mathbb{E}\big[X^2\big] \neq \big(\mathbb{E}[X]\big)^2$, come si vedrà nel seguito.

1.14.4 Momenti centrali e varianza

Definizione 1.72. Sia X una variabile aleatoria dotata di valore atteso $\mu := \mathbb{E}[X]$, e sia $k \in \mathbb{N}_0$ tale che X sia dotata di momento di ordine k. Si dice *momento intorno alla media* (o *momento centrale*) *di ordine* k della variabile aleatoria X, e si indica con μ_k, il numero reale

$$\mu_k := \mathbb{E}\big[(X-\mu)^k\big] = \int_{-\infty}^{+\infty} (x-\mu)^k\,\mathrm{d}F_X(x).$$

Osservazione. La definizione è ben posta: per la proprietà (*iv*) della Proposizione 1.47, con $a = 1$ e $b = -\mu$, la variabile aleatoria $(X-\mu)^k$ è dotata di valore atteso, che si esprime in termini dei momenti intorno all'origine:

$$\mu_k = \sum_{j=0}^{k} \binom{k}{j} (-\mu)^{k-j}\,\mathbb{E}\big[X^j\big] = \sum_{j=0}^{k} \binom{k}{j} (-\mu)^{k-j}\,\mu'_j,$$

mentre la seconda uguaglianza della definizione segue dal Teorema 1.46 con $g(x) = (x-\mu)^k$. Esplicitando gli addendi, e raggruppando gli ultimi due (quelli con $j = 1$ e $j = 0$), per i quali $\mu'_1 = \mu$ e $\mu'_0 = 1$, la relazione si scrive anche nella forma

$$\mu_k = \mu'_k - \binom{k}{1}\mu'_{k-1}\,\mu + \binom{k}{2}\mu'_{k-2}\,\mu^2 - \dots$$
$$+ (-1)^{k-2}\binom{k}{k-2}\mu'_2\,\mu^{k-2} + (-1)^{k-1}(k-1)\,\mu^k,$$

essendo $(-1)^{k-1}k\,\mu'_1\,\mu^{k-1} + (-1)^k\mu^k = (-1)^{k-1}(k-1)\,\mu^k$. In particolare $\mu_0 = 1$ e, per la proprietà *(iii)*,

$$\mu_1 = \mathbb{E}[X-\mu] = \mathbb{E}[X] - \mu = \mu - \mu = 0:$$

il momento centrale di ordine 1 è sempre nullo. Per i primi ordini successivi si ha:

$$\mu_2 = \mu'_2 - \mu^2, \qquad \mu_3 = \mu'_3 - 3\mu'_2\,\mu + 2\mu^3, \qquad \mu_4 = \mu'_4 - 4\mu'_3\,\mu + 6\mu'_2\,\mu^2 - 3\mu^4.$$

Definizione 1.73. Sia X una variabile aleatoria dotata di momento di ordine 2, e sia $\mu := \mathbb{E}[X]$. Il momento centrale di ordine 2 si chiama *varianza* della variabile aleatoria X, e si indica con $\mathrm{Var}[X]$, con $D^2[X]$ oppure con σ^2:

$$\mathrm{Var}[X] = D^2[X] = \sigma^2 := \mu_2 = \mathbb{E}\big[(X-\mu)^2\big] = \int_{-\infty}^{+\infty}(x-\mu)^2\,\mathrm{d}F_X(x).$$

La radice quadrata non negativa $\sigma := \sqrt{\mathrm{Var}[X]}$ si chiama *deviazione standard* (o *scarto quadratico medio*) della variabile aleatoria X.

Osservazione. La varianza è non negativa, essendo l'integrale della funzione non negativa $(x-\mu)^2$ rispetto alla funzione integratrice non decrescente F_X, e misura la dispersione dei valori di X intorno al valore atteso μ: quanto più la legge di X è concentrata in prossimità di μ, tanto più la varianza è piccola. La deviazione standard si esprime nella stessa unità di misura di X, a differenza della varianza; lo stesso accadrà per gli indici di dispersione di un insieme di dati.

Proposizione 1.48. *Sia X una variabile aleatoria dotata di momento di ordine 2, e sia $\mu := \mathbb{E}[X]$. Allora:*

$$\mathrm{Var}[X] = \mathbb{E}\big[X^2\big] - \big(\mathbb{E}[X]\big)^2 = \mu'_2 - \mu^2.$$

Dimostrazione. Sviluppando il quadrato e usando la linearità dell'integrale di Riemann–Stieltjes si ha:

$$\begin{aligned}\mathrm{Var}[X] &= \int_{-\infty}^{+\infty}\big(x^2 - 2\mu x + \mu^2\big)\,\mathrm{d}F_X(x)\\ &= \int_{-\infty}^{+\infty}x^2\,\mathrm{d}F_X(x) - 2\mu\int_{-\infty}^{+\infty}x\,\mathrm{d}F_X(x) + \mu^2\int_{-\infty}^{+\infty}\mathrm{d}F_X(x)\\ &= \mu'_2 - 2\mu\cdot\mu + \mu^2\cdot 1 = \mu'_2 - \mu^2 = \mathbb{E}\big[X^2\big] - \big(\mathbb{E}[X]\big)^2.\end{aligned}$$

□

Osservazione. La relazione della Proposizione 1.48, che si scrive spesso nella forma abbreviata

$$\mathrm{Var}[X] = \mathbb{E}\big[X^2\big] - \mathbb{E}^2[X], \qquad \text{con } \mathbb{E}^2[X] := \big(\mathbb{E}[X]\big)^2,$$

è la *formula fondamentale* per il calcolo della varianza, poiché riconduce il calcolo di μ_2 a quello dei momenti intorno all'origine μ'_1 e μ'_2; una relazione analoga si otterrà per la varianza di un insieme di dati (Proposizione 2.4). Si osservi inoltre che, essendo $\mathrm{Var}[X] \geq 0$, si ha sempre $\mathbb{E}\big[X^2\big] \geq \mathbb{E}^2[X]$.

1.14.5 Varianza delle variabili aleatorie notevoli

Si calcola ora la varianza delle variabili aleatorie notevoli introdotte in precedenza. Per le variabili aleatorie discrete a valori interi è utile l'osservazione seguente.

Osservazione. Sia X una variabile aleatoria dotata di momento di ordine 2. Per il Teorema 1.46 con $g(x) = x\,(x-1) = x^2 - x$ e per la linearità dell'integrale di Riemann–Stieltjes, la variabile aleatoria $X(X-1)$ è dotata di valore atteso, detto *momento fattoriale di ordine* 2, e si ha

$$\mathbb{E}\big[X(X-1)\big] = \int_{-\infty}^{+\infty} \big(x^2 - x\big)\,\mathrm{d}F_X(x) = \mathbb{E}\big[X^2\big] - \mathbb{E}[X],$$

da cui, per la formula fondamentale,

$$\mathrm{Var}[X] = \mathbb{E}\big[X(X-1)\big] + \mathbb{E}[X] - \mathbb{E}^2[X].$$

Per le variabili aleatorie binomiale, geometrica e di Poisson il calcolo di $\mathbb{E}\big[X(X-1)\big]$ è più agevole di quello di $\mathbb{E}\big[X^2\big]$: il fattore $x\,(x-1)$ si semplifica con i fattoriali o con le potenze che compaiono nella funzione massa di probabilità, e la somma si riconduce alla condizione di normalizzazione o a una serie nota, con lo stesso procedimento già seguito per il valore atteso.

Esempio 1.43. Sia $X \sim \mathrm{Ber}(p)$ (Definizione 1.44), con $p \in (0,1)$, supporto $S_X = \{0,1\}$ e funzione massa di probabilità $p_X(x) = p^x(1-p)^{1-x}$. Essendo $\mathbb{E}[X] = p$ (Esempio 1.35), per il Teorema 1.46 con $g(x) = (x-p)^2$ si ha:

$$\begin{aligned}\mathrm{Var}[X] &= \sum_{x=0}^{1} (x-p)^2\, p_X(x) = (0-p)^2(1-p) + (1-p)^2 p = p^2(1-p) + (1-p)^2 p \\ &= p^2 - p^3 + p - 2p^2 + p^3 = p - p^2 = p\,(1-p).\end{aligned}$$

Lo stesso risultato si ottiene con la formula fondamentale: essendo $x^2 = x$ per $x \in \{0,1\}$, si ha $\mathbb{E}\big[X^2\big] = \mathbb{E}[X] = p$, e quindi

$$\mathrm{Var}[X] = \mathbb{E}\big[X^2\big] - \mathbb{E}^2[X] = p - p^2 = p\,(1-p).$$

Si osservi che la varianza è massima per $p = 1/2$, ovvero quando l'esito della prova è massimamente incerto, e tende a zero per $p \to 0^+$ e per $p \to 1^-$, quando l'esito diventa quasi certo.

Esempio 1.44. Sia $X \sim \mathrm{Bin}(n,p)$ (Definizione 1.45), con $\mathbb{E}[X] = np$ (Esempio 1.36). Gli addendi corrispondenti a $x = 0$ e $x = 1$ sono nulli e, semplificando $x\,(x-1)$ con

$x! = x\,(x-1)\,(x-2)!$, si ha:

$$\begin{aligned}\mathbb{E}\big[X(X-1)\big] &= \sum_{x=0}^{n} x\,(x-1)\binom{n}{x} p^x (1-p)^{n-x} = \sum_{x=2}^{n} \frac{n!}{(x-2)!\,(n-x)!}\, p^x (1-p)^{n-x} \\ &= n\,(n-1)\,p^2 \sum_{x=2}^{n} \binom{n-2}{x-2} p^{x-2} (1-p)^{(n-2)-(x-2)} \\ &= n\,(n-1)\,p^2 \sum_{y=0}^{n-2} \binom{n-2}{y} p^{y} (1-p)^{(n-2)-y} \\ &= n\,(n-1)\,p^2 \big(p + (1-p)\big)^{n-2} = n\,(n-1)\,p^2,\end{aligned}$$

dove si è usato che $n - x = (n-2) - (x-2)$, si è posto $y = x - 2$ e si è applicata la formula del binomio di Newton; per $n = 1$ la somma è vuota e il risultato, pari a 0, resta valido. Per l'osservazione sul momento fattoriale si ottiene dunque:

$$\mathrm{Var}[X] = n\,(n-1)\,p^2 + np - (np)^2 = n^2p^2 - np^2 + np - n^2p^2 = np - np^2 = np\,(1-p).$$

La varianza di una variabile binomiale è dunque n volte quella di una variabile di Bernoulli con lo stesso parametro, coerentemente con l'espressione di X come somma di n variabili di Bernoulli indipendenti di parametro p.

Esempio 1.45. Sia $X \sim \mathrm{Geom}(p)$ (Definizione 1.46), con $\mathbb{E}[X] = 1/p$ (Esempio 1.37). Poiché per ogni $x \in \mathbb{N}$ risulta

$$\frac{\mathrm{d}^2}{\mathrm{d}p^2}\big\{(1-p)^x\big\} = x\,(x-1)\,(1-p)^{x-2},$$

derivando due volte termine a termine la serie geometrica di ragione $1-p$, operazione lecita per le stesse ragioni esposte nell'Esempio 1.37, si ha:

$$\begin{aligned}\mathbb{E}\big[X(X-1)\big] &= \sum_{x=1}^{+\infty} x\,(x-1)\,p\,(1-p)^{x-1} = p\,(1-p) \sum_{x=1}^{+\infty} x\,(x-1)\,(1-p)^{x-2} \\ &= p\,(1-p)\,\frac{\mathrm{d}^2}{\mathrm{d}p^2}\left\{\sum_{x=1}^{+\infty}(1-p)^x\right\}.\end{aligned}$$

Essendo

$$\sum_{x=1}^{+\infty}(1-p)^x = \frac{1}{p} - 1,$$

la cui derivata seconda rispetto a p vale $2/p^3$, si ottiene

$$\mathbb{E}\big[X(X-1)\big] = p\,(1-p)\cdot\frac{2}{p^3} = \frac{2\,(1-p)}{p^2},$$

e quindi, per l'osservazione sul momento fattoriale,

$$\mathrm{Var}[X] = \frac{2\,(1-p)}{p^2} + \frac{1}{p} - \frac{1}{p^2} = \frac{2 - 2p + p - 1}{p^2} = \frac{1-p}{p^2}.$$

Si osservi che la varianza, come il valore atteso, cresce illimitatamente per $p \to 0^+$: quanto più il successo è raro, tanto più il numero di prove necessarie per ottenerlo è incerto.

Esempio 1.46. Sia $X \sim \text{Poisson}(\lambda)$ (Definizione 1.47), con $\mathbb{E}[X] = \lambda$ (Esempio 1.38). Gli addendi corrispondenti a $x = 0$ e $x = 1$ sono nulli e, semplificando $x(x-1)$ con $x! = x(x-1)(x-2)!$, con la sostituzione $y = x - 2$ si ha:

$$\mathbb{E}\big[X(X-1)\big] = \sum_{x=0}^{+\infty} x(x-1)\frac{\lambda^x}{x!}\mathrm{e}^{-\lambda} = \lambda^2\mathrm{e}^{-\lambda}\sum_{x=2}^{+\infty}\frac{\lambda^{x-2}}{(x-2)!}$$
$$= \lambda^2\mathrm{e}^{-\lambda}\sum_{y=0}^{+\infty}\frac{\lambda^y}{y!} = \lambda^2\mathrm{e}^{-\lambda}\mathrm{e}^{\lambda} = \lambda^2,$$

e quindi, per l'osservazione sul momento fattoriale,

$$\text{Var}[X] = \lambda^2 + \lambda - \lambda^2 = \lambda.$$

Valore atteso e varianza di una variabile di Poisson coincidono dunque entrambi con il parametro λ.

Si considerano ora le variabili aleatorie assolutamente continue notevoli. Per esse la formula fondamentale conviene quando il calcolo di $\mathbb{E}\big[X^2\big]$ si riconduce alla funzione Gamma di Eulero, come per le variabili esponenziale e chi quadro, mentre la definizione conviene quando la densità ha un'espressione semplice in termini di $x - \mu$, come per le variabili uniforme e normale; in tutti i casi la convergenza assoluta degli integrali è immediata, essendo la funzione integranda non negativa.

Esempio 1.47. Sia $X \sim \text{Exp}(\lambda)$ (Definizione 1.52), con $\mathbb{E}[X] = 1/\lambda$ (Esempio 1.39). Con la sostituzione $z = \lambda x$, da cui $x = z/\lambda$ e $\mathrm{d}x = (1/\lambda)\,\mathrm{d}z$, e ricordando che $\Gamma(3) = 2! = 2$ (proprietà *(iii)* della funzione Gamma), si ha:

$$\mathbb{E}\big[X^2\big] = \int_0^{+\infty} x^2\,\lambda\mathrm{e}^{-\lambda x}\,\mathrm{d}x = \lambda\int_0^{+\infty}\frac{z^2}{\lambda^2}\mathrm{e}^{-z}\frac{1}{\lambda}\,\mathrm{d}z = \frac{1}{\lambda^2}\int_0^{+\infty} z^{3-1}\mathrm{e}^{-z}\,\mathrm{d}z = \frac{\Gamma(3)}{\lambda^2} = \frac{2}{\lambda^2},$$

e quindi

$$\text{Var}[X] = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}.$$

La deviazione standard $\sigma = 1/\lambda$ coincide dunque con il valore atteso.

Esempio 1.48. Sia $X \sim \mathcal{U}(a,b)$ (Definizione 1.54), con $\mathbb{E}[X] = (a+b)/2$, punto medio dell'intervallo (Esempio 1.40). Conviene applicare direttamente la definizione: con la sostituzione $t = x - (a+b)/2$, che porta il punto medio nell'origine, gli estremi a e b diventano rispettivamente $-(b-a)/2$ e $(b-a)/2$, e si ha:

$$\text{Var}[X] = \int_a^b \left(x - \frac{a+b}{2}\right)^2 \frac{1}{b-a}\,\mathrm{d}x = \frac{1}{b-a}\int_{-(b-a)/2}^{(b-a)/2} t^2\,\mathrm{d}t = \frac{1}{b-a}\left[\frac{t^3}{3}\right]_{-(b-a)/2}^{(b-a)/2}$$
$$= \frac{1}{b-a}\cdot\frac{2}{3}\cdot\frac{(b-a)^3}{8} = \frac{(b-a)^2}{12}.$$

Con la formula fondamentale si ottiene lo stesso risultato, al prezzo di qualche passaggio algebrico in più: essendo

$$\mathbb{E}\big[X^2\big] = \int_a^b \frac{x^2}{b-a}\,\mathrm{d}x = \frac{b^3-a^3}{3(b-a)} = \frac{a^2+ab+b^2}{3},$$

si ha

$$\mathrm{Var}[X] = \frac{a^2+ab+b^2}{3} - \frac{(a+b)^2}{4} = \frac{4a^2+4ab+4b^2-3a^2-6ab-3b^2}{12} = \frac{(b-a)^2}{12}.$$

La varianza dipende soltanto dall'ampiezza $b-a$ dell'intervallo e non dalla sua posizione, in accordo con l'interpretazione come misura di dispersione.

Esempio 1.49. Sia $X \sim \mathcal{N}(a,b)$ (Definizione 1.51), con $\mathbb{E}[X] = a$ (Esempio 1.41). Anche in questo caso conviene la definizione, poiché la densità dipende da x soltanto attraverso $(x-a)^2$. Con la sostituzione $z = (x-a)/\sqrt{b}$, da cui $(x-a)^2 = bz^2$ e $\mathrm{d}x = \sqrt{b}\,\mathrm{d}z$, si ha:

$$\mathrm{Var}[X] = \int_{-\infty}^{+\infty} (x-a)^2 \frac{1}{\sqrt{2\pi b}} \exp\left(-\frac{(x-a)^2}{2b}\right) \mathrm{d}x = \frac{b}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} z^2 \mathrm{e}^{-z^2/2}\,\mathrm{d}z.$$

Integrando per parti, essendo

$$z\mathrm{e}^{-z^2/2} = -\frac{\mathrm{d}}{\mathrm{d}z}\left\{\mathrm{e}^{-z^2/2}\right\}, \qquad \lim_{z\to\pm\infty} z\mathrm{e}^{-z^2/2} = 0,$$

si ottiene:

$$\int_{-\infty}^{+\infty} z\cdot z\mathrm{e}^{-z^2/2}\,\mathrm{d}z = \left[-z\mathrm{e}^{-z^2/2}\right]_{-\infty}^{+\infty} + \int_{-\infty}^{+\infty} \mathrm{e}^{-z^2/2}\,\mathrm{d}z = 0 + \sqrt{2\pi},$$

dove l'ultimo integrale è quello della condizione di normalizzazione della densità $\mathcal{N}(0,1)$. Si conclude che

$$\mathrm{Var}[X] = \frac{b}{\sqrt{2\pi}} \cdot \sqrt{2\pi} = b.$$

I due parametri di una variabile normale sono dunque il suo valore atteso e la sua varianza. In particolare, poiché nello studio del grafico della densità normale si è visto che i punti di flesso hanno ascisse $a \pm \sqrt{b}$, la deviazione standard $\sqrt{b}$ è la distanza dei punti di flesso della densità dall'asse di simmetria $x = a$.

Esempio 1.50. Sia $X \sim \chi^2(n)$ (Definizione 1.61), con $\mathbb{E}[X] = n$ (Esempio 1.42). Procedendo come per il valore atteso, con la sostituzione $z = x/2$ e applicando due volte la proprietà (*i*) della funzione Gamma, si ha:

$$\begin{aligned}\mathbb{E}\left[X^2\right] &= \frac{1}{2^{n/2}\,\Gamma\left(\frac{n}{2}\right)} \int_0^{+\infty} x^2 \cdot x^{n/2-1}\mathrm{e}^{-x/2}\,\mathrm{d}x = \frac{2^{n/2+2}}{2^{n/2}\,\Gamma\left(\frac{n}{2}\right)} \int_0^{+\infty} z^{(n/2+2)-1}\mathrm{e}^{-z}\,\mathrm{d}z \\ &= \frac{4\,\Gamma\left(\frac{n}{2}+2\right)}{\Gamma\left(\frac{n}{2}\right)} = 4\left(\frac{n}{2}+1\right)\frac{n}{2} = n^2+2n,\end{aligned}$$

e quindi

$$\mathrm{Var}[X] = n^2+2n-n^2 = 2n.$$

Osservazione. Per una variabile aleatoria X di tipo Gamma (Definizione 1.55) di parametri $a > -1$ e $b > 0$, per la quale si è già ottenuto $\mathbb{E}[X] = b\,(a+1)$, il calcolo è analogo: con la sostituzione $z = x/b$ e la proprietà (*i*) della funzione Gamma si ha

$$\mathbb{E}\left[X^2\right] = \frac{1}{b^{a+1}\,\Gamma(a+1)} \int_0^{+\infty} x^{a+2}\mathrm{e}^{-x/b}\,\mathrm{d}x = \frac{b^{a+3}\,\Gamma(a+3)}{b^{a+1}\,\Gamma(a+1)} = b^2\,(a+2)\,(a+1),$$

e quindi

$$\mathrm{Var}[X] = b^2\,(a+1)\,(a+2) - b^2\,(a+1)^2 = b^2\,(a+1).$$

Per $a = 0$ e $b = 1/\lambda$ si ritrova la varianza $1/\lambda^2$ della variabile $\mathrm{Exp}(\lambda)$ (Esempio 1.47), mentre per $a = n/2 - 1$ e $b = 2$ si ritrova la varianza $2n$ della variabile $\chi^2(n)$ (Esempio 1.50). Si osservi infine che la variabile di Cauchy (Esempio 1.34), non essendo dotata di valore atteso, non è dotata di alcun momento di ordine $k \geq 1$, e dunque neppure di varianza.

Nella Tabella 1.2 sono riassunti il valore atteso e la varianza delle variabili aleatorie notevoli.

Tabella 1.2. Valore atteso e varianza delle variabili aleatorie notevoli.

Variabile aleatoria	Notazione	Parametri	$\mathbb{E}[X]$	$\mathrm{Var}[X]$
Variabili aleatorie discrete				
Bernoulli	$\mathrm{Ber}(p)$	$p \in (0,1)$	p	$p\,(1-p)$
Binomiale	$\mathrm{Bin}(n,p)$	$n \in \mathbb{N}$, $p \in (0,1)$	np	$np\,(1-p)$
Geometrica	$\mathrm{Geom}(p)$	$p \in (0,1)$	$1/p$	$(1-p)/p^2$
Poisson	$\mathrm{Poisson}(\lambda)$	$\lambda > 0$	λ	λ
Variabili aleatorie assolutamente continue				
Esponenziale	$\mathrm{Exp}(\lambda)$	$\lambda > 0$	$1/\lambda$	$1/\lambda^2$
Uniforme	$\mathcal{U}(a,b)$	$a < b$	$(a+b)/2$	$(b-a)^2/12$
Normale	$\mathcal{N}(a,b)$	$a \in \mathbb{R}$, $b > 0$	a	b
Chi quadro	$\chi^2(n)$	$n \in \mathbb{N}$	n	$2n$
Gamma	—	$a > -1$, $b > 0$	$b\,(a+1)$	$b^2\,(a+1)$

1.14.6 Proprietà della varianza

Proposizione 1.49 (Proprietà della varianza). *Sia X una variabile aleatoria dotata di momento di ordine 2, e siano $\mu := \mathbb{E}[X]$ e $\sigma := \sqrt{\mathrm{Var}[X]}$. Allora:*

(*i*) *se X è degenere in $c \in \mathbb{R}$ (Definizione 1.43), si ha*

$$\mathrm{Var}[X] = 0;$$

(*ii*) *per ogni $a, b \in \mathbb{R}$, la variabile aleatoria $aX + b$ è dotata di momento di ordine 2 e si ha*

$$\mathrm{Var}[aX + b] = a^2\ \mathrm{Var}[X],$$

per cui la sua deviazione standard è $|a|\,\sigma$.

Dimostrazione.

(*i*) Se X è degenere in c, si ha $S_X = \{c\}$, $p_X(c) = 1$ e $\mu = c$ (proprietà (*i*) della Proposizione 1.47); per il Teorema 1.46 con $g(x) = (x-c)^2$ si ottiene

$$\mathrm{Var}[X] = \sum_{x \in S_X} (x-c)^2\, p_X(x) = (c-c)^2 \cdot 1 = 0.$$

(*ii*) Posto $Y := aX + b$, per la proprietà (*iv*) della Proposizione 1.47 con $n = 2$ la variabile aleatoria Y è dotata di momento di ordine 2, e per la proprietà (*iii*) si ha $\mathbb{E}[Y] = a\mu + b$. Per il Teorema 1.46 con $g(x) = \big(ax + b - (a\mu + b)\big)^2 = a^2(x-\mu)^2$ si ottiene allora:

$$\begin{aligned}\mathrm{Var}[Y] = \mathbb{E}\big[(Y - \mathbb{E}[Y])^2\big] &= \int_{-\infty}^{+\infty} a^2(x-\mu)^2 \,\mathrm{d}F_X(x) \\ &= a^2 \int_{-\infty}^{+\infty} (x-\mu)^2 \,\mathrm{d}F_X(x) = a^2 \,\mathrm{Var}[X]. \qquad \square\end{aligned}$$

Osservazione. A differenza del valore atteso, la varianza non è un operatore lineare, bensì *quadratico*: un fattore moltiplicativo a esce dalla varianza elevato al quadrato e, in particolare, si ha $\mathrm{Var}[-X] = \mathrm{Var}[X]$. Il termine additivo b, invece, non modifica la varianza: una traslazione sposta tutti i valori della variabile aleatoria della stessa quantità, insieme al valore atteso, e lascia inalterata la dispersione intorno a esso. In particolare, per una variabile aleatoria costante pari a c si ha $\mathbb{E}[c] = c$ e $\mathrm{Var}[c] = 0$.

La proprietà (*i*) della Proposizione 1.49 ammette un viceversa: la varianza è nulla *soltanto* per le variabili aleatorie degeneri.

Teorema 1.50. *Sia X una variabile aleatoria dotata di momento di ordine 2, e sia $\mu := \mathbb{E}[X]$. Allora $\mathrm{Var}[X] = 0$ se e solo se X è degenere in μ, ovvero se e solo se $\mathbb{P}(X = \mu) = 1$.*

Dimostrazione. Se X è degenere in μ, si ha $\mathrm{Var}[X] = 0$ per la proprietà (*i*) della Proposizione 1.49. Viceversa, sia $\mathrm{Var}[X] = 0$ e si fissi $\varepsilon > 0$. La funzione $x \longmapsto (x-\mu)^2$ è non negativa e vale almeno ε^2 per $x \le \mu - \varepsilon$ e per $x \ge \mu + \varepsilon$; essendo F_X non decrescente, si ha dunque:

$$\begin{aligned}\mathrm{Var}[X] &= \int_{-\infty}^{+\infty} (x-\mu)^2 \,\mathrm{d}F_X(x) \ge \int_{-\infty}^{\mu-\varepsilon} (x-\mu)^2 \,\mathrm{d}F_X(x) + \int_{\mu+\varepsilon}^{+\infty} (x-\mu)^2 \,\mathrm{d}F_X(x) \\ &\ge \varepsilon^2 \left(\int_{-\infty}^{\mu-\varepsilon} \mathrm{d}F_X(x) + \int_{\mu+\varepsilon}^{+\infty} \mathrm{d}F_X(x) \right) = \varepsilon^2 \big(F_X(\mu-\varepsilon) + 1 - F_X(\mu+\varepsilon) \big) \\ &= \varepsilon^2 \big(\mathbb{P}(X \le \mu-\varepsilon) + \mathbb{P}(X > \mu+\varepsilon) \big) \ge \varepsilon^2 \, \mathbb{P}\big(|X-\mu| > \varepsilon\big),\end{aligned}$$

poiché $\big\{|X-\mu| > \varepsilon\big\} = \{X < \mu-\varepsilon\} \cup \{X > \mu+\varepsilon\} \subseteq \{X \le \mu-\varepsilon\} \cup \{X > \mu+\varepsilon\}$. Essendo $\mathrm{Var}[X] = 0$, si conclude che

$$\mathbb{P}\big(|X-\mu| > \varepsilon\big) = 0 \qquad \forall \varepsilon > 0.$$

Infine, gli eventi $A_n := \big\{|X-\mu| > 1/n\big\}$, per $n \in \mathbb{N}$, formano una successione monotòna crescente la cui unione è $\{X \ne \mu\}$; per la *continuità della misura di probabilità* si ottiene

$$\mathbb{P}(X \ne \mu) = \lim_{n \to +\infty} \mathbb{P}(A_n) = 0,$$

ovvero $\mathbb{P}(X = \mu) = 1$. $\square$

Dimostrazione alternativa (per assurdo). Si dimostra soltanto l'implicazione non banale. Sia $\mathrm{Var}[X] = 0$ e si supponga per assurdo che X non sia degenere in μ, ovvero che $\mathbb{P}(X \ne \mu) > 0$. Gli eventi $A_n := \big\{|X-\mu| > 1/n\big\}$, per $n \in \mathbb{N}$, formano una successione monotòna crescente la cui unione è $\{X \ne \mu\}$; per la *continuità della misura di probabilità* si ha

$$\lim_{n \to +\infty} \mathbb{P}(A_n) = \mathbb{P}(X \ne \mu) > 0,$$

per cui esiste $\varepsilon > 0$ tale che

$$\mathbb{P}\big(|X-\mu| > \varepsilon\big) > 0.$$

La funzione $x \longmapsto (x-\mu)^2$ è non negativa e vale almeno ε^2 per $x \le \mu-\varepsilon$ e per $x \ge \mu+\varepsilon$; essendo F_X non decrescente, si ha dunque:

$$\begin{aligned}\mathrm{Var}[X] &= \int_{-\infty}^{+\infty} (x-\mu)^2 \,\mathrm{d}F_X(x) \ge \int_{-\infty}^{\mu-\varepsilon} (x-\mu)^2 \,\mathrm{d}F_X(x) + \int_{\mu+\varepsilon}^{+\infty} (x-\mu)^2 \,\mathrm{d}F_X(x)\\ &\ge \varepsilon^2\left(\int_{-\infty}^{\mu-\varepsilon} \mathrm{d}F_X(x) + \int_{\mu+\varepsilon}^{+\infty} \mathrm{d}F_X(x)\right) = \varepsilon^2\big(F_X(\mu-\varepsilon) + 1 - F_X(\mu+\varepsilon)\big)\\ &= \varepsilon^2\big(\mathbb{P}(X \le \mu-\varepsilon) + \mathbb{P}(X > \mu+\varepsilon)\big) \ge \varepsilon^2\,\mathbb{P}\big(|X-\mu| > \varepsilon\big) > 0,\end{aligned}$$

poiché $\big\{|X-\mu| > \varepsilon\big\} = \{X < \mu-\varepsilon\} \cup \{X > \mu+\varepsilon\} \subseteq \{X \le \mu-\varepsilon\} \cup \{X > \mu+\varepsilon\}$. Ciò è assurdo, essendo $\mathrm{Var}[X] = 0$. □

Osservazione. La disuguaglianza ottenuta nel corso della dimostrazione,

$$\mathbb{P}\big(|X-\mu| > \varepsilon\big) \le \frac{\mathrm{Var}[X]}{\varepsilon^2} \qquad \forall \varepsilon > 0,$$

vale per ogni variabile aleatoria dotata di momento di ordine 2, è nota come *disuguaglianza di Čebyšëv* e sarà ripresa nel Teorema 1.70: essa precisa in che senso la varianza misura la dispersione di X intorno al valore atteso, poiché limita la probabilità che X si discosti da μ di più di una quantità assegnata.

Definizione 1.74. Sia X una variabile aleatoria non degenere dotata di momento di ordine 2, e siano $\mu := \mathbb{E}[X]$ e $\sigma := \sqrt{\mathrm{Var}[X]}$, con $\sigma > 0$ per il Teorema 1.50. Si dice *standardizzata* di X la variabile aleatoria

$$X^* := \frac{X-\mu}{\sigma}.$$

Osservazione. La standardizzata è una funzione affine di X, con $a = 1/\sigma$ e $b = -\mu/\sigma$; per la proprietà *(iii)* della Proposizione 1.47 e per la proprietà *(ii)* della Proposizione 1.49 si ha dunque

$$\mathbb{E}[X^*] = \frac{\mathbb{E}[X]-\mu}{\sigma} = 0, \qquad \mathrm{Var}[X^*] = \frac{1}{\sigma^2}\,\mathrm{Var}[X] = 1.$$

La standardizzazione è l'operazione che riporta una variabile aleatoria qualsiasi ad avere valore atteso nullo e varianza unitaria; viceversa, $X = \mu + \sigma X^*$ si ricostruisce dalla sua standardizzata.

Esempio 1.51. Sia $X \sim \mathcal{N}(a,b)$ (Definizione 1.51), con $a \in \mathbb{R}$ e $b > 0$. Essendo $\mathbb{E}[X] = a$ e $\mathrm{Var}[X] = b$ (Esempio 1.41 ed Esempio 1.49), la standardizzata di X è

$$X^* = \frac{X-a}{\sqrt{b}} = g(X), \qquad \text{con } g(x) = \frac{x-a}{\sqrt{b}}.$$

La funzione g è strettamente crescente e derivabile, con $g'(x) = 1/\sqrt{b} > 0$ e inversa $g^{-1}(z) = a + \sqrt{b}\,z$; per il Teorema 1.35, per ogni $z \in \mathbb{R}$ si ha

$$f_{X^*}(z) = f_X\big(a+\sqrt{b}\,z\big)\cdot\sqrt{b} = \frac{\sqrt{b}}{\sqrt{2\pi b}}\exp\left(-\frac{\big(\sqrt{b}\,z\big)^2}{2b}\right) = \frac{1}{\sqrt{2\pi}}\exp\left(-\frac{z^2}{2}\right),$$

ovvero $X^* \sim \mathcal{N}(0,1)$: la standardizzata di una variabile normale è la variabile normale *standard*, il che giustifica il nome di quest'ultima. Viceversa, se $Z \sim \mathcal{N}(0,1)$, la variabile aleatoria $a + \sqrt{b}\,Z$ è normale di parametri a e b.

1.15 Momenti di vettori aleatori

Sia $\boldsymbol{X} = (X_1, \dots, X_n)$ un vettore aleatorio definito sullo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$; le sue componenti $X_1, \dots, X_n$, essendo variabili aleatorie definite sullo stesso spazio di probabilità, si dicono *congiuntamente distribuite*. In questa sezione si estendono ai vettori aleatori le nozioni di valore atteso e di momento, e si studia come il valore atteso e la varianza si comportano rispetto alla somma e al prodotto di variabili aleatorie congiuntamente distribuite.

1.15.1 Valore atteso di funzioni di un vettore aleatorio

Il Teorema 1.46 si estende alle funzioni di più variabili aleatorie: il valore atteso di una variabile aleatoria della forma $g(X_1, \dots, X_n)$ si calcola a partire dalla legge congiunta del vettore, senza determinarne preliminarmente la legge.

Teorema 1.51. *Siano $\boldsymbol{X} = (X_1, \dots, X_n)$ un vettore aleatorio e $g : \mathbb{R}^n \to \mathbb{R}$ una funzione $\mathfrak{B}(\mathbb{R}^n)$-misurabile, e sia $Y = g(X_1, \dots, X_n)$, che è una variabile aleatoria.*

(*i*) *Se $\boldsymbol{X}$ è discreto, con supporto $S_{\boldsymbol{X}}$ e funzione massa di probabilità congiunta $p_{\boldsymbol{X}}$, allora Y è dotata di valore atteso se e solo se la serie seguente converge assolutamente e, in tal caso, si ha:*

$$\mathbb{E}\big[g(X_1, \dots, X_n)\big] = \sum_{(x_1,\dots,x_n)\in S_{\boldsymbol{X}}} g(x_1, \dots, x_n)\, p_{\boldsymbol{X}}(x_1, \dots, x_n).$$

(*ii*) *Se $\boldsymbol{X}$ è assolutamente continuo, con funzione densità di probabilità congiunta $f_{\boldsymbol{X}}$, allora Y è dotata di valore atteso se e solo se l'integrale seguente converge assolutamente e, in tal caso, si ha:*

$$\mathbb{E}\big[g(X_1, \dots, X_n)\big] = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} g(x_1, \dots, x_n)\, f_{\boldsymbol{X}}(x_1, \dots, x_n)\, \mathrm{d}x_1 \cdots \mathrm{d}x_n.$$

Dimostrazione. Omessa. □

Osservazione. Si osservi che:

(*i*) per la linearità della somma e dell'integrale, se $g_1(\boldsymbol{X}), \dots, g_m(\boldsymbol{X})$ sono dotate di valore atteso, per ogni $c_1, \dots, c_m \in \mathbb{R}$ anche $c_1\, g_1(\boldsymbol{X}) + \cdots + c_m\, g_m(\boldsymbol{X})$ lo è, e si ha

$$\mathbb{E}\big[c_1\, g_1(\boldsymbol{X}) + \cdots + c_m\, g_m(\boldsymbol{X})\big] = c_1\, \mathbb{E}\big[g_1(\boldsymbol{X})\big] + \cdots + c_m\, \mathbb{E}\big[g_m(\boldsymbol{X})\big];$$

(*ii*) scegliendo $g(x_1, \dots, x_n) = x_j$, con $j \in I_n$, si ottiene il valore atteso della componente X_j a partire dalla legge congiunta; nel caso assolutamente continuo, integrando prima rispetto alle variabili x_i con $i \neq j$, si ritrova la densità marginale

$$f_{X_j}(x_j) = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f_{\boldsymbol{X}}(x_1, \dots, x_n)\, \mathrm{d}x_1 \cdots \mathrm{d}x_{j-1}\, \mathrm{d}x_{j+1} \cdots \mathrm{d}x_n,$$

che si ottiene come nella Proposizione 1.38, e dunque

$$\mathbb{E}[X_j] = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} x_j\, f_{\boldsymbol{X}}(x_1, \dots, x_n)\, \mathrm{d}x_1 \cdots \mathrm{d}x_n = \int_{-\infty}^{+\infty} x_j\, f_{X_j}(x_j)\, \mathrm{d}x_j,$$

in accordo con la Proposizione 1.44; lo scambio dell'ordine di integrazione è lecito per la convergenza assoluta. Allo stesso modo, con $g(x_1,\dots,x_n) = x_j^k$ e $g(x_1,\dots,x_n) = (x_j - \mathbb{E}[X_j])^k$, si ottengono a partire dalla legge congiunta il momento di ordine k e il momento centrale di ordine k della componente X_j.

Proposizione 1.52 (Linearità del valore atteso). *Siano $X_1,\dots,X_n$ variabili aleatorie congiuntamente distribuite, ciascuna dotata di valore atteso, e siano $a_1,\dots,a_n,b \in \mathbb{R}$. Allora la variabile aleatoria $a_1X_1 + \cdots + a_nX_n + b$ è dotata di valore atteso e si ha:*

$$\mathbb{E}[a_1X_1 + \cdots + a_nX_n + b] = a_1\,\mathbb{E}[X_1] + \cdots + a_n\,\mathbb{E}[X_n] + b.$$

In particolare, il valore atteso della somma di due variabili aleatorie è la somma dei valori attesi:

$$\mathbb{E}[X_1 + X_2] = \mathbb{E}[X_1] + \mathbb{E}[X_2].$$

Dimostrazione. Si dimostra la tesi nel caso in cui il vettore $\boldsymbol{X} = (X_1,\dots,X_n)$ sia assolutamente continuo, con densità congiunta $f_{\boldsymbol{X}}$; il caso discreto si tratta allo stesso modo, sostituendo gli integrali con le somme, e il caso generale si omette. Si applica il Teorema 1.51 con $g(x_1,\dots,x_n) = a_1x_1 + \cdots + a_nx_n + b$. Per ogni $j \in I_n$, per il punto *(ii)* dell'osservazione precedente, si ha

$$\int_{-\infty}^{+\infty}\cdots\int_{-\infty}^{+\infty} |x_j|\, f_{\boldsymbol{X}}(x_1,\dots,x_n)\,\mathrm{d}x_1\cdots\mathrm{d}x_n = \int_{-\infty}^{+\infty} |x_j|\, f_{X_j}(x_j)\,\mathrm{d}x_j < +\infty,$$

essendo X_j dotata di valore atteso; poiché $|g(x_1,\dots,x_n)| \le |a_1|\,|x_1| + \cdots + |a_n|\,|x_n| + |b|$ e l'integrale di $f_{\boldsymbol{X}}$ su $\mathbb{R}^n$ vale 1, l'integrale di $|g|\,f_{\boldsymbol{X}}$ è finito. Per la linearità dell'integrale e per il punto *(ii)* si ottiene allora:

$$\begin{aligned}
\mathbb{E}[a_1X_1 + \cdots + a_nX_n + b] &= \sum_{j=1}^{n} a_j \int_{-\infty}^{+\infty}\cdots\int_{-\infty}^{+\infty} x_j\, f_{\boldsymbol{X}}(x_1,\dots,x_n)\,\mathrm{d}x_1\cdots\mathrm{d}x_n \\
&\qquad + b\int_{-\infty}^{+\infty}\cdots\int_{-\infty}^{+\infty} f_{\boldsymbol{X}}(x_1,\dots,x_n)\,\mathrm{d}x_1\cdots\mathrm{d}x_n \\
&= \sum_{j=1}^{n} a_j \int_{-\infty}^{+\infty} x_j\, f_{X_j}(x_j)\,\mathrm{d}x_j + b \\
&= a_1\,\mathbb{E}[X_1] + \cdots + a_n\,\mathbb{E}[X_n] + b. \qquad \square
\end{aligned}$$

Osservazione. La Proposizione 1.52 non richiede alcuna ipotesi di indipendenza: il valore atteso di una combinazione lineare di variabili aleatorie dipende soltanto dai valori attesi delle singole variabili, qualunque sia la loro legge congiunta. Per $n = 1$ si ritrova la proprietà *(iii)* della Proposizione 1.47.

Per il prodotto di variabili aleatorie, invece, la legge congiunta interviene in modo essenziale, e un risultato analogo vale soltanto sotto l'ipotesi di indipendenza.

Proposizione 1.53. *(i) Siano X e Y variabili aleatorie indipendenti e $h, g : \mathbb{R} \to \mathbb{R}$ funzioni $\mathcal{B}$-misurabili tali che $h(X)$ e $g(Y)$ siano dotate di valore atteso. Allora $h(X)\,g(Y)$ è dotata di valore atteso e si ha:*

$$\mathbb{E}\big[h(X)\,g(Y)\big] = \mathbb{E}\big[h(X)\big]\,\mathbb{E}\big[g(Y)\big].$$

(*ii*) *Siano $X_1, \dots, X_n$ variabili aleatorie indipendenti, ciascuna dotata di valore atteso. Allora il prodotto $X_1 X_2 \cdots X_n$ è dotato di valore atteso e si ha:*

$$\mathbb{E}[X_1 X_2 \cdots X_n] = \mathbb{E}[X_1]\,\mathbb{E}[X_2] \cdots \mathbb{E}[X_n].$$

DIMOSTRAZIONE. Si dimostra la tesi nel caso assolutamente continuo; il caso discreto si tratta allo stesso modo, con le somme al posto degli integrali, e il caso generale si omette.

(*i*) Per la PROPOSIZIONE 1.39 la densità congiunta si fattorizza, $f_{X,Y}(x,y) = f_X(x)\, f_Y(y)$, per cui la funzione integranda $h(x)\, g(y)\, f_{X,Y}(x,y)$ è il prodotto di una funzione della sola x per una funzione della sola y. Per il TEOREMA 1.51 e per il TEOREMA 1.46 si ha allora

$$\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} \big|h(x)\, g(y)\big|\, f_{X,Y}(x,y)\,\mathrm{d}x\,\mathrm{d}y = \int_{-\infty}^{+\infty} \big|h(x)\big|\, f_X(x)\,\mathrm{d}x \cdot \int_{-\infty}^{+\infty} \big|g(y)\big|\, f_Y(y)\,\mathrm{d}y < +\infty,$$

e lo stesso calcolo senza i valori assoluti fornisce

$$\mathbb{E}\big[h(X)\, g(Y)\big] = \int_{-\infty}^{+\infty} h(x)\, f_X(x)\,\mathrm{d}x \cdot \int_{-\infty}^{+\infty} g(y)\, f_Y(y)\,\mathrm{d}y = \mathbb{E}\big[h(X)\big]\,\mathbb{E}\big[g(Y)\big].$$

(*ii*) Per la PROPOSIZIONE 1.39 si ha $f_{\boldsymbol{X}}(x_1, \dots, x_n) = f_{X_1}(x_1) \cdots f_{X_n}(x_n)$, per cui l'integrale n-dimensionale del TEOREMA 1.51 con $g(x_1, \dots, x_n) = x_1 \cdots x_n$ si spezza nel prodotto di n integrali semplici:

$$\begin{aligned}\mathbb{E}[X_1 \cdots X_n] &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} x_1 \cdots x_n\, f_{X_1}(x_1) \cdots f_{X_n}(x_n)\,\mathrm{d}x_1 \cdots \mathrm{d}x_n \\ &= \prod_{j=1}^{n} \int_{-\infty}^{+\infty} x_j\, f_{X_j}(x_j)\,\mathrm{d}x_j = \prod_{j=1}^{n} \mathbb{E}[X_j],\end{aligned}$$

e la convergenza assoluta si verifica allo stesso modo, con $|x_1 \cdots x_n|$ al posto di $x_1 \cdots x_n$. □

1.15.2 Momenti misti, covarianza e coefficiente di correlazione

Oltre ai momenti delle singole componenti, per un vettore aleatorio si considerano momenti che coinvolgono più componenti contemporaneamente.

DEFINIZIONE 1.75. Sia $\boldsymbol{X} = (X_1, \dots, X_n)$ un vettore aleatorio, e siano $i, j \in I_n$ e $h, k \in \mathbb{N}_0$. Qualora i valori attesi seguenti esistano, si definiscono:

(*i*) il *momento assoluto* intorno all'origine di ordine k della componente X_j, indicato anche con β_k,

$$\mathbb{E}\big[|X_j|^k\big];$$

(*ii*) il *momento prodotto* (o *momento misto*) di ordine h e k delle componenti X_i e X_j,

$$\mathbb{E}\big[X_i^h\, X_j^k\big];$$

(*iii*) il *momento centrale prodotto* di ordine h e k delle componenti X_i e X_j, se esse sono dotate di valore atteso,

$$\mathbb{E}\Big[\big(X_i - \mathbb{E}[X_i]\big)^h \big(X_j - \mathbb{E}[X_j]\big)^k\Big].$$

Per il Teorema 1.51 ciascuno di essi si calcola come somma o integrale, rispetto alla legge congiunta, della corrispondente funzione di $(x_1, \dots, x_n)$; ad esempio, nel caso assolutamente continuo,

$$\mathbb{E}\big[X_i^h\, X_j^k\big] = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} x_i^h\, x_j^k\, f_{\boldsymbol{X}}(x_1, \dots, x_n)\, \mathrm{d}x_1 \cdots \mathrm{d}x_n.$$

Osservazione. Il momento assoluto di ordine k di una variabile aleatoria X è ben definito per ogni X dotata di momento di ordine k, ed è proprio l'integrale

$$\int_{-\infty}^{+\infty} |x|^k \, \mathrm{d}F_X(x)$$

che compare nella condizione di convergenza assoluta della Definizione 1.70; per k pari esso coincide con il momento di ordine k.

Tra i momenti centrali prodotto di due variabili aleatorie è particolarmente importante quello di ordine 1 e 1.

Definizione 1.76. Siano X e Y variabili aleatorie congiuntamente distribuite, dotate di momento di ordine 2, e siano $\mu_X := \mathbb{E}[X]$ e $\mu_Y := \mathbb{E}[Y]$. Si dice *covarianza* di X e Y il momento centrale prodotto di ordine 1 e 1:

$$\mathrm{Cov}[X, Y] := \mathbb{E}\big[(X - \mu_X)(Y - \mu_Y)\big].$$

Osservazione. La definizione è ben posta: essendo $|(x - \mu_X)(y - \mu_Y)| \le \frac{1}{2}(x - \mu_X)^2 + \frac{1}{2}(y - \mu_Y)^2$ per ogni $(x, y) \in \mathbb{R}^2$, e avendo le due funzioni a secondo membro valore atteso finito, pari rispettivamente a $\frac{1}{2}\mathrm{Var}[X]$ e $\frac{1}{2}\mathrm{Var}[Y]$ (punto (*ii*) dell'osservazione successiva al Teorema 1.51), la condizione di convergenza assoluta è soddisfatta. La covarianza è simmetrica, $\mathrm{Cov}[X, Y] = \mathrm{Cov}[Y, X]$, e la covarianza di una variabile aleatoria con se stessa è la sua varianza:

$$\mathrm{Cov}[X, X] = \mathbb{E}\big[(X - \mu_X)^2\big] = \mathrm{Var}[X].$$

Si osservi che quest'ultima relazione richiede che X e Y siano la *stessa* variabile aleatoria, cioè che $X(\omega) = Y(\omega)$ per ogni $\omega \in \Omega$; non basta che X e Y abbiano la stessa legge, nel qual caso esse si dicono *identicamente distribuite*. Ad esempio, se X e Y sono identicamente distribuite e indipendenti, si vedrà che $\mathrm{Cov}[X, Y] = 0$, che è diverso da $\mathrm{Var}[X]$ non appena X non è degenere.

Proposizione 1.54. *Siano X e Y variabili aleatorie congiuntamente distribuite, dotate di momento di ordine 2. Allora XY è dotata di valore atteso e si ha:*

$$\mathrm{Cov}[X, Y] = \mathbb{E}[XY] - \mathbb{E}[X]\,\mathbb{E}[Y].$$

Dimostrazione. Essendo $|xy| \le \frac{1}{2}x^2 + \frac{1}{2}y^2$, la variabile aleatoria XY è dotata di valore atteso, come nell'osservazione precedente. Sviluppando il prodotto e applicando la linearità del valore atteso (punto (*i*) dell'osservazione successiva al Teorema 1.51) si ottiene:

$$\begin{aligned}\mathrm{Cov}[X, Y] &= \mathbb{E}[XY - \mu_Y X - \mu_X Y + \mu_X \mu_Y] = \mathbb{E}[XY] - \mu_Y\,\mathbb{E}[X] - \mu_X\,\mathbb{E}[Y] + \mu_X \mu_Y \\ &= \mathbb{E}[XY] - \mu_X \mu_Y - \mu_X \mu_Y + \mu_X \mu_Y = \mathbb{E}[XY] - \mathbb{E}[X]\,\mathbb{E}[Y].\end{aligned}$$

□

Osservazione. Per $Y = X$ la Proposizione 1.54 si riduce alla formula fondamentale per la varianza (Proposizione 1.48), $\mathrm{Var}[X] = \mathbb{E}\big[X^2\big] - \mathbb{E}^2[X]$; essa svolge per la covarianza lo stesso ruolo, riconducendone il calcolo ai momenti $\mathbb{E}[XY]$, $\mathbb{E}[X]$ e $\mathbb{E}[Y]$.

Definizione 1.77. Siano X e Y variabili aleatorie congiuntamente distribuite, dotate di momento di ordine 2, e siano $\sigma_X := \sqrt{\mathrm{Var}[X]}$ e $\sigma_Y := \sqrt{\mathrm{Var}[Y]}$.

(*i*) Le variabili aleatorie X e Y si dicono *scorrelate* (o *incorrelate*) se

$$\mathrm{Cov}[X, Y] = 0.$$

(*ii*) Se X e Y sono non degeneri, si dice *coefficiente di correlazione* di X e Y il numero reale

$$\rho(X, Y) := \frac{\mathrm{Cov}[X, Y]}{\sigma_X \, \sigma_Y}.$$

Osservazione. Il coefficiente di correlazione è ben definito perché, per il Teorema 1.50, le deviazioni standard di variabili aleatorie non degeneri sono strettamente positive. A differenza della covarianza, esso è un numero puro: per la proprietà (*ii*) della Proposizione 1.49, moltiplicando X per una costante $a > 0$ la covarianza e la deviazione standard σ_X vengono moltiplicate entrambe per a, e ρ non cambia. Due variabili aleatorie non degeneri sono dunque scorrelate se e solo se $\rho(X, Y) = 0$.

Proposizione 1.55. *Siano X e Y variabili aleatorie indipendenti, dotate di momento di ordine 2. Allora X e Y sono scorrelate; se inoltre sono non degeneri, si ha $\rho(X, Y) = 0$.*

Dimostrazione. Per la proprietà (*ii*) della Proposizione 1.53 si ha $\mathbb{E}[XY] = \mathbb{E}[X]\,\mathbb{E}[Y]$, e dalla Proposizione 1.54 segue

$$\mathrm{Cov}[X, Y] = \mathbb{E}[XY] - \mathbb{E}[X]\,\mathbb{E}[Y] = \mathbb{E}[X]\,\mathbb{E}[Y] - \mathbb{E}[X]\,\mathbb{E}[Y] = 0. \qquad \square$$

Osservazione. Il viceversa è falso: due variabili aleatorie scorrelate non sono, in generale, indipendenti, come mostra l'esempio seguente. L'indipendenza è una condizione sull'intera legge congiunta, che deve fattorizzarsi su ogni coppia di boreliani, mentre la scorrelazione è una condizione su un solo momento, $\mathbb{E}[XY]$.

Esempio 1.52. Sia (X, Y) un vettore aleatorio discreto con supporto e funzione massa di probabilità congiunta

$$S_{(X,Y)} = \big\{(-1, 1),\ (0, 0),\ (1, 1)\big\}, \qquad p_{X,Y}(-1, 1) = p_{X,Y}(0, 0) = p_{X,Y}(1, 1) = \frac{1}{3},$$

riassunta nella Tabella 1.3, nella quale l'ultima riga e l'ultima colonna riportano le funzioni massa marginali, ottenute sommando lungo le colonne e lungo le righe.

Si ha dunque $S_X = \{-1, 0, 1\}$, con $p_X(x) = 1/3$ per ogni $x \in S_X$, e $S_Y = \{0, 1\}$, con $p_Y(0) = 1/3$ e $p_Y(1) = 2/3$. I valori attesi sono

$$\mathbb{E}[X] = -1 \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} = 0, \qquad \mathbb{E}[Y] = 0 \cdot \frac{1}{3} + 1 \cdot \frac{2}{3} = \frac{2}{3},$$

mentre, per il Teorema 1.51 con $g(x, y) = xy$, sommando sui tre punti del supporto congiunto si ha

$$\mathbb{E}[XY] = (-1 \cdot 1) \cdot \frac{1}{3} + (0 \cdot 0) \cdot \frac{1}{3} + (1 \cdot 1) \cdot \frac{1}{3} = 0.$$

Tabella 1.3. Funzione massa di probabilità congiunta del vettore aleatorio (X, Y) e funzioni massa marginali.

$p_{X,Y}(x,y)$	$y=0$	$y=1$	$p_X(x)$
$x=-1$	0	1/3	1/3
$x=0$	1/3	0	1/3
$x=1$	0	1/3	1/3
$p_Y(y)$	1/3	2/3	1

Per la Proposizione 1.54 si ottiene $\mathrm{Cov}[X,Y] = 0 - 0 \cdot \frac{2}{3} = 0$: le variabili X e Y sono scorrelate. Esse non sono tuttavia indipendenti, poiché la funzione massa congiunta non si fattorizza (Proposizione 1.39): ad esempio

$$p_{X,Y}(-1,1) = \frac{1}{3} \neq \frac{2}{9} = \frac{1}{3} \cdot \frac{2}{3} = p_X(-1)\, p_Y(1).$$

Si osservi che in questo esempio $Y = X^2$: la variabile Y è addirittura una funzione di X, e dunque ne dipende nel modo più forte possibile, ma la dipendenza non è di tipo lineare e la covarianza, che misura soltanto la dipendenza lineare, non la rileva. In generale, se la legge di X è simmetrica rispetto all'origine e X è dotata di momento di ordine 3, si ha $\mathbb{E}[X] = \mathbb{E}\big[X^3\big] = 0$ e quindi $\mathrm{Cov}\big[X, X^2\big] = \mathbb{E}\big[X^3\big] - \mathbb{E}[X]\,\mathbb{E}\big[X^2\big] = 0$.

1.15.3 Varianza della somma e coefficiente di correlazione

Proposizione 1.56. *Siano X e Y variabili aleatorie congiuntamente distribuite, dotate di momento di ordine 2. Allora $X+Y$ e $X-Y$ sono dotate di momento di ordine 2 e si ha:*

$$\mathrm{Var}[X \pm Y] = \mathrm{Var}[X] + \mathrm{Var}[Y] \pm 2\ \mathrm{Cov}[X,Y].$$

Se inoltre X e Y sono non degeneri, con deviazioni standard σ_X e σ_Y, si ha:

$$\mathrm{Var}[X \pm Y] = \mathrm{Var}[X] + \mathrm{Var}[Y] \pm 2\,\rho(X,Y)\,\sigma_X\,\sigma_Y.$$

Dimostrazione. Essendo $(x \pm y)^2 \leq 2x^2 + 2y^2$, la variabile aleatoria $(X \pm Y)^2$ è dotata di valore atteso, come nell'osservazione successiva alla Definizione 1.76. Posto $\mu_X := \mathbb{E}[X]$ e $\mu_Y := \mathbb{E}[Y]$, per la Proposizione 1.52 si ha $\mathbb{E}[X \pm Y] = \mu_X \pm \mu_Y$, per cui, sviluppando il quadrato e applicando la linearità del valore atteso, si ottiene:

$$\begin{aligned}
\mathrm{Var}[X \pm Y] &= \mathbb{E}\Big[\big((X-\mu_X) \pm (Y-\mu_Y)\big)^2\Big] \\
&= \mathbb{E}\big[(X-\mu_X)^2 \pm 2(X-\mu_X)(Y-\mu_Y) + (Y-\mu_Y)^2\big] \\
&= \mathbb{E}\big[(X-\mu_X)^2\big] \pm 2\,\mathbb{E}\big[(X-\mu_X)(Y-\mu_Y)\big] + \mathbb{E}\big[(Y-\mu_Y)^2\big] \\
&= \mathrm{Var}[X] \pm 2\ \mathrm{Cov}[X,Y] + \mathrm{Var}[Y].
\end{aligned}$$

La seconda relazione segue dalla prima, poiché per definizione di coefficiente di correlazione si ha $\mathrm{Cov}[X,Y] = \rho(X,Y)\,\sigma_X\,\sigma_Y$. □

Corollario 1.57. *Se X e Y sono scorrelate, e in particolare se sono indipendenti, si ha:*

$$\mathrm{Var}[X \pm Y] = \mathrm{Var}[X] + \mathrm{Var}[Y].$$

Dimostrazione. Basta porre $\mathrm{Cov}[X, Y] = 0$ nella Proposizione 1.56; se X e Y sono indipendenti, la covarianza è nulla per la Proposizione 1.55. □

Osservazione. La varianza della somma di due variabili aleatorie non è, in generale, la somma delle varianze: il termine correttivo $2\,\mathrm{Cov}[X, Y]$ può essere positivo o negativo, e la varianza della somma può risultare sia maggiore sia minore della somma delle varianze. Ad esempio, per $Y = X$ si ha $\mathrm{Var}[X + X] = \mathrm{Var}[2X] = 4\,\mathrm{Var}[X]$, mentre $\mathrm{Var}[X - X] = \mathrm{Var}[0] = 0$, in accordo con $\mathrm{Cov}[X, X] = \mathrm{Var}[X]$. Lo stesso sviluppo del quadrato, applicato a n variabili aleatorie $X_1, \dots, X_n$ dotate di momento di ordine 2, fornisce

$$\mathrm{Var}[X_1 + \cdots + X_n] = \sum_{i=1}^{n} \mathrm{Var}[X_i] + 2 \sum_{1 \le i < j \le n} \mathrm{Cov}[X_i, X_j],$$

per cui la varianza della somma è la somma delle varianze se le variabili sono a due a due scorrelate, e in particolare se sono a due a due indipendenti.

Esempio 1.53. Sia $X \sim \mathrm{Bin}(n, p)$ (Definizione 1.45). Come osservato dopo la definizione, X si esprime come somma $X = X_1 + \cdots + X_n$ di n variabili aleatorie di Bernoulli indipendenti di parametro p, dove X_i vale 1 se la prova i-esima ha successo e 0 altrimenti. Essendo $\mathbb{E}[X_i] = p$ e $\mathrm{Var}[X_i] = p\,(1-p)$ per ogni $i \in I_n$ (Esempio 1.35 ed Esempio 1.43), per la Proposizione 1.52 e per l'osservazione precedente si ottiene, senza alcun calcolo con la funzione massa binomiale,

$$\mathbb{E}[X] = \sum_{i=1}^{n} \mathbb{E}[X_i] = np, \qquad \mathrm{Var}[X] = \sum_{i=1}^{n} \mathrm{Var}[X_i] = np\,(1-p),$$

in accordo con l'Esempio 1.36 e con l'Esempio 1.44.

Proposizione 1.58. *Siano X una variabile aleatoria non degenere dotata di momento di ordine 2 e $Y = aX + b$, con $a, b \in \mathbb{R}$ e $a \neq 0$. Allora:*

$$\rho(X, Y) = \frac{a}{|a|} = \operatorname{sgn} a = \begin{cases} 1 & \text{se } a > 0 \\ -1 & \text{se } a < 0 \end{cases}$$

Dimostrazione. Posto $\mu := \mathbb{E}[X]$, per la Proposizione 1.47 si ha $\mathbb{E}[Y] = a\mu + b$ e, per la linearità dell'integrale, $\mathbb{E}[XY] = \mathbb{E}\big[aX^2 + bX\big] = a\,\mathbb{E}\big[X^2\big] + b\mu$; dalla Proposizione 1.54 e dalla formula fondamentale per la varianza segue

$$\mathrm{Cov}[X, Y] = a\,\mathbb{E}\big[X^2\big] + b\mu - \mu\,(a\mu + b) = a\big(\mathbb{E}\big[X^2\big] - \mu^2\big) = a\ \mathrm{Var}[X].$$

Per la proprietà *(ii)* della Proposizione 1.49 si ha $\sigma_Y = |a|\,\sigma_X$, con $\sigma_X > 0$, per cui Y è non degenere e

$$\rho(X, Y) = \frac{a\ \mathrm{Var}[X]}{\sigma_X \cdot |a|\,\sigma_X} = \frac{a\,\sigma_X^2}{|a|\,\sigma_X^2} = \frac{a}{|a|}.$$

□

Proposizione 1.59. *Siano X e Y variabili aleatorie congiuntamente distribuite, non degeneri e dotate di momento di ordine 2. Allora:*

$$-1 \leq \rho(X,Y) \leq 1.$$

Inoltre $\rho(X,Y) = 1$ se e solo se esistono $a > 0$ e $b \in \mathbb{R}$ tali che $Y = aX + b$ quasi certamente, e $\rho(X,Y) = -1$ se e solo se ciò accade con $a < 0$.

Dimostrazione. Siano $X^* = (X - \mu_X)/\sigma_X$ e $Y^* = (Y - \mu_Y)/\sigma_Y$ le standardizzate di X e Y (Definizione 1.74), per le quali $\mathbb{E}[X^*] = \mathbb{E}[Y^*] = 0$ e $\operatorname{Var}[X^*] = \operatorname{Var}[Y^*] = 1$. Per la linearità del valore atteso si ha

$$\operatorname{Cov}[X^*, Y^*] = \mathbb{E}[X^*Y^*] = \frac{1}{\sigma_X\,\sigma_Y}\,\mathbb{E}\big[(X-\mu_X)(Y-\mu_Y)\big] = \frac{\operatorname{Cov}[X,Y]}{\sigma_X\,\sigma_Y} = \rho(X,Y),$$

per cui, applicando la Proposizione 1.56 alle standardizzate, si ottiene:

$$0 \leq \operatorname{Var}[X^* \pm Y^*] = \operatorname{Var}[X^*] + \operatorname{Var}[Y^*] \pm 2\operatorname{Cov}[X^*, Y^*] = 2\big(1 \pm \rho(X,Y)\big).$$

Dalla disuguaglianza con il segno $+$ segue $\rho(X,Y) \geq -1$, da quella con il segno $-$ segue $\rho(X,Y) \leq 1$.

Se $\rho(X,Y) = 1$, si ha $\operatorname{Var}[X^* - Y^*] = 0$ e, per il Teorema 1.50, la variabile aleatoria $X^* - Y^*$ è degenere nel proprio valore atteso $\mathbb{E}[X^*] - \mathbb{E}[Y^*] = 0$: dunque $Y^* = X^*$ quasi certamente, ovvero

$$Y = \mu_Y + \sigma_Y X^* = \frac{\sigma_Y}{\sigma_X}\,X + \left(\mu_Y - \frac{\sigma_Y}{\sigma_X}\,\mu_X\right) \quad \text{quasi certamente,}$$

che è della forma $aX + b$ con $a = \sigma_Y/\sigma_X > 0$. Allo stesso modo, se $\rho(X,Y) = -1$ si ha $\operatorname{Var}[X^* + Y^*] = 0$, da cui $Y^* = -X^*$ quasi certamente e $Y = aX + b$ con $a = -\sigma_Y/\sigma_X < 0$. Viceversa, se $Y = aX + b$ quasi certamente con $a \neq 0$, per la Proposizione 1.58 si ha $\rho(X,Y) = \operatorname{sgn} a$. □

Osservazione. Il coefficiente di correlazione misura dunque l'intensità e il verso del *legame lineare* tra due variabili aleatorie: il suo valore assoluto è massimo, pari a 1, esattamente quando Y è una funzione affine di X, con segno positivo se Y cresce al crescere di X e negativo in caso contrario; esso è nullo quando le variabili sono scorrelate, in particolare quando sono indipendenti. I valori intermedi corrispondono a legami lineari parziali, mentre, come mostra l'Esempio 1.52, un legame non lineare può non essere rilevato affatto dal coefficiente di correlazione.

1.16 Funzioni generatrici

In questa sezione si introducono due funzioni associate alla legge di una variabile aleatoria, definite come valori attesi di opportune trasformazioni della variabile: la *funzione generatrice di probabilità*, per le variabili aleatorie discrete a valori interi non negativi, e la *funzione generatrice dei momenti*, per variabili aleatorie qualsiasi. Esse consentono di calcolare i momenti per derivazione, anziché mediante somme o integrali, e di trattare in modo semplice la somma di variabili aleatorie indipendenti.

1.16.1 Funzione generatrice di probabilità

Definizione 1.78. Sia X una variabile aleatoria discreta a valori interi non negativi, ovvero con supporto $S_X \subseteq \mathbb{N}_0$, e con funzione massa di probabilità p_X. Si dice *funzione generatrice di probabilità* di X la funzione $G_X : [-1, 1] \to \mathbb{R}$ definita da

$$G_X(s) := \mathbb{E}\big[s^X\big] = \sum_{x \in S_X} s^x \, p_X(x) \qquad \forall s \in [-1, 1],$$

dove, come per il momento di ordine zero, si pone $s^0 = 1$ anche per $s = 0$.

Osservazione. La definizione è ben posta. Per il punto *(i)* del Teorema 1.46 con $g(x) = s^x$, funzione che interessa soltanto per $x \in S_X$, la variabile aleatoria s^X è dotata di valore atteso, dato dalla serie della definizione, se e solo se tale serie converge assolutamente. Ciò accade per ogni $s \in [-1, 1]$: per ogni $x \in S_X$ si ha infatti

$$\big|s^x \, p_X(x)\big| \leq p_X(x) \qquad \forall s \in [-1, 1],$$

e la serie delle probabilità $p_X(x)$ converge, con somma 1, per la condizione di normalizzazione. Per il criterio di Weierstrass la serie che definisce G_X converge dunque assolutamente e uniformemente su $[-1, 1]$, e la sua somma G_X è una funzione continua, con $|G_X(s)| \leq 1$ per ogni $s \in [-1, 1]$. Inoltre si ha

$$G_X(1) = \sum_{x \in S_X} p_X(x) = 1, \qquad G_X(0) = \mathbb{P}(X = 0),$$

e quindi, per la continuità di G_X,

$$\lim_{s \to 1^-} G_X(s) = G_X(1) = 1.$$

Si osservi infine che è essenziale che X assuma soltanto valori interi: per $s < 0$ la potenza s^x non è definita, in generale, se x non è intero.

Generalizzando il momento fattoriale di ordine 2, introdotto nell'osservazione sul momento fattoriale che precede gli esempi sulla varianza delle variabili aleatorie notevoli, per $k \in \mathbb{N}$ si dice *momento fattoriale di ordine k* di una variabile aleatoria X il valore atteso

$$\mathbb{E}\big[X(X-1)\cdots(X-k+1)\big],$$

qualora esista. Il risultato seguente mostra che i momenti fattoriali di una variabile aleatoria a valori in $\mathbb{N}_0$ si ottengono derivando la sua funzione generatrice di probabilità in $s = 1$.

Teorema 1.60. *Sia X una variabile aleatoria discreta a valori in $\mathbb{N}_0$, con funzione generatrice di probabilità G_X, e sia $k \in \mathbb{N}$. Se X è dotata di momento di ordine k, allora G_X è derivabile k volte in $[-1, 1]$, con derivate unilaterali negli estremi, e si ha*

$$G_X^{(k)}(1) = \mathbb{E}\big[X(X-1)\cdots(X-k+1)\big].$$

In particolare:

(*i*) *se X è dotata di valore atteso, si ha*

$$G_X'(1) = \mathbb{E}[X];$$

(*ii*) *se X è dotata di momento di ordine 2, si ha*

$$G_X''(1) = \mathbb{E}\big[X^2\big] - \mathbb{E}[X];$$

(*iii*) *se X è dotata di momento di ordine 3, si ha*

$$G_X'''(1) = \mathbb{E}\big[X^3\big] - 3\,\mathbb{E}\big[X^2\big] + 2\,\mathbb{E}[X].$$

Dimostrazione. Posto $p_X(x) := 0$ per $x \in \mathbb{N}_0 \setminus S_X$, si ha

$$G_X(s) = \sum_{x=0}^{+\infty} p_X(x)\, s^x \qquad \forall s \in [-1, 1].$$

Sia $j \in \{1, \dots, k\}$. La derivata j-esima del termine $p_X(x)\, s^x$ è nulla per $x < j$ e vale $x(x-1)\cdots(x-j+1)\, p_X(x)\, s^{x-j}$ per $x \geq j$; poiché per $x \geq j$ ciascuno dei j fattori $x, x-1, \dots, x-j+1$ è compreso tra 1 e x, per ogni $s \in [-1, 1]$ si ha

$$\big|x(x-1)\cdots(x-j+1)\, p_X(x)\, s^{x-j}\big| \leq x^j\, p_X(x) \qquad \forall x \geq j.$$

Il secondo membro non dipende da s, e la serie dei termini $x^j\, p_X(x)$ converge, con somma $\mathbb{E}\big[X^j\big]$, poiché X, essendo dotata di momento di ordine k, lo è anche di ordine $j \leq k$ (osservazione successiva alla Definizione 1.70). Per il criterio di Weierstrass, per ogni $j \in \{1, \dots, k\}$ la serie delle derivate j-esime converge dunque uniformemente su $[-1, 1]$ e, per il teorema di derivazione termine a termine delle serie di funzioni, applicato k volte, G_X è derivabile k volte in $[-1, 1]$, con

$$G_X^{(k)}(s) = \sum_{x=k}^{+\infty} x(x-1)\cdots(x-k+1)\, p_X(x)\, s^{x-k} \qquad \forall s \in [-1, 1].$$

Per $s = 1$, includendo nella somma i termini nulli con $x < k$ e applicando il punto (*i*) del Teorema 1.46 con $g(x) = x(x-1)\cdots(x-k+1)$, si ottiene

$$G_X^{(k)}(1) = \sum_{x \in S_X} x(x-1)\cdots(x-k+1)\, p_X(x) = \mathbb{E}\big[X(X-1)\cdots(X-k+1)\big].$$

I casi particolari seguono per $k = 1, 2, 3$, sviluppando i prodotti

$$x(x-1) = x^2 - x, \qquad x(x-1)(x-2) = x^3 - 3x^2 + 2x$$

e applicando la linearità della somma di serie convergenti, essendo X dotata dei momenti di ordine $1, \dots, k$. □

Corollario 1.61. *Sia X una variabile aleatoria discreta a valori in $\mathbb{N}_0$, dotata di momento di ordine 2. Allora:*

$$\mathbb{E}[X] = G_X'(1), \qquad \mathbb{E}\big[X^2\big] = G_X''(1) + G_X'(1), \qquad \mathrm{Var}[X] = G_X''(1) + G_X'(1) - \big(G_X'(1)\big)^2.$$

Dimostrazione. La prima relazione è il punto (*i*) del Teorema 1.60, mentre dal punto (*ii*) si ha $\mathbb{E}\big[X^2\big] = G_X''(1) + \mathbb{E}[X] = G_X''(1) + G_X'(1)$. La terza relazione segue dalle prime due e dalla formula fondamentale per la varianza (Proposizione 1.48). Essendo $G_X''(1) = \mathbb{E}\big[X(X-1)\big]$, essa coincide con la relazione dell'osservazione sul momento fattoriale. □

Mentre le derivate in $s = 1$ forniscono i momenti fattoriali, le derivate in $s = 0$ forniscono le probabilità dei singoli valori, da cui il nome della funzione G_X.

Proposizione 1.62. *Sia X una variabile aleatoria discreta a valori in $\mathbb{N}_0$, con funzione generatrice di probabilità G_X. Allora G_X è derivabile infinite volte nell'intervallo $(-1, 1)$ e si ha*

$$\mathbb{P}(X = x) = \frac{G_X^{(x)}(0)}{x!} \qquad \forall x \in \mathbb{N}_0,$$

dove $G_X^{(0)} := G_X$. In particolare, se due variabili aleatorie X e Y discrete a valori in $\mathbb{N}_0$ hanno la stessa funzione generatrice di probabilità, esse hanno lo stesso supporto e la stessa funzione massa di probabilità, e dunque sono identicamente distribuite.

Dimostrazione. Come nella dimostrazione del Teorema 1.60, G_X è la somma della serie di potenze

$$\sum_{x=0}^{+\infty} p_X(x)\, s^x,$$

con $p_X(x) = 0$ per $x \notin S_X$, che converge per ogni $s \in [-1, 1]$ e ha dunque raggio di convergenza almeno pari a 1. Per il teorema di derivazione delle serie di potenze, G_X è derivabile infinite volte nell'intervallo aperto di convergenza, e quindi in $(-1, 1)$, e i coefficienti della serie sono legati alle derivate in 0 dalla formula di Taylor: $p_X(x) = G_X^{(x)}(0)/x!$ per ogni $x \in \mathbb{N}_0$. Se $G_X = G_Y$, si ha dunque $\mathbb{P}(X = x) = \mathbb{P}(Y = x)$ per ogni $x \in \mathbb{N}_0$: i supporti S_X e S_Y, formati dai valori di probabilità positiva, coincidono, così come le funzioni massa di probabilità e quindi le leggi di X e Y, che sono dunque identicamente distribuite (osservazione successiva alla Definizione 1.76). □

Proposizione 1.63. *Siano $X_1, \dots, X_n$ variabili aleatorie indipendenti, discrete e a valori in $\mathbb{N}_0$, e sia $Y := X_1 + \cdots + X_n$. Allora Y è una variabile aleatoria discreta a valori in $\mathbb{N}_0$, e la sua funzione generatrice di probabilità è il prodotto delle funzioni generatrici di probabilità delle singole variabili:*

$$G_Y(s) = G_{X_1}(s)\, G_{X_2}(s) \cdots G_{X_n}(s) \qquad \forall s \in [-1, 1].$$

In particolare, se $X_1, \dots, X_n$ sono anche identicamente distribuite, con funzione generatrice di probabilità comune G, si ha

$$G_Y(s) = \big(G(s)\big)^n \qquad \forall s \in [-1, 1].$$

Dimostrazione. Il vettore aleatorio $\boldsymbol{X} = (X_1, \dots, X_n)$ è discreto e, per il punto *(ii)* della Proposizione 1.39, la sua funzione massa di probabilità congiunta è il prodotto delle marginali, per cui il suo supporto è $S_{X_1} \times \cdots \times S_{X_n} \subseteq \mathbb{N}_0^n$; la variabile aleatoria Y assume dunque, con probabilità 1, valori in $\mathbb{N}_0$. Fissato $s \in [-1, 1]$, si ha

$$\begin{aligned} G_Y(s) &= \mathbb{E}\big[s^{X_1 + \cdots + X_n}\big] = \mathbb{E}\big[s^{X_1} s^{X_2} \cdots s^{X_n}\big] \\ &= \mathbb{E}\big[s^{X_1}\big]\, \mathbb{E}\big[s^{X_2}\big] \cdots \mathbb{E}\big[s^{X_n}\big] = G_{X_1}(s)\, G_{X_2}(s) \cdots G_{X_n}(s), \end{aligned}$$

dove la terza uguaglianza estende a n variabili aleatorie indipendenti la proprietà *(i)* della Proposizione 1.53, con le funzioni $x \longmapsto s^x$. Infatti, per il punto *(i)* del Teorema 1.51 e per la fattorizzazione della funzione massa congiunta, si ha

$$\mathbb{E}\big[s^{X_1} \cdots s^{X_n}\big] = \sum_{x_1 \in S_{X_1}} \cdots \sum_{x_n \in S_{X_n}} s^{x_1}\, p_{X_1}(x_1) \cdots s^{x_n}\, p_{X_n}(x_n) = \prod_{i=1}^{n} \sum_{x_i \in S_{X_i}} s^{x_i}\, p_{X_i}(x_i),$$

dove la serie multipla si somma come prodotto di n serie semplici perché converge assolutamente: la somma dei moduli dei suoi termini è maggiorata dal prodotto delle somme delle probabilità $p_{X_i}(x_i)$, ciascuna pari a 1. Se infine le variabili sono identicamente distribuite, esse hanno la stessa funzione massa di probabilità e quindi la stessa funzione generatrice di probabilità G, da cui $G_Y = G^n$. □

1.16.2 Funzioni generatrici di probabilità delle variabili aleatorie notevoli

Si calcolano ora le funzioni generatrici di probabilità delle variabili aleatorie discrete notevoli a valori in $\mathbb{N}_0$. In ciascun caso, il Corollario 1.61 permette di ritrovare rapidamente il valore atteso e la varianza già calcolati in precedenza.

Esempio 1.54. Sia X degenere in $c \in \mathbb{N}_0$ (Definizione 1.43). Essendo $S_X = \{c\}$ e $p_X(c) = 1$, la serie che definisce G_X si riduce al solo termine corrispondente a $x = c$:

$$G_X(s) = s^c\, p_X(c) = s^c \qquad \forall s \in [-1, 1].$$

Per il Corollario 1.61 si ritrovano $\mathbb{E}[X] = c$ e $\mathrm{Var}[X] = c\,(c-1) + c - c^2 = 0$, in accordo con la proprietà (i) della Proposizione 1.49.

Esempio 1.55. Sia $X \sim \mathrm{Ber}(p)$ (Definizione 1.44), con $p_X(0) = 1 - p$ e $p_X(1) = p$. Si ha:

$$G_X(s) = s^0\, p_X(0) + s^1\, p_X(1) = 1 - p + ps \qquad \forall s \in [-1, 1].$$

Essendo $G'_X(s) = p$ e $G''_X(s) = 0$, per il Corollario 1.61 si ritrovano $\mathbb{E}[X] = p$ e $\mathrm{Var}[X] = 0 + p - p^2 = p\,(1-p)$ (Esempio 1.35 ed Esempio 1.43).

Esempio 1.56. Sia $X \sim \mathrm{Bin}(n, p)$ (Definizione 1.45). Per ogni $s \in [-1, 1]$, per la formula del binomio di Newton si ha:

$$G_X(s) = \sum_{x=0}^{n} s^x \binom{n}{x} p^x (1-p)^{n-x} = \sum_{x=0}^{n} \binom{n}{x} (ps)^x (1-p)^{n-x} = (1 - p + ps)^n.$$

Lo stesso risultato segue dalla Proposizione 1.63. Infatti, come osservato dopo la Definizione 1.45, X si esprime come somma di n variabili aleatorie di Bernoulli indipendenti di parametro p, ciascuna delle quali ha funzione generatrice di probabilità $1 - p + ps$ (Esempio 1.55), per cui $G_X(s) = (1 - p + ps)^n$. Derivando si ha

$$G'_X(s) = np\,(1 - p + ps)^{n-1}, \qquad G''_X(s) = n(n-1)\,p^2 (1 - p + ps)^{n-2},$$

dove per $n = 1$ si intende $G''_X = 0$; per il Corollario 1.61 si ritrovano quindi $\mathbb{E}[X] = np$ e

$$\mathrm{Var}[X] = n(n-1)\,p^2 + np - n^2 p^2 = np - np^2 = np\,(1-p)$$

(Esempio 1.36 ed Esempio 1.44).

Esempio 1.57. Sia $X \sim \mathrm{Geom}(p)$ (Definizione 1.46). Per ogni $s \in [-1, 1]$ si ha $|s\,(1-p)| \leq 1 - p < 1$; con la sostituzione $y = x - 1$ e sommando la serie geometrica di ragione $s\,(1-p)$ si ottiene:

$$G_X(s) = \sum_{x=1}^{+\infty} s^x\, p\,(1-p)^{x-1} = ps \sum_{y=0}^{+\infty} \big[s\,(1-p)\big]^y = \frac{ps}{1 - (1-p)\,s}.$$

Essendo

$$G'_X(s) = \frac{p}{\big(1-(1-p)\,s\big)^2}, \qquad G''_X(s) = \frac{2p\,(1-p)}{\big(1-(1-p)\,s\big)^3},$$

per il Corollario 1.61 si ritrovano $\mathbb{E}[X] = 1/p$ e

$$\mathrm{Var}[X] = \frac{2\,(1-p)}{p^2} + \frac{1}{p} - \frac{1}{p^2} = \frac{1-p}{p^2}$$

(Esempio 1.37 ed Esempio 1.45), senza dover derivare la serie geometrica rispetto al parametro p.

Esempio 1.58. Sia $X \sim \text{Poisson}(\lambda)$ (Definizione 1.47). Sviluppando in serie di Taylor l'esponenziale, come nella verifica della condizione di normalizzazione, per ogni $s \in [-1, 1]$ si ha:

$$G_X(s) = \sum_{x=0}^{+\infty} s^x \frac{\lambda^x}{x!}\,\mathrm{e}^{-\lambda} = \mathrm{e}^{-\lambda} \sum_{x=0}^{+\infty} \frac{(\lambda s)^x}{x!} = \mathrm{e}^{-\lambda}\mathrm{e}^{\lambda s} = \mathrm{e}^{\lambda(s-1)}.$$

Essendo $G'_X(s) = \lambda \mathrm{e}^{\lambda(s-1)}$ e $G''_X(s) = \lambda^2 \mathrm{e}^{\lambda(s-1)}$, per il Corollario 1.61 si ritrovano $\mathbb{E}[X] = \lambda$ e $\mathrm{Var}[X] = \lambda^2 + \lambda - \lambda^2 = \lambda$ (Esempio 1.38 ed Esempio 1.46).

La Proposizione 1.62 e la Proposizione 1.63 consentono di determinare la legge della somma di variabili aleatorie indipendenti a partire dalle funzioni generatrici di probabilità degli addendi.

Esempio 1.59. Siano $X_1 \sim \text{Poisson}(\lambda_1)$ e $X_2 \sim \text{Poisson}(\lambda_2)$ variabili aleatorie indipendenti, con $\lambda_1, \lambda_2 > 0$. Per la Proposizione 1.63 e per l'Esempio 1.58 si ha

$$G_{X_1+X_2}(s) = \mathrm{e}^{\lambda_1(s-1)}\,\mathrm{e}^{\lambda_2(s-1)} = \mathrm{e}^{(\lambda_1+\lambda_2)(s-1)} \qquad \forall s \in [-1, 1],$$

che è la funzione generatrice di probabilità di una variabile aleatoria di Poisson di parametro $\lambda_1+\lambda_2$. Per la Proposizione 1.62 si conclude che $X_1+X_2 \sim \text{Poisson}(\lambda_1+\lambda_2)$: la somma di due variabili aleatorie di Poisson indipendenti è ancora una variabile di Poisson, di parametro pari alla somma dei parametri, e lo stesso argomento mostra che la somma di n variabili di Poisson indipendenti di parametri $\lambda_1, \ldots, \lambda_n$ è di Poisson di parametro $\lambda_1 + \cdots + \lambda_n$. Allo stesso modo, se $X_1 \sim \text{Bin}(n_1, p)$ e $X_2 \sim \text{Bin}(n_2, p)$ sono indipendenti, con lo stesso parametro p, per l'Esempio 1.56 si ha $G_{X_1+X_2}(s) = (1 - p + ps)^{n_1+n_2}$, e dunque $X_1 + X_2 \sim \text{Bin}(n_1 + n_2, p)$.

1.16.3 Funzione generatrice dei momenti

La funzione generatrice di probabilità è definita soltanto per le variabili aleatorie discrete a valori in $\mathbb{N}_0$. Per una variabile aleatoria qualsiasi si considera, in luogo di s^X, la variabile aleatoria positiva e^{tX}, con $t \in \mathbb{R}$, il cui valore atteso può tuttavia non essere finito.

Definizione 1.79. Sia X una variabile aleatoria con funzione di ripartizione F_X. Si dice *funzione generatrice dei momenti* di X la funzione M_X definita da

$$M_X(t) := \mathbb{E}\big[\mathrm{e}^{tX}\big] = \int_{-\infty}^{+\infty} \mathrm{e}^{tx}\,\mathrm{d}F_X(x)$$

per ogni $t \in \mathbb{R}$ per il quale l'integrale è finito, ovvero per il quale la variabile aleatoria e^{tX} è dotata di valore atteso. Si dice che X *ammette funzione generatrice dei momenti* se esiste $t_0 > 0$ tale che $M_X(t)$ sia finita per ogni $t \in (-t_0, t_0)$.

Osservazione. Si osservi che:

(*i*) per il Teorema 1.46 con $g(x) = \mathrm{e}^{tx}$, se X è discreta si ha

$$M_X(t) = \sum_{x \in S_X} \mathrm{e}^{tx}\, p_X(x),$$

mentre se X è assolutamente continua si ha

$$M_X(t) = \int_{-\infty}^{+\infty} \mathrm{e}^{tx}\, f_X(x)\,\mathrm{d}x;$$

essendo la funzione $x \longmapsto \mathrm{e}^{tx}$ positiva, la serie e l'integrale hanno sempre senso, con valore finito oppure pari a $+\infty$, e $M_X(t)$ è definita per i valori di t per i quali essi sono finiti;

(*ii*) per la condizione di normalizzazione si ha

$$M_X(0) = \int_{-\infty}^{+\infty} \mathrm{d}F_X(x) = 1,$$

per cui M_X è definita almeno in $t = 0$; se X ammette funzione generatrice dei momenti, M_X è continua in 0, come segue dal Teorema 1.65, e quindi

$$\lim_{t \to 0} M_X(t) = 1;$$

(*iii*) l'insieme dei $t \in \mathbb{R}$ per i quali $M_X(t)$ è finita è un intervallo contenente 0: infatti, se $M_X(t_1)$ e $M_X(t_2)$ sono finite, con $t_1 < t_2$, e $t \in [t_1, t_2]$, si ha $\mathrm{e}^{tx} \leq \mathrm{e}^{t_2 x}$ per $x \geq 0$ e $\mathrm{e}^{tx} \leq \mathrm{e}^{t_1 x}$ per $x < 0$, per cui

$$\mathrm{e}^{tx} \leq \mathrm{e}^{t_1 x} + \mathrm{e}^{t_2 x} \quad \forall x \in \mathbb{R} \qquad \Longrightarrow \qquad M_X(t) \leq M_X(t_1) + M_X(t_2) < +\infty.$$

La Definizione 1.79 richiede dunque che tale intervallo contenga 0 al proprio interno;

(*iv*) se X è assolutamente continua, si ha $M_X(t) = \mathscr{L}\{f_X\}(-t)$, dove

$$\mathscr{L}\{f\}(t) := \int_{-\infty}^{+\infty} \mathrm{e}^{-tx} f(x)\,\mathrm{d}x$$

è la *trasformata di Laplace* (bilatera) della funzione f: la funzione generatrice dei momenti è la trasformata di Laplace della densità di probabilità, calcolata in $-t$;

(*v*) se X è discreta a valori in $\mathbb{N}_0$, essendo $\mathrm{e}^{tx} = (\mathrm{e}^t)^x$, si ha

$$M_X(t) = \sum_{x \in S_X} (\mathrm{e}^t)^x\, p_X(x) = G_X(\mathrm{e}^t) \qquad \forall t \leq 0,$$

e viceversa $G_X(s) = M_X(\log s)$ per ogni $s \in (0, 1]$. Per $t > 0$ la relazione $M_X(t) = G_X(\mathrm{e}^t)$ continua a valere ogni volta che la serie di potenze che definisce G_X converge in $s = \mathrm{e}^t > 1$, indicando ancora con $G_X(\mathrm{e}^t)$ la sua somma.

Per stabilire il legame tra la funzione generatrice dei momenti e i momenti di X occorre un risultato della teoria dell'integrazione secondo Lebesgue, che si richiama di seguito insieme alle nozioni che esso richiede; la costruzione dell'integrale rispetto a una misura qualsiasi, come quella dell'integrale di Lebesgue–Stieltjes, esula da questi appunti.

Definizione 1.80. Sia $(X, \mathcal{G})$ uno spazio misurabile. Si dice *misura* su $(X, \mathcal{G})$ una funzione $\mu : \mathcal{G} \to [0, +\infty]$ tale che $\mu(\emptyset) = 0$ e numerabilmente additiva, ovvero tale che

$$\mu\left(\bigcup_{n=1}^{+\infty} A_n\right) = \sum_{n=1}^{+\infty} \mu(A_n)$$

per ogni successione $\{A_n\}_{n\in\mathbb{N}} \subseteq \mathcal{G}$ di insiemi a due a due disgiunti; la terna $(X, \mathcal{G}, \mu)$ si dice *spazio di misura*. Una funzione $\mathcal{G}$-misurabile $g : X \to \mathbb{R}$ si dice *sommabile*, o *di classe* L^1, se

$$\int_X |g| \, \mathrm{d}\mu < +\infty.$$

Osservazione. Uno spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$ è uno spazio di misura con $\mathbb{P}(\Omega) = 1$. In particolare, per la Proposizione 1.23, ogni variabile aleatoria X induce lo spazio di misura $(\mathbb{R}, \mathcal{B}, \mathbb{P}_X)$, per il quale l'integrale rispetto alla misura $\mathbb{P}_X$ è l'integrale di Lebesgue–Stieltjes rispetto alla funzione di ripartizione F_X:

$$\int_{\mathbb{R}} g \, \mathrm{d}\mathbb{P}_X = \int_{-\infty}^{+\infty} g(x) \, \mathrm{d}F_X(x);$$

una funzione $\mathcal{B}$-misurabile g è dunque sommabile rispetto a $\mathbb{P}_X$ se e solo se la variabile aleatoria $g(X)$ è dotata di valore atteso (Teorema 1.46).

Teorema di Lebesgue sulla convergenza dominata 1.64. *Siano $(X, \mathcal{G}, \mu)$ uno spazio di misura, $\{f_m\}_{m\in\mathbb{N}}$ una successione di funzioni $\mathcal{G}$-misurabili da X in $\mathbb{R}$ e $f : X \to \mathbb{R}$ una funzione $\mathcal{G}$-misurabile tali che*

$$\lim_{m\to+\infty} f_m(x) = f(x) \qquad \text{per quasi ogni } x \in X,$$

ovvero per ogni $x \in X$ al di fuori di un insieme di misura nulla. Se esiste una funzione sommabile $g : X \to \mathbb{R}$ tale che

$$|f_m(x)| \leq g(x) \qquad \forall m \in \mathbb{N},\ \forall x \in X,$$

allora:

(*i*) *la funzione f_m è sommabile per ogni $m \in \mathbb{N}$, e la funzione f è sommabile;*

(*ii*) *si ha*

$$\lim_{m\to+\infty} \int_X |f_m - f| \, \mathrm{d}\mu = 0;$$

(*iii*) *si ha*

$$\lim_{m\to+\infty} \int_X f_m \, \mathrm{d}\mu = \int_X f \, \mathrm{d}\mu.$$

Dimostrazione. Omessa. □

Il risultato seguente giustifica il nome della funzione M_X: i momenti di X sono, a meno del fattore $k!$, i coefficienti dello sviluppo in serie di Taylor di M_X centrato in 0, e si ottengono derivando M_X in $t = 0$.

Teorema 1.65. *Sia X una variabile aleatoria che ammette funzione generatrice dei momenti M_X, finita nell'intervallo $(-t_0, t_0)$, con $t_0 > 0$. Allora:*

(*i*) *X è dotata di momento di ordine k per ogni $k \in \mathbb{N}$ e, indicato con $\mu'_k = \mathbb{E}\big[X^k\big]$ il momento di ordine k (Definizione 1.70), si ha*

$$M_X(t) = \sum_{k=0}^{+\infty} \frac{t^k}{k!}\,\mu'_k \qquad \forall t \in (-t_0, t_0);$$

(*ii*) *M_X è derivabile infinite volte in $(-t_0, t_0)$ e si ha*

$$M_X^{(k)}(0) = \mu'_k \qquad \forall k \in \mathbb{N}.$$

In particolare

$$\mathbb{E}[X] = M'_X(0), \qquad \mathrm{Var}[X] = M''_X(0) - \big(M'_X(0)\big)^2.$$

Dimostrazione.

(*i*) Si fissi $t_1 \in (0, t_0)$. Per ogni $k \in \mathbb{N}$ e per ogni $x \in \mathbb{R}$, dallo sviluppo in serie di Taylor dell'esponenziale, i cui termini sono non negativi se l'argomento è non negativo, si ha

$$\frac{t_1^k\,|x|^k}{k!} \le \mathrm{e}^{t_1|x|} \le \mathrm{e}^{t_1 x} + \mathrm{e}^{-t_1 x},$$

per cui

$$\int_{-\infty}^{+\infty} |x|^k \,\mathrm{d}F_X(x) \le \frac{k!}{t_1^k}\big(M_X(t_1) + M_X(-t_1)\big) < +\infty,$$

ovvero X è dotata di momento di ordine k per ogni $k \in \mathbb{N}$. Si fissi ora $t \in (-t_0, t_0)$ e si applichi il Teorema 1.64 allo spazio di misura $(\mathbb{R}, \mathfrak{B}, \mathbb{P}_X)$ (osservazione successiva alla Definizione 1.80), con le funzioni continue, e dunque $\mathfrak{B}$-misurabili,

$$f_m(x) := \sum_{k=0}^{m} \frac{t^k}{k!}\,x^k, \qquad f(x) := \mathrm{e}^{tx}, \qquad g(x) := \mathrm{e}^{|tx|} \qquad \forall x \in \mathbb{R},\ \forall m \in \mathbb{N}.$$

Per lo sviluppo in serie di Taylor dell'esponenziale si ha

$$\lim_{m\to+\infty} f_m(x) = \sum_{k=0}^{+\infty} \frac{(tx)^k}{k!} = \mathrm{e}^{tx} = f(x) \qquad \forall x \in \mathbb{R}.$$

Per la disuguaglianza triangolare, ed essendo ogni somma parziale di una serie a termini non negativi non superiore alla sua somma, si ha inoltre

$$|f_m(x)| \le \sum_{k=0}^{m} \frac{|tx|^k}{k!} \le \sum_{k=0}^{+\infty} \frac{|tx|^k}{k!} = \mathrm{e}^{|tx|} = g(x) \qquad \forall m \in \mathbb{N},\ \forall x \in \mathbb{R},$$

e la funzione g è sommabile, poiché $\mathrm{e}^{|tx|} \le \mathrm{e}^{tx} + \mathrm{e}^{-tx}$ e $t, -t \in (-t_0, t_0)$:

$$\begin{aligned}\int_{-\infty}^{+\infty} \mathrm{e}^{|tx|}\,\mathrm{d}F_X(x) &\le \int_{-\infty}^{+\infty} \mathrm{e}^{tx}\,\mathrm{d}F_X(x) + \int_{-\infty}^{+\infty} \mathrm{e}^{-tx}\,\mathrm{d}F_X(x)\\ &= M_X(t) + M_X(-t) < +\infty.\end{aligned}$$

Per il punto (*iii*) del Teorema 1.64 e per la linearità dell'integrale, essendo X dotata dei momenti di ogni ordine, si conclude che

$$M_X(t) = \int_{-\infty}^{+\infty} f(x)\,\mathrm{d}F_X(x) = \lim_{m\to+\infty} \int_{-\infty}^{+\infty} f_m(x)\,\mathrm{d}F_X(x)$$
$$= \lim_{m\to+\infty} \sum_{k=0}^{m} \frac{t^k}{k!} \int_{-\infty}^{+\infty} x^k\,\mathrm{d}F_X(x) = \sum_{k=0}^{+\infty} \frac{t^k}{k!}\,\mu'_k.$$

(*ii*) Per il punto (*i*) la serie di potenze che vi compare converge per ogni $t \in (-t_0, t_0)$, e ha dunque raggio di convergenza almeno pari a t_0. Per il teorema di derivazione delle serie di potenze, la sua somma M_X è derivabile infinite volte nell'intervallo $(-t_0, t_0)$, e le sue derivate si ottengono derivando termine a termine: per ogni $r \in \mathbb{N}$ si ha

$$M_X^{(r)}(t) = \sum_{k=0}^{+\infty} \frac{\mu'_k}{k!} \frac{\mathrm{d}^r}{\mathrm{d}t^r}\{t^k\} = \sum_{k=r}^{+\infty} \frac{\mu'_k}{k!}\,k(k-1)\cdots(k-r+1)\,t^{k-r} \qquad \forall t \in (-t_0, t_0),$$

dove gli addendi con $k < r$ sono nulli, essendo nulla la derivata r-esima di un polinomio di grado $k < r$. Per $t = 0$ si annullano tutti gli addendi con $k > r$, che contengono il fattore t^{k-r}, mentre per $k = r$ si ha $t^{k-r} = t^0 = 1$: resta dunque il solo addendo con $k = r$, e

$$M_X^{(r)}(0) = \frac{\mu'_r}{r!}\,r(r-1)\cdots 1 = \frac{\mu'_r}{r!}\,r! = \mu'_r.$$

Infine, l'espressione della varianza segue dal punto (*ii*) per $k = 1, 2$ e dalla formula fondamentale (Proposizione 1.48). □

Osservazione. Per il punto (*i*) del Teorema 1.65, la funzione generatrice dei momenti è la somma della propria serie di Taylor centrata in 0, i cui coefficienti sono i momenti di X divisi per $k!$. Viceversa, poiché i coefficienti di una serie di potenze con raggio di convergenza positivo sono determinati dalle derivate in 0 della sua somma, se in un intorno di 0 la funzione M_X si scrive come somma di una serie di potenze

$$M_X(t) = \sum_{k=0}^{+\infty} c_k\,\frac{t^k}{k!},$$

per il punto (*ii*) si ha $c_k = M_X^{(k)}(0) = \mathbb{E}\big[X^k\big]$ per ogni $k \in \mathbb{N}_0$: i momenti di X si possono dunque leggere direttamente sullo sviluppo in serie di M_X, senza calcolarne le derivate. In modo analogo, per la Proposizione 1.62, i coefficienti dello sviluppo in serie di potenze della funzione generatrice di probabilità sono le probabilità $\mathbb{P}(X = x)$.

1.16.4 Funzioni generatrici dei momenti delle variabili aleatorie notevoli

Per le variabili aleatorie discrete notevoli, a valori in $\mathbb{N}_0$, la funzione generatrice dei momenti si ottiene dalla funzione generatrice di probabilità mediante la relazione $M_X(t) = G_X(\mathrm{e}^t)$ (osservazione successiva alla Definizione 1.79).

Esempio 1.60. Dagli esempi della sottosezione precedente, dall'Esempio 1.54 all'Esempio 1.58, si ottiene quanto segue.

(*i*) Se X è degenere in $c \in \mathbb{R}$, si ha $M_X(t) = \mathrm{e}^{ct}$ per ogni $t \in \mathbb{R}$: il risultato segue direttamente dalla definizione, poiché la serie si riduce al solo termine corrispondente a $x = c$, e vale anche se $c \notin \mathbb{N}_0$.

(*ii*) Se $X \sim \mathrm{Ber}(p)$, si ha $M_X(t) = 1 - p + p\mathrm{e}^t$ per ogni $t \in \mathbb{R}$.

(*iii*) Se $X \sim \mathrm{Bin}(n, p)$, si ha $M_X(t) = (1 - p + p\mathrm{e}^t)^n$ per ogni $t \in \mathbb{R}$.

(*iv*) Se $X \sim \mathrm{Geom}(p)$, la serie

$$M_X(t) = \sum_{x=1}^{+\infty} \mathrm{e}^{tx}\, p\,(1-p)^{x-1} = p\mathrm{e}^t \sum_{y=0}^{+\infty} \big[(1-p)\mathrm{e}^t\big]^y$$

è geometrica di ragione positiva $(1-p)\mathrm{e}^t$, e converge se e solo se $(1-p)\mathrm{e}^t < 1$, ovvero se e solo se $t < -\log(1-p)$; per tali valori di t si ha

$$M_X(t) = \frac{p\mathrm{e}^t}{1-(1-p)\mathrm{e}^t}.$$

(*v*) Se $X \sim \mathrm{Poisson}(\lambda)$, si ha $M_X(t) = \mathrm{e}^{\lambda(\mathrm{e}^t-1)}$ per ogni $t \in \mathbb{R}$, poiché la serie esponenziale converge per ogni valore del suo argomento.

Nei casi di Bernoulli e binomiale la funzione G_X è un polinomio, e la relazione $M_X(t) = G_X(\mathrm{e}^t)$ vale per ogni $t \in \mathbb{R}$. In tutti i casi M_X è finita in un intorno di 0, essendo $-\log(1-p) > 0$: le variabili aleatorie discrete notevoli ammettono funzione generatrice dei momenti.

Si considerano ora le variabili aleatorie assolutamente continue notevoli, per le quali la funzione generatrice dei momenti si calcola direttamente dalla definizione.

Esempio 1.61. Sia $X \sim \mathrm{Exp}(\lambda)$ (Definizione 1.52). Per ogni $t \in \mathbb{R}$ si ha

$$M_X(t) = \int_0^{+\infty} \mathrm{e}^{tx}\, \lambda \mathrm{e}^{-\lambda x}\, \mathrm{d}x = \lambda \int_0^{+\infty} \mathrm{e}^{-(\lambda-t)x}\, \mathrm{d}x.$$

Se $t \geq \lambda$, la funzione integranda è maggiore o uguale a 1 per ogni $x > 0$, e l'integrale diverge: $M_X(t)$ non è finita. Se invece $t < \lambda$, si ha

$$M_X(t) = \lambda \left[-\frac{\mathrm{e}^{-(\lambda-t)x}}{\lambda - t} \right]_0^{+\infty} = \frac{\lambda}{\lambda - t}.$$

La funzione generatrice dei momenti è dunque finita esattamente per $t < \lambda$, e in particolare in un intorno di 0. Essendo

$$M_X'(t) = \frac{\lambda}{(\lambda-t)^2}, \qquad M_X''(t) = \frac{2\lambda}{(\lambda-t)^3},$$

per il Teorema 1.65 si ritrovano $\mathbb{E}[X] = 1/\lambda$ e $\mathrm{Var}[X] = 2/\lambda^2 - 1/\lambda^2 = 1/\lambda^2$ (Esempio 1.39 ed Esempio 1.47). Inoltre, per $|t| < \lambda$, sviluppando in serie geometrica si ha

$$M_X(t) = \frac{1}{1 - t/\lambda} = \sum_{k=0}^{+\infty} \frac{t^k}{\lambda^k} = \sum_{k=0}^{+\infty} \frac{k!}{\lambda^k}\, \frac{t^k}{k!},$$

per cui, per l'osservazione successiva al Teorema 1.65, $\mathbb{E}\big[X^k\big] = k!/\lambda^k$ per ogni $k \in \mathbb{N}_0$.

Esempio 1.62. Sia $X \sim \mathcal{U}(a,b)$ (Definizione 1.54). Per ogni $t \neq 0$ si ha

$$M_X(t) = \int_a^b \frac{\mathrm{e}^{tx}}{b-a}\,\mathrm{d}x = \frac{1}{b-a}\left[\frac{\mathrm{e}^{tx}}{t}\right]_a^b = \frac{\mathrm{e}^{bt}-\mathrm{e}^{at}}{(b-a)\,t},$$

mentre $M_X(0) = 1$: la funzione generatrice dei momenti è finita per ogni $t \in \mathbb{R}$, e il limite del secondo membro per $t \to 0$ vale 1, in accordo con la continuità di M_X in 0. Per calcolare i momenti conviene qui, anziché derivare, sviluppare in serie gli esponenziali: per ogni $t \neq 0$ si ha

$$M_X(t) = \frac{1}{(b-a)\,t}\sum_{k=1}^{+\infty}\frac{(b^k-a^k)\,t^k}{k!} = \sum_{k=0}^{+\infty}\frac{b^{k+1}-a^{k+1}}{(k+1)(b-a)}\,\frac{t^k}{k!},$$

e l'ultima serie vale $1 = M_X(0)$ anche per $t = 0$. Per l'osservazione successiva al Teorema 1.65 si ha dunque

$$\mathbb{E}\left[X^k\right] = \frac{b^{k+1}-a^{k+1}}{(k+1)(b-a)} \qquad \forall k \in \mathbb{N}_0.$$

Per $k = 1$ e $k = 2$ si ritrovano $\mathbb{E}[X] = (a+b)/2$ e $\mathbb{E}\left[X^2\right] = (a^2+ab+b^2)/3$, da cui $\mathrm{Var}[X] = (b-a)^2/12$ (Esempio 1.40 ed Esempio 1.48).

Esempio 1.63. Sia $X \sim \mathcal{N}(a,b)$ (Definizione 1.51). Per ogni $x, t \in \mathbb{R}$, completando il quadrato all'esponente si ha

$$tx - \frac{(x-a)^2}{2b} = -\frac{x^2-2(a+bt)\,x+a^2}{2b} = -\frac{\big(x-(a+bt)\big)^2}{2b} + at + \frac{bt^2}{2},$$

per cui, per ogni $t \in \mathbb{R}$,

$$\begin{aligned} M_X(t) &= \int_{-\infty}^{+\infty}\frac{\mathrm{e}^{tx}}{\sqrt{2\pi b}}\exp\left(-\frac{(x-a)^2}{2b}\right)\mathrm{d}x \\ &= \exp\left(at+\frac{bt^2}{2}\right)\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi b}}\exp\left(-\frac{\big(x-(a+bt)\big)^2}{2b}\right)\mathrm{d}x = \exp\left(at+\frac{bt^2}{2}\right), \end{aligned}$$

poiché l'ultimo integrale vale 1: la funzione integranda è infatti la densità di una variabile aleatoria normale di parametri $a+bt$ e b, che soddisfa la condizione di normalizzazione, come verificato dopo la Definizione 1.51. In particolare, per la variabile normale standard $Z \sim \mathcal{N}(0,1)$ si ha $M_Z(t) = \mathrm{e}^{t^2/2}$. Essendo

$$M_X'(t) = (a+bt)\,M_X(t), \qquad M_X''(t) = \big(b+(a+bt)^2\big)M_X(t),$$

per il Teorema 1.65 si ritrovano $\mathbb{E}[X] = a$ e $\mathrm{Var}[X] = b + a^2 - a^2 = b$ (Esempio 1.41 ed Esempio 1.49).

Esempio 1.64. Sia $X \sim \chi^2(n)$ (Definizione 1.61), con $n \in \mathbb{N}$. Per ogni $t \in \mathbb{R}$ si ha

$$M_X(t) = \frac{1}{2^{n/2}\,\Gamma\left(\frac{n}{2}\right)}\int_0^{+\infty} x^{n/2-1}\mathrm{e}^{-(1-2t)x/2}\,\mathrm{d}x.$$

Se $t \geq 1/2$, l'esponenziale nella funzione integranda è maggiore o uguale a 1 e l'integrale diverge, essendo $n/2-1 > -1$: $M_X(t)$ non è finita. Se invece $t < 1/2$, con la sostituzione

$z = (1-2t)x/2$, da cui $\mathrm{d}x = 2/(1-2t)\,\mathrm{d}z$, e per la definizione della funzione Gamma di Eulero si ottiene

$$M_X(t) = \frac{1}{2^{n/2}\,\Gamma\left(\frac{n}{2}\right)}\left(\frac{2}{1-2t}\right)^{n/2}\int_0^{+\infty} z^{n/2-1}\mathrm{e}^{-z}\,\mathrm{d}z = \frac{1}{(1-2t)^{n/2}}.$$

Essendo

$$M_X'(t) = \frac{n}{(1-2t)^{n/2+1}}, \qquad M_X''(t) = \frac{n\,(n+2)}{(1-2t)^{n/2+2}},$$

per il Teorema 1.65 si ritrovano $\mathbb{E}[X] = n$ e $\mathrm{Var}[X] = n^2 + 2n - n^2 = 2n$ (Esempio 1.42 ed Esempio 1.50).

Osservazione. Per una variabile aleatoria X di tipo Gamma (Definizione 1.55) di parametri $a > -1$ e $b > 0$ il calcolo è analogo: $M_X(t)$ non è finita per $t \geq 1/b$, mentre per $t < 1/b$, con la sostituzione $z = (1-bt)x/b$, si ha

$$\begin{aligned} M_X(t) &= \frac{1}{b^{a+1}\,\Gamma(a+1)}\int_0^{+\infty} x^a \mathrm{e}^{-(1-bt)x/b}\,\mathrm{d}x \\ &= \frac{1}{b^{a+1}\,\Gamma(a+1)}\left(\frac{b}{1-bt}\right)^{a+1}\Gamma(a+1) = \frac{1}{(1-bt)^{a+1}}. \end{aligned}$$

Per $a = 0$ e $b = 1/\lambda$ si ritrova la funzione generatrice dei momenti della variabile $\mathrm{Exp}(\lambda)$ (Esempio 1.61), mentre per $a = n/2 - 1$ e $b = 2$ si ritrova quella della variabile $\chi^2(n)$ (Esempio 1.64). La variabile di Cauchy (Esempio 1.34), invece, non ammette funzione generatrice dei momenti: per $t > 0$, essendo $\mathrm{e}^u \geq u$ per ogni $u \in \mathbb{R}$, si ha

$$\int_0^{+\infty} \frac{\mathrm{e}^{tx}}{\pi\,(1+x^2)}\,\mathrm{d}x \geq t\int_0^{+\infty} \frac{x}{\pi\,(1+x^2)}\,\mathrm{d}x = +\infty,$$

e analogamente, per $t < 0$, diverge l'integrale su $(-\infty, 0]$; dunque $M_X(t)$ è finita soltanto per $t = 0$. Ciò è in accordo con il Teorema 1.65: se M_X fosse finita in un intorno di 0, la variabile X sarebbe dotata di momenti di ogni ordine e, in particolare, di valore atteso.

Nella Tabella 1.4 sono riassunte le funzioni generatrici delle variabili aleatorie notevoli, con i valori di t per i quali la funzione generatrice dei momenti è finita.

1.16.5 Trasformazioni affini e somme di variabili aleatorie indipendenti

Le funzioni generatrici si comportano in modo semplice rispetto alle trasformazioni affini e alla somma di variabili aleatorie indipendenti; ciò le rende uno strumento efficace per determinare la legge di una variabile aleatoria ottenuta da altre variabili aleatorie di legge nota.

Proposizione 1.66. *Siano X una variabile aleatoria e $a, b \in \mathbb{R}$, e sia $Y := aX + b$. Allora:*

(*i*) *se X è discreta a valori in $\mathbb{N}_0$ e $a, b \in \mathbb{N}_0$, anche Y è discreta a valori in $\mathbb{N}_0$, e si ha*

$$G_Y(s) = s^b\,G_X(s^a) \qquad \forall s \in [-1, 1];$$

(*ii*) *per ogni $t \in \mathbb{R}$, $M_Y(t)$ è finita se e solo se lo è $M_X(at)$, e in tal caso si ha*

$$M_Y(t) = \mathrm{e}^{bt}\,M_X(at).$$

In particolare, se X ammette funzione generatrice dei momenti, anche Y la ammette.

Tabella 1.4. Funzioni generatrici delle variabili aleatorie notevoli. Per la variabile uniforme l'espressione di $M_X(t)$ vale per $t \neq 0$, mentre $M_X(0) = 1$.

Variabile aleatoria	Notazione	$G_X(s)$	$M_X(t)$	$M_X(t)$ finita per
Variabili aleatorie discrete				
Bernoulli	$\mathrm{Ber}(p)$	$1-p+ps$	$1-p+pe^t$	$t \in \mathbb{R}$
Binomiale	$\mathrm{Bin}(n,p)$	$(1-p+ps)^n$	$(1-p+pe^t)^n$	$t \in \mathbb{R}$
Geometrica	$\mathrm{Geom}(p)$	$\dfrac{ps}{1-(1-p)s}$	$\dfrac{pe^t}{1-(1-p)e^t}$	$t < -\log(1-p)$
Poisson	$\mathrm{Poisson}(\lambda)$	$e^{\lambda(s-1)}$	$e^{\lambda(e^t-1)}$	$t \in \mathbb{R}$
Variabili aleatorie assolutamente continue				
Esponenziale	$\mathrm{Exp}(\lambda)$	—	$\lambda/(\lambda-t)$	$t < \lambda$
Uniforme	$\mathcal{U}(a,b)$	—	$\dfrac{e^{bt}-e^{at}}{(b-a)t}$	$t \in \mathbb{R}$
Normale	$\mathcal{N}(a,b)$	—	$\exp(at+bt^2/2)$	$t \in \mathbb{R}$
Chi quadro	$\chi^2(n)$	—	$(1-2t)^{-n/2}$	$t < 1/2$
Gamma	—	—	$(1-bt)^{-(a+1)}$	$t < 1/b$

Dimostrazione.

(*i*) Essendo $a, b \in \mathbb{N}_0$, per ogni $x \in S_X \subseteq \mathbb{N}_0$ si ha $ax+b \in \mathbb{N}_0$, per cui Y è discreta a valori in $\mathbb{N}_0$. Fissato $s \in [-1,1]$, si ha $s^a \in [-1,1]$ e $s^{ax+b} = s^b(s^a)^x$ per ogni $x \in \mathbb{N}_0$, con la convenzione $s^0 = 1$ della Definizione 1.78; per la proprietà (*ii*) della Proposizione 1.47 si ottiene quindi

$$G_Y(s) = \mathbb{E}\left[s^{aX+b}\right] = \mathbb{E}\left[s^{aX}s^b\right] = s^b\,\mathbb{E}\left[(s^a)^X\right] = s^b\,G_X(s^a).$$

(*ii*) Per ogni $t \in \mathbb{R}$ si ha $e^{tY} = e^{t(aX+b)} = e^{bt}e^{(at)X}$, dove il fattore e^{bt} è una costante positiva. La variabile aleatoria e^{tY} è dunque dotata di valore atteso se e solo se lo è $e^{(at)X}$, ovvero se e solo se $M_X(at)$ è finita, e in tal caso, per la proprietà (*ii*) della Proposizione 1.47,

$$M_Y(t) = \mathbb{E}\left[e^{t(aX+b)}\right] = e^{bt}\,\mathbb{E}\left[e^{(at)X}\right] = e^{bt}\,M_X(at).$$

Se infine M_X è finita in $(-t_0, t_0)$, con $t_0 > 0$, la funzione M_Y è finita per ogni $t \in \mathbb{R}$ se $a = 0$, e per $|t| < t_0/|a|$ se $a \neq 0$. □

La proprietà della funzione generatrice di probabilità relativa alla somma di variabili aleatorie indipendenti (Proposizione 1.63) vale anche per la funzione generatrice dei momenti, per variabili aleatorie qualsiasi, non necessariamente discrete a valori in $\mathbb{N}_0$, nei punti t in cui le funzioni generatrici dei momenti degli addendi sono finite.

Proposizione 1.67. *Siano $X_1, \ldots, X_n$ variabili aleatorie indipendenti e sia $Y := X_1 + \cdots + X_n$. Allora, per ogni $t \in \mathbb{R}$ per il quale $M_{X_1}(t), \ldots, M_{X_n}(t)$ sono finite, anche $M_Y(t)$ è finita e si ha*

$$M_Y(t) = M_{X_1}(t)\,M_{X_2}(t)\cdots M_{X_n}(t).$$

In particolare, se $X_1, \dots, X_n$ sono anche identicamente distribuite, con funzione generatrice dei momenti comune M, si ha $M_Y(t) = \big(M(t)\big)^n$.

Dimostrazione. Fissato $t \in \mathbb{R}$, sia $g(x) := \mathrm{e}^{tx}$ per ogni $x \in \mathbb{R}$. Le variabili aleatorie $g(X_1), \dots, g(X_n)$ sono indipendenti: per ogni scelta di boreliani $B_1, \dots, B_n$, le controimmagini $g^{-1}(B_1), \dots, g^{-1}(B_n)$ sono boreliani, essendo g continua, e quindi, per la Definizione 1.69,

$$\begin{aligned}\mathbb{P}\big(g(X_1) \in B_1, \dots, g(X_n) \in B_n\big) &= \mathbb{P}\big(X_1 \in g^{-1}(B_1), \dots, X_n \in g^{-1}(B_n)\big) \\ &= \prod_{i=1}^n \mathbb{P}\big(X_i \in g^{-1}(B_i)\big) = \prod_{i=1}^n \mathbb{P}\big(g(X_i) \in B_i\big).\end{aligned}$$

Ciascuna di esse è inoltre dotata di valore atteso $\mathbb{E}\big[\mathrm{e}^{tX_i}\big] = M_{X_i}(t)$. Per il punto *(ii)* della Proposizione 1.53, il loro prodotto $\mathrm{e}^{tX_1} \cdots \mathrm{e}^{tX_n} = \mathrm{e}^{tY}$ è dunque dotato di valore atteso e si ha

$$M_Y(t) = \mathbb{E}\Big[\mathrm{e}^{t(X_1+\cdots+X_n)}\Big] = \mathbb{E}\left[\prod_{i=1}^n \mathrm{e}^{tX_i}\right] = \prod_{i=1}^n \mathbb{E}\big[\mathrm{e}^{tX_i}\big] = \prod_{i=1}^n M_{X_i}(t).$$

Se infine le variabili sono identicamente distribuite, esse hanno la stessa funzione generatrice dei momenti M, da cui $M_Y = M^n$. □

Osservazione. Una variabile aleatoria $X \sim \mathrm{Bin}(n, p)$ si esprime come somma di n variabili aleatorie di Bernoulli indipendenti di parametro p (osservazione successiva alla Definizione 1.45), ciascuna con funzione generatrice dei momenti $1 - p + p\mathrm{e}^t$ (Esempio 1.60). Per la Proposizione 1.67 si ritrova dunque

$$M_X(t) = \big(1 - p + p\mathrm{e}^t\big)^n \qquad \forall t \in \mathbb{R}.$$

Esempio 1.65. Sia $X \sim \mathcal{N}(\mu, \sigma^2)$, con $\mu \in \mathbb{R}$ e $\sigma > 0$. Per l'Esempio 1.63, con $a = \mu$ e $b = \sigma^2$, la funzione generatrice dei momenti di X, che conviene ricordare, è

$$M_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right) \qquad \forall t \in \mathbb{R}.$$

La standardizzata $X^* = (X - \mu)/\sigma$ di X è la funzione affine di X con coefficienti $1/\sigma$ e $-\mu/\sigma$ (osservazione successiva alla Definizione 1.74); per il punto *(ii)* della Proposizione 1.66, per ogni $t \in \mathbb{R}$ si ha quindi

$$M_{X^*}(t) = \mathrm{e}^{-\mu t/\sigma} M_X\left(\frac{t}{\sigma}\right) = \exp\left(-\frac{\mu t}{\sigma} + \frac{\mu t}{\sigma} + \frac{\sigma^2}{2} \cdot \frac{t^2}{\sigma^2}\right) = \mathrm{e}^{t^2/2},$$

che è la funzione generatrice dei momenti della variabile aleatoria normale standard, in accordo con l'Esempio 1.51, secondo il quale $X^* \sim \mathcal{N}(0, 1)$. Viceversa, essendo $X = \mu + \sigma X^*$, dalla funzione generatrice dei momenti della normale standard si ricava quella di X:

$$M_X(t) = \mathrm{e}^{\mu t} M_{X^*}(\sigma t) = \mathrm{e}^{\mu t} \mathrm{e}^{\sigma^2 t^2/2} = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right) \qquad \forall t \in \mathbb{R}.$$

1.17 Legge del 3σ e disuguaglianze notevoli

Per una variabile aleatoria dotata di momento di ordine 2, la deviazione standard σ misura la dispersione dei valori intorno al valore atteso μ (Definizione 1.73). In questa sezione si studia la probabilità che la variabile aleatoria si discosti da μ di più di un multiplo assegnato di σ: per le variabili aleatorie normali essa si calcola mediante la standardizzazione, mentre per una variabile aleatoria qualsiasi la si stima con la disuguaglianza di Čebyšëv. La sezione si chiude con la disuguaglianza di Schwarz, che maggiora il valore atteso del prodotto di due variabili aleatorie mediante i loro momenti di ordine 2.

1.17.1 Legge del 3σ per le variabili aleatorie normali

Sia $X \sim \mathcal{N}(\mu, \sigma^2)$ (Definizione 1.51), con $\mu \in \mathbb{R}$ e $\sigma > 0$: per l'Esempio 1.41 e l'Esempio 1.49, la variabile X ha valore atteso μ e varianza σ^2, ovvero deviazione standard σ. La probabilità

$$\mathbb{P}(\mu - 3\sigma \leq X \leq \mu + 3\sigma)$$

che X assuma valori nell'intervallo centrato nel valore atteso e di semiampiezza 3σ è l'integrale della densità f_X su tale intervallo, il cui calcolo diretto per μ e σ generici non è agevole. Esso si riconduce tuttavia, mediante la standardizzazione (Definizione 1.74), alla variabile aleatoria normale standard, la cui funzione di ripartizione è tabulata.

Proposizione 1.68 (Legge del 3σ). *Siano $X \sim \mathcal{N}(\mu, \sigma^2)$, con $\mu \in \mathbb{R}$ e $\sigma > 0$, e $Z \sim \mathcal{N}(0, 1)$, con funzione di ripartizione F_Z e densità f_Z. Per ogni $k > 0$ si ha*

$$\mathbb{P}(\mu - k\sigma \leq X \leq \mu + k\sigma) = 2F_Z(k) - 1 = 2\int_0^k f_Z(z)\,\mathrm{d}z$$

e, in particolare,

$$\mathbb{P}(\mu - 3\sigma \leq X \leq \mu + 3\sigma) \approx 0.9973.$$

Dimostrazione. Per l'Esempio 1.51, la standardizzata $X^* = (X - \mu)/\sigma$ di X è una variabile aleatoria normale standard, e ha dunque la stessa funzione di ripartizione F_Z e la stessa densità f_Z di Z. Sottraendo μ a tutti i membri della doppia disuguaglianza e dividendoli poi per $\sigma > 0$, si ha

$$\begin{aligned}\mathbb{P}(\mu - k\sigma \leq X \leq \mu + k\sigma) &= \mathbb{P}(-k\sigma \leq X - \mu \leq k\sigma) \\ &= \mathbb{P}\left(-k \leq \frac{X - \mu}{\sigma} \leq k\right) = \mathbb{P}(-k \leq X^* \leq k).\end{aligned}$$

Essendo X^* assolutamente continua, si ha $\mathbb{P}(X^* = -k) = 0$; decomponendo gli integrali nel punto 0 si ottiene quindi

$$\begin{aligned}\mathbb{P}(-k \leq X^* \leq k) = F_Z(k) - F_Z(-k) &= \int_{-\infty}^{k} f_Z(z)\,\mathrm{d}z - \int_{-\infty}^{-k} f_Z(z)\,\mathrm{d}z \\ &= \int_{-\infty}^{0} f_Z(z)\,\mathrm{d}z + \int_0^k f_Z(z)\,\mathrm{d}z - \left(\int_{-\infty}^{0} f_Z(z)\,\mathrm{d}z - \int_{-k}^{0} f_Z(z)\,\mathrm{d}z\right) \\ &= \int_{-k}^{0} f_Z(z)\,\mathrm{d}z + \int_0^k f_Z(z)\,\mathrm{d}z.\end{aligned}$$

La densità f_Z è una funzione pari, per cui i due integrali all'ultimo membro sono uguali e

$$\mathbb{P}(\mu - k\sigma \le X \le \mu + k\sigma) = 2\int_0^k f_Z(z)\,\mathrm{d}z = 2F_Z(k) - 1,$$

dove l'ultima uguaglianza segue da

$$F_Z(k) = \int_{-\infty}^0 f_Z(z)\,\mathrm{d}z + \int_0^k f_Z(z)\,\mathrm{d}z = \frac{1}{2} + \int_0^k f_Z(z)\,\mathrm{d}z,$$

essendo l'integrale di f_Z sulla semiretta $(-\infty, 0]$ pari, per simmetria, alla metà dell'integrale su $\mathbb{R}$, che vale 1. Per $k = 3$, dalla tabulazione della funzione di ripartizione della normale standard si ha

$$\int_0^3 f_Z(z)\,\mathrm{d}z = F_Z(3) - \frac{1}{2} \approx 0.49865,$$

da cui $\mathbb{P}(\mu - 3\sigma \le X \le \mu + 3\sigma) \approx 2 \cdot 0.49865 = 0.9973$. □

Osservazione. La Proposizione 1.68 esprime la *legge del* 3σ: una variabile aleatoria normale assume, con probabilità molto prossima a 1, valori nell'intervallo $[\mu - 3\sigma, \mu + 3\sigma]$, centrato nel valore atteso e di semiampiezza pari a tre volte la deviazione standard. È dunque in tale intervallo, lontano dalle code, che si concentra la densità di probabilità, e la probabilità che X assuma valori esterni a esso è $1 - 0.9973 = 0.0027$, inferiore al 3 per mille. Con lo stesso procedimento, per $k = 1$ e $k = 2$ si ottiene

$$\mathbb{P}(\mu - \sigma \le X \le \mu + \sigma) \approx 2 \cdot 0.34134 \approx 0.6827,$$
$$\mathbb{P}(\mu - 2\sigma \le X \le \mu + 2\sigma) \approx 2 \cdot 0.47725 = 0.9545$$

(Figura 1.7). Tali probabilità non dipendono da μ e da σ, ma soltanto dal numero k di deviazioni standard. Con una tabulazione a quattro cifre decimali, nella quale gli integrali di f_Z su $[0, k]$ valgono 0.3413, 0.4772 e 0.4987 per $k = 1, 2, 3$, raddoppiando si ottengono i valori 0.6826, 0.9544 e 0.9974, che differiscono dai precedenti nell'ultima cifra per effetto dell'arrotondamento.

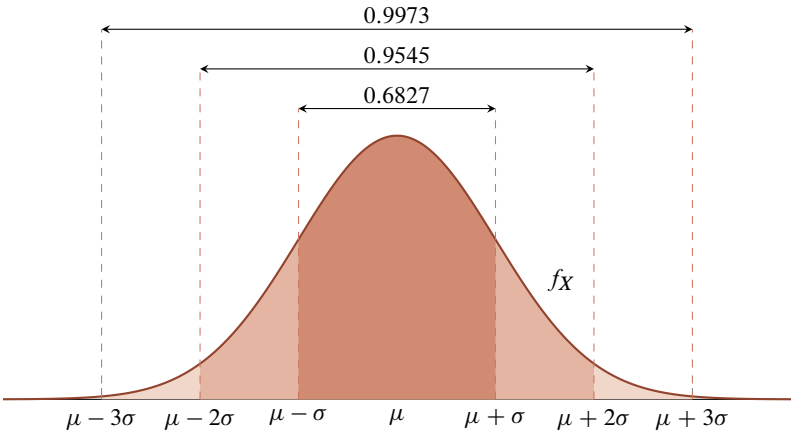


Figura 1.7. Densità di una variabile aleatoria normale $\mathcal{N}(\mu, \sigma^2)$. Le aree delle regioni ombreggiate sugli intervalli centrati in μ e di semiampiezza σ, 2σ e 3σ valgono, rispettivamente, circa 0.6827, 0.9545 e 0.9973.

1.17.2 Disuguaglianze di Markov e di Čebyšëv

La legge del 3σ si estende, in una forma più debole, a una variabile aleatoria qualsiasi dotata di momento di ordine 2. Per dimostrarlo occorre premettere il risultato seguente.

Lemma 1.69 (Disuguaglianza di Markov). *Siano X una variabile aleatoria e $\psi : \mathbb{R} \to [0, +\infty)$ una funzione non negativa e $\mathcal{B}$-misurabile, tale che la variabile aleatoria $\psi(X)$ sia dotata di valore atteso. Allora, per ogni $a > 0$, si ha*

$$\mathbb{P}\big(\psi(X) \geq a\big) \leq \frac{\mathbb{E}\big[\psi(X)\big]}{a}.$$

Dimostrazione. Sia $B := \big\{ x \in \mathbb{R} \mid \psi(x) \geq a \big\}$, che è un boreliano essendo ψ una funzione $\mathcal{B}$-misurabile, e per il quale $\{X \in B\} = \big\{\psi(X) \geq a\big\}$. La retta reale è unione dei due boreliani disgiunti B e B^{C}, per cui, per il Teorema 1.46, si ha

$$\begin{aligned}\mathbb{E}\big[\psi(X)\big] &= \int_{-\infty}^{+\infty} \psi(x)\,\mathrm{d}F_X(x) = \int_B \psi(x)\,\mathrm{d}F_X(x) + \int_{B^{\mathrm{C}}} \psi(x)\,\mathrm{d}F_X(x) \\ &\geq \int_B \psi(x)\,\mathrm{d}F_X(x) \geq a \int_B \mathrm{d}F_X(x) = a\ \mathbb{P}(X \in B) = a\ \mathbb{P}\big(\psi(X) \geq a\big),\end{aligned}$$

dove la prima disuguaglianza segue dalla non negatività di ψ, la seconda dal fatto che $\psi(x) \geq a$ per ogni $x \in B$, e la penultima uguaglianza dall'espressione di $\mathbb{P}(X \in B)$ come integrale di Stieltjes rispetto alla funzione di ripartizione F_X, già vista a proposito della legge di una variabile aleatoria. La tesi segue dividendo per $a > 0$. □

Osservazione. Essendo $\big\{\psi(X) > a\big\} \subseteq \big\{\psi(X) \geq a\big\}$, dalla disuguaglianza di Markov segue anche

$$\mathbb{P}\big(\psi(X) > a\big) \leq \frac{\mathbb{E}\big[\psi(X)\big]}{a},$$

e, passando agli eventi complementari nelle due disuguaglianze, si ottengono le formulazioni equivalenti

$$\mathbb{P}\big(\psi(X) < a\big) \geq 1 - \frac{\mathbb{E}\big[\psi(X)\big]}{a}, \qquad \mathbb{P}\big(\psi(X) \leq a\big) \geq 1 - \frac{\mathbb{E}\big[\psi(X)\big]}{a}.$$

La disuguaglianza di Markov è significativa soltanto per $a > \mathbb{E}\big[\psi(X)\big]$: altrimenti il suo secondo membro è maggiore o uguale a 1, e la stima è banale.

Teorema 1.70 (Disuguaglianza di Čebyšëv). *Sia X una variabile aleatoria dotata di momento di ordine 2, e siano $\mu := \mathbb{E}[X]$ e $\sigma^2 := \mathrm{Var}[X]$. Allora, per ogni $\varepsilon > 0$, si ha*

$$\mathbb{P}\big(|X - \mu| \geq \varepsilon\big) \leq \frac{\sigma^2}{\varepsilon^2}$$

e, equivalentemente,

$$\mathbb{P}\big(|X - \mu| < \varepsilon\big) \geq 1 - \frac{\sigma^2}{\varepsilon^2}.$$

Dimostrazione. Si applica il Lemma 1.69 con la funzione continua e non negativa $\psi(x) = (x - \mu)^2$, per la quale la variabile aleatoria $\psi(X) = (X - \mu)^2$ è dotata di valore atteso

$\mathbb{E}\big[(X-\mu)^2\big] = \sigma^2$ (Definizione 1.73), e con $a = \varepsilon^2 > 0$. Essendo $(x-\mu)^2 \geq \varepsilon^2$ se e solo se $|x-\mu| \geq \varepsilon$, si ha $\big\{(X-\mu)^2 \geq \varepsilon^2\big\} = \big\{|X-\mu| \geq \varepsilon\big\}$, e quindi

$$\mathbb{P}\big(|X-\mu| \geq \varepsilon\big) = \mathbb{P}\big((X-\mu)^2 \geq \varepsilon^2\big) \leq \frac{\mathbb{E}\big[(X-\mu)^2\big]}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2}.$$

La seconda disuguaglianza segue passando all'evento complementare, come nell'osservazione successiva al Lemma 1.69. □

Osservazione. La disuguaglianza di Čebyšëv, detta anche *legge di Čebyšëv*, era già emersa nel corso della dimostrazione del Teorema 1.50, nella forma

$$\mathbb{P}\big(|X-\mu| > \varepsilon\big) \leq \frac{\sigma^2}{\varepsilon^2} \qquad \forall \varepsilon > 0.$$

Essendo $\big\{|X-\mu| > \varepsilon\big\} \subseteq \big\{|X-\mu| \geq \varepsilon\big\}$ e $\big\{|X-\mu| < \varepsilon\big\} \subseteq \big\{|X-\mu| \leq \varepsilon\big\}$, dal Teorema 1.70 seguono sia tale forma sia la

$$\mathbb{P}\big(|X-\mu| \leq \varepsilon\big) \geq 1 - \frac{\sigma^2}{\varepsilon^2} \qquad \forall \varepsilon > 0.$$

La disuguaglianza stima la probabilità che X si discosti dal proprio valore atteso di almeno ε utilizzando soltanto la varianza, senza alcuna informazione sulla legge di X; per $\varepsilon \leq \sigma$ il secondo membro della prima disuguaglianza è maggiore o uguale a 1, e la stima è banale.

Corollario 1.71 (Legge del 3σ per variabili aleatorie qualsiasi). *Sia X una variabile aleatoria non degenere, dotata di momento di ordine 2, con valore atteso μ e deviazione standard σ. Allora, per ogni $k > 0$, si ha*

$$\mathbb{P}(\mu - k\sigma < X < \mu + k\sigma) \geq 1 - \frac{1}{k^2};$$

in particolare

$$\mathbb{P}(\mu - 3\sigma < X < \mu + 3\sigma) \geq \frac{8}{9} \approx 0.8889.$$

Dimostrazione. Essendo X non degenere, per il Teorema 1.50 si ha $\sigma > 0$. Applicando la seconda disuguaglianza del Teorema 1.70 con $\varepsilon = k\sigma > 0$, ed essendo $\big\{|X-\mu| < k\sigma\big\} = \{\mu - k\sigma < X < \mu + k\sigma\}$, si ottiene

$$\mathbb{P}(\mu - k\sigma < X < \mu + k\sigma) = \mathbb{P}\big(|X-\mu| < k\sigma\big) \geq 1 - \frac{\sigma^2}{k^2\sigma^2} = 1 - \frac{1}{k^2}.$$

Per $k = 3$ si ha $1 - 1/9 = 8/9$. □

Osservazione. Per una variabile aleatoria normale la probabilità dell'intervallo $[\mu - 3\sigma, \mu + 3\sigma]$ vale circa 0.9973 (Proposizione 1.68), mentre il Corollario 1.71 garantisce, per ogni variabile aleatoria non degenere dotata di momento di ordine 2, una probabilità non inferiore a $8/9 \approx 0.8889$. La stima è più debole perché vale qualunque sia la legge di X, e utilizza soltanto il valore atteso e la varianza; allo stesso modo, per $k = 2$ essa garantisce una probabilità non inferiore a $3/4$, contro il valore 0.9545 delle variabili normali, mentre per $k \leq 1$ non fornisce alcuna informazione, essendo $1 - 1/k^2 \leq 0$. In ogni caso l'intervallo centrato nel valore atteso e di semiampiezza 3σ contiene i valori di una qualsiasi variabile aleatoria non degenere dotata di momento di ordine 2 con probabilità almeno pari a $8/9$.

Il Lemma 1.69, applicato con altre scelte della funzione ψ, fornisce ulteriori stime della probabilità che una variabile aleatoria assuma valori lontani dall'origine, ovvero della probabilità delle *code* della sua legge.

Proposizione 1.72. *Sia X una variabile aleatoria. Allora:*

(*i*) *se X è dotata di momento di ordine 2, indicato con $\mu'_2 = \mathbb{E}\left[X^2\right]$ (Definizione 1.70), si ha*

$$\mathbb{P}\left(|X| \geq \sqrt{a}\right) \leq \frac{\mu'_2}{a} \qquad \forall a > 0;$$

(*ii*) *se X è dotata di momento di ordine $n \in \mathbb{N}$ e il suo momento assoluto di ordine n, $\beta_n = \mathbb{E}\left[|X|^n\right]$ (Definizione 1.75), è positivo, si ha*

$$\mathbb{P}\left(|X| \geq k\sqrt[n]{\beta_n}\right) \leq \frac{1}{k^n} \qquad \forall k > 0;$$

(*iii*) *se $c \in \mathbb{R}$ è tale che $M_X(c)$ sia finita, si ha*

$$\mathbb{P}\left(\mathrm{e}^{cX} \geq \mathrm{e}^{c\lambda}\right) \leq \frac{M_X(c)}{\mathrm{e}^{c\lambda}} \qquad \forall \lambda \in \mathbb{R}$$

e quindi, per ogni $\lambda \in \mathbb{R}$,

$$\mathbb{P}(X \geq \lambda) \leq \frac{M_X(c)}{\mathrm{e}^{c\lambda}} \quad \text{se } c > 0, \qquad \mathbb{P}(X \leq \lambda) \leq \frac{M_X(c)}{\mathrm{e}^{c\lambda}} \quad \text{se } c < 0.$$

Dimostrazione. In ciascun caso si applica il Lemma 1.69 con una funzione ψ continua, e dunque $\mathfrak{B}$-misurabile, e non negativa.

(*i*) Con $\psi(x) = x^2$, per la quale $\psi(X) = X^2$ è dotata di valore atteso μ'_2, e con $a > 0$ si ottiene $\mathbb{P}\left(X^2 \geq a\right) \leq \mu'_2/a$. Essendo $x^2 \geq a$ se e solo se $|x| \geq \sqrt{a}$, si ha $\left\{X^2 \geq a\right\} = \left\{|X| \geq \sqrt{a}\right\}$, da cui la tesi.

(*ii*) Con $\psi(x) = |x|^n$, per la quale $\psi(X) = |X|^n$ è dotata di valore atteso β_n (osservazione successiva alla Definizione 1.75), e con $a = k^n\beta_n > 0$ si ottiene

$$\mathbb{P}\left(|X|^n \geq k^n\beta_n\right) \leq \frac{\beta_n}{k^n\beta_n} = \frac{1}{k^n}.$$

Essendo la funzione $u \longmapsto u^n$ strettamente crescente sulla semiretta $[0, +\infty)$, si ha $|x|^n \geq k^n\beta_n$ se e solo se $|x| \geq k\sqrt[n]{\beta_n}$, per cui gli eventi $\left\{|X|^n \geq k^n\beta_n\right\}$ e $\left\{|X| \geq k\sqrt[n]{\beta_n}\right\}$ coincidono, da cui la tesi.

(*iii*) Con $\psi(x) = \mathrm{e}^{cx}$, per la quale $\psi(X) = \mathrm{e}^{cX}$ è dotata di valore atteso $M_X(c)$, e con $a = \mathrm{e}^{c\lambda} > 0$ si ottiene la prima disuguaglianza. Se $c > 0$, la funzione $x \longmapsto \mathrm{e}^{cx}$ è strettamente crescente, per cui $\mathrm{e}^{cx} \geq \mathrm{e}^{c\lambda}$ se e solo se $x \geq \lambda$, e quindi $\left\{\mathrm{e}^{cX} \geq \mathrm{e}^{c\lambda}\right\} = \{X \geq \lambda\}$; se $c < 0$, essa è strettamente decrescente, e allo stesso modo $\left\{\mathrm{e}^{cX} \geq \mathrm{e}^{c\lambda}\right\} = \{X \leq \lambda\}$. □

Osservazione. Applicando il punto (*i*) alla variabile aleatoria $X - \mu$, dove $\mu := \mathbb{E}[X]$, il cui momento di ordine 2 è la varianza σ^2, si ritrova la disuguaglianza di Čebyšëv (Teorema 1.70) con $\varepsilon = \sqrt{a}$. Il punto (*ii*) mostra che la probabilità che $|X|$ superi k volte la quantità $\sqrt[n]{\beta_n}$ è maggiorata da $1/k^n$: quanto più elevato è l'ordine dei momenti di cui X è dotata, tanto più rapidamente decresce, al crescere di k, la stima della probabilità delle code. Le disuguaglianze

del punto *(iii)* sono note come *disuguaglianze di Chernoff*; poiché il loro primo membro non dipende da c, si può scegliere il valore di c che rende minimo il secondo membro. Ad esempio, se $M_X(c)$ è finita per qualche $c > 0$, si ha

$$\mathbb{P}(X \geq \lambda) \leq \inf_{c>0} \frac{M_X(c)}{\mathrm{e}^{c\lambda}} \qquad \forall \lambda \in \mathbb{R},$$

dove l'estremo inferiore è calcolato sui valori $c > 0$ per i quali $M_X(c)$ è finita.

Se X è una variabile aleatoria non negativa dotata di valore atteso $\mu > 0$, il Lemma 1.69 con $\psi(x) = |x|$ e $a = \lambda\mu$ stima la probabilità che X superi un multiplo assegnato del proprio valore atteso: $\mathbb{P}(X \geq \lambda\mu) \leq 1/\lambda$ per ogni $\lambda > 0$. Ragionando direttamente si ottiene la forma seguente, con la disuguaglianza stretta.

Proposizione 1.73 (Disuguaglianza di Markov per variabili aleatorie non negative). *Sia X una variabile aleatoria non negativa, ovvero tale che $\mathbb{P}(X \geq 0) = 1$, dotata di valore atteso $\mu := \mathbb{E}[X]$. Allora, per ogni $\lambda > 0$, si ha*

$$\mathbb{P}(X > \lambda\mu) < \frac{1}{\lambda}.$$

Dimostrazione. Essendo $\mathbb{P}(X < 0) = 0$, la funzione di ripartizione F_X è nulla sulla semiretta $(-\infty, 0)$, per cui ogni integrale rispetto a F_X si riduce all'integrale sulla semiretta $[0, +\infty)$; in particolare $\mu \geq 0$. Siano $B := (\lambda\mu, +\infty)$, per il quale $\{X \in B\} = \{X > \lambda\mu\}$, e $B^{\mathrm{c}} = (-\infty, \lambda\mu]$. Se $\mathbb{P}(X \in B) = 0$, la tesi è ovvia, essendo $1/\lambda > 0$; si supponga dunque $\mathbb{P}(X \in B) > 0$. Come nella dimostrazione del Lemma 1.69, si ha

$$\mu = \int_{-\infty}^{+\infty} x \,\mathrm{d}F_X(x) = \int_B x \,\mathrm{d}F_X(x) + \int_{B^{\mathrm{c}}} x \,\mathrm{d}F_X(x) \geq \int_B x \,\mathrm{d}F_X(x),$$

dove la disuguaglianza segue dal fatto che l'integrale su B^{c} si riduce all'integrale su $B^{\mathrm{c}} \cap [0, +\infty)$, dove la funzione integranda è non negativa. Per ogni $m \in \mathbb{N}$ sia poi $B_m := [\lambda\mu + 1/m, +\infty)$. La successione di eventi $\{\{X \in B_m\}\}_{m\in\mathbb{N}}$ è crescente, con unione $\{X \in B\}$, per cui, per la continuità della misura di probabilità, $\mathbb{P}(X \in B_m)$ tende a $\mathbb{P}(X \in B) > 0$ per $m \to +\infty$: esiste dunque $m \in \mathbb{N}$ tale che $\mathbb{P}(X \in B_m) > 0$. Essendo $x \geq \lambda\mu + 1/m$ per ogni $x \in B_m$ e $x > \lambda\mu$ per ogni $x \in B \setminus B_m$, si ha

$$\begin{aligned}
\int_B x \,\mathrm{d}F_X(x) &= \int_{B_m} x \,\mathrm{d}F_X(x) + \int_{B\setminus B_m} x \,\mathrm{d}F_X(x) \\
&\geq \left(\lambda\mu + \frac{1}{m}\right)\mathbb{P}(X \in B_m) + \lambda\mu\, \mathbb{P}(X \in B \setminus B_m) \\
&= \lambda\mu\, \mathbb{P}(X \in B) + \frac{1}{m}\, \mathbb{P}(X \in B_m) > \lambda\mu\, \mathbb{P}(X \in B).
\end{aligned}$$

Si ottiene dunque

$$\mu \geq \int_B x \,\mathrm{d}F_X(x) > \lambda\mu\, \mathbb{P}(X > \lambda\mu) \geq 0,$$

per cui $\mu > 0$ e, dividendo per $\lambda\mu > 0$,

$$\mathbb{P}(X > \lambda\mu) < \frac{1}{\lambda}.$$

□

Osservazione. Ad esempio, una variabile aleatoria non negativa supera il doppio del proprio valore atteso con probabilità minore di $1/2$, e il decuplo con probabilità minore di $1/10$; per $\lambda < 1$, invece, la stima è banale, essendo $1/\lambda > 1$. Se $\mu > 0$, posto $a = \lambda\mu$, la disuguaglianza di Markov si scrive anche

$$\mathbb{P}(X > a) < \frac{\mathbb{E}[X]}{a} \qquad \forall a > 0.$$

Nella forma con la disuguaglianza larga, $\mathbb{P}(X \geq a) \leq \mathbb{E}[X]/a$, essa è il caso particolare del Lemma 1.69 con $\psi(x) = |x|$, essendo $|X| = X$ con probabilità 1: per questo motivo anche il lemma è noto come disuguaglianza di Markov.

Osservazione. Nella teoria dell'affidabilità una variabile aleatoria non negativa X rappresenta tipicamente il *tempo di vita* di un componente o di un sistema, ovvero l'istante in cui esso si guasta, e la funzione

$$S_X(x) := \mathbb{P}(X > x) = 1 - F_X(x) \qquad \forall x \in \mathbb{R}$$

prende il nome di *funzione di sopravvivenza* (in inglese *survival function*) o *funzione di affidabilità*: $S_X(x)$ è la probabilità che il componente funzioni ancora all'istante x. Le disuguaglianze di questa sottosezione forniscono maggiorazioni della funzione di sopravvivenza, ovvero della coda destra della legge di X, che dipendono soltanto dal valore atteso, dai momenti o dalla funzione generatrice dei momenti di X. Se $\mu = \mathbb{E}[X] > 0$, per la Proposizione 1.73 si ha

$$S_X(x) < \frac{\mu}{x} \qquad \forall x > 0,$$

mentre, se $M_X(c)$ è finita per qualche $c > 0$, per il punto *(iii)* della Proposizione 1.72, essendo $\{X > x\} \subseteq \{X \geq x\}$, si ha

$$S_X(x) \leq M_X(c)\, \mathrm{e}^{-cx} \qquad \forall x \in \mathbb{R}.$$

In tal caso la funzione di sopravvivenza tende a 0, per $x \to +\infty$, almeno con la rapidità di un esponenziale.

1.17.3 Disuguaglianza di Schwarz

La disuguaglianza seguente estende alle variabili aleatorie la disuguaglianza di Cauchy–Schwarz, valida negli spazi vettoriali dotati di prodotto scalare, secondo la quale il valore assoluto del prodotto scalare di due vettori non supera il prodotto delle rispettive norme:

$$\big|\langle \boldsymbol{v}, \boldsymbol{w} \rangle\big| \leq \|\boldsymbol{v}\|\, \|\boldsymbol{w}\|.$$

Teorema 1.74 (Disuguaglianza di Schwarz). *Siano X e Y variabili aleatorie congiuntamente distribuite, dotate di momento di ordine 2. Allora le variabili aleatorie XY e $|XY|$ sono dotate di valore atteso e si ha*

$$\mathbb{E}^2[XY] \leq \mathbb{E}^2\big[|XY|\big] \leq \mathbb{E}\big[X^2\big]\mathbb{E}\big[Y^2\big].$$

Dimostrazione. Per la Proposizione 1.54 la variabile aleatoria XY è dotata di valore atteso, ovvero l'integrale di $|xy|$ rispetto alla legge congiunta converge, per cui anche $|XY|$ è dotata di valore atteso. Essendo $-|XY| \leq XY \leq |XY|$, per la monotonia della somma e dell'integrale (Teorema 1.51) si ha $\big|\mathbb{E}[XY]\big| \leq \mathbb{E}\big[|XY|\big]$, da cui la prima disuguaglianza.

Per la seconda, si supponga dapprima $\mathbb{E}\big[X^2\big] > 0$. Per ogni $a \in \mathbb{R}$ la variabile aleatoria $\big(a|X| - |Y|\big)^2$ è non negativa, e ha dunque valore atteso non negativo; sviluppando il quadrato, essendo $|X|^2 = X^2$ e $|X|\,|Y| = |XY|$, per la linearità del valore atteso si ha

$$0 \le \mathbb{E}\Big[\big(a|X| - |Y|\big)^2\Big] = a^2\,\mathbb{E}\big[X^2\big] - 2a\,\mathbb{E}\big[|XY|\big] + \mathbb{E}\big[Y^2\big] \qquad \forall a \in \mathbb{R}.$$

Raccogliendo $\mathbb{E}\big[X^2\big]$ e completando il quadrato, il secondo membro si scrive

$$\begin{aligned}\mathbb{E}\big[X^2\big]&\left(a^2 - 2a\,\frac{\mathbb{E}\big[|XY|\big]}{\mathbb{E}[X^2]} + \frac{\mathbb{E}^2\big[|XY|\big]}{\mathbb{E}^2[X^2]} - \frac{\mathbb{E}^2\big[|XY|\big]}{\mathbb{E}^2[X^2]} + \frac{\mathbb{E}\big[Y^2\big]}{\mathbb{E}[X^2]}\right)\\ &= \mathbb{E}\big[X^2\big]\left(\left(a - \frac{\mathbb{E}\big[|XY|\big]}{\mathbb{E}[X^2]}\right)^2 - \frac{\mathbb{E}^2\big[|XY|\big] - \mathbb{E}\big[X^2\big]\mathbb{E}\big[Y^2\big]}{\mathbb{E}^2[X^2]}\right).\end{aligned}$$

La disuguaglianza vale per ogni $a \in \mathbb{R}$ e, in particolare, per $a = \mathbb{E}\big[|XY|\big]/\mathbb{E}\big[X^2\big]$, che annulla il quadrato: si ottiene

$$0 \le -\frac{\mathbb{E}^2\big[|XY|\big] - \mathbb{E}\big[X^2\big]\mathbb{E}\big[Y^2\big]}{\mathbb{E}[X^2]},$$

ovvero, essendo $\mathbb{E}\big[X^2\big] > 0$, la seconda disuguaglianza. Se invece $\mathbb{E}\big[X^2\big] = 0$, per la formula fondamentale (Proposizione 1.48) si ha

$$0 \le \mathrm{Var}[X] = \mathbb{E}\big[X^2\big] - \mathbb{E}^2[X] = -\mathbb{E}^2[X] \le 0,$$

per cui $\mathrm{Var}[X] = 0$ ed $\mathbb{E}[X] = 0$: per il Teorema 1.50 la variabile X è degenere in 0. Allora anche $|XY|$ è degenere in 0, per cui $\mathbb{E}\big[|XY|\big] = 0$ e la seconda disuguaglianza è verificata. □

Osservazione. Si osservi che:

(*i*) applicando la disuguaglianza di Schwarz alle variabili aleatorie $X - \mu_X$ e $Y - \mu_Y$, dove $\mu_X := \mathbb{E}[X]$ e $\mu_Y := \mathbb{E}[Y]$, si ottiene

$$\begin{aligned}\mathrm{Cov}^2[X,Y] &= \mathbb{E}^2\big[(X - \mu_X)(Y - \mu_Y)\big]\\ &\le \mathbb{E}\big[(X - \mu_X)^2\big]\,\mathbb{E}\big[(Y - \mu_Y)^2\big] = \mathrm{Var}[X]\ \mathrm{Var}[Y].\end{aligned}$$

Ne segue che la covarianza di due variabili aleatorie dotate di momento di ordine 2 è finita, come già osservato dopo la Definizione 1.76, e, se le variabili sono non degeneri, si ha $|\rho(X,Y)| \le 1$. Si ritrova così, per altra via, la prima parte della Proposizione 1.59;

(*ii*) se Y è degenere in 1, la disuguaglianza di Schwarz fornisce $\mathbb{E}^2\big[|X|\big] \le \mathbb{E}\big[X^2\big]$, e quindi

$$\big|\mathbb{E}[X]\big| \le \mathbb{E}\big[|X|\big] \le \sqrt{\mathbb{E}\big[X^2\big]};$$

in particolare la disuguaglianza $\mathbb{E}^2[X] \le \mathbb{E}\big[X^2\big]$ equivale, per la formula fondamentale, alla non negatività della varianza;

(*iii*) la disuguaglianza di Cauchy–Schwarz per i numeri reali è un caso particolare della disuguaglianza di Schwarz. Dati $a_1, \dots, a_n, b_1, \dots, b_n \in \mathbb{R}$, si considerino lo spazio campione

$\Omega = I_n$, con la σ-algebra $\mathcal{P}(\Omega)$ e la misura di probabilità uniforme $\mathbb{P}\big(\{i\}\big) = 1/n$, e le variabili aleatorie definite da $X(i) = a_i$ e $Y(i) = b_i$ per ogni $i \in I_n$. Si ha allora

$$\mathbb{E}[XY] = \frac{1}{n}\sum_{i=1}^{n} a_i b_i, \qquad \mathbb{E}\big[X^2\big] = \frac{1}{n}\sum_{i=1}^{n} a_i^2, \qquad \mathbb{E}\big[Y^2\big] = \frac{1}{n}\sum_{i=1}^{n} b_i^2,$$

e la disuguaglianza $\mathbb{E}^2[XY] \le \mathbb{E}\big[X^2\big]\mathbb{E}\big[Y^2\big]$, moltiplicata per n^2, diventa

$$\left(\sum_{i=1}^{n} a_i b_i\right)^2 \le \left(\sum_{i=1}^{n} a_i^2\right)\left(\sum_{i=1}^{n} b_i^2\right).$$

1.18 Condizionamento e regressione

La probabilità condizionata di un evento A dato un evento B è stata definita soltanto nel caso $\mathbb{P}(B) > 0$ (Definizione 1.32). In molte applicazioni occorre tuttavia condizionare rispetto al valore assunto da una variabile aleatoria X, ovvero rispetto a eventi della forma $B = \{X = x\}$. Se X è discreta e $\mathbb{P}(X = x) > 0$ non vi sono difficoltà; se invece X è assolutamente continua, si ha $\mathbb{P}(X = x) = 0$ per ogni $x \in \mathbb{R}$, e occorre procedere in modo diverso. Il valore atteso condizionato che ne deriva è alla base del problema della regressione.

1.18.1 Condizionamento nel continuo

Definizione 1.81. Sia X una variabile aleatoria assolutamente continua, con funzione di ripartizione F_X, e sia $x \in \mathbb{R}$ tale che, per $h, k \ge 0$ non entrambi nulli e sufficientemente piccoli, l'evento

$$A_{h,k} := \{x - h \le X \le x + k\}$$

abbia probabilità $\mathbb{P}(A_{h,k}) = F_X(x + k) - F_X(x - h) > 0$. Si dice *probabilità* di un evento $A \in \mathcal{F}$ *condizionata dall'evento* $\{X = x\}$, e si indica con $\mathbb{P}(A \,|\, X = x)$ o con $\mathbb{P}(A \,|\, x)$, il limite

$$\mathbb{P}(A \,|\, X = x) = \mathbb{P}(A \,|\, x) := \lim_{h,k \to 0^+} \mathbb{P}(A \,|\, A_{h,k}) = \lim_{h,k \to 0^+} \frac{\mathbb{P}(A \cap A_{h,k})}{\mathbb{P}(A_{h,k})},$$

qualora esso esista.

Osservazione. Se X è discreta e $x \in S_X$, l'evento $\{X = x\}$ ha probabilità positiva, e la probabilità condizionata $\mathbb{P}(A \,|\, X = x)$ è definita direttamente dalla Definizione 1.32. Se invece X è assolutamente continua, la Definizione 1.81 approssima l'evento $\{X = x\}$, di probabilità nulla, con gli eventi $A_{h,k}$, di probabilità positiva, che lo contengono e si restringono intorno a esso per $h, k \to 0^+$.

Definizione 1.82. Siano X e Y variabili aleatorie congiuntamente distribuite, con X assolutamente continua, siano F_X e $F_{X,Y}$ le funzioni di ripartizione di X e del vettore aleatorio (X, Y), e sia $x \in \mathbb{R}$ come nella Definizione 1.81. Si dice *funzione di ripartizione di Y condizionata dall'evento* $\{X = x\}$ la funzione definita da

$$F_{Y\,|\,X}(y \,|\, x) := \mathbb{P}(Y \le y \,|\, X = x) = \lim_{h,k \to 0^+} \mathbb{P}(Y \le y \,|\, x - h \le X \le x + k) \qquad \forall y \in \mathbb{R},$$

sempre che il limite esista finito per ogni $y \in \mathbb{R}$. Essendo $\mathbb{P}(X = x - h) = 0$, si ha

$$F_{Y\,|\,X}(y\,|\,x) = \lim_{h,k\to 0^+} \frac{\mathbb{P}(x-h \le X \le x+k,\ Y \le y)}{\mathbb{P}(x-h \le X \le x+k)} = \lim_{h,k\to 0^+} \frac{F_{X,Y}(x+k,y) - F_{X,Y}(x-h,y)}{F_X(x+k) - F_X(x-h)}.$$

Scambiando i ruoli di X e Y si definisce, se Y è assolutamente continua, la funzione di ripartizione $F_{X\,|\,Y}(\cdot\,|\,y)$ di X condizionata dall'evento $\{Y = y\}$.

Alla funzione di ripartizione condizionata si associa, sotto opportune ipotesi di regolarità, una densità di probabilità.

Proposizione 1.75. *Sia (X, Y) un vettore aleatorio assolutamente continuo, con densità congiunta $f_{X,Y}$, funzione di ripartizione congiunta $F_{X,Y}$ e densità marginali f_X e f_Y, e sia $x \in \mathbb{R}$ un punto in un intorno del quale f_X è continua, con $f_X(x) > 0$. Allora, per ogni $y \in \mathbb{R}$ tale che in un intorno del punto (x, y) la densità $f_{X,Y}$ sia continua e la funzione $F_{X,Y}$ abbia derivate parziali continue fino al secondo ordine, la funzione di ripartizione condizionata $F_{Y\,|\,X}(\cdot\,|\,x)$ è derivabile in y e si ha*

$$f_{Y\,|\,X}(y\,|\,x) := \frac{\partial}{\partial y}\{F_{Y\,|\,X}(y\,|\,x)\} = \frac{f_{X,Y}(x,y)}{f_X(x)}.$$

La funzione $f_{Y\,|\,X}(\cdot\,|\,x)$ si dice densità di probabilità di Y condizionata dall'evento $\{X = x\}$.

Dimostrazione. Per il teorema fondamentale del calcolo integrale, essendo f_X continua in un intorno di x, la funzione di ripartizione F_X è ivi derivabile, con $F_X' = f_X$. Sia y' un punto sufficientemente vicino a y, per il quale $F_{X,Y}$ ha derivate parziali continue in un intorno di (x, y'). Per $h, k \ge 0$ non entrambi nulli e sufficientemente piccoli, per il teorema di Lagrange applicato alle funzioni $u \longmapsto F_{X,Y}(u, y')$ e F_X sull'intervallo $[x-h, x+k]$, esistono $\xi, \eta \in (x-h, x+k)$ tali che

$$F_{X,Y}(x+k,y') - F_{X,Y}(x-h,y') = (h+k)\,\frac{\partial F_{X,Y}}{\partial x}(\xi, y'),$$
$$F_X(x+k) - F_X(x-h) = (h+k)\,f_X(\eta),$$

con $f_X(\eta) > 0$ per h e k sufficientemente piccoli, essendo f_X continua in x e $f_X(x) > 0$. Per $h, k \to 0^+$ si ha $\xi, \eta \to x$ e, per la continuità di $\partial F_{X,Y}/\partial x$ e di f_X, si ottiene

$$F_{Y\,|\,X}(y'\,|\,x) = \lim_{h,k\to 0^+} \frac{1}{f_X(\eta)}\,\frac{\partial F_{X,Y}}{\partial x}(\xi, y') = \frac{1}{f_X(x)}\,\frac{\partial F_{X,Y}}{\partial x}(x, y').$$

Per $h = 0$ il calcolo si riduce alla forma

$$F_{Y\,|\,X}(y'\,|\,x) = \lim_{k\to 0^+} \frac{k}{F_X(x+k) - F_X(x)} \cdot \frac{F_{X,Y}(x+k,y') - F_{X,Y}(x,y')}{k}.$$

Derivando rispetto a y' in $y' = y$, per il teorema di Schwarz sulle derivate seconde miste e per l'osservazione successiva alla Definizione 1.67, essendo $f_{X,Y}$ continua in (x, y), si conclude che

$$\frac{\partial}{\partial y}\{F_{Y\,|\,X}(y\,|\,x)\} = \frac{1}{f_X(x)}\,\frac{\partial^2 F_{X,Y}}{\partial y\,\partial x}(x,y) = \frac{1}{f_X(x)}\,\frac{\partial^2 F_{X,Y}}{\partial x\,\partial y}(x,y) = \frac{f_{X,Y}(x,y)}{f_X(x)}. \qquad \square$$

Osservazione. Se le ipotesi della Proposizione 1.75 sono soddisfatte per ogni $y \in \mathbb{R}$, salvo al più un numero finito di punti, la funzione

$$f_{Y \mid X}(y \mid x) = \frac{f_{X,Y}(x, y)}{f_X(x)}$$

è non negativa e, per la Proposizione 1.38, si ha

$$\int_{-\infty}^{+\infty} f_{Y \mid X}(y \mid x)\,\mathrm{d}y = \frac{1}{f_X(x)} \int_{-\infty}^{+\infty} f_{X,Y}(x, y)\,\mathrm{d}y = \frac{f_X(x)}{f_X(x)} = 1.$$

Essa è dunque una densità di probabilità, e $F_{Y \mid X}(\cdot \mid x)$ è la funzione di ripartizione di una legge assolutamente continua. Scambiando i ruoli di X e Y si ottiene, per $f_Y(y) > 0$, la densità di X condizionata dall'evento $\{Y = y\}$:

$$f_{X \mid Y}(x \mid y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}.$$

Se X e Y sono indipendenti, per la Proposizione 1.39 si ha $f_{X,Y}(x, y) = f_X(x)\, f_Y(y)$, e quindi

$$f_{Y \mid X}(y \mid x) = f_Y(y), \qquad f_{X \mid Y}(x \mid y) = f_X(x),$$
$$F_{Y \mid X}(y \mid x) = F_Y(y), \qquad F_{X \mid Y}(x \mid y) = F_X(x).$$

Il condizionamento rispetto al valore assunto da una delle due variabili non modifica la legge dell'altra.

Osservazione. Se X e Y sono discrete e $x \in S_X$, la funzione

$$p_{Y \mid X}(y \mid x) := \mathbb{P}(Y = y \mid X = x) = \frac{\mathbb{P}(X = x,\ Y = y)}{\mathbb{P}(X = x)} = \frac{p_{X,Y}(x, y)}{p_X(x)} \qquad \forall y \in S_Y$$

si dice *funzione massa di probabilità di Y condizionata dall'evento $\{X = x\}$*; essa è l'analogo discreto della densità condizionata, e ha somma 1, poiché la funzione massa marginale si ottiene sommando la funzione massa congiunta (osservazione successiva alla Proposizione 1.38):

$$p_X(x) = \mathbb{P}(X = x) = \sum_{y \in S_Y} \mathbb{P}(X = x,\ Y = y) = \sum_{y \in S_Y} p_{X,Y}(x, y).$$

1.18.2 Valore atteso condizionato e regressione

Definizione 1.83. Siano X e Y variabili aleatorie congiuntamente distribuite, e sia $x \in \mathbb{R}$ tale che sia definita la funzione di ripartizione $F_{Y \mid X}(\cdot \mid x)$ di Y condizionata dall'evento $\{X = x\}$: quella della Definizione 1.82 se X è assolutamente continua, oppure, se X è discreta e $x \in S_X$, quella della misura di probabilità condizionata $\mathbb{P}(\cdot \mid X = x)$. Si dice *valore atteso di Y condizionato dall'evento $\{X = x\}$*, e si indica con $\mathbb{E}[Y \mid X = x]$ o con $\mathbb{E}[Y \mid x]$, il valore atteso della legge di funzione di ripartizione $F_{Y \mid X}(\cdot \mid x)$:

$$\mathbb{E}[Y \mid X = x] = \mathbb{E}[Y \mid x] := \int_{-\infty}^{+\infty} y\,\mathrm{d}F_{Y \mid X}(y \mid x),$$

qualora l'integrale converga assolutamente.

Osservazione. Come per il valore atteso (Proposizione 1.44), nei due casi fondamentali il valore atteso condizionato si calcola mediante un integrale ordinario o una somma. Se (X, Y) è assolutamente continuo e vale la Proposizione 1.75, si ha

$$\mathbb{E}[Y \mid x] = \int_{-\infty}^{+\infty} y \, f_{Y \mid X}(y \mid x) \, \mathrm{d}y = \frac{1}{f_X(x)} \int_{-\infty}^{+\infty} y \, f_{X,Y}(x, y) \, \mathrm{d}y,$$

mentre, se X e Y sono discrete e $x \in S_X$, si ha

$$\mathbb{E}[Y \mid x] = \sum_{y \in S_Y} y \, p_{Y \mid X}(y \mid x) = \frac{1}{p_X(x)} \sum_{y \in S_Y} y \, p_{X,Y}(x, y).$$

Si osservi che in $\mathbb{E}[Y \mid x]$ compare la lettera minuscola x: il valore atteso condizionato è un numero reale, che dipende dal valore x assunto da X.

Proposizione 1.76. *Siano X, Y e Z variabili aleatorie congiuntamente distribuite, e sia $x \in \mathbb{R}$ come nella Definizione 1.83. Allora:*

(*i*) *se X e Y sono indipendenti e Y è dotata di valore atteso, si ha*

$$\mathbb{E}[Y \mid x] = \mathbb{E}[Y];$$

(*ii*) *per ogni funzione $g : \mathbb{R} \to \mathbb{R}$ $\mathfrak{B}$-misurabile e, se X è assolutamente continua, continua in x, si ha*

$$\mathbb{E}\big[g(X) \mid x\big] = g(x);$$

(*iii*) *se $\mathbb{E}[Y \mid x]$ ed $\mathbb{E}[Z \mid x]$ esistono, per ogni $a, b \in \mathbb{R}$ si ha*

$$\mathbb{E}[aY + bZ \mid x] = a\,\mathbb{E}[Y \mid x] + b\,\mathbb{E}[Z \mid x].$$

Dimostrazione. Si considera il caso in cui X è assolutamente continua; il caso discreto si tratta allo stesso modo, sostituendo agli eventi $A_{h,k}$ l'evento $\{X = x\}$.

(*i*) Per l'indipendenza di X e Y (Definizione 1.69), per ogni $y \in \mathbb{R}$ e per h e k come nella Definizione 1.81 si ha

$$\mathbb{P}(Y \le y \mid x - h \le X \le x + k) = \frac{\mathbb{P}(Y \le y)\,\mathbb{P}(x - h \le X \le x + k)}{\mathbb{P}(x - h \le X \le x + k)} = F_Y(y),$$

per cui $F_{Y \mid X}(y \mid x) = F_Y(y)$ per ogni $y \in \mathbb{R}$: la legge di Y condizionata dall'evento $\{X = x\}$ coincide con la legge di Y, e quindi $\mathbb{E}[Y \mid x] = \mathbb{E}[Y]$.

(*ii*) Sia $t > g(x)$. Per la continuità di g in x esiste $\delta > 0$ tale che $g(u) < t$ per ogni $u \in (x - \delta, x + \delta)$, per cui, per $h, k < \delta$, si ha $A_{h,k} \subseteq \big\{g(X) \le t\big\}$ e

$$\mathbb{P}\big(g(X) \le t \mid A_{h,k}\big) = \frac{\mathbb{P}(A_{h,k})}{\mathbb{P}(A_{h,k})} = 1.$$

Allo stesso modo, per $t < g(x)$ si ha $A_{h,k} \cap \big\{g(X) \le t\big\} = \emptyset$ per h, k sufficientemente piccoli, e la probabilità condizionata è nulla. Passando al limite, la funzione di ripartizione di $g(X)$ condizionata dall'evento $\{X = x\}$ vale 0 per $t < g(x)$ e 1 per $t > g(x)$: essa è quella della variabile aleatoria degenere in $g(x)$, il cui valore atteso è $g(x)$ (Proposizione 1.47).

(*iii*) Si dimostra come la linearità del valore atteso (PROPOSIZIONE 1.52), sostituendo alla legge congiunta del vettore (Y, Z) la legge condizionata dall'evento $\{X = x\}$; si omettono i dettagli. □

Il valore atteso condizionato è alla base del problema della *regressione*: stabilire se tra grandezze aleatorie esiste un legame che permetta di prevedere il valore di alcune di esse a partire da quello assunto dalle altre. Si parla di *regressione multivariata* quando si studia, al variare di $(x_1, \dots, x_k)$, il valore atteso di Y condizionato dall'evento $\{X_1 = x_1, \dots, X_k = x_k\}$,

$$\mathbb{E}[Y \mid x_1, \dots, x_k] := \mathbb{E}[Y \mid X_1 = x_1, \dots, X_k = x_k];$$

nel seguito ci si limita al caso $k = 1$, detto di *regressione bivariata*, nel quale si studia il valore atteso $\mathbb{E}[Y \mid x]$ al variare di x.

DEFINIZIONE 1.84. Siano X e Y variabili aleatorie congiuntamente distribuite. La funzione $x \longmapsto \mathbb{E}[Y \mid x]$, definita per i valori di x per i quali il valore atteso condizionato esiste, si dice *funzione di regressione* di Y su X. Se esistono $a, b \in \mathbb{R}$ tali che

$$\mathbb{E}[Y \mid x] = a + bx$$

per ogni tale x, la regressione di Y su X si dice *lineare*, e i numeri a e b si dicono *coefficienti di regressione*.

Osservazione. Nota la densità congiunta $f_{X,Y}$, il calcolo della funzione di regressione procede dunque come segue: si calcola la densità marginale

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y)\,\mathrm{d}y$$

(PROPOSIZIONE 1.38); per ogni x con $f_X(x) > 0$ si ricava la densità condizionata

$$f_{Y \mid X}(y \mid x) = \frac{f_{X,Y}(x, y)}{f_X(x)}$$

(PROPOSIZIONE 1.75); infine si calcola

$$\mathbb{E}[Y \mid x] = \int_{-\infty}^{+\infty} y\, f_{Y \mid X}(y \mid x)\,\mathrm{d}y.$$

Nel caso discreto si procede allo stesso modo, con le somme al posto degli integrali.

ESEMPIO 1.66. Sia (X, Y) un vettore aleatorio assolutamente continuo con densità congiunta

$$f_{X,Y}(x, y) = \begin{cases} \dfrac{8}{(x + y + 4)^3} & \text{se } x > 0 \text{ e } y > 0 \\ 0 & \text{altrimenti} \end{cases}$$

Per $x > 0$ la densità marginale di X è

$$f_X(x) = \int_0^{+\infty} \frac{8}{(x + y + 4)^3}\,\mathrm{d}y = \left[-\frac{4}{(x + y + 4)^2}\right]_0^{+\infty} = \frac{4}{(x + 4)^2},$$

mentre $f_X(x) = 0$ per $x \leq 0$; si verifica che $f_{X,Y}$, che è non negativa, soddisfa la condizione di normalizzazione:

$$\int_0^{+\infty} \frac{4}{(x + 4)^2}\,\mathrm{d}x = \left[-\frac{4}{x + 4}\right]_0^{+\infty} = 1.$$

Per $x > 0$ la densità di Y condizionata dall'evento $\{X = x\}$ è dunque

$$f_{Y\,|\,X}(y\,|\,x) = \frac{8}{(x+y+4)^3} \cdot \frac{(x+4)^2}{4} = \frac{2\,(x+4)^2}{(x+y+4)^3} \qquad \text{per } y > 0,$$

nulla per $y \leq 0$. Integrando per parti, con fattore finito y e fattore differenziale $(x+y+4)^{-3}$, di primitiva $-(x+y+4)^{-2}/2$, si ottiene

$$\begin{aligned}
\mathbb{E}[Y\,|\,x] &= 2\,(x+4)^2 \int_0^{+\infty} \frac{y}{(x+y+4)^3}\,\mathrm{d}y \\
&= 2\,(x+4)^2 \left(\left[-\frac{y}{2\,(x+y+4)^2} \right]_0^{+\infty} + \frac{1}{2} \int_0^{+\infty} \frac{\mathrm{d}y}{(x+y+4)^2} \right) \\
&= (x+4)^2 \left[-\frac{1}{x+y+4} \right]_0^{+\infty} = \frac{(x+4)^2}{x+4} = x+4 \qquad \forall x > 0.
\end{aligned}$$

La regressione di Y su X è dunque lineare, con coefficienti di regressione $a = 4$ e $b = 1$. Si osservi che Y, la cui densità marginale è, per simmetria, $f_Y(y) = 4/(y+4)^2$ per $y > 0$, non è dotata di valore atteso, poiché $y\, f_Y(y)$ si comporta come $4/y$ per $y \to +\infty$; il valore atteso condizionato esiste invece per ogni $x > 0$, poiché la densità condizionata decresce come $1/y^3$.

Esempio 1.67. Sia (X, Y) un vettore aleatorio discreto con $S_X = S_Y = \{0, 1\}$ e funzione massa di probabilità congiunta riportata nella Tabella 1.5, nella quale l'ultima riga e l'ultima colonna riportano le funzioni massa marginali, ottenute sommando lungo le righe e lungo le colonne:

$$\begin{aligned}
p_X(0) &= 0.3 + 0.2 = 0.5, & p_X(1) &= 0.1 + 0.4 = 0.5, \\
p_Y(0) &= 0.3 + 0.1 = 0.4, & p_Y(1) &= 0.2 + 0.4 = 0.6.
\end{aligned}$$

Tabella 1.5. Funzione massa di probabilità congiunta del vettore aleatorio (X, Y) dell'Esempio 1.67 e funzioni massa marginali.

$p_{X,Y}(x,y)$	$y=0$	$y=1$	$p_X(x)$
$x=0$	0.3	0.2	0.5
$x=1$	0.1	0.4	0.5
$p_Y(y)$	0.4	0.6	1

Le variabili X e Y sono dunque di Bernoulli (Definizione 1.44), con $X \sim \mathrm{Ber}(0.5)$ e $Y \sim \mathrm{Ber}(0.6)$, per cui (Esempio 1.35 ed Esempio 1.43)

$$\begin{aligned}
\mathbb{E}[X] &= 0.5, & \mathrm{Var}[X] &= 0.5 \cdot 0.5 = 0.25, \\
\mathbb{E}[Y] &= 0.6, & \mathrm{Var}[Y] &= 0.6 \cdot 0.4 = 0.24.
\end{aligned}$$

Il prodotto XY è non nullo soltanto per $x = y = 1$, per cui $\mathbb{E}[XY] = 1 \cdot 1 \cdot 0.4 = 0.4$ e, per la Proposizione 1.54,

$$\mathrm{Cov}[X, Y] = \mathbb{E}[XY] - \mathbb{E}[X]\,\mathbb{E}[Y] = 0.4 - 0.5 \cdot 0.6 = 0.1,$$

e quindi

$$\rho(X,Y) = \frac{\mathrm{Cov}[X,Y]}{\sigma_X\,\sigma_Y} = \frac{0.1}{0.5\cdot\sqrt{0.24}} \approx 0.408.$$

Le variabili X e Y sono dunque correlate positivamente. I valori attesi condizionati si ottengono dalle funzioni massa condizionate: poiché soltanto il valore $y = 1$ contribuisce alla somma, si ha

$$\mathbb{E}[Y \mid x] = \sum_{y=0}^{1} y\,\frac{p_{X,Y}(x,y)}{p_X(x)} = \frac{p_{X,Y}(x,1)}{p_X(x)} = \begin{cases} \dfrac{0.2}{0.5} = \dfrac{2}{5} & \text{se } x = 0 \\ \dfrac{0.4}{0.5} = \dfrac{4}{5} & \text{se } x = 1 \end{cases}$$

e, allo stesso modo,

$$\mathbb{E}[X \mid y] = \sum_{x=0}^{1} x\,\frac{p_{X,Y}(x,y)}{p_Y(y)} = \frac{p_{X,Y}(1,y)}{p_Y(y)} = \begin{cases} \dfrac{0.1}{0.4} = \dfrac{1}{4} & \text{se } y = 0 \\ \dfrac{0.4}{0.6} = \dfrac{2}{3} & \text{se } y = 1 \end{cases}$$

In particolare $\mathbb{E}[Y \mid x] = 2/5 + 2x/5$ per $x \in \{0,1\}$: la regressione di Y su X è lineare, con coefficienti di regressione $a = b = 2/5$.

1.19 Teoremi limite

In questa sezione si studia il comportamento, al crescere del numero n delle prove, di una variabile aleatoria binomiale $X_n \sim \mathrm{Bin}(n,p)$. La standardizzata di X_n ha, al limite, la legge normale standard, il che consente di approssimare le probabilità relative a X_n mediante la funzione di ripartizione della normale standard; la frequenza relativa X_n/n dei successi si discosta invece dalla probabilità p di successo nella singola prova di meno di una qualsiasi soglia assegnata, con probabilità tendente a 1.

1.19.1 Approssimazione normale della distribuzione binomiale

Il calcolo esatto delle probabilità relative a una variabile aleatoria binomiale richiede coefficienti binomiali e potenze che, per n elevato, sono laboriosi da calcolare senza strumenti di calcolo. Il risultato seguente mostra che, per n elevato, la standardizzata di una variabile binomiale si comporta come una variabile aleatoria normale standard.

Teorema 1.77. *Sia $p \in (0,1)$ e, per ogni $n \in \mathbb{N}$, sia $X_n \sim \mathrm{Bin}(n,p)$, con valore atteso $\mu_n := np$ e deviazione standard $\sigma_n := \sqrt{np\,(1-p)}$. Posto*

$$X_n^* := \frac{X_n - \mu_n}{\sigma_n} \qquad \forall n \in \mathbb{N},$$

si ha

$$\lim_{n\to+\infty} M_{X_n^*}(t) = \mathrm{e}^{t^2/2} = M_Z(t) \qquad \forall t \in \mathbb{R},$$

dove $Z \sim \mathcal{N}(0,1)$: la funzione generatrice dei momenti della standardizzata di una variabile aleatoria binomiale converge, per $n \to +\infty$, a quella della variabile aleatoria normale standard.

Dimostrazione. Per l'Esempio 1.36 e l'Esempio 1.44 si ha $\mathbb{E}[X_n] = \mu_n$ e $\mathrm{Var}[X_n] = \sigma_n^2$, con $\sigma_n > 0$ essendo $p \in (0,1)$, per cui X_n^* è la standardizzata di X_n (Definizione 1.74), ovvero la funzione affine di X_n con coefficienti $1/\sigma_n$ e $-\mu_n/\sigma_n$. Per il punto *(ii)* della Proposizione 1.66 e per l'Esempio 1.60, secondo il quale $M_{X_n}(t) = (1-p+pe^t)^n$ per ogni $t \in \mathbb{R}$, si ha

$$M_{X_n^*}(t) = \mathbb{E}\Big[e^{t(X_n-\mu_n)/\sigma_n}\Big] = e^{-t\mu_n/\sigma_n} M_{X_n}\left(\frac{t}{\sigma_n}\right) = e^{-t\mu_n/\sigma_n}\left(1-p+pe^{t/\sigma_n}\right)^n \qquad \forall t \in \mathbb{R}.$$

Per $t = 0$ si ha $M_{X_n^*}(0) = 1 = e^0$ per ogni $n \in \mathbb{N}$, e la tesi è ovvia; si fissi dunque $t \neq 0$. Essendo $M_{X_n^*}(t) > 0$, conviene studiare il limite del logaritmo

$$\log M_{X_n^*}(t) = -\frac{t\mu_n}{\sigma_n} + n \log\left(1-p+pe^{t/\sigma_n}\right).$$

Si utilizzano gli sviluppi di Taylor, per $u \to 0$,

$$e^u = 1 + u + \frac{u^2}{2} + o\big(u^2\big), \qquad \log(1+u) = u - \frac{u^2}{2} + o\big(u^2\big),$$

dove, come di consueto, $o\big(u^2\big)$ indica una funzione tale che $o\big(u^2\big)/u^2 \to 0$ per $u \to 0$; analogamente, per una successione $\{u_n\}_{n\in\mathbb{N}}$ di numeri non nulli e infinitesima, $o\big(u_n^2\big)$ indica una successione tale che $o\big(u_n^2\big)/u_n^2 \to 0$ per $n \to +\infty$. Posto $u_n := t/\sigma_n$, si ha $u_n \neq 0$ e $u_n \to 0$, essendo $\sigma_n \to +\infty$. Si ha

$$1 - p + pe^{u_n} = 1 + v_n, \qquad \text{con } v_n := p(e^{u_n} - 1) \neq 0,$$

e, per il primo sviluppo,

$$v_n = pu_n + \frac{pu_n^2}{2} + o\big(u_n^2\big).$$

Si ha dunque $v_n \to 0$ e $v_n^2 = p^2u_n^2 + o\big(u_n^2\big)$; in particolare $v_n^2/u_n^2 \to p^2$, per cui ogni $o\big(v_n^2\big)$ è anche un $o\big(u_n^2\big)$. Dal secondo sviluppo si ottiene allora

$$\log(1-p+pe^{u_n}) = v_n - \frac{v_n^2}{2} + o\big(v_n^2\big) = pu_n + \frac{p\,(1-p)}{2}\,u_n^2 + o\big(u_n^2\big).$$

Essendo $\mu_n = np$ e $nu_n^2 = nt^2/\sigma_n^2 = t^2/\big(p\,(1-p)\big)$, moltiplicando per n si ottiene

$$\log M_{X_n^*}(t) = -\frac{npt}{\sigma_n} + \frac{npt}{\sigma_n} + \frac{p\,(1-p)}{2} \cdot \frac{t^2}{p\,(1-p)} + n\,o\big(u_n^2\big) = \frac{t^2}{2} + n\,o\big(u_n^2\big),$$

dove l'ultimo termine è infinitesimo, poiché

$$n\,o\big(u_n^2\big) = nu_n^2 \cdot \frac{o\big(u_n^2\big)}{u_n^2} = \frac{t^2}{p\,(1-p)} \cdot \frac{o\big(u_n^2\big)}{u_n^2} \longrightarrow 0 \qquad \text{per } n \to +\infty.$$

Si ha dunque

$$\lim_{n\to+\infty} \log M_{X_n^*}(t) = \frac{t^2}{2}$$

e, per la continuità della funzione esponenziale e per l'Esempio 1.63,

$$\lim_{n\to+\infty} M_{X_n^*}(t) = e^{t^2/2} = M_Z(t). \qquad \square$$

Osservazione. La convergenza delle funzioni generatrici dei momenti ha un'importante conseguenza sulle funzioni di ripartizione. Si dimostra infatti, e qui si omette, un *teorema di continuità*: se le funzioni generatrici dei momenti di una successione di variabili aleatorie $\{Y_n\}_{n\in\mathbb{N}}$ sono finite in un intervallo aperto contenente 0 e vi convergono alla funzione generatrice dei momenti di una variabile aleatoria Z, allora $F_{Y_n}(y)$ converge a $F_Z(y)$ in ogni punto y di continuità di F_Z. Nel caso del Teorema 1.77 la funzione di ripartizione F_Z della normale standard è continua, per cui

$$\lim_{n\to+\infty} \mathbb{P}\left(\frac{X_n - np}{\sqrt{np\,(1-p)}} \le y\right) = F_Z(y) \qquad \forall y \in \mathbb{R},$$

risultato noto come *teorema di De Moivre–Laplace*. Per n elevato si può dunque approssimare la legge di $X_n \sim \mathrm{Bin}(n, p)$ con quella di una variabile aleatoria normale $Y \sim \mathcal{N}\big(np, np\,(1-p)\big)$, che ha lo stesso valore atteso e la stessa varianza. Poiché X_n assume soltanto valori interi, per $a, b \in \mathbb{Z}$ con $a \le b$ si ha $\{a \le X_n \le b\} = \{a - 1/2 \le X_n \le b + 1/2\}$, e conviene approssimare la probabilità di tale evento con quella dell'intervallo allargato di $1/2$ da entrambe le parti (*correzione di continuità*):

$$\mathbb{P}(a \le X_n \le b) \approx \mathbb{P}\left(a - \frac{1}{2} \le Y \le b + \frac{1}{2}\right) = F_Z\left(\frac{b + 1/2 - np}{\sqrt{np\,(1-p)}}\right) - F_Z\left(\frac{a - 1/2 - np}{\sqrt{np\,(1-p)}}\right).$$

Senza la correzione, per $a = b$ si otterrebbe una probabilità nulla, essendo Y assolutamente continua. Nella pratica l'approssimazione si ritiene accettabile se $np > 5$ e $n\,(1-p) > 5$, ovvero se i numeri attesi sia dei successi sia degli insuccessi superano 5.

Esempio 1.68. Sia $X \sim \mathrm{Bin}(20, 1/2)$, con supporto $S_X = \{0, 1, \ldots, 20\}$ e funzione massa di probabilità

$$p_X(x) = \binom{20}{x}\left(\frac{1}{2}\right)^x\left(\frac{1}{2}\right)^{20-x} = \binom{20}{x}\left(\frac{1}{2}\right)^{20} \qquad \forall x \in S_X.$$

Il valore esatto della probabilità

$$\mathbb{P}(X = 10) = \binom{20}{10}\left(\frac{1}{2}\right)^{20} = \frac{184\,756}{1\,048\,576} \approx 0.17620$$

è laborioso da calcolare senza una calcolatrice. Essendo $np = n\,(1-p) = 10 > 5$, si può utilizzare l'approssimazione normale, con la variabile aleatoria $Y \sim \mathcal{N}(10, 5)$, che ha lo stesso valore atteso $np = 10$ e la stessa varianza $np\,(1-p) = 5$ di X. Poiché $\{X = 10\} = \{9.5 \le X \le 10.5\}$, con la correzione di continuità (osservazione precedente, con $a = b = 10$) si approssima $\mathbb{P}(X = 10)$ con $\mathbb{P}(9.5 \le Y \le 10.5)$, e non con $\mathbb{P}(Y = 10)$, che è nulla. Per la Proposizione 1.68, con $\mu = 10$, $\sigma = \sqrt{5}$ e $k = 0.5/\sqrt{5} \approx 0.2236$, si ha

$$\mathbb{P}(9.5 \le Y \le 10.5) = \mathbb{P}\big(10 - k\sqrt{5} \le Y \le 10 + k\sqrt{5}\big) = 2F_Z(k) - 1 \approx 2F_Z(0.2236) - 1,$$

dove F_Z è la funzione di ripartizione della variabile aleatoria normale standard. Le tabulazioni usuali della funzione di ripartizione della normale standard riportano i valori di F_Z per argomenti con due cifre decimali: il valore $F_Z(0.2236)$ si ottiene allora per interpolazione lineare tra $F_Z(0.22) \approx 0.58706$ e $F_Z(0.23) \approx 0.59095$,

$$F_Z(0.2236) \approx 0.58706 + 0.36 \cdot (0.59095 - 0.58706) \approx 0.58846,$$

da cui

$$\mathbb{P}(X = 10) \approx \mathbb{P}(9.5 \leq Y \leq 10.5) \approx 2 \cdot 0.58846 - 1 = 0.17692.$$

Rispetto al valore esatto, l'errore assoluto è circa 0.0007 e l'errore relativo circa lo 0.4 %: l'approssimazione è dunque accettabile. È importante conservare un numero adeguato di cifre decimali: arrotondando 0.2236 a 0.22 si otterrebbe $2F_Z(0.22) - 1 \approx 0.17412$, con un errore relativo di circa l'1.2 %, quasi triplo, dovuto in gran parte all'arrotondamento e non all'approssimazione normale.

1.19.2 Teorema di Bernoulli

Si consideri un esperimento aleatorio che consiste in una successione di prove ripetute e indipendenti, in ciascuna delle quali un evento, detto *successo*, si verifica con la stessa probabilità $p \in (0, 1)$. Per ogni $n \in \mathbb{N}$, il numero X_n di successi nelle prime n prove è una variabile aleatoria binomiale, $X_n \sim \text{Bin}(n, p)$ (osservazione successiva alla Definizione 1.45), e la *frequenza relativa* dei successi nelle prime n prove è la variabile aleatoria

$$Y_n := \frac{X_n}{n}.$$

Teorema di Bernoulli 1.78. *Nelle ipotesi precedenti, per ogni $\varepsilon > 0$ si ha*

$$\lim_{n \to +\infty} \mathbb{P}\big(|Y_n - p| < \varepsilon\big) = 1.$$

Dimostrazione. Per l'Esempio 1.36 e l'Esempio 1.44 si ha $\mathbb{E}[X_n] = np$ e $\text{Var}[X_n] = np(1-p)$, per cui, per la proprietà *(iii)* della Proposizione 1.47 e per la proprietà *(ii)* della Proposizione 1.49,

$$\mathbb{E}[Y_n] = \frac{1}{n}\,\mathbb{E}[X_n] = p, \qquad \text{Var}[Y_n] = \frac{1}{n^2}\,\text{Var}[X_n] = \frac{p(1-p)}{n}.$$

Fissato $\varepsilon > 0$, per la disuguaglianza di Čebyšëv (Teorema 1.70) applicata alla variabile aleatoria Y_n si ha quindi

$$1 \geq \mathbb{P}\big(|Y_n - p| < \varepsilon\big) \geq 1 - \frac{p(1-p)}{n\varepsilon^2} \qquad \forall n \in \mathbb{N}.$$

L'ultimo membro tende a 1 per $n \to +\infty$, e la tesi segue dal teorema del confronto per i limiti di successioni. □

Osservazione. Il teorema di Bernoulli è detto anche *legge empirica del caso*: al crescere del numero delle prove, la probabilità che la frequenza relativa del successo si discosti dalla probabilità p di successo nella singola prova di almeno una qualsiasi soglia $\varepsilon > 0$ tende a 0. Il teorema giustifica, all'interno della teoria assiomatica, la definizione frequentista della probabilità data all'inizio del capitolo: la probabilità di un evento si può stimare con la frequenza relativa con cui esso si verifica in un numero elevato di prove indipendenti, effettuate nelle medesime condizioni. Si osservi tuttavia che il teorema non afferma che, per n elevato, la frequenza relativa disti da p meno di ε con certezza, ma soltanto che ciò accade con probabilità arbitrariamente prossima a 1.

Capitolo 2

Statistica descrittiva

La *statistica* è la scienza delle decisioni in condizioni di incertezza: essa rappresenta la parte della conoscenza umana sostenuta dall'evidenza empirica e si fonda su quattro momenti:

(*i*) *vedere con i sensi*, ovvero l'*analisi esplorativa* dei dati;
(*ii*) *capire per deduzione*, ovvero la *teoria della probabilità*;
(*iii*) *capire per induzione*, ovvero l'*inferenza statistica*;
(*iv*) *agire per formalizzare*, ovvero la costruzione di *modelli statistici*.

Il percorso seguito dalla statistica si può schematizzare come segue:

$$\text{dati} \longrightarrow \text{informazione} \longrightarrow \text{conoscenza}.$$

L'incertezza è una componente fondamentale e ineliminabile della conoscenza statistica: non si tratta di un difetto da rimuovere, bensì di un elemento da quantificare e da gestire, che costituisce, in un certo senso, il fondamento scientifico della nostra libertà di scelta.

2.1 Popolazione, caratteri e frequenze

Definizione 2.1. Si chiama *statistica descrittiva* l'insieme delle tecniche e degli strumenti atti a rappresentare e a sintetizzare in modo opportuno un insieme di dati relativi a una o più caratteristiche di un collettivo di interesse, detto *popolazione*. Gli elementi della popolazione si dicono *unità statistiche* e la cardinalità N della popolazione prende il nome di *taglia* (o *numerosità*) della popolazione.

Definizione 2.2. Le caratteristiche della popolazione oggetto di rilevazione si dicono *caratteri*. Dato un carattere, si chiama *modalità* ciascuna delle espressioni con le quali esso può manifestarsi sulle unità statistiche.

Esempio 2.1. (*i*) Nella valutazione delle caratteristiche somatiche di una popolazione di esseri umani, il carattere *"colore degli occhi"* può manifestarsi, ad esempio, con le modalità *"scuri"* e *"chiari"*.

(*ii*) Nella valutazione della didattica, il carattere *"gradimento del docente"* può manifestarsi, ad esempio, con le modalità *"decisamente no"*, *"più no che sì"*, *"più sì che no"* e *"decisamente sì"*.

I caratteri si classificano in base alla natura delle loro modalità:

(*i*) *qualitativi nominali*, le cui modalità non ammettono un ordinamento naturale (ad esempio il colore degli occhi o il gruppo sanguigno);

(*ii*) *qualitativi ordinali*, le cui modalità ammettono un ordinamento naturale (ad esempio il gradimento del docente);

(*iii*) *quantitativi discreti*, le cui modalità sono numeri appartenenti a un insieme al più numerabile, tipicamente numeri interi (ad esempio il numero di figli di una famiglia);

(*iv*) *quantitativi continui*, le cui modalità possono assumere, almeno in linea di principio, qualsiasi valore di un intervallo reale (ad esempio l'altezza di una persona).

Notazione 2.3. Sia data una popolazione di taglia N e sia fissato un carattere, che si indica con una lettera maiuscola, ad esempio Y. I valori del carattere rilevati sulle N unità statistiche si indicano con le corrispondenti lettere minuscole $y_1, y_2, \dots, y_N$, e la N-upla

$$\boldsymbol{y} = (y_1, y_2, \dots, y_N)$$

prende il nome di *rilevazione*. Le modalità *distinte* del carattere Y presenti nella rilevazione si indicano con $x_1, x_2, \dots, x_k$, dove $k \leq N$. Nel seguito l'indice $i \in I_N$ scorre sempre sui dati, mentre l'indice $j \in I_k$ scorre sempre sulle modalità.

Definizione 2.4. Nelle notazioni precedenti, per ogni $j \in I_k$ si definiscono:

(*i*) la *frequenza assoluta* della modalità x_j, ovvero il numero di unità statistiche sulle quali si osserva la modalità x_j:

$$n_j := \#\big\{ i \in I_N \mid y_i = x_j \big\};$$

(*ii*) la *frequenza relativa* della modalità x_j:

$$f_j := \frac{n_j}{N}.$$

La frequenza relativa si esprime spesso in forma percentuale, come $100 f_j$ %.

Proposizione 2.1. *Nelle notazioni precedenti si ha:*

$$\sum_{j=1}^{k} n_j = n_1 + n_2 + \cdots + n_k = N, \qquad \sum_{j=1}^{k} f_j = f_1 + f_2 + \cdots + f_k = 1,$$

e inoltre $0 < f_j \leq 1$ *per ogni* $j \in I_k$.

Dimostrazione. Per ogni $j \in I_k$ si ponga $A_j := \big\{ i \in I_N \mid y_i = x_j \big\}$, cosicché $n_j = \#A_j$. Gli insiemi $A_1, \dots, A_k$ sono a due a due disgiunti, poiché ciascun dato coincide con una sola modalità, e la loro unione è I_N, poiché ciascun dato coincide con una delle modalità $x_1, \dots, x_k$. Si ha quindi:

$$\sum_{j=1}^{k} n_j = \sum_{j=1}^{k} \#A_j = \#\left(\bigcup_{j=1}^{k}{\cdot} A_j \right) = \#I_N = N.$$

Dividendo per N si ottiene

$$\sum_{j=1}^{k} f_j = 1.$$

Infine, ciascuna modalità x_j è presente nella rilevazione, per cui $1 \leq n_j \leq N$ e dunque $0 < f_j \leq 1$. □

Esempio 2.2. Si consideri una popolazione di $N = 10$ famiglie e il carattere quantitativo discreto Y, *"numero di figli"*. Si supponga di ottenere la rilevazione:

$$\boldsymbol{y} = (0, 1, 1, 2, 0, 1, 3, 2, 1, 0).$$

Nessuna famiglia considerata ha più di 3 figli, per cui le modalità distinte sono $k = 4$:

$$x_1 = 0, \quad x_2 = 1, \quad x_3 = 2, \quad x_4 = 3.$$

Contando le occorrenze di ciascuna modalità si ottengono le frequenze assolute e relative riassunte nella Tabella 2.1.

Tabella 2.1. Frequenze assolute e relative del numero di figli per famiglia.

x_j	0	1	2	3	Totale
n_j	3	4	2	1	10
f_j	3/10	4/10	2/10	1/10	1

In accordo con la Proposizione 2.1, si ha $n_1 + n_2 + n_3 + n_4 = 3 + 4 + 2 + 1 = 10 = N$ e $f_1 + f_2 + f_3 + f_4 = 1$.

Osservazione. Se il carattere è quantitativo e le modalità sono numerate in ordine crescente, $x_1 < x_2 < \cdots < x_k$, si definiscono le *frequenze cumulate*, assolute e relative:

$$N_j := \sum_{h=1}^{j} n_h, \qquad F_j := \frac{N_j}{N} = \sum_{h=1}^{j} f_h \qquad \forall\, j \in I_k.$$

La funzione

$$\widehat{F}(x) := \frac{1}{N} \#\{\, i \in I_N \mid y_i \le x \,\} = \sum_{\substack{j \in I_k \\ x_j \le x}} f_j \qquad \forall x \in \mathbb{R}$$

prende il nome di *funzione di ripartizione empirica* della rilevazione: essa coincide con la funzione di ripartizione di una variabile aleatoria discreta con supporto $\{x_1, \ldots, x_k\}$ e funzione massa di probabilità $p(x_j) = f_j$, ed è dunque costante a tratti, continua a destra, con salti di ampiezza f_j nei punti x_j. Per la rilevazione dell'Esempio 2.2 si costruisce la funzione di ripartizione empirica come segue.

$$\widehat{F}(x) = \begin{cases} 0 & \text{se } x < 0 \\ 0.3 & \text{se } 0 \le x < 1 \\ 0.7 & \text{se } 1 \le x < 2 \\ 0.9 & \text{se } 2 \le x < 3 \\ 1 & \text{se } x \ge 3 \end{cases}$$

2.2 Rappresentazioni grafiche

Le frequenze di una rilevazione possono essere rappresentate graficamente. Le rappresentazioni più comuni sono le seguenti.

(*i*) *Diagrammi a torta* (o *circolari*): un cerchio è suddiviso in k settori circolari, uno per ciascuna modalità, e il settore associato alla modalità x_j ha ampiezza angolare pari a $360° \cdot f_j$, per cui la sua area è proporzionale alla frequenza relativa. Sono adatti a caratteri con un numero piccolo di modalità; risulta tuttavia difficile confrontare tra loro due diagrammi a torta, perché l'occhio valuta angoli e aree con minore precisione rispetto alle lunghezze.

(*ii*) *Diagrammi a barre*: sull'asse delle ascisse si riportano le modalità e sull'asse delle ordinate le corrispondenti frequenze (assolute o relative); a ciascuna modalità corrisponde una barra verticale, separata dalle altre, di altezza pari alla frequenza. Sono adatti a caratteri qualitativi e a caratteri quantitativi discreti.

(*iii*) *Istogrammi*: si utilizzano per caratteri quantitativi continui (o discreti con molte modalità), i cui dati vengono raggruppati in *classi*, ovvero in intervalli contigui dell'asse reale. A ciascuna classe corrisponde un rettangolo avente per base la classe stessa, per cui i rettangoli risultano adiacenti.

Osservazione. Il fatto che i rettangoli di un istogramma siano adiacenti dipende esclusivamente dalla contiguità delle classi, e non ha nulla a che vedere con le frequenze cumulate: in un istogramma ciascun rettangolo rappresenta la frequenza della propria classe. Se le classi hanno tutte la stessa ampiezza, l'altezza di ciascun rettangolo si può porre pari alla frequenza della classe; se invece le ampiezze sono diverse, affinché l'*area* di ciascun rettangolo risulti proporzionale alla frequenza, l'altezza deve essere pari al rapporto tra la frequenza e l'ampiezza della classe (*densità di frequenza*).

Esempio 2.3. In un'indagine sullo sport praticato da un collettivo di $N = 260$ persone, ciascuna delle quali pratica un solo sport, si ottengono le frequenze assolute riportate nella Tabella 2.2.

Tabella 2.2. Frequenze assolute dello sport praticato.

x_j	Calcio	Tennis	Pallavolo	Nuoto	Basket	Danza	Totale
n_j	90	30	50	60	20	10	260

Il carattere è qualitativo nominale, e le frequenze si rappresentano con il diagramma a barre della Figura 2.1, nel quale l'ordine delle barre è del tutto arbitrario.

Esempio 2.4. Si consideri un insieme di $N = 45$ spedizioni e il carattere quantitativo continuo *"peso della spedizione"*. Raggruppando i dati in classi di ampiezza pari a 2 kg si ottengono le frequenze assolute riportate nella Tabella 2.3.

Tabella 2.3. Frequenze assolute delle spedizioni suddivise in classi di peso.

Classe (kg)	$[0,2)$	$[2,4)$	$[4,6)$	$[6,8)$	$[8,10]$	Totale
n_j	10	14	9	7	5	45

Poiché le classi hanno tutte la stessa ampiezza, l'istogramma della Figura 2.2 ha rettangoli di altezza pari alle frequenze assolute.

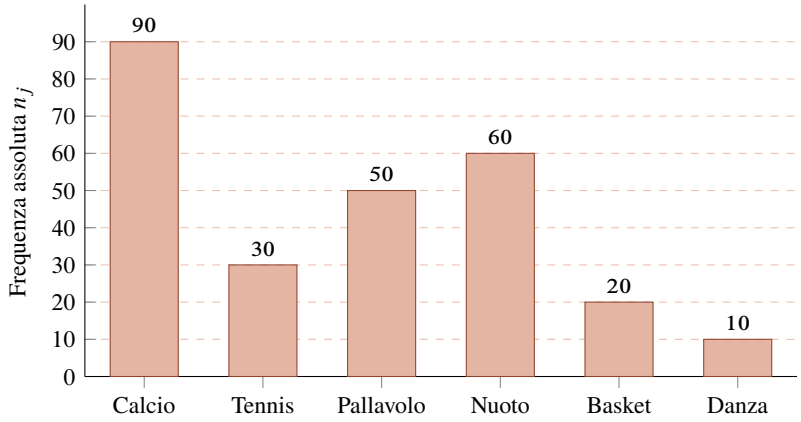


Figura 2.1. Diagramma a barre delle frequenze assolute dello sport praticato.

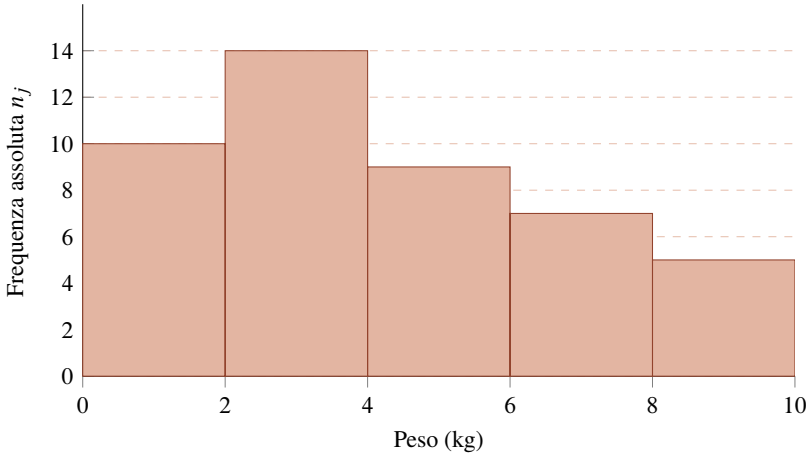


Figura 2.2. Istogramma delle spedizioni suddivise in classi di peso.

Esempio 2.5. Le frequenze della rilevazione dell'Esempio 2.2 si possono rappresentare con un diagramma a torta (Figura 2.3), i cui settori hanno ampiezze angolari

$$360° \cdot \frac{3}{10} = 108°, \qquad 360° \cdot \frac{4}{10} = 144°, \qquad 360° \cdot \frac{2}{10} = 72°, \qquad 360° \cdot \frac{1}{10} = 36°,$$

oppure, trattandosi di un carattere quantitativo discreto, con un diagramma a barre (Figura 2.4), nel quale le barre sono ridotte a segmenti verticali posti in corrispondenza delle modalità.

2.3 Indici di posizione

Gli *indici di posizione* (o di *tendenza centrale*) sintetizzano la rilevazione mediante un unico valore, rappresentativo dell'intero insieme di dati.

Definizione 2.5. Si chiama *moda* di una rilevazione ogni modalità x_j alla quale corrisponde la frequenza massima.

Osservazione. La moda è definita per caratteri di qualsiasi tipo, anche qualitativi nominali, ma non è necessariamente unica: se più modalità presentano la stessa frequenza massima, la rilevazione si dice *plurimodale* (in particolare *bimodale*, se le mode sono due). Ad esempio, nell'Esempio 2.2 la moda è $x_2 = 1$, mentre nell'indagine sullo sport praticato la moda è *"Calcio"*.

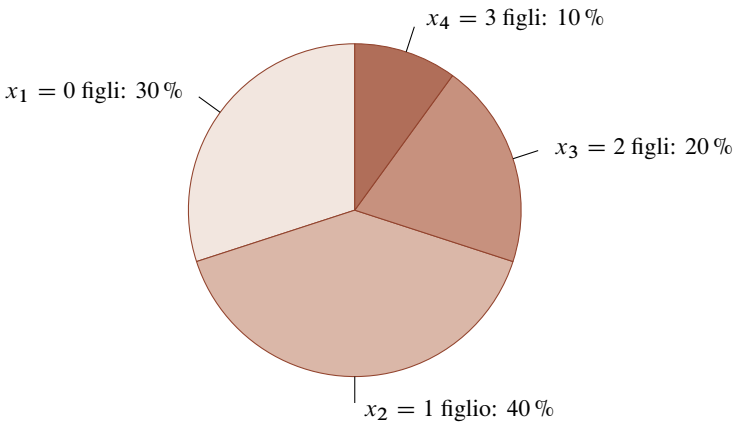


Figura 2.3. Diagramma a torta del numero di figli per famiglia.

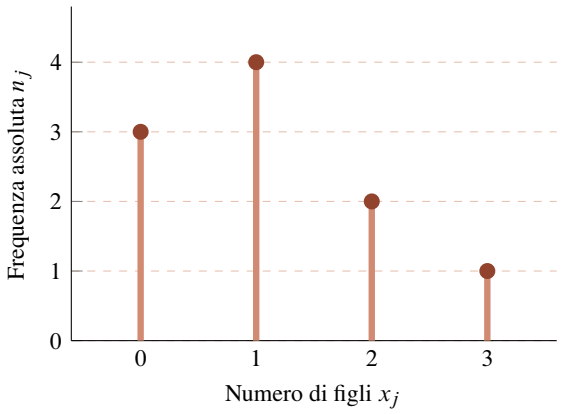


Figura 2.4. Diagramma a barre del numero di figli per famiglia.

Notazione 2.6. Data una rilevazione $\boldsymbol{y} = (y_1, \ldots, y_N)$ di un carattere quantitativo, si indicano con

$$y_{(1)} \leq y_{(2)} \leq \cdots \leq y_{(N)}$$

i dati disposti in ordine non decrescente: $y_{(1)}$ è il dato più piccolo, $y_{(N)}$ il più grande e, in generale, $y_{(i)}$ è il dato che occupa la posizione i-esima nell'ordinamento.

Definizione 2.7. Sia $\boldsymbol{y} = (y_1, \ldots, y_N)$ una rilevazione di un carattere quantitativo. Si chiama *mediana* della rilevazione il dato centrale della rilevazione ordinata, se N è dispari, e la semisomma dei due dati centrali, se N è pari:

$$\text{Me} := \begin{cases} y_{(h)} & \text{se } N = 2h - 1 \\ \dfrac{y_{(h)} + y_{(h+1)}}{2} & \text{se } N = 2h \end{cases} \qquad h \in \mathbb{N}.$$

Osservazione. Si osservi che:

(*i*) nella disposizione ordinata dei dati occorrono disuguaglianze *larghe*, poiché in una rilevazione lo stesso valore può comparire più volte;

(*ii*) la semisomma dei dati centrali ha senso soltanto per caratteri quantitativi; per un carattere qualitativo ordinale con N dispari, tuttavia, il dato centrale $y_{(h)}$ è ancora una modalità ben definita e può essere assunto come mediana;

(*iii*) la mediana della rilevazione è in accordo con la definizione di mediana di una variabile aleatoria data nel capitolo precedente: se Z è una variabile aleatoria discreta che assume il valore x_j con probabilità f_j, per ogni $j \in I_k$, il numero Me è una mediana di Z. Ad esempio, se $N = 2h$ e $y_{(h)} \le t \le y_{(h+1)}$, almeno $h = N/2$ dati sono minori o uguali a t (quelli di posto $1, \dots, h$) e almeno h dati sono maggiori o uguali a t (quelli di posto $h+1, \dots, N$), per cui $\mathbb{P}(Z \le t) \ge 1/2$ e $\mathbb{P}(Z \ge t) \ge 1/2$. Ogni reale dell'intervallo $[y_{(h)}, y_{(h+1)}]$ è dunque una mediana di Z, e Me ne è il punto medio.

Esempio 2.6. Per la rilevazione dell'Esempio 2.2 si ha $N = 10 = 2 \cdot 5$, e i dati ordinati sono:

$$(y_{(1)}, \dots, y_{(10)}) = (0, 0, 0, 1, 1, 1, 1, 2, 2, 3).$$

Si ottiene quindi:

$$\text{Me} = \frac{y_{(5)} + y_{(6)}}{2} = \frac{1+1}{2} = 1.$$

Per i caratteri quantitativi si possono introdurre ulteriori indici di posizione, noti come *medie di Chisini* (Oscar Chisini, 1929).

Definizione 2.8. Siano $I \subseteq \mathbb{R}$ un intervallo, $y_1, \dots, y_N \in I$ i dati di una rilevazione e $f : I^N \to \mathbb{R}$ una funzione *simmetrica*, ovvero tale che il suo valore non cambi scambiando tra loro gli argomenti:

$$f\big(y_{\tau(1)}, \dots, y_{\tau(N)}\big) = f(y_1, \dots, y_N) \qquad \text{per ogni permutazione } \tau \text{ di } I_N.$$

Si chiama *media di Chisini* dei dati $y_1, \dots, y_N$ associata alla funzione f ogni numero $M \in I$ tale che:

$$f(M, M, \dots, M) = f(y_1, y_2, \dots, y_N).$$

Proposizione 2.2. *Nelle notazioni della Definizione 2.8, si supponga che la funzione f sia continua e strettamente crescente in ciascun argomento (oppure strettamente decrescente in ciascun argomento). Allora la media di Chisini M associata a f esiste ed è unica; inoltre essa è* interna *ai dati, ovvero:*

$$y_{(1)} \le M \le y_{(N)}.$$

Dimostrazione. Si supponga f strettamente crescente in ciascun argomento; in caso contrario si applica lo stesso ragionamento alla funzione $-f$, che possiede le stesse medie di Chisini. Si consideri la funzione

$$g : I \longrightarrow \mathbb{R}, \qquad g(t) := f(t, t, \dots, t),$$

continua in quanto composizione della funzione continua f con la funzione continua

$$t \longmapsto (t, \dots, t).$$

(*i*) La funzione g è strettamente crescente: se $t, s \in I$ con $t < s$, sostituendo gli argomenti uno alla volta si ha

$$g(t) = f(t, t, \dots, t) < f(s, t, \dots, t) < f(s, s, t, \dots, t) < \cdots < f(s, s, \dots, s) = g(s).$$

(*ii*) Poiché $y_{(1)} \le y_i \le y_{(N)}$ per ogni $i \in I_N$, con lo stesso procedimento (e con disuguaglianze larghe, potendo alcuni dati coincidere con gli estremi) si ottiene:

$$g\big(y_{(1)}\big) \le f(y_1, \dots, y_N) \le g\big(y_{(N)}\big).$$

(*iii*) Essendo I un intervallo, si ha $[y_{(1)}, y_{(N)}] \subseteq I$; per il teorema dei valori intermedi, applicato alla funzione continua g su tale intervallo, esiste $M \in [y_{(1)}, y_{(N)}]$ tale che $g(M) = f(y_1, \dots, y_N)$.

(*iv*) Essendo g strettamente crescente su I, essa è iniettiva, e dunque M è l'unico elemento di I che soddisfa $g(M) = f(y_1, \dots, y_N)$. □

Esempio 2.7. Si ottengono le medie di uso più comune scegliendo opportunamente la funzione f; in ciascun caso le ipotesi della Proposizione 2.2 sono soddisfatte.

(*i*) Se $I = \mathbb{R}$ e $f(y_1, \dots, y_N) = y_1 + y_2 + \cdots + y_N$, la media M è tale che

$$NM = \sum_{i=1}^{N} y_i,$$

da cui si ottiene la *media aritmetica*:

$$M_{\text{arit}} = \frac{y_1 + y_2 + \cdots + y_N}{N} = \frac{1}{N} \sum_{i=1}^{N} y_i.$$

(*ii*) Se $I = [0, +\infty)$ e $f(y_1, \dots, y_N) = y_1^2 + y_2^2 + \cdots + y_N^2$, la media M è tale che

$$NM^2 = \sum_{i=1}^{N} y_i^2,$$

da cui, essendo $M \geq 0$, si ottiene la *media quadratica*:

$$M_{\text{quad}} = \sqrt{\frac{y_1^2 + y_2^2 + \cdots + y_N^2}{N}}.$$

(*iii*) Se $I = (0, +\infty)$ e $f(y_1, \dots, y_N) = y_1 \cdot y_2 \cdots y_N$, la media M è tale che

$$M^N = y_1 \cdot y_2 \cdots y_N,$$

da cui, essendo $M > 0$, si ottiene la *media geometrica*:

$$M_{\text{geom}} = \sqrt[N]{y_1 \cdot y_2 \cdots y_N}.$$

(*iv*) Se $I = (0, +\infty)$ e $f(y_1, \dots, y_N) = 1/y_1 + 1/y_2 + \cdots + 1/y_N$, funzione strettamente *decrescente* in ciascun argomento, la media M è tale che

$$\frac{N}{M} = \frac{1}{y_1} + \frac{1}{y_2} + \cdots + \frac{1}{y_N},$$

da cui si ottiene la *media armonica*:

$$M_{\text{arm}} = \frac{N}{1/y_1 + 1/y_2 + \cdots + 1/y_N}.$$

Osservazione. Nella DEFINIZIONE 2.8 la funzione f esprime la grandezza che si vuole lasciare *invariata* sostituendo tutti i dati con un unico valore M: la somma per la media aritmetica, la somma dei quadrati per la media quadratica, il prodotto per la media geometrica e la somma dei reciproci per la media armonica. La scelta della media appropriata dipende quindi dal problema in esame, come mostrano gli esempi che seguono.

Se i dati sono raggruppati per modalità, ciascuna modalità x_j compare n_j volte nella somma che definisce la media aritmetica, la quale si può dunque scrivere come

$$M_{\text{arit}} = \frac{x_1 n_1 + x_2 n_2 + \cdots + x_k n_k}{N} = \sum_{j=1}^{k} x_j f_j, \qquad \text{con } n_1 + n_2 + \cdots + n_k = N.$$

Si tratta di un caso particolare della definizione seguente, in cui i pesi coincidono con le frequenze.

DEFINIZIONE 2.9. Siano $x_1, \ldots, x_k \in \mathbb{R}$ e siano $w_1, \ldots, w_k > 0$ dei numeri reali, detti *pesi*. Si chiama *media aritmetica ponderata* dei valori $x_1, \ldots, x_k$ con pesi $w_1, \ldots, w_k$ la quantità:

$$M_w := \frac{w_1 x_1 + w_2 x_2 + \cdots + w_k x_k}{w_1 + w_2 + \cdots + w_k} = \frac{\displaystyle\sum_{j=1}^{k} w_j x_j}{\displaystyle\sum_{j=1}^{k} w_j}.$$

ESEMPIO 2.8. (*i*) Per la rilevazione dell'ESEMPIO 2.2, la media aritmetica, calcolata come media ponderata delle modalità con pesi pari alle frequenze assolute, vale:

$$M_{\text{arit}} = \frac{0 \cdot 3 + 1 \cdot 4 + 2 \cdot 2 + 3 \cdot 1}{10} = \frac{11}{10} = 1.1.$$

(*ii*) Uno studente supera due esami: il primo, da 8 crediti, con votazione 28/30, il secondo, da 6 crediti, con votazione 30/30. La sua media ponderata, con pesi pari ai crediti, è:

$$M_w = \frac{8 \cdot 28 + 6 \cdot 30}{8 + 6} = \frac{404}{14} = \frac{202}{7} \approx 28.86,$$

dove il denominatore è il numero totale di crediti acquisiti.

ESEMPIO 2.9 (Media geometrica e tassi di rendimento)**.** La media geometrica è utile per calcolare il tasso medio di rendimento di un investimento quando gli interessi si accumulano nel tempo. Si supponga che un investimento abbia avuto i seguenti rendimenti annui: $+10\,\%$ il primo anno, $+20\,\%$ il secondo anno e $-5\,\%$ il terzo anno. Si vuole determinare il *tasso medio annuo equivalente*, ovvero il rendimento costante $\overline{r}$ che, applicato per tre anni, produce lo stesso capitale finale.

Si scrivono i tassi come *fattori di crescita*:

$$1 + 0.10 = 1.10, \qquad 1 + 0.20 = 1.20, \qquad 1 - 0.05 = 0.95.$$

Il capitale finale si ottiene moltiplicando il capitale iniziale per il prodotto dei fattori di crescita:

$$1.10 \cdot 1.20 \cdot 0.95 = 1.254,$$

ovvero in tre anni il capitale è diventato 1.254 volte quello iniziale. La grandezza da lasciare invariata è dunque il *prodotto* dei fattori di crescita, e il fattore medio cercato è la loro media geometrica:

$$1 + \overline{r} = M_{\text{geom}} = \sqrt[3]{1.10 \cdot 1.20 \cdot 0.95} = \sqrt[3]{1.254} \approx 1.0784,$$

da cui $\overline{r} \approx 0.0784$: l'investimento equivale a un rendimento costante di circa il 7.84 % annuo.

Si verifica il risultato considerando un investimento iniziale di 10 000 euro. Il capitale vale 11 000 euro dopo il primo anno, $11\,000 \cdot 1.20 = 13\,200$ euro dopo il secondo e $13\,200 \cdot 0.95 = 12\,540$ euro dopo il terzo; con il tasso medio geometrico si ottiene lo stesso capitale finale:

$$10\,000 \cdot (1 + \overline{r})^3 = 10\,000 \cdot 1.254 = 12\,540.$$

La media aritmetica dei tassi, invece, vale

$$\frac{10\,\% + 20\,\% - 5\,\%}{3} = \frac{25}{3}\,\% \approx 8.33\,\%$$

e non è il rendimento annuo effettivo: applicata per tre anni, essa fornirebbe infatti un capitale finale $10\,000 \cdot (1 + 1/12)^3 \approx 12\,714$ euro, superiore a quello reale.

Esempio 2.10 (Media armonica e velocità media)**.** Si percorre due volte la stessa distanza $d > 0$: all'andata alla velocità $v_1 = 60\,\text{km/h}$ e al ritorno alla velocità $v_2 = 40\,\text{km/h}$. La media aritmetica delle due velocità vale

$$M_{\text{arit}} = \frac{60 + 40}{2}\,\text{km/h} = 50\,\text{km/h},$$

ma *non* è la velocità media del viaggio, definita come rapporto tra la distanza totale percorsa e il tempo totale impiegato. Supponendo, ad esempio, $d = 120\,\text{km}$, i tempi di percorrenza sono

$$t_1 = \frac{120\,\text{km}}{60\,\text{km/h}} = 2\,\text{h}, \qquad t_2 = \frac{120\,\text{km}}{40\,\text{km/h}} = 3\,\text{h},$$

per cui la distanza totale è 240 km, il tempo totale è 5 h e la velocità media effettiva vale

$$v_{\text{m}} = \frac{240\,\text{km}}{5\,\text{h}} = 48\,\text{km/h}.$$

Lo stesso valore si ottiene con la media armonica delle due velocità:

$$M_{\text{arm}} = \frac{2}{1/60 + 1/40}\,\text{km/h} = \frac{2}{5/120}\,\text{km/h} = 48\,\text{km/h}.$$

Il risultato non dipende dalla distanza d: in generale si ha infatti

$$v_{\text{m}} = \frac{2d}{t_1 + t_2} = \frac{2d}{d/v_1 + d/v_2} = \frac{2}{1/v_1 + 1/v_2} = M_{\text{arm}}.$$

La media aritmetica fallisce perché presuppone che le due velocità siano mantenute per lo *stesso tempo*: se ciascuna velocità fosse mantenuta per un tempo t, si avrebbe proprio $v_{\text{m}} = (v_1 t + v_2 t)/(2t) = (v_1 + v_2)/2$. Si conclude che:

(*i*) a parità di *durata* dei tratti, la velocità media è la media aritmetica delle velocità;
(*ii*) a parità di *distanza* percorsa nei tratti, la velocità media è la media armonica delle velocità.

Osservazione. Oltre a quelle già introdotte, esistono altre medie di uso frequente.

(*i*) La media quadratica M_{quad} si utilizza, ad esempio, per misurare l'ampiezza di un segnale alternato: in elettrotecnica il *valore efficace* di una tensione o di una corrente alternata è la media quadratica dei suoi valori su un periodo.

(*ii*) Dati due numeri reali $a, b > 0$ con $a \neq b$, si chiama *media logaritmica* di a e b la quantità

$$L(a,b) := \frac{b-a}{\log b - \log a},$$

dove log indica il logaritmo naturale. Essa è simmetrica e, poiché

$$\lim_{b\to a} \frac{b-a}{\log b - \log a} = \frac{1}{\dfrac{\mathrm{d}}{\mathrm{d}x}\{\log x\}_{x=a}} = a,$$

si estende per continuità ponendo $L(a,a) := a$. Ad esempio:

$$L(4,16) = \frac{12}{\log 4} \approx 8.66.$$

Tra le medie introdotte sussiste un ordinamento. Prima di enunciarlo, lo si verifica su un esempio numerico.

Esempio 2.11. Per i due numeri 4 e 16 si ha:

$$M_{\text{arm}} = \frac{2}{1/4+1/16} = \frac{2}{5/16} = \frac{32}{5} = 6.4, \qquad M_{\text{geom}} = \sqrt{4\cdot 16} = \sqrt{64} = 8,$$

$$M_{\text{arit}} = \frac{4+16}{2} = 10, \qquad M_{\text{quad}} = \sqrt{\frac{4^2+16^2}{2}} = \sqrt{136} \approx 11.66,$$

e dunque $M_{\text{arm}} < M_{\text{geom}} < M_{\text{arit}} < M_{\text{quad}}$. Si osservi inoltre che la media logaritmica $L(4,16) \approx 8.66$ è compresa tra la media geometrica e la media aritmetica.

Proposizione 2.3. *Siano $a, b \in \mathbb{R}$ con $a, b > 0$. Allora:*

$$\underbrace{\frac{2}{1/a+1/b}}_{M_{\text{arm}}} \leq \underbrace{\sqrt{ab}}_{M_{\text{geom}}} \leq \underbrace{\frac{a+b}{2}}_{M_{\text{arit}}} \leq \underbrace{\sqrt{\frac{a^2+b^2}{2}}}_{M_{\text{quad}}},$$

e ciascuna delle tre disuguaglianze è un'uguaglianza se e solo se $a = b$.

Dimostrazione.

(*i*) $M_{\text{geom}} \leq M_{\text{arit}}$. Poiché $a, b > 0$, i numeri $a+b$ e $2\sqrt{ab}$ sono positivi, e la funzione radice quadrata è strettamente crescente; si ha quindi la catena di equivalenze:

$$(a-b)^2 \geq 0 \iff a^2 - 2ab + b^2 \geq 0 \iff a^2 + 2ab + b^2 \geq 4ab$$
$$\iff (a+b)^2 \geq 4ab \iff a+b \geq 2\sqrt{ab} \iff \frac{a+b}{2} \geq \sqrt{ab}.$$

La prima disuguaglianza è sempre vera, dunque lo è anche l'ultima; inoltre, ripercorrendo le equivalenze con il segno di uguaglianza, si ha $(a+b)/2 = \sqrt{ab}$ se e solo se $(a-b)^2 = 0$, cioè se e solo se $a = b$.

(*ii*) $M_{\text{arm}} \le M_{\text{geom}}$. Applicando il punto (*i*) ai numeri positivi $1/a$ e $1/b$ si ottiene:

$$\frac{1}{2}\left(\frac{1}{a}+\frac{1}{b}\right) \ge \sqrt{\frac{1}{a}\cdot\frac{1}{b}} = \frac{1}{\sqrt{ab}},$$

da cui, passando ai reciproci di quantità positive, si ricava $2/(1/a + 1/b) \le \sqrt{ab}$, con uguaglianza se e solo se $1/a = 1/b$, cioè se e solo se $a = b$.

(*iii*) $M_{\text{arit}} \le M_{\text{quad}}$. Essendo entrambe le medie positive, la disuguaglianza equivale a quella tra i loro quadrati:

$$\left(\frac{a+b}{2}\right)^2 \le \frac{a^2+b^2}{2} \iff a^2+2ab+b^2 \le 2a^2+2b^2$$
$$\iff 0 \le a^2-2ab+b^2 = (a-b)^2,$$

che è sempre vera, con uguaglianza se e solo se $a = b$. □

Osservazione. L'ordinamento appena dimostrato vale più in generale per N dati $y_1, \dots, y_N$ *positivi*:

$$M_{\text{arm}} \le M_{\text{geom}} \le M_{\text{arit}} \le M_{\text{quad}},$$

con uguaglianze se e solo se tutti i dati coincidono; analogamente, per $a, b > 0$ con $a \ne b$, la media logaritmica soddisfa $M_{\text{geom}} < L(a,b) < M_{\text{arit}}$. Di entrambi i risultati si omette la dimostrazione. L'ipotesi di positività è essenziale: in presenza di dati negativi la media geometrica può non essere definita (ad esempio per i dati -2 e 8, il cui prodotto è negativo) oppure perdere l'informazione sul segno (per i dati -2 e -8 si ottiene $\sqrt{16} = 4 > 0$), mentre la media quadratica elimina il segno dei dati (per i dati -3 e 3 si ha $M_{\text{arit}} = 0$, ma $M_{\text{quad}} = 3$).

2.4 Indici di dispersione

Gli indici di posizione non descrivono quanto i dati siano dispersi: ad esempio, le rilevazioni $(5,5,5)$ e $(0,5,10)$ hanno la stessa media aritmetica e la stessa mediana, pari a 5, ma nella seconda i dati sono molto più sparpagliati. Per quantificare tale dispersione si introducono gli *indici di dispersione*, definiti per caratteri quantitativi.

Notazione 2.10. Nel seguito la media aritmetica dei dati $y_1, \dots, y_N$ si indica anche con

$$\overline{y} := M_{\text{arit}} = \frac{1}{N}\sum_{i=1}^{N} y_i.$$

Definizione 2.11. Sia $\boldsymbol{y} = (y_1, \dots, y_N)$ una rilevazione di un carattere quantitativo, con modalità numerate in ordine crescente $x_1 < x_2 < \cdots < x_k$, media aritmetica $\overline{y}$ e mediana Me. Si definiscono:

(*i*) l'*intervallo di variazione* (o *campo di variazione*):

$$x_k - x_1 = y_{(N)} - y_{(1)};$$

(*ii*) lo *scarto medio assoluto* dalla media aritmetica, ovvero la media aritmetica dei valori assoluti delle differenze tra i dati e la media aritmetica:

$$S_{\overline{y}} := \frac{1}{N}\sum_{i=1}^{N} |y_i - \overline{y}|;$$

(*iii*) lo *scarto medio assoluto dalla mediana*:

$$S_{\mathrm{Me}} := \frac{1}{N}\sum_{i=1}^{N}\left|y_i - \mathrm{Me}\right|;$$

(*iv*) la *varianza*, ovvero la media aritmetica dei quadrati delle differenze tra i dati e la media aritmetica:

$$\sigma^2 := \frac{1}{N}\sum_{i=1}^{N}\left(y_i - \overline{y}\right)^2;$$

(*v*) la *deviazione standard* (o *scarto quadratico medio*), ovvero la radice quadrata non negativa della varianza:

$$\sigma := \sqrt{\sigma^2} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}\left(y_i - \overline{y}\right)^2}.$$

Osservazione. Si osservi che:

(*i*) tutti gli indici di dispersione sono non negativi e si annullano se e solo se tutti i dati coincidono: ad esempio, la varianza è una somma di termini non negativi, nulla se e solo se $y_i = \overline{y}$ per ogni $i \in I_N$;

(*ii*) la deviazione standard è la media quadratica degli scarti $\left|y_i - \overline{y}\right|$, e si esprime nella stessa unità di misura dei dati, a differenza della varianza;

(*iii*) raggruppando i dati per modalità, ogni somma estesa ai dati si può riscrivere come somma estesa alle modalità; ad esempio:

$$\sigma^2 = \frac{1}{N}\sum_{j=1}^{k} n_j\left(x_j - \overline{y}\right)^2 = \sum_{j=1}^{k} f_j\left(x_j - \overline{y}\right)^2;$$

(*iv*) l'indice S_{Me} viene talvolta chiamato *scarto mediano assoluto*; in letteratura, tuttavia, con tale nome si indica più spesso la *mediana* (e non la media) dei valori $\left|y_i - \mathrm{Me}\right|$.

Proposizione 2.4. *La varianza è pari alla differenza tra la media aritmetica dei quadrati dei dati e il quadrato della media aritmetica:*

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N} y_i^2 - \overline{y}^2.$$

Dimostrazione. Sviluppando il quadrato e sfruttando la linearità della somma, si ottiene:

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}\left(y_i^2 - 2\overline{y}\,y_i + \overline{y}^2\right) = \frac{1}{N}\sum_{i=1}^{N} y_i^2 - 2\overline{y}\cdot\underbrace{\frac{1}{N}\sum_{i=1}^{N} y_i}_{\overline{y}} + \frac{1}{N}\cdot N\,\overline{y}^2$$

$$= \frac{1}{N}\sum_{i=1}^{N} y_i^2 - 2\overline{y}^2 + \overline{y}^2 = \frac{1}{N}\sum_{i=1}^{N} y_i^2 - \overline{y}^2. \qquad \square$$

Esempio 2.12. Si calcolano gli indici di dispersione per la rilevazione dell'Esempio 2.2, per la quale $\overline{y} = 1.1$ e $\mathrm{Me} = 1$. Raggruppando i dati per modalità (con frequenze $n_1 = 3$, $n_2 = 4$, $n_3 = 2$, $n_4 = 1$) si ottiene:

(*i*) intervallo di variazione: $x_4 - x_1 = 3 - 0 = 3$;

(*ii*) scarto medio assoluto dalla media aritmetica:

$$S_{\overline{y}} = \frac{1}{10}\sum_{i=1}^{10}|y_i - 1.1| = \frac{1}{10}\big(3\cdot 1.1 + 4\cdot 0.1 + 2\cdot 0.9 + 1\cdot 1.9\big)$$
$$= \frac{3.3 + 0.4 + 1.8 + 1.9}{10} = \frac{7.4}{10} = 0.74;$$

(*iii*) scarto medio assoluto dalla mediana:

$$S_{\mathrm{Me}} = \frac{1}{10}\sum_{i=1}^{10}|y_i - 1| = \frac{1}{10}\big(3\cdot 1 + 4\cdot 0 + 2\cdot 1 + 1\cdot 2\big) = \frac{7}{10} = 0.7;$$

(*iv*) varianza:

$$\sigma^2 = \frac{1}{10}\sum_{i=1}^{10}(y_i - 1.1)^2 = \frac{1}{10}\big(3\cdot 1.21 + 4\cdot 0.01 + 2\cdot 0.81 + 1\cdot 3.61\big)$$
$$= \frac{3.63 + 0.04 + 1.62 + 3.61}{10} = \frac{8.9}{10} = 0.89,$$

in accordo con la Proposizione 2.4, essendo

$$\frac{1}{10}\sum_{i=1}^{10} y_i^2 - \overline{y}^2 = \frac{3\cdot 0 + 4\cdot 1 + 2\cdot 4 + 1\cdot 9}{10} - 1.21 = 2.1 - 1.21 = 0.89;$$

(*v*) deviazione standard: $\sigma = \sqrt{0.89} \approx 0.943$.

Probabilità e Statistica I — Appunti delle lezioni

Appunti del corso di Probabilità e Statistica I (anno accademico 2026/2027), Corso di laurea in Matematica, Università degli Studi di Napoli Federico II. Il primo capitolo tratta il calcolo delle probabilità: spazi di probabilità, probabilità condizionata e indipendenza, variabili aleatorie discrete e continue, vettori aleatori, momenti, funzioni generatrici, disuguaglianze notevoli e teoremi limite. Il secondo capitolo introduce la statistica descrittiva: popolazione, caratteri e frequenze, rappresentazioni grafiche, indici di posizione e di dispersione.

Davide De Marco
Corso di laurea in Matematica
Università degli Studi di Napoli Federico II